第 3 讲　分 类

分类的定义

分类的过程和评价准则

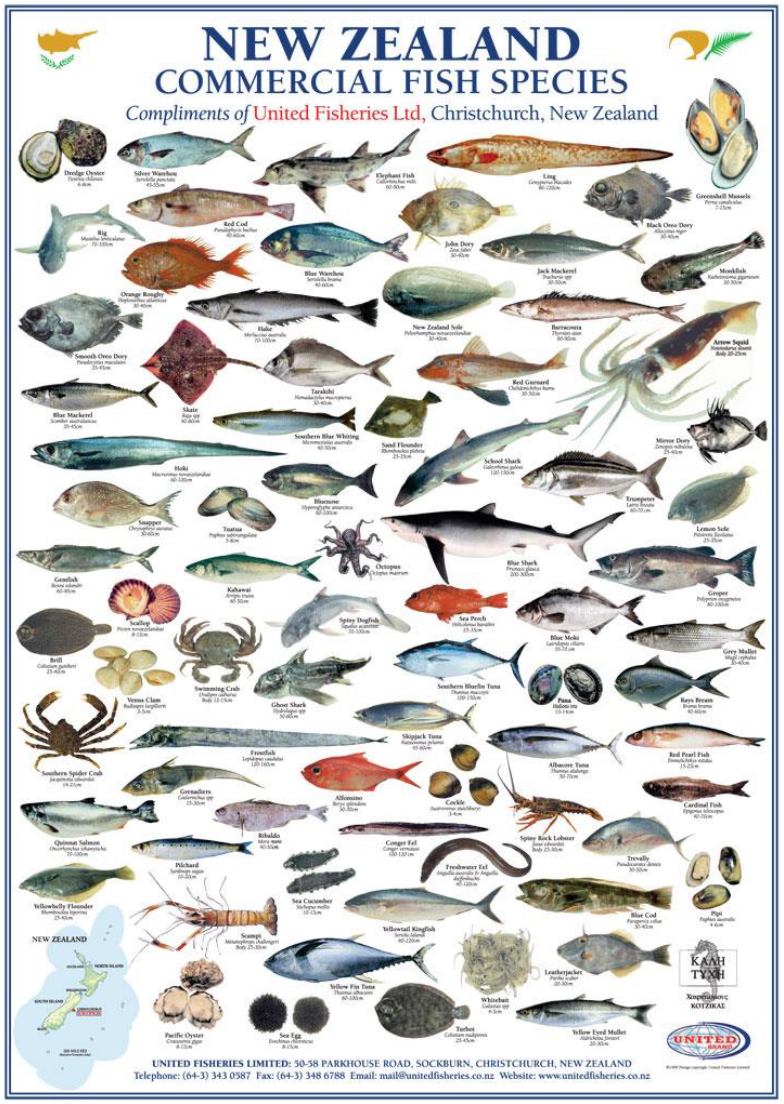
决策树算法（ID3，C4.5）

贝叶斯理论分析

朴素贝叶斯分类器

案例讲解

分类（Classification）









3.1 分类的定义



数据挖掘第一大问题-分类

名称	胎生	会飞	水中生活	有腿	类别
Human	是	否	否	是	哺乳动物
python	否	否	否	否	非哺乳动物
salmon	否	否	是	否	非哺乳动物
whale	是	否	是	否	哺乳动物
frog	否	否	有时	是	非哺乳动物
komodo	否	否	否	是	非哺乳动物
bat	是	是	否	是	哺乳动物
pigeon	否	是	否	是	非哺乳动物
cat	是	否	否	是	哺乳动物
leopard_shark	是	否	是	否	非哺乳动物
turtle	否	否	有时	是	非哺乳动物
penguin	否	否	有时	是	非哺乳动物
porcupine	是	否	否	是	哺乳动物
eel	否	否	是	否	非哺乳动物
salamander	否	否	有时	是	非哺乳动物
gila_monster	否	否	否	是	非哺乳动物
platypus	否	否	否	是	哺乳动物
owl	否	是	否	是	非哺乳动物
dolphin	胎生	会飞	水中生活	有腿	类别
eagle	是	否	是	否	?



什么是分类?

- **分类的定义**
  - 分类是指把数据样本映射到一个事先定义的类中的学习过程，即给定一组输入的属性向量及其对应的类，用基于归纳的学习算法得出分类。
  - 分类是根据一个或多个特征(称为变量)上的定量信息，并基于先前标记的项的训练集，将单个项放入组中的过程。
- 分类是一种有监督的学习，它是从样本数据中演绎函数的技术
- 分类与聚类的最大区别在于，分类数据中的一部分的类别是已知的，而聚类数据的类别未知。
- < Input, Output >
  - Input: 特征向量
  - Output: 布尔值(二进制分类)或整数(多类)
- “有监督” 意思是：需要一个教师信号来标记输出样本



分类：定义

- **给定记录的集合 (训练集，*Training Set*)**
  - 每个记录都用一组属性描述，其中一个属性是类标号.
- **找出一个模型（*Model* ），类标号属性是其他属性值的函数.**
- **目标: 应该能够尽可能正确地为先前未看到的记录确定类标号.**
  - 使用检验集（*Test Set* ）确定模型的准确率.
  - 通常, 给定的数据集被划分成训练集合检验集, 训练集用于构建模型，而检验集用于评估模型



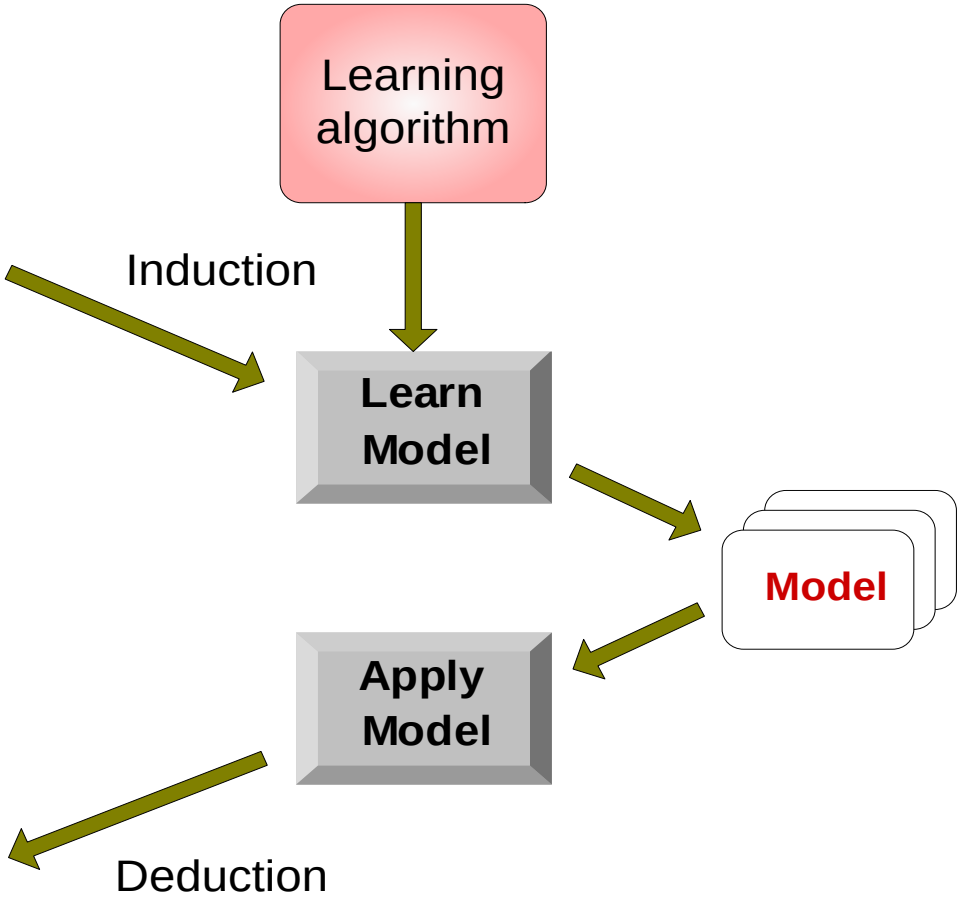
分类：解释评估

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Training Set

Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Test Set



训练分类器（Training a Classifier）









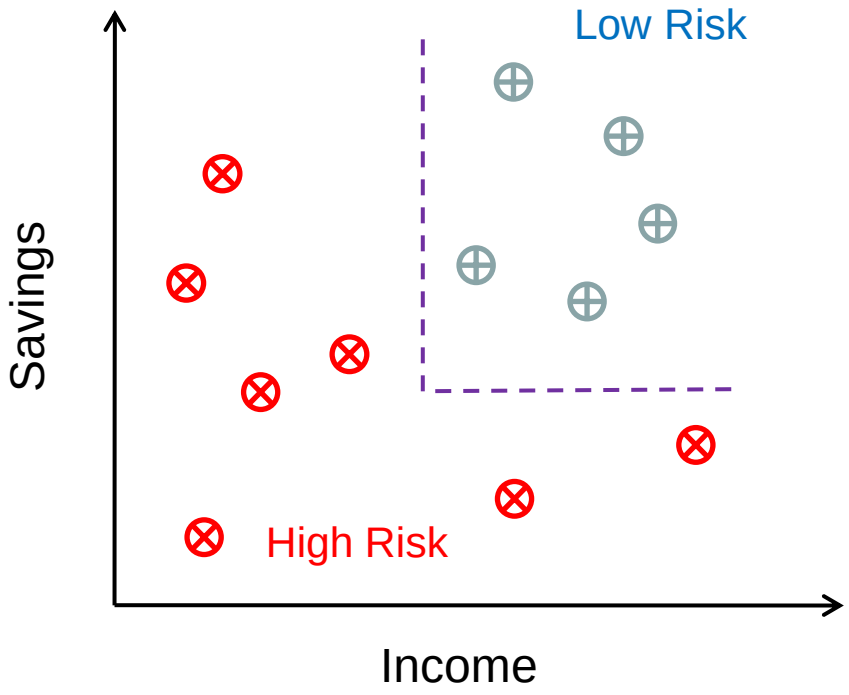
Learning

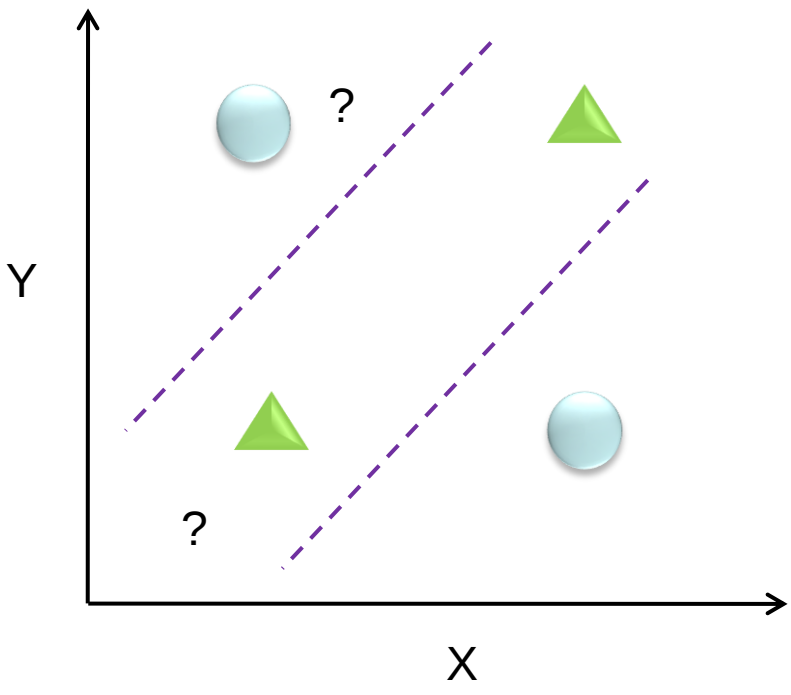






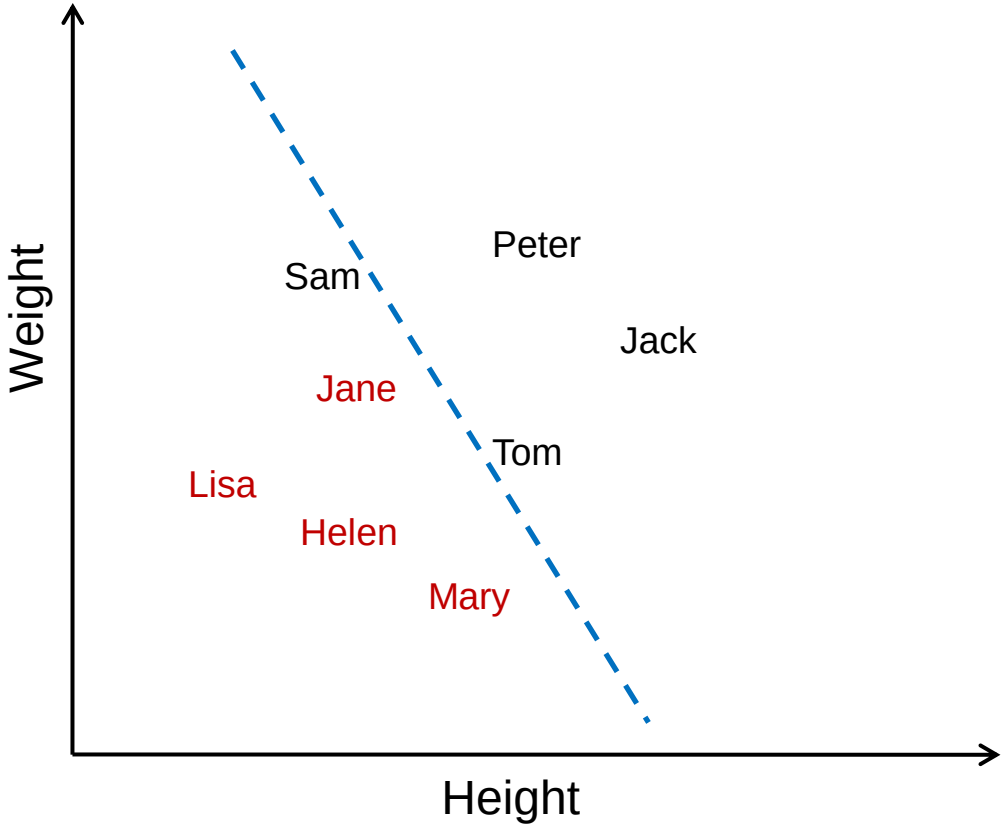
分界面（Classification Boundaries）

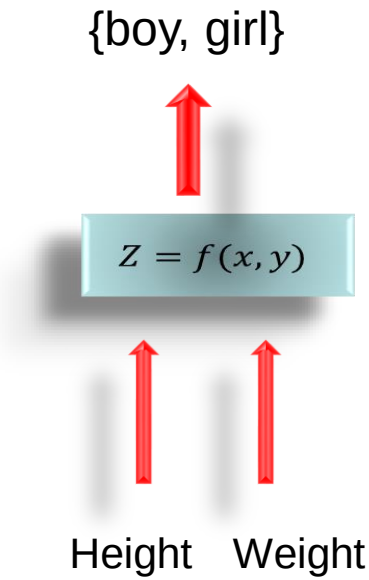






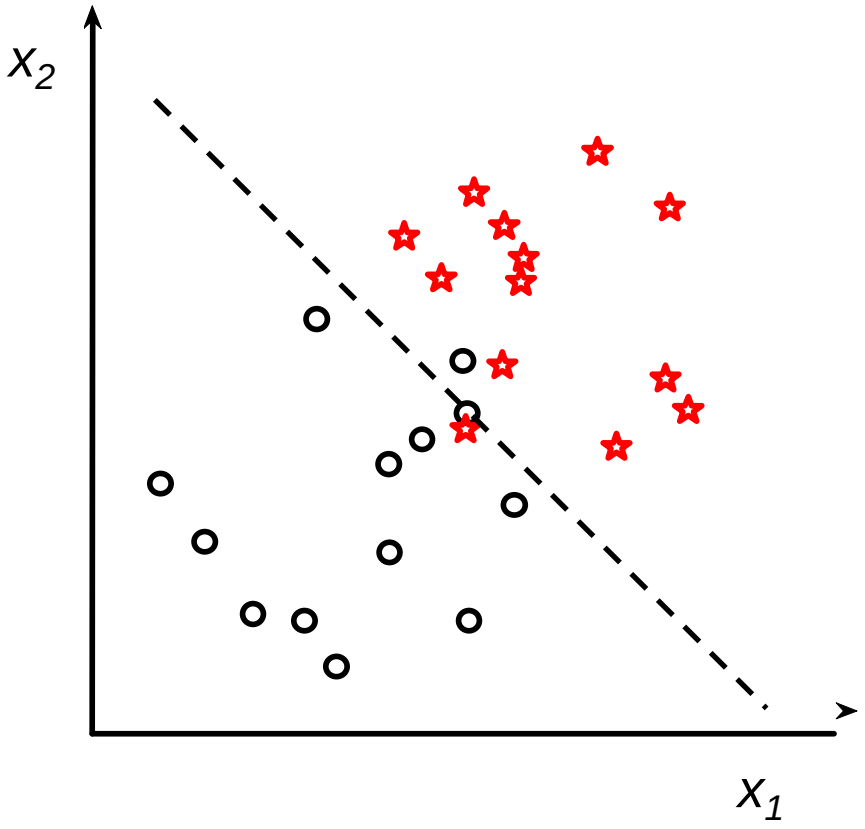
分类器（Classifiers）

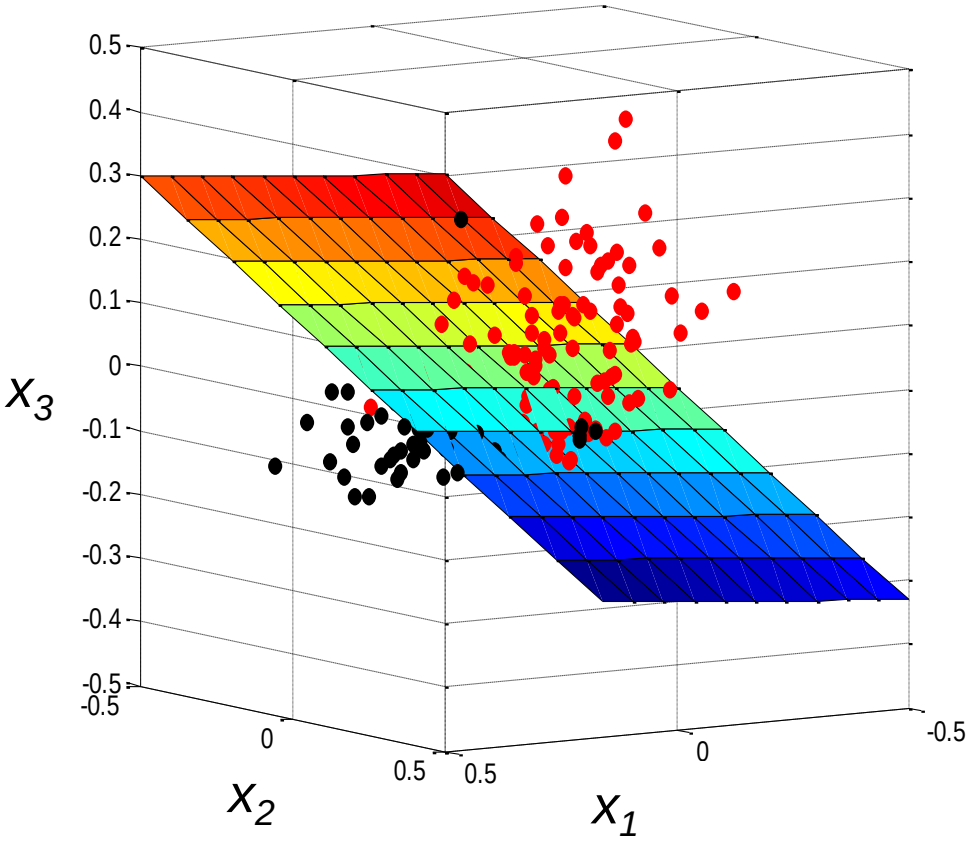






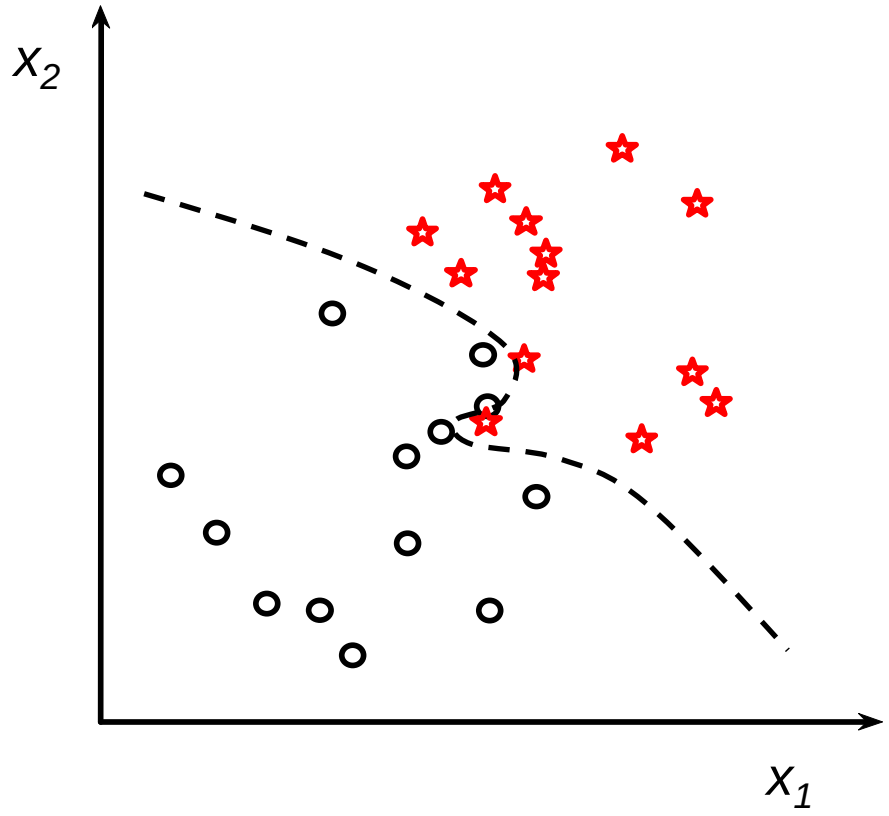
分类器（Classifiers 2D-3D ）

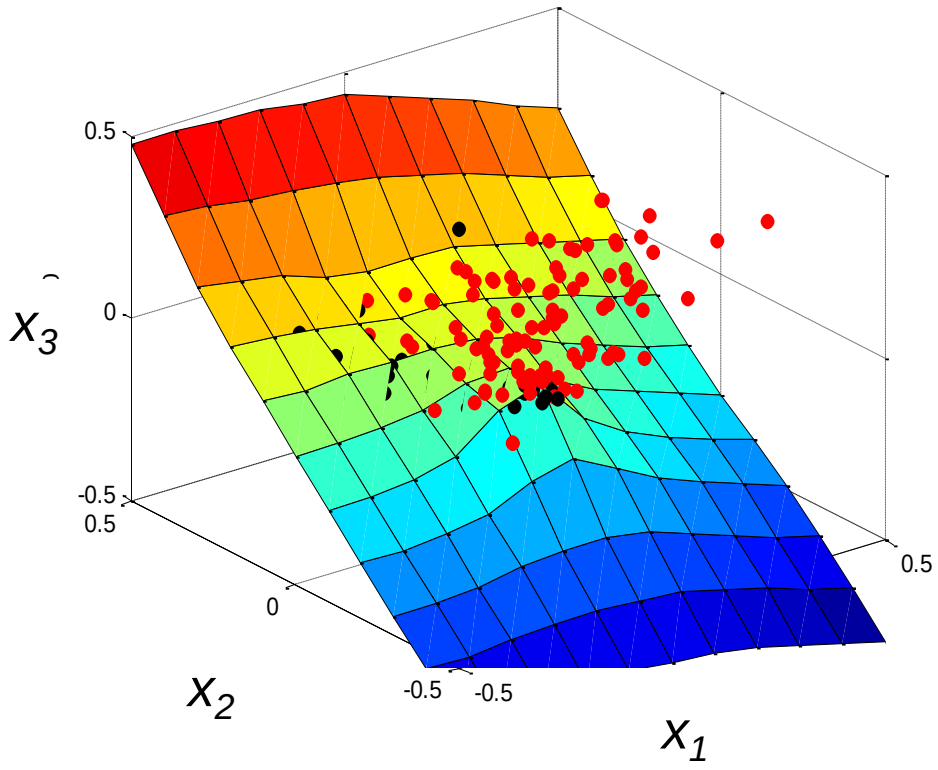




线性可分问题-Linear

分类器（Classifiers 2D-3D ）

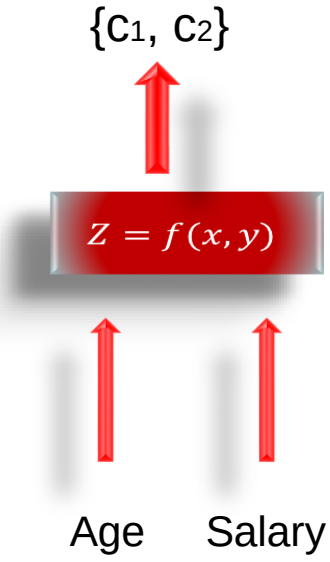




线性不可分问题-Non-Linear

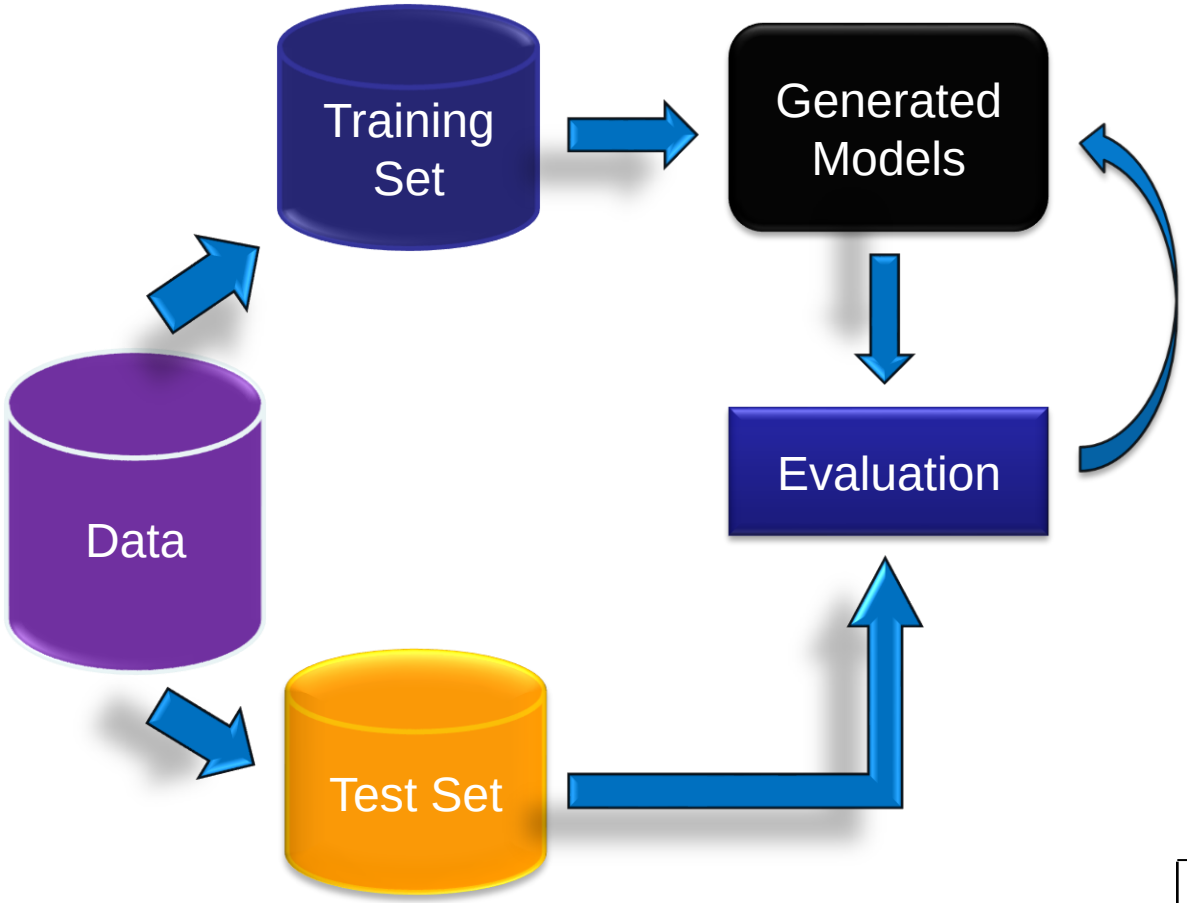
分类问题使用的数据集格式：

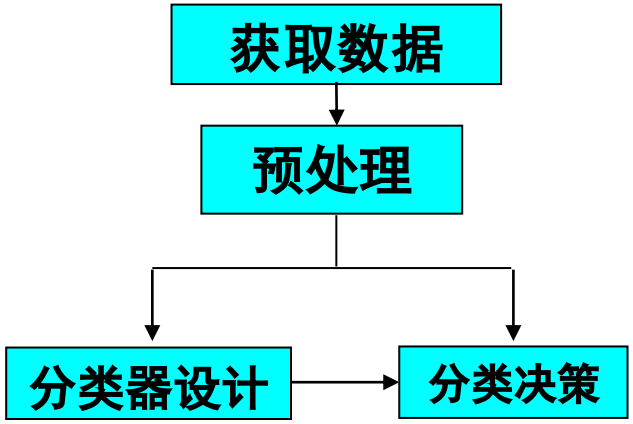
- 描述属性可以是连续型属性，也可以是离散型属性；而**类别属性必须是离散型属性**。
- 连续型属性是指在某一个区间或者无穷区间内该属性的取值是连续的，例如属性“Age”
- 离散型属性是指该属性的取值是不连续的，例如属性“Salary”和“Class”





分类的过程


Training Set
Generated Models
Data
Evaluation
Test Set


获取数据
预处理
分类器设计
分类决策



分类的过程

- **获取数据**
  - 输入数据、对数据进行量化
- **预处理**
  - 去除噪声数据、对空缺值进行处理
  - 数据集成或者变换
- **分类器设计**
  - 划分数据集、**分类器构造**、**分类器测试**
- **分类决策**
  - 对未知类标号的数据样本进行分类

分类的评价



混淆矩阵（Confusion Matrix）

Confusion Matrix				
		Predicted Value		
		Positive	Negative	Total
Actual Value	Positive	True Positive	False Negative	P
	Negative	False Positive	True Negative	N
Total		P'	N'	

TPR=TP/(TP+FN)

TNR=TN/(TN+FP)

Accuracy=(TP+TN)/(P+N)



$TP: 1(1)$ $FN: 1(0)$

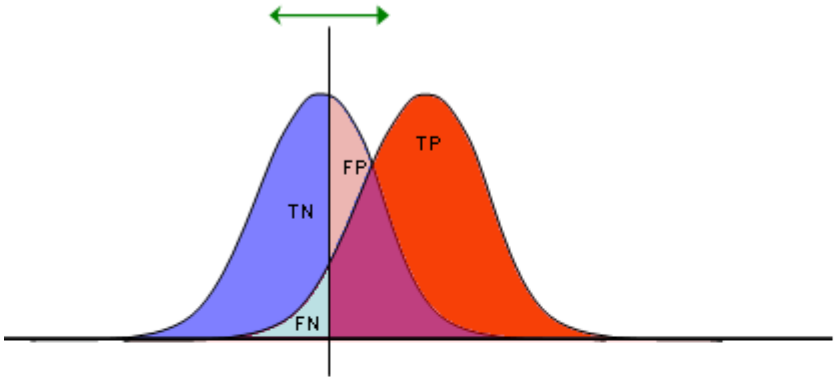
$FP: 0(1)$ $TN: 0(0)$

TP: 正确接受 FN: 错误拒绝

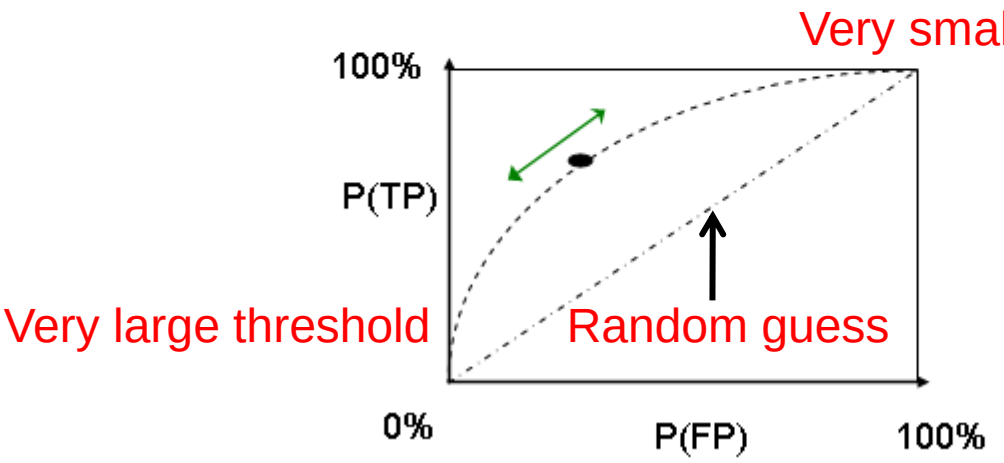
FP: 错误接受 TN: 正确拒绝



Receiver Operating Characteristic



TP	FP
FN	TN
1	1



ROC：受试者特征曲线（Receiver Operating Characteristic Curve）

AUC：Area Under the Curve

Cost Sensitive Learning











分类的评价准则

- **分类模型总体判断的准确率：**

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **查全率：表示在本类样本中被正确分类的样本所占的比例**

$$Sensitivity = Recall = \frac{TP}{TP + FN}$$

正确分类为正类在真实为正类的占比

- **查准率：表示被分类为该类的样本中，真正属于该类的样本所占的比例**

$$Precision = \frac{TP}{TP + FP} \qquad Negative\ Prediction = \frac{TN}{TN + FN}$$

正确分类为正类在所有被分为正类的占比

- **几何均值： 是各个类别的查全率的平方根**

$$G - mean = \sqrt{\prod_{j=1}^{m} Recall_j} \qquad Acc^{+} = \frac{TP}{TP + FN}; \quad Acc^{-} = \frac{TN}{TN + FP}$$



分类的评价准则

The accuracy (ACC) is the percentage of test instances that are correctly detected and can be calculated as follows:

$$ACC = \frac{TP + TN}{TP + FP + FN + TN} \tag{13}$$

The sensitivity (TPR) is also an essential criterion for a classifier. It can measure the ability to classify positive samples as positive and is calculated as follows:

$$Sensitivity = \frac{TP}{TP + FN} \tag{14}$$

The specificity (TNR, also called Recall) represents the ability of the classifier to detect negative samples as negative and is characterized by the following equation:

$$Specificity = \frac{TN}{FP + TN} \tag{15}$$

The false negative rate (FNR) denotes the percentage of individuals that are classified as negative, but in fact, they are positive. It is given by the following equation:

$$FNR = \frac{FN}{TP + FN} \tag{16}$$

Similarly, the false positive rate (FPR) is the percentage of instances that are identified as positive, while in actuality, they are negative. It is calculated by the following equation:

$$FPR = \frac{FP}{FP + TN} \tag{17}$$

The F_measure value is another important evaluation metric to estimate the classifier's performance. It ranges from 0 to 1. A larger value of F_measure represents a successful classification. The F_measure value is calculated according to the harmonic mean of the recall and precision by the following equation:

$$F_measure = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{18}$$

where $Precision$ is defined as follows:

$$Precision = \frac{TP}{TP + FP} \tag{19}$$

Moreover, Cohen's Kappa (K) is also employed as a classifier measure that replaces the accuracy ratio measure (Cohen, 1960). It evaluates the probability evaluation of a classifier that occurs due to chance and takes a value between 0 and 1. A value close to 1 indicates an excellent classifier; a value close to −1 corresponds to an unsuccessful classifier. It can be measured by the following equation:

$$K = \frac{P_0 - P_e}{1 - P_e} \tag{20}$$

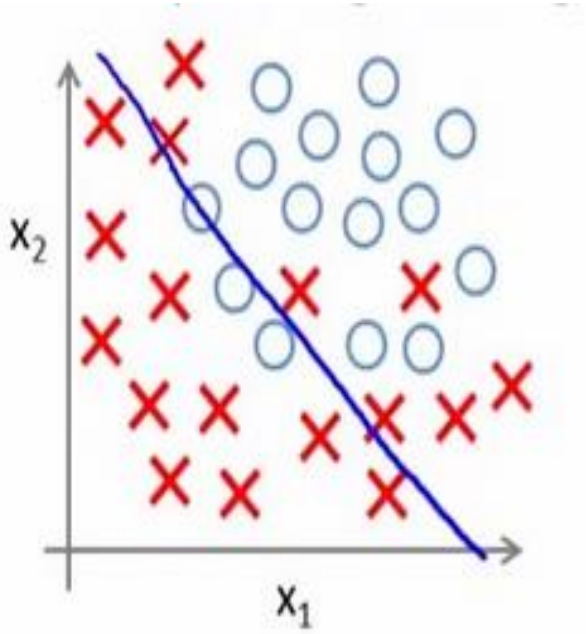
where P_0 represents the total agreement probability and P_e is the accuracy value achieved by random estimation.

Finally, the AUC is the area calculated under the receiver operating characteristic (ROC) curve (Fawcett, 2004). It is the probability that the classifier randomly ranks a selected positive instance higher than a selected negative instance. Its range is $[0, 1]$. The larger the AUC value is, the greater the performance of the classifier. It can be expressed by the following equation:

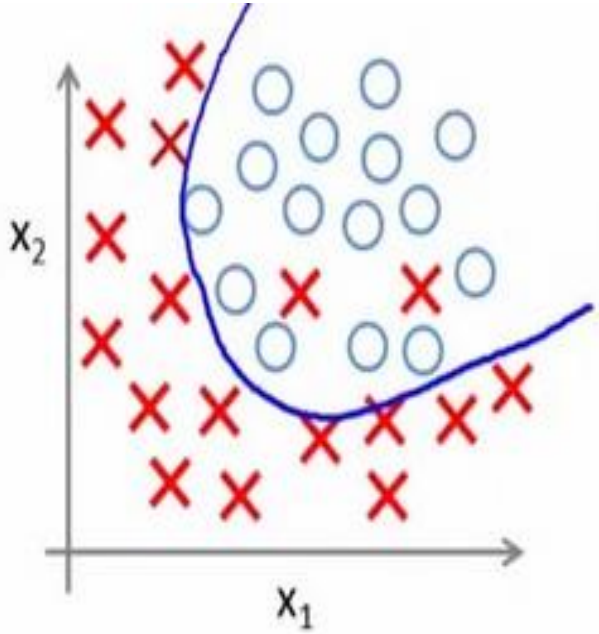
$$AUC = \int_0^1 TPR(FPR)\, \mathrm{d}\, FPR \tag{21}$$



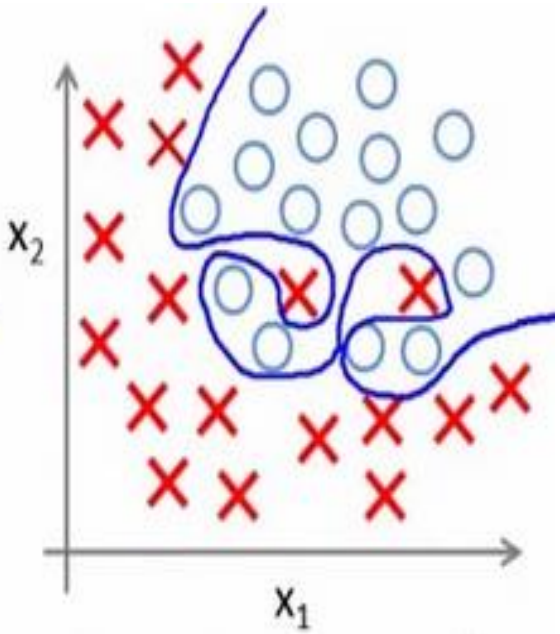
欠学习、合适学习、过学习



欠学习



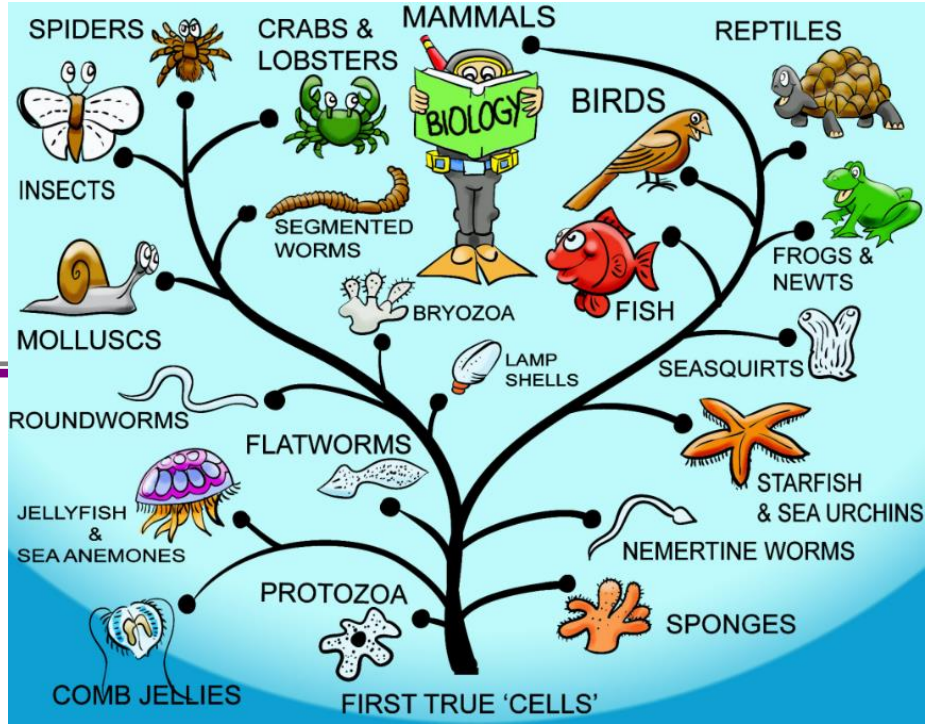
合适学习



过学习

决策树

Evolution Tree





Decision Tree Classification

女儿：多大年纪了?

母亲：25。

女儿：长的帅不帅?

母亲：挺帅的。

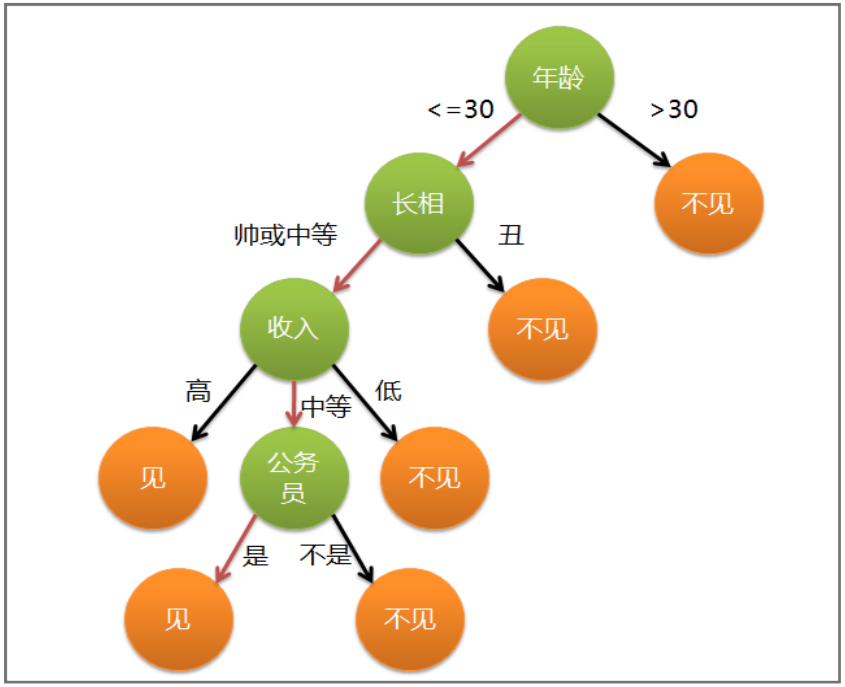
女儿：收入高不?

母亲：不算很高，中等情况。

女儿：是公务员不?

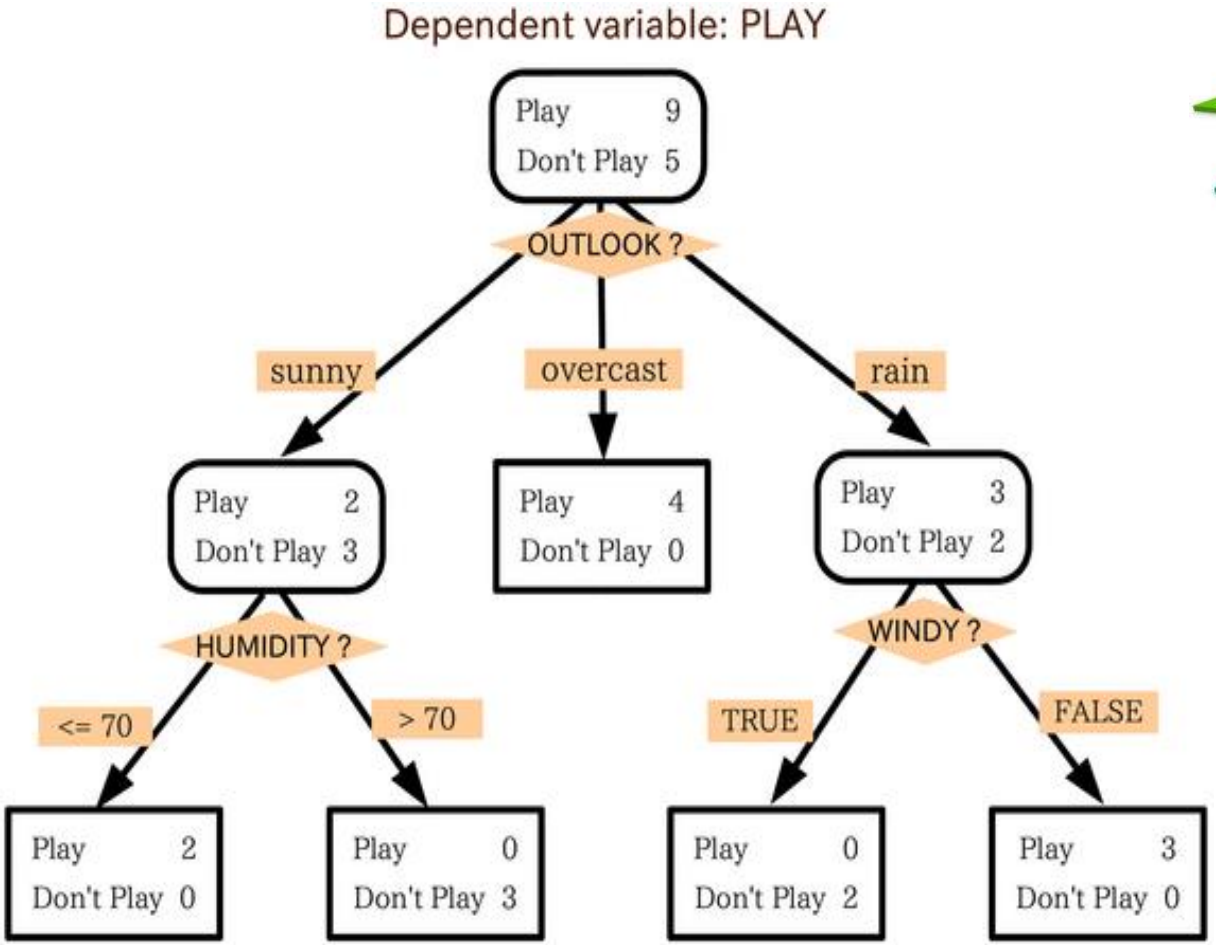
母亲：是，在税务局上班呢。

女儿：那好，我去见见。





Decision Making











决策树

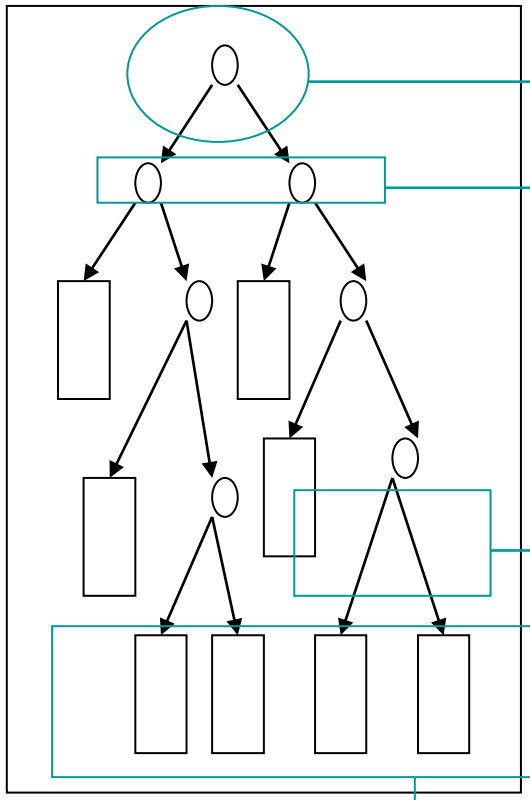
- 从数据产生决策树的机器学习技术称为决策树学习，简称决策树（Decision Tree）。
- 决策树是数据挖掘中最常用的一种分类和预测技术，使用其可建立分类和预测模型。
- 决策树模型是一个树状结构，树中每个节点表示分析对象的某个属性，每个分支表示这个属性的某个可能的取值，每个叶节点表示经历从根节点到该叶节点这条路径上的对象的值。模型通过树中的各个分支对对象进行分类，叶节点表示的对象值表达了决策树分类的结果。决策树仅有一个输出，若需要有多个输出，可以建立多棵独立的决策树以处理不同输出。
- 适用于离散值属性、连续值属性
- 采用自顶向下的递归方式产生一个类似于流程图的树结构
- 在根节点和各内部节点上选择合适的描述属性，并且根据该属性的不同取值向下建立分枝 。



决策树

- 决策树的优点：
  - 进行分类器设计时，决策树分类方法所需时间相对较少
  - 决策树的分类模型是树状结构，简单直观，比较符合人类的理解方式
  - 可以将决策树中到达每个叶节点的路径转换为IF—THEN形式的分类规则，这种形式更有利于理解

决策树的结构



根部节点(root node)

中间节点(non-leaf node)

(代表测试的条件)

分支(branches)

(代表测试的结果)

叶节点(leaf node)

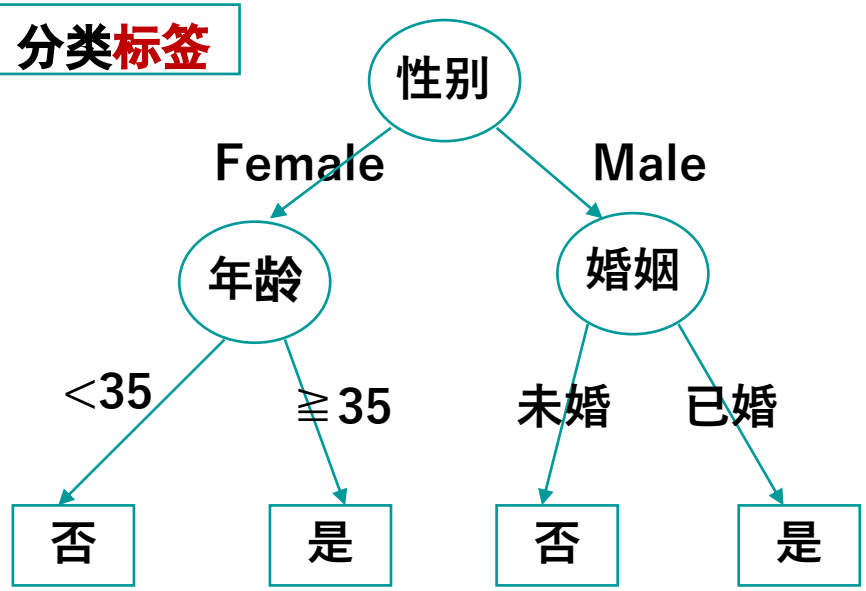
(代表分类后所获得的分类标记)

决策树

数据集

編號	性別	年齡	婚姻	家庭人數	購買RV房車
A0001	Male	45	未婚	1	是
A0002	Male	52	已婚	7	是
A0003	Female	38	已婚	5	是
A0004	Male	25	已婚	5	否
A0005	Female	48	已婚	4	是
A0006	Male	32	未婚	3	是
A0007	Female	65	已婚	4	否
A0008	Male	33	已婚	3	是
A0009	Male	45	已婚	4	是
A0010	Female	52	未婚	1	是
A0011	Male	38	未婚	1	否
…	…	…	…	…	…
Z0099	Male	22	未婚	4	是

分类标签



这个决策树唯一吗?

决策树分类的步骤

数据库

編號	性別	年齡	婚姻	家庭人數	購買RV房車
A0001	Male	45	未婚	1	是
A0002	Male	52	已婚	7	是
A0003	Female	38	已婚	5	是
A0004	Male	25	已婚	5	否
A0005	Female	48	已婚	4	是
A0006	Male	32	未婚	3	是
A0007	Female	65	已婚	4	否
A0008	Male	33	已婚	3	是
A0009	Male	45	已婚	4	是
A0010	Female	52	未婚	1	是
A0011	Male	38	未婚	1	否
…	…	…	…	…	…
Z0099	Male	22	未婚	4	是

建立模型

训练样本(Training samples)

测试样本(Testing samples)

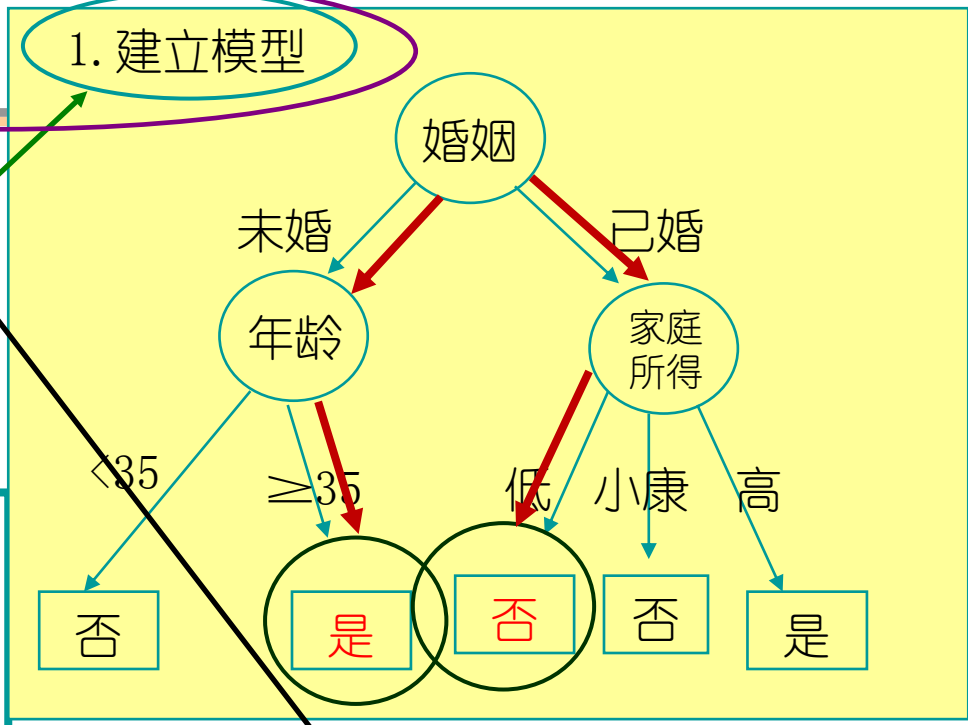
评估模型



Example

2. 模型评估

1. 建立模型



资料

編號	性別	年齡	婚姻	家庭所得	購買RV房車
A0001	Male	<35	未婚	高所得	否
A0002	Male	<35	未婚	小康	否
A0003	Female	≧35	已婚	高所得	是
A0004	Male	≧35	未婚	低所得	是
A0005	Female	≧35	已婚	高所得	否
A0006	Male	≧35	已婚	低所得	否
A0007	Female	≧35	未婚	小康	否
A0008	Male	≧35	已婚	高所得	是
A0009	Male	<35	已婚	低所得	是

测试样本

	預測結果
是	錯誤
是	正確
否	錯誤

错误率为66.67%

修改模型

3.使用模型

編號	性別	年齡	婚姻	家庭所得	購買RV房車
W0144	Male	55	已婚	高所得	?



决策树(Decision Tree)

- 决策树归纳的基本算法是贪心算法，它以自顶向下递归各个击破的方式构造决策树。
  - 贪心算法：在每一步选择中都采取在当前状态下最好/优的选择。
- 在其生成过程中，分割方法即属性选择度量是关键。通过属性选择度量，选择出最好的将样本分类的属性。
- 根据**分割方法**的不同，决策树可以分为两类：基于信息论的方法（较有代表性的是ID3、C4.5算法等）和最小GINI指标方法（常用的有CART、SLIQ及SPRINT算法等）。

Quinlan(1979)提出，以Shannon(1949)的信息论为依据。ID3算法的属性选择度量就是使用信息增益，选择最高信息增益的属性作为当前节点的测试属性。



决策树

- **工作原理**
  - 在数据集划分时寻找起**决定性作用**的特征，然后按照这一特征将原始数据集划分为多个子集。
  - 决策树的建模是一个迭代递归的过程，从根节点开始第一次分枝成若干子节点，之后对每一个子节点进行分枝，算法何时停止由数据决定。
  - 通常做法是先生成一颗最大树，然后通过剪枝处理得到最终的决策树模型。所以决策树的构造可以分为三个部分，分别是**特征选择**，**决策树的生成**，**决策树的剪枝**。



信息熵 (Entropy)

- 我们常说信息很多，或信息很少，但却很难说清楚信息到底有多少；
- 比如一本50多万字的《史记》有多少信息量？或一套莎士比亚全集有多少信息量？
- 这个问题几千年来都没有人给出很好的解答，直到1948年，克劳德·香农(Claude Shannon)在他著名的论文“通信的数学原理”中提出了信息熵的概念，才解决了信息的度量问题，并且量化出信息的作用。



信息熵 (Entropy)

- 一条信息的信息量和它的不确定性有着直接的关系；
- 比如，要搞清楚一件非常不确定的事，或是我们一无所知的事情，就需要了解大量信息。相反，如果我们对某件事已经有了较多了解，那么不需要太多信息就能把它搞清楚；
- 从这个角度看，信息量就等于不确定性的多少；
- 如何量化信息的度量呢？



信息熵 (Entropy)

- 假如我错过了一个有32支球队参加的足球赛，赛后我问一个知道比赛结果的观众“哪支球队是冠军”？他不愿意直接告诉我，而让我猜，每猜一次，他要收一元钱才肯告诉我是否猜对，那我需要付多少钱才能知道谁是冠军呢？

- 我可以把球队编号，从1到32，然后问“冠军球队在1-16号中吗？”，假如他告诉我猜对了，我就接着问“冠军在1-8号中吗？”，假如他说猜错了，那我就知道冠军在9-16号中。这样只要5次，我就能知道哪支球队是冠军
- 当然，香农不是用钱，而是用比特(bit)来度量信息量，在上例中，这条消息的信息量是**5**比特

信息量的比特数和所有可能情况的对数有关，例如本例中，信息量 = $\log_2$(球队数)，即 5 = $\log_2$(32)



信息熵 (Entropy)

- 实际上可能不需要5次就能猜出谁是冠军，因为一些强队得冠的可能性更高，因此第一次猜测时可以把少数几支强队分成一组，其它球队分成另一组，然后猜冠军球队是否在那几支强队中
- **这样，也许三次或四次就能猜出结果。因此，当每支球队夺冠的可能性(概率)不等时，这条信息的信息量比5比特少**
- 香农指出，它的准确信息量应该是

$$H = -(p_1 \cdot \log_2 p_1 + p_2 \cdot \log_2 p_2 + \ldots + p_{32} \cdot \log_2 p_{32})$$

$p_1, p_2, \ldots, p_{32}$分别是这32支球队夺冠概率，香农把它称作**信息熵，单位为比特**；可以算出，当32支球队夺冠概率相同时，对应的信息熵为5比特。



信息熵(Entropy)

- 信息变化的平均信息量称为“信息熵”（信息量化）
- 在信息论中，信息熵是信息的**不确定程度**的度量。
- 熵越大，信息就越不容易搞清楚，需要的信息量就越大，能传输的信息就越多。

$$H(x) = -\sum_{i=1}^{n} p(x_i)\log_2(p(x_i))$$

p: Xi 出现的概率

H(x): 随机事件 *x* 的熵

Xi: *x*所有可能的结果



信息熵

- 例：抛硬币实验：

$$H(x) = -\sum_{i=1}^{n} p(x_i)\log_2(p(x_i))$$

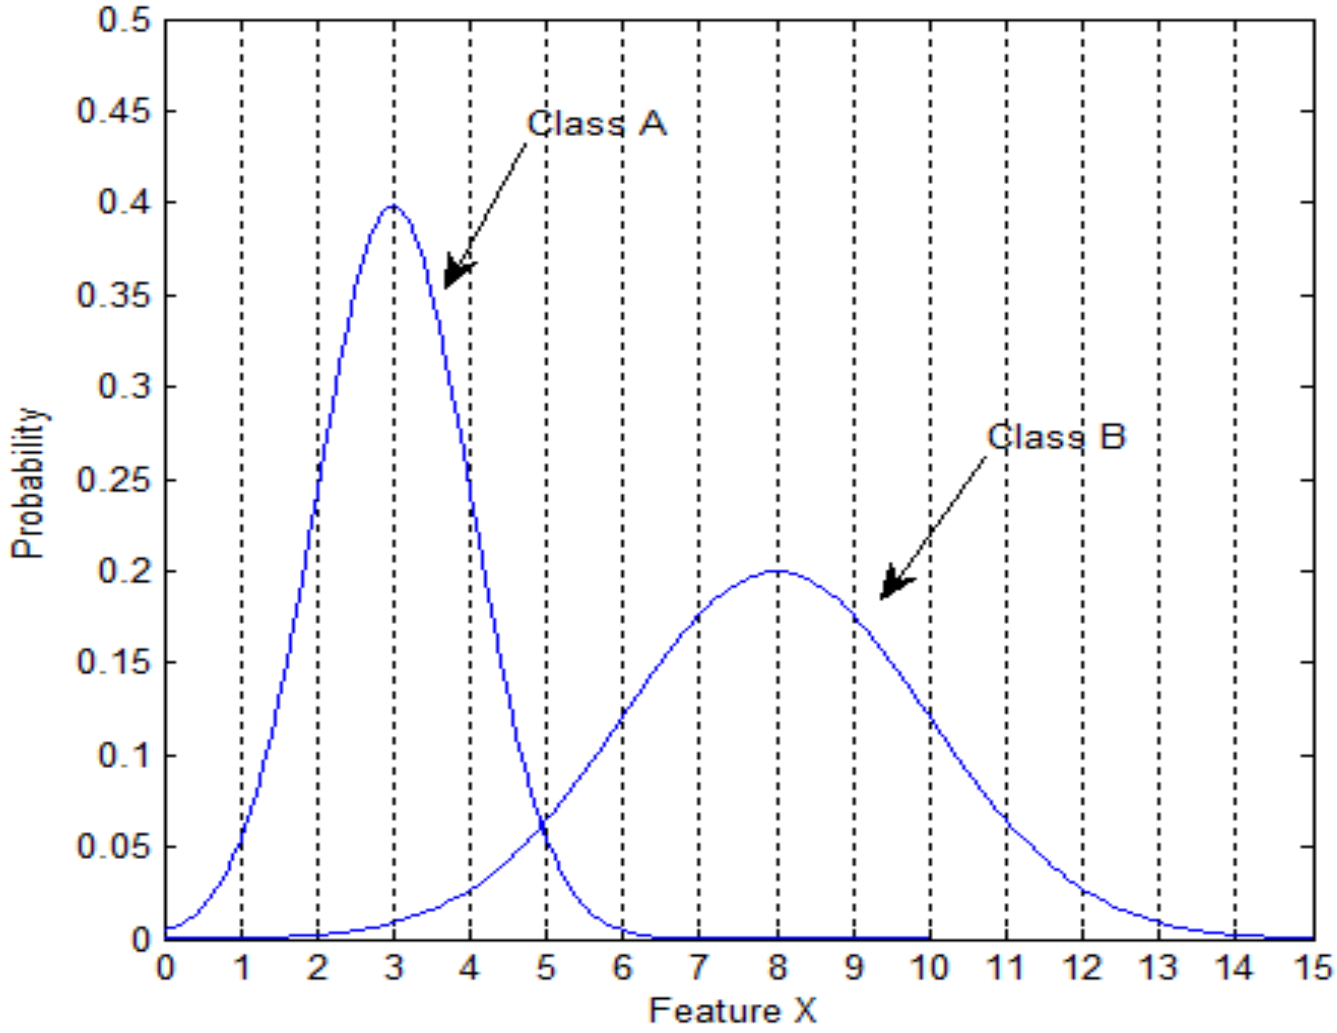
$$H(\text{抛硬币}) = -(\frac{1}{2}log_2(\frac{1}{2}) + \frac{1}{2}log_2(\frac{1}{2})) = 1$$

- 例：一个随机事件x,三种取值可能：x_1，x_2，x_3出现的概率分别为1/4,1/2,1/4

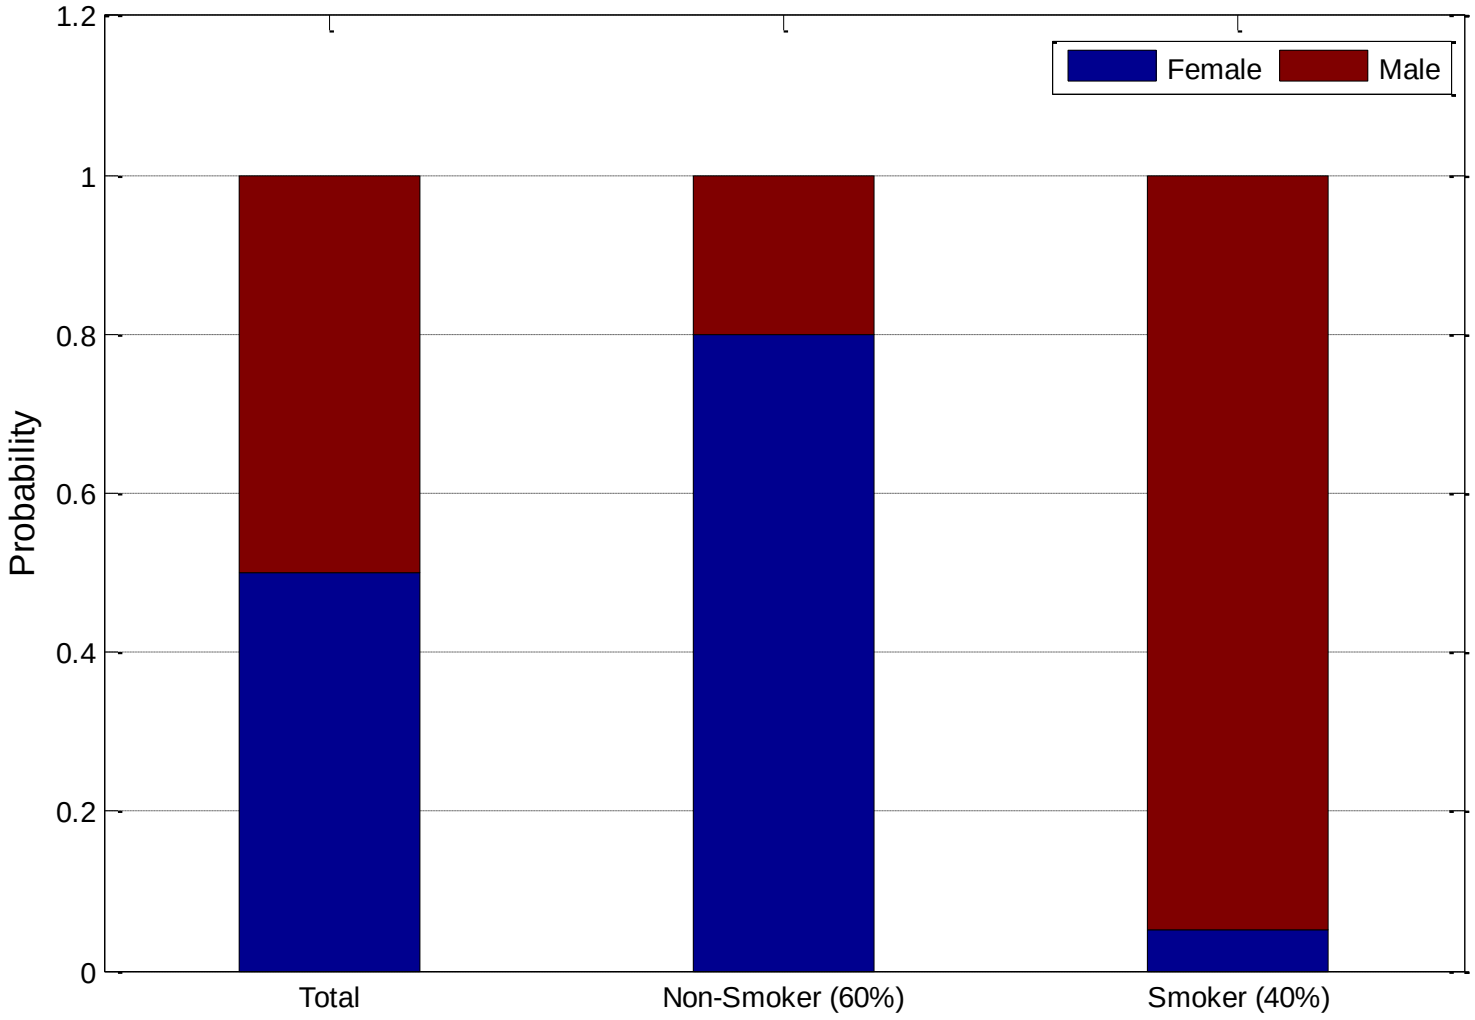
$$H(x) = -(\frac{1}{4}log_2\left(\frac{1}{4}\right) + \frac{1}{2}log_2\left(\frac{1}{2}\right) + \frac{1}{4}log_2\left(\frac{1}{4}\right)) = \frac{3}{2}$$



Class Distributions

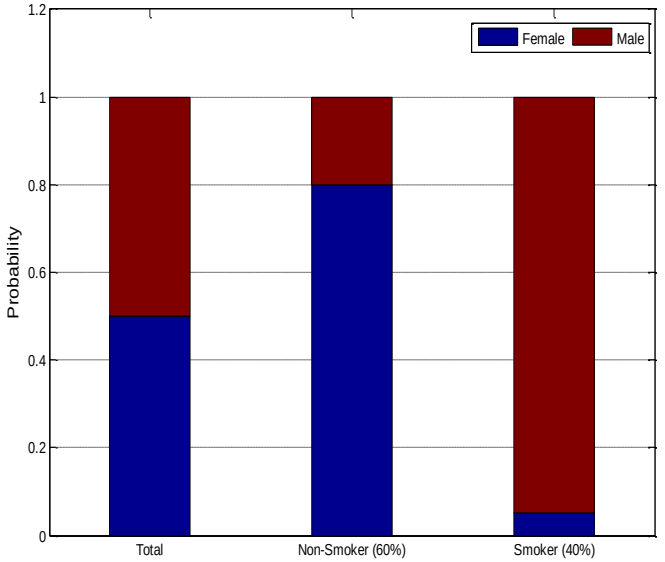


信息增益（Information Gain）



信息增益（Information Gain）

$$H(X) = -\sum_{i=1}^{n} p(x_i)\log_b p(x_i)$$

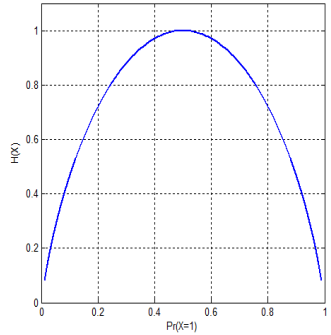


$$H(S) = -0.5 \cdot \log_2 0.5 - 0.5 \cdot \log_2 0.5 = 1.0$$

$$X:\{a = \text{"Non-Smoker"};\quad b = \text{"Smoker"}\}$$

$$H(S \mid X = a) = -0.8 \cdot \log_2 0.8 - 0.2 \cdot \log_2 0.2 = 0.7219$$

$$H(S \mid X = b) = -0.05 \cdot \log_2 0.05 - 0.95 \cdot \log_2 0.95 = 0.2864$$



$$H(S \mid X) = 0.6 \cdot H(S \mid X = a) + 0.4 \cdot H(S \mid X = b) = 0.5477$$

$$Gain(S, X) = H(S) - H(S \mid X) = 0.4523$$

Information Gain
信息增益



信息增益（Information Gain）

- 信息增益表示当 x 取属性 x_i 值时，其对降低 x 的熵的贡献大小。
- 信息增益值越大，越适于对 x 进行分类。
- 其中，对于一组 I 实例，计算Gain(A)：

$$\text{Gain}(A) = \text{Info}(I) - \text{Info}(I,A)$$

选择具有最高信息增益Gain(A)的属性A作为分裂属性

$$\max \quad Gain(A)$$

按照能做“最佳分类”的属性A划分，使完成样本分类需要的信息量最小

$$\min \quad Info(I,A)$$



信息增益（Information Gain）

所有实例总数为：N

出现在 i 类中的实例个数为：n_i

出现在 j 类中的实例个数为：n_j

- **Info*(I)* 为当前数据集所有实例所表达的信息量**

$$Info(I) = -\sum_{i=1}^{n} \frac{n_i}{N} log_2\left(\frac{n_i}{N}\right)$$

- **Info*(I,A)* 为根据属性 A 的 k 个可能取值分类 I 中实例之后所表达的信息量**

$$Info(I,A) = -\sum_{j=1}^{k} \frac{n_j}{N} Info(j类)$$

Example(Gain)

年齡	性別	家庭所得	購買RV房車
<35	Male	小康	否
≧35	Female	小康	否
≧35	Female	小康	否
≧35	Female	低所得	否
<35	Male	高所得	否
≧35	Female	低所得	否
<35	Female	低所得	否
<35	Female	高所得	是
≧35	Male	小康	是
<35	Male	高所得	否
≧35	Female	小康	否
<35	Male	低所得	否
≧35	Female	小康	否
≧35	Male	低所得	是
≧35	Male	小康	是
≧35	Female	低所得	否

$I(16,4)=-\{(4/16)*\log_2(4/16)+(12/16)*\log_2(12/16)\}=0.8113$

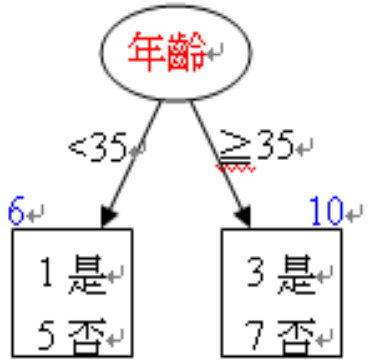
$I(6,1)=-\{(1/6)*\log_2(1/6)+(5/6)*\log_2(5/6)\}$

$E(年龄)=(6/16)*I(6,1)+(10/16)*I(10,3)=0.7946$

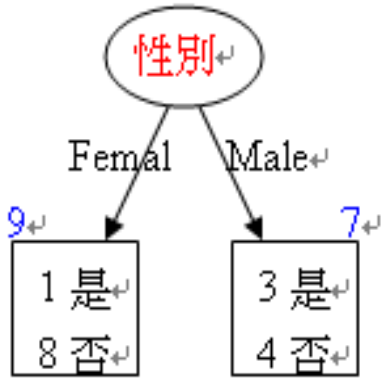
$Gain(年龄)=I(16,4)-E(年龄)=0.0167$

$n=16$

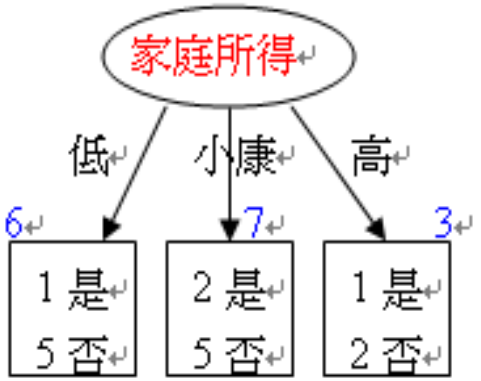
$n_1=4$



- Gain(年龄)=0.0167



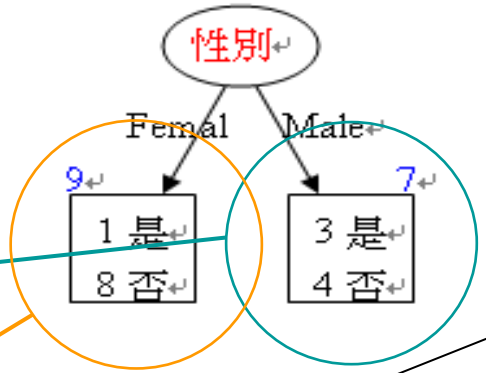
- Gain(性别)=0.0972



- Gain(家庭所得)=0.0177

- **Max:作为第一个分类依据**

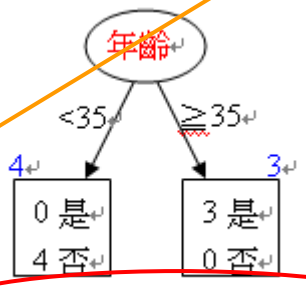
Example(续)



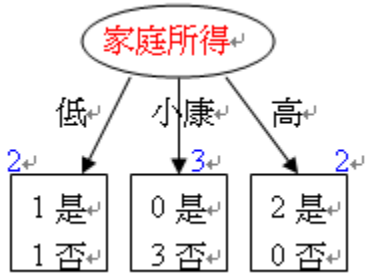
已纯

年齡	性別	家庭所得	購買RV房車
<35	Male	小康	否
<35	Male	低所得	否
<35	Male	高所得	否
<35	Male	高所得	否
≧35	Male	小康	是
≧35	Male	小康	是
≧35	Male	低所得	是

Gain(7,3)=-((3/7)*log$_2$(3/7)+(4/7)*log$_2$(4/7))**-0** = 0.9852



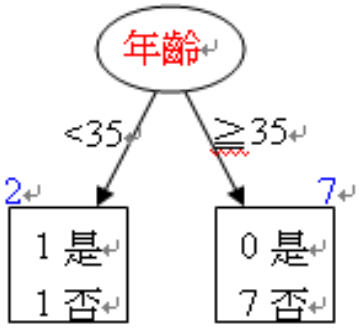
- Gain(年齡)=0.9852



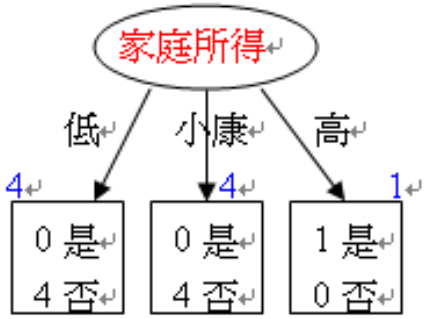
- Gain(家庭所得)=0.688

年齡	性別	家庭所得	購買RV房車
<35	Female	低所得	否
<35	Female	高所得	是
≧35	Female	小康	否
≧35	Female	小康	否
≧35	Female	小康	否
≧35	Female	小康	否
≧35	Female	低所得	否
≧35	Female	低所得	否
≧35	Female	低所得	否

Gain(9,1)=-((1/9)*log$_2$(1/9)+(8/9)*log$_2$(8/9))**-0** = 0.5032



- Gain(年齡)=0.2222

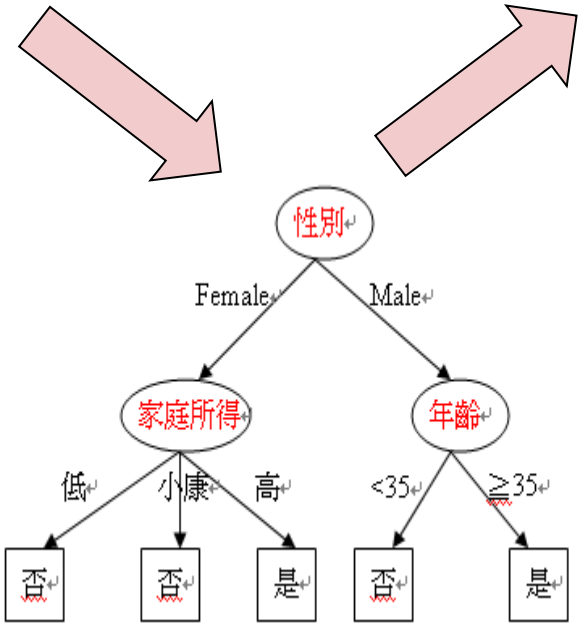


- Gain(家庭所得)=0.5032

Example(end)ID3算法

- Dataset

年齡	性別	家庭所得	購買RV房車
<35	Male	小康	否
≧35	Female	小康	否
≧35	Female	小康	否
≧35	Female	低所得	否
<35	Male	高所得	否
≧35	Female	低所得	否
<35	Female	低所得	否
<35	Female	高所得	是
≧35	Male	小康	是
<35	Male	高所得	否
≧35	Female	小康	否
<35	Male	低所得	否
≧35	Female	小康	否
≧35	Male	低所得	是
≧35	Male	小康	是
≧35	Female	低所得	否



- Rule

分类规则：

IF性别=Female AND家庭所得=低所得THEN购买RV房车=否

IF性别=Female AND家庭所得=小康THEN购买RV房车=否

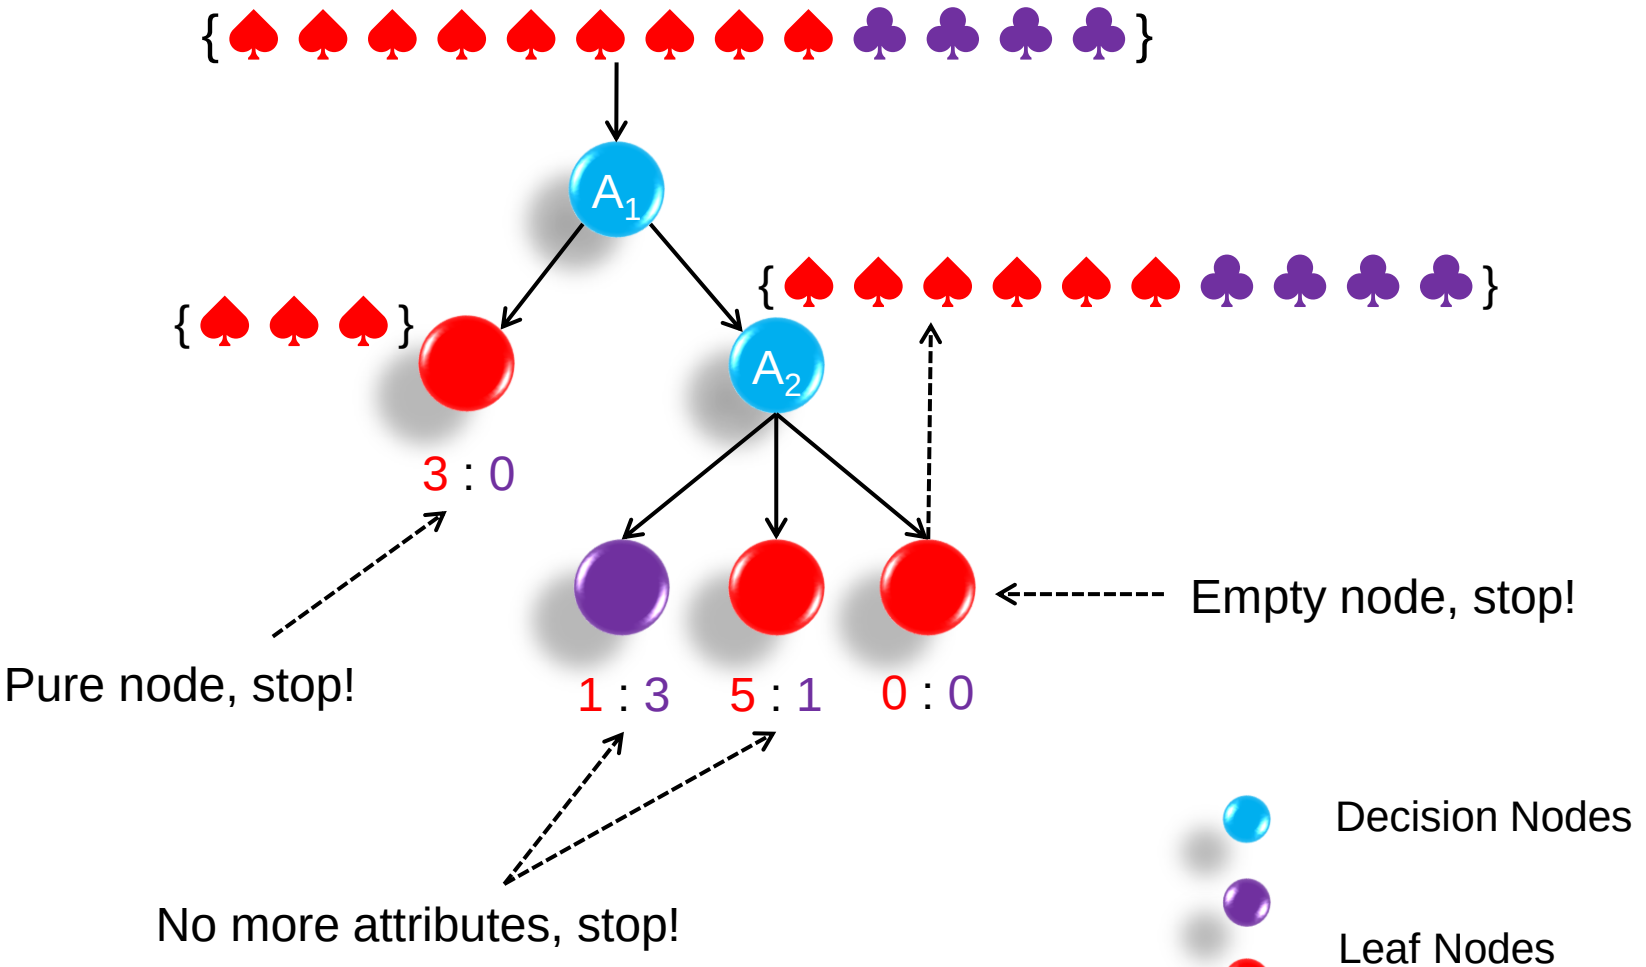
IF性别=Female AND家庭所得=高所得THEN购买RV房车=是

IF性别=Male AND年龄<35 THEN购买RV房车=否

IF性别=Male AND年龄≧35 THEN购买RV房车=是

- Decision Tree

ID3 算法框架



Overfitting Problem



ID3决策树建立算法

1．决定分类属性

2．对目前的数据表，建立一个节点N

3．如果数据库中的数据都属于同一个类，N就是树叶，在树叶上标出所属的类

4．如果数据表中没有其他属性可以考虑，则N也是树叶，按照少数服从多数的原则在树叶上标出所属类别

5．否则，根据平均信息期望值E或GAIN值选出一个最佳属性作为节点N的测试属性

6．节点属性选定后，对于该属性中的每个值：

从N生成一个分支，并将数据表中与该分支有关的数据收集形成分支节点的数据表，在表中删除节点属性那一栏

7. 如果分支数据表属性非空，则转1，运用以上算法从该节点建立子树



Continuous Attributes

Samples are sorted based on *Temperature*.

Temperature	40	48	60	72	80	90
Play Tennis	No	No	Yes	Yes	Yes	No

Threshold **A**

Threshold **B**

$$Gain(S,A) = Entropy(S) - \frac{1}{3}\cdot 0 - \frac{2}{3}\cdot(-\frac{3}{4}\cdot \log_2 \frac{3}{4} - \frac{1}{4}\cdot \log_2 \frac{1}{4}) = 1 - 0.541 = 0.459$$

$$Gain(S,B) = Entropy(S) - \frac{1}{6}\cdot 0 - \frac{5}{6}\cdot(-\frac{3}{5}\cdot \log_2 \frac{3}{5} - \frac{2}{5}\cdot \log_2 \frac{2}{5}) = 1 - 0.809 = 0.191$$



C4.5算法

- C4.5使用信息量和信息增益的概念计算所有属性的增益，并计算所有属性的增益率，选择值最大的属性来划分数据实例。

$$\text{GainRatio}(A) = \frac{\text{Gain}(A)}{\text{SplitsInfo}(A)}$$

由于：系统熵的最小值（基数）会随着系统取值的个数而增加

- ***SplitsInfo(A)*** 作用是对 A 属性的增益值的**标准化**，目的是消除属性选择上的偏差（Bias）

$$SplitsInfo(A) = -\sum_{j=1}^{k} \frac{n_j}{N} log_2\left(\frac{n_j}{N}\right)$$



C4.5算法-信息熵偏差（Entropy Bias）

- 信息熵的计算指导了整个决策树的建造过程
- 有一种自然的偏差倾向于具有许多值的属性
- 比如考虑属性：“出生年月日”
- 此属性可能会将训练数据集分成非常小的数据子集：
  - 非常高的信息增益
  - 在不可见实例上，目标函数是个很糟糕预测器
- 这些属性需要加以惩罚：相当于加了**惩罚项**

C4.5使用分裂信息(Split information)将信息增益规范化

选择具有**最大信息增益率**的属性作为**分裂属性**

$$SplitInfomation(S,A) = -\sum_{i=1}^{C} \frac{|S_i|}{|S|} \log_2 \frac{|S_i|}{|S|}$$

分的越细，熵就会越大

$$GainRatio(S,A) = \frac{Gain(S,A)}{SplitInfomation(S,A)}$$



C4.5算法对ID3的改进

- C4.5使用了信息论（Information Theory）的方法，即使用增益率（Gain Ratio）的概念来选择属性；
- 目的是使树的层次和节点数最小，使数据的概化程度最大化。
- C4.5选择的基本思想
  - 选择具有最大增益率的属性作为分支节点来分类实例数据。

- 改进1：用**信息增益率**代替**信息增益**来选择**属性**
- 改进2：能够完成对**连续值属性**的**离散化处理**
- 改进3：能处理**属性值缺失**的情况
- 改进4：在决策树构造完成之后进行**剪枝**



改进3：C4.5中缺失值的处理

其中 F 为属性值未缺失的实例所占比例；

计算 Info(D) 和 $Info_A(D)$ 时忽略属性值缺失的实例

天气	湿度	有雨？	去玩？
晴	70	有	玩
晴	90	有	不玩
晴	85	无	不玩
晴	95	无	不玩
晴	70	无	玩
缺失	90	有	玩
多云	78	无	玩
多云	65	有	玩
多云	75	无	玩
雨	80	有	不玩
雨	70	有	不玩
雨	80	无	玩
雨	80	无	玩
雨	96	无	玩

$$
\begin{aligned}
&Info(D) \\
&= -8/13 \times \log(8/13) - 5/13 \times \log(5/13) \\
&= 0.961 \text{ bits}
\end{aligned}
$$

$$
\begin{aligned}
&Info_{天气}(D) \\
&= 5/13 \times (-2/5\log(2/5) - 3/5 \times \log(3/5)) \\
&\quad + 3/13 \times (-3/3\log(3/3) - 0/3 \times \log(0/3)) \\
&\quad + 5/13 \times (-3/5\log(3/5) - 2/5 \times \log(2/5)) \\
&= 0.747 \text{ bits}
\end{aligned}
$$

$$
\begin{aligned}
&Gain(天气) \\
&= \mathbf{13/14} \times (0.961 - 0.747) \\
&= 0.199 \text{ bits}
\end{aligned}
$$



改进3：C4.5中缺失值的处理

计算 SplitInfo 时，将缺失的属性值当作一个正常值进行计算，
本例中，当作天气有四个值，分别是晴, 多云, 雨, ?，再计算其 SplitInfo

天气	湿度	有雨？	去玩？
晴	70	有	玩
晴	90	有	不玩
晴	85	无	不玩
晴	95	无	不玩
晴	70	无	玩
缺失	90	有	玩
多云	78	无	玩
多云	65	有	玩
多云	75	无	玩
雨	80	有	不玩
雨	70	有	不玩
雨	80	无	玩
雨	80	无	玩
雨	96	无	玩

$SplitInfo_{天气}(D)$

$= -5/14 \times \log(5/14)$ ➡ 晴

$-3/14 \times \log(3/14)$ ➡ 多云

$-5/14 \times \log(5/14)$ ➡ 雨

$-1/14 \times \log(1/14)$ ➡ 缺失

$= 1.809$ bits

$GainRatio(天气)$
$= Gain(天气) / SplitInfo_{天气}(D)$
$= 0.199 / 1.809$



改进3：C4.5中缺失值的处理

分裂时，将属性值缺失的实例分配给所有分支，但是带一个权重

T1: (天气=晴)

湿度	有风	玩?	权重
70	有	玩	1
90	有	不玩	1
85	无	不玩	1
95	无	不玩	1
70	无	玩	1
90	**有**	**玩**	**5/13**

T1: (天气=多云)

湿度	有风	玩?	权重
90	**有**	**玩**	**3/13**
78	无	玩	1
65	有	玩	1
75	无	玩	1

T1: (天气=雨)

湿度	有风	玩?	权重
80	有	不玩	1
70	有	不玩	1
80	无	玩	1
80	无	玩	1
96	无	玩	1
90	**有**	**玩**	**5/13**

本例14个实例中共13个实例天气属性值未缺失：

其中5个实例的天气属性为“晴”，3个实例的天气属性为“多云”， 5个实例的天气属性为“雨”

本例14个实例中共1个实例天气属性值缺失，因此估算出天气属性值缺失的第6个实例：

天气是晴的概率是5/13，天气是多云的概率是3/13，天气是雨的概率是5/13

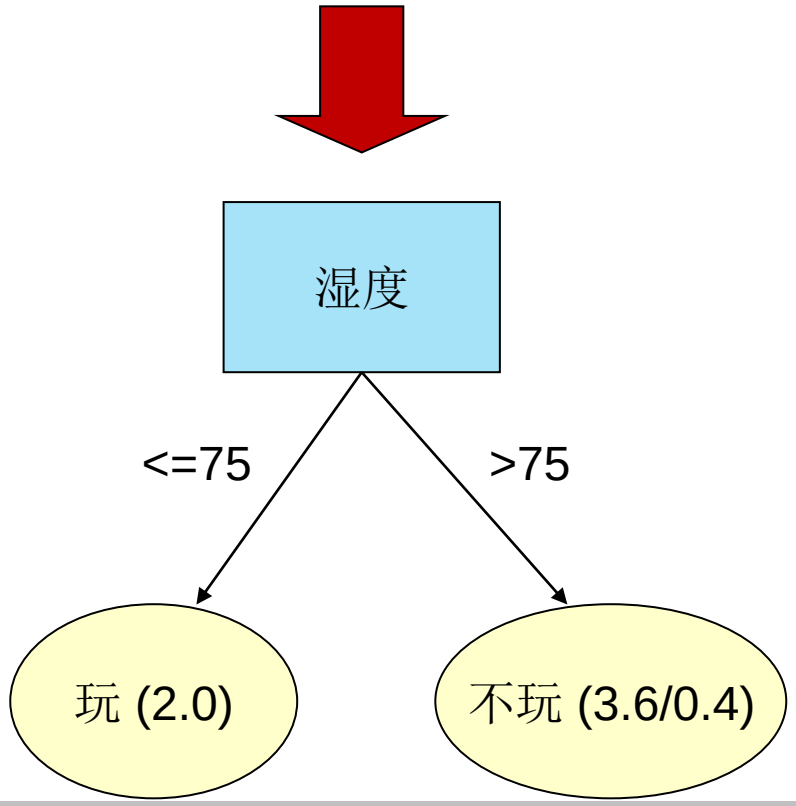
改进3：C4.5中缺失值的处理

T1: (天气=晴)

湿度	有风	玩?	权重
70	有	玩	1
90	有	不玩	1
85	无	不玩	1
95	无	不玩	1
70	无	玩	1
90	**有**	**玩**	**5/13=0.4**

湿度<=75　2玩，　0不玩

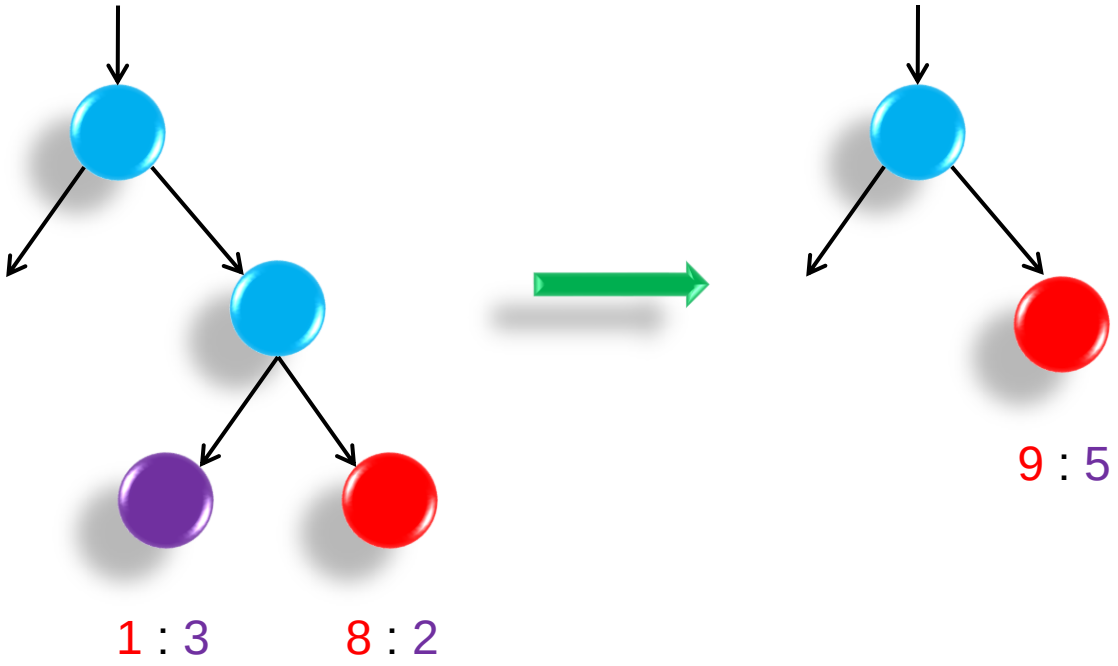
湿度 > 75　5/13玩，3不玩



叶节点以 (N/E) 的形式定义，
其中 N 为到达该叶节点的实例数，
E 为其中属于其它分类的实例数。

例如，**不玩(3.6/0.4)** 表示3.6个实例到达“不玩”节点，其中0.4个实例不属于“不玩”

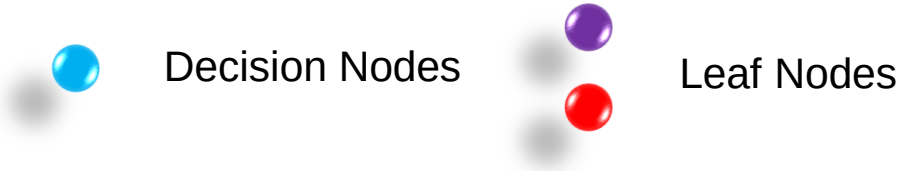
改进4：剪枝（Pruning）



Training Set

Test Set

Prediction Set





决策树-过学习

- **避免过学习**

  目标：训练误差 ≥ 测试误差

  属性多的情况下不能让树太复杂

  训练拐点终止

- 上述的决策树算法增长树的每一个分支的深度，直到恰好能对训练样例比较完美地分类。
- 实际应用中，当训练样本中有噪声或训练样例的数量太少以至于不能产生目标函数的有代表性的采样时，该策略可能会遇到困难
- 在以上情况发生时，这个简单的算法产生的树会**过度拟合训练样例** (过度拟合: Over fitting)
- 过度拟合产生的原因：训练样本中有噪声，训练样例太小等



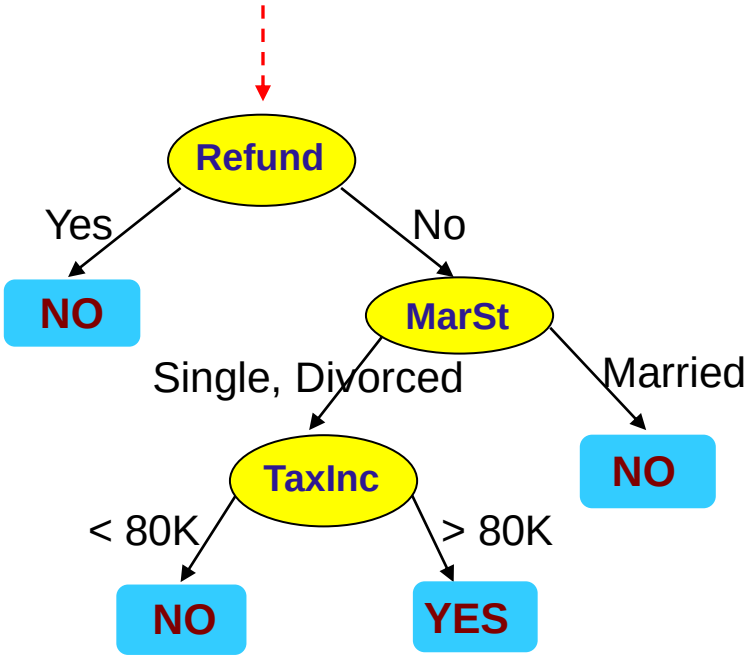
停止条件

- 当结点中的所有记录**都属于同一个类时**，停止扩展该结点
- 当结点中的所有记录都**具有类似的属性值时**，停止扩展该结点
- 当**没有属性可用时**，停止扩展该结点
- 提前终止



决策树: 模型的使用

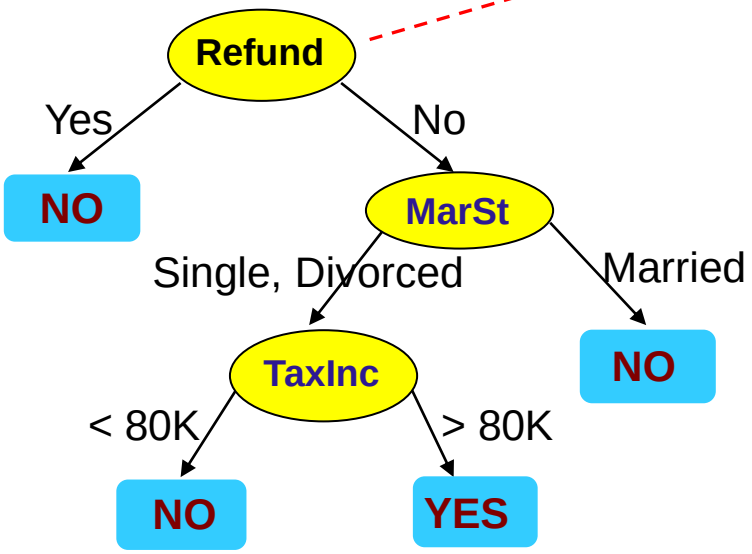
Start from the root of tree.



Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

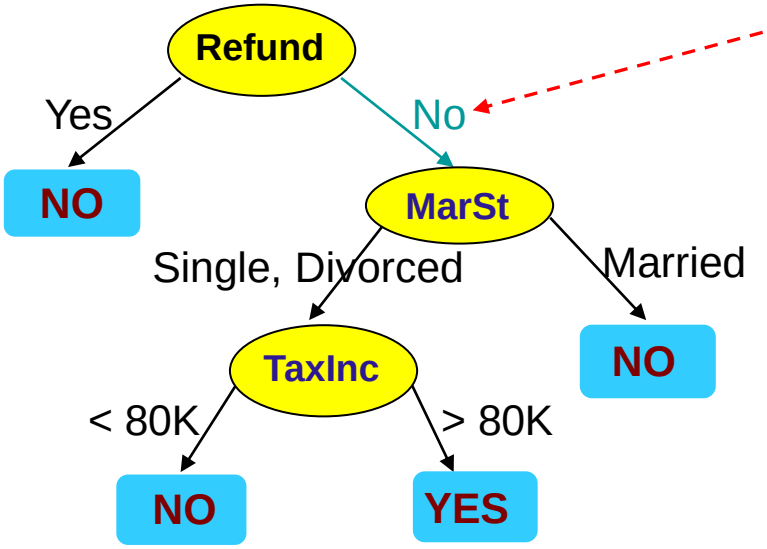
决策树: 模型的使用



Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

决策树: 模型的使用

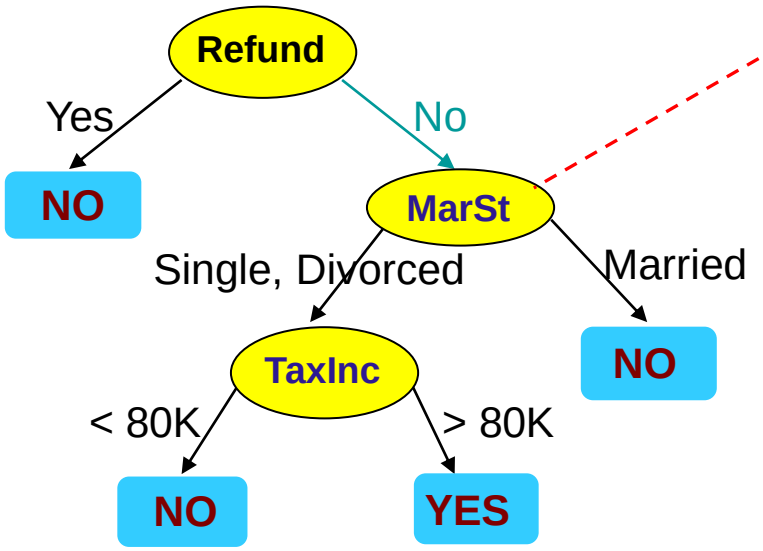


Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



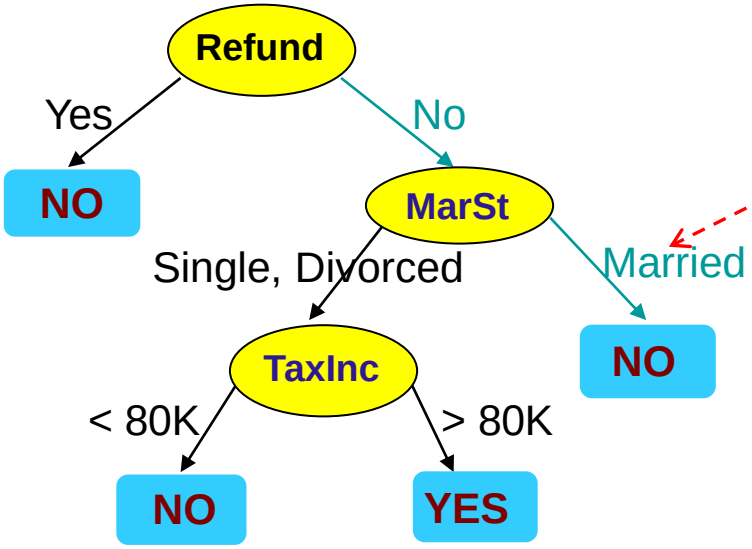
决策树: 模型的使用



Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

决策树: 模型的使用

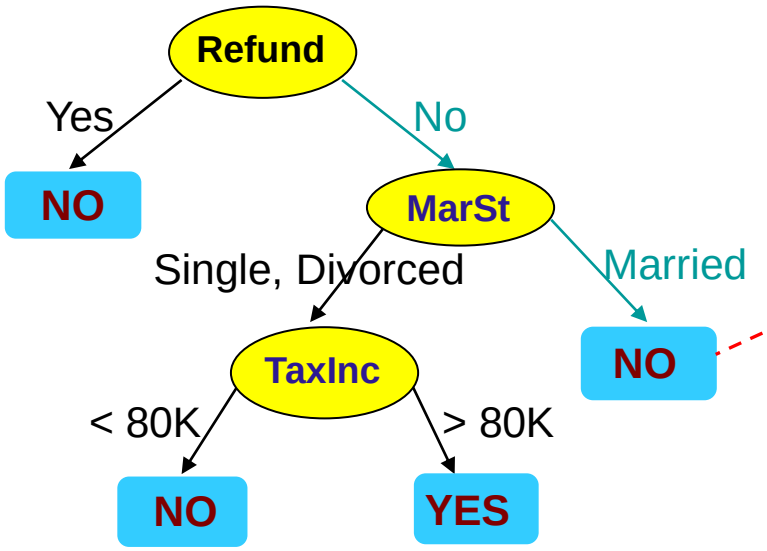


Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?



决策树: 模型的使用



Test Data

Refund	Marital Status	Taxable Income	Cheat
No	Married	80K	?

Assign Cheat to “No”

【例2.1】

给定如表2.1所示的数据集T，建立一棵决策树，用于预测某个学生是否决定去打篮球。



表2.1 一个假想的打篮球数据集

序号	Weather	Temperature/°C	Courses	Partner	Play
1	Sunny	20~30	4	Yes	**Yes**
2	Sunny	20~30	4	No	**Yes**
3	Rain	10~0	1	Yes	**Yes**
4	Sunny	30~40	5	Yes	**Yes**
5	Rain	20~30	8	No	**No**
6	Sunny	-10~0	5	Yes	**Yes**
7	Sunny	-10~0	7	No	**No**
8	Rain	20~30	2	Yes	**Yes**
9	Rain	20~30	6	Yes	**No**
10	Sunny	10~20	6	Yes	**No**
11	Rain	10~20	3	No	**No**
12	Rain	10~20	1	Yes	**No**
13	Sunny	10~20	8	Yes	**No**
14	Sunny	0~10	3	Yes	**Yes**
15	Rain	0~10	2	Yes	**No**

决策树

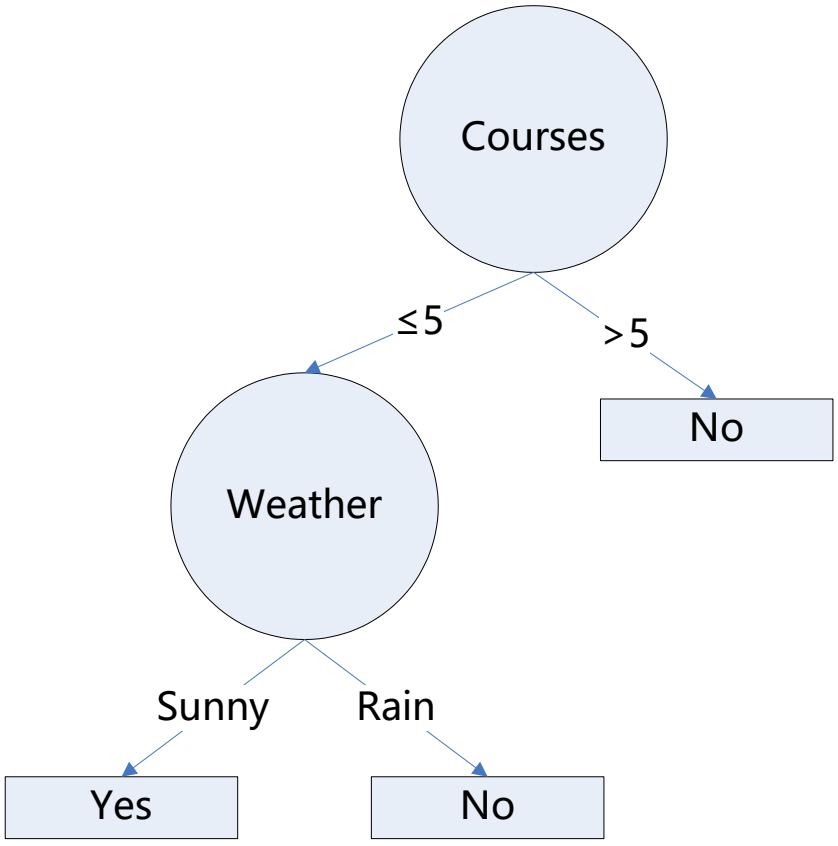


图2.1 打篮球决策树

- 使用15个实例进行有训练，其中Weather、Temperature、Courses和Partner作为输入属性，Play作为输出属性。



以Weather作为根节点

(1) Info(*I*) = - (7/15log$_2$(7/15) - 8/15log$_2$(8/15) = 0.9968

(2) Info(*I*,Weather) = 8/15Info(Sunny) + 7/15Info(Rain) = 0.9118

其中：Info(Sunny) = - (5/8log$_2$ (5/8) + 3/8log$_2$ (3/8)) = 0.9544

Info(Rain) = - (2/7(log$_2$ (2/7) + 5/7log$_2$ (5/7)) = 0.8631

(3) SplitsInfo(Weather) = - (8/15log$_2$ (8/15) + 7/15log$_2$ (7/15)) = 0.9968

(4) Gain(Weather) = Info(*I*) - Info(*I*,Weather) = 0.9968 - 0.9118 = 0.085

(5) GainRatio(Weather) = Gain(Weather) / SplitsInfo(Weather)

= 0.085 / 0.9968 = 0.085

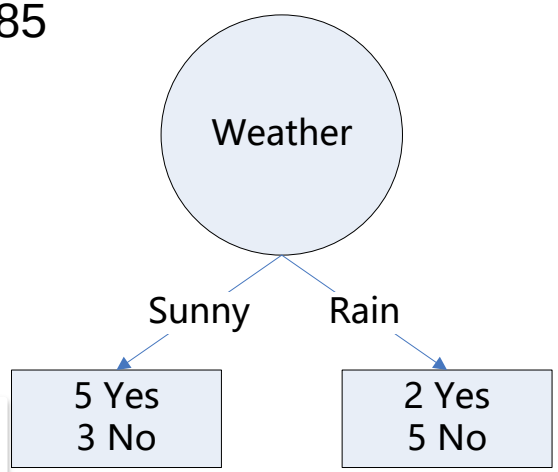


图2.2 Weather作为根节点的局部决策树



二元分裂点（Binary Splits）

- 数值型属性Courses的增益值如何计算呢?
  - C4.5算法对这些数值型数据进行排序，计算每个可能的二元分裂点的增益率值来离散化这个属性值。

1	1	2	2	3	3	4	4	5	5	6	6	7	8	8
Yes	No	Yes	No	No	Yes	Yes	Yes	Yes	Yes	No	No	No	No	No

表2.2 打篮球数据集中数值型属性Courses的排序结果



Courses属性作为根节点

- 计算4个属性的增益率值后，发现Courses属性的 ≤5 和 >5 分裂点处具有最佳增益率值，为0.4457。

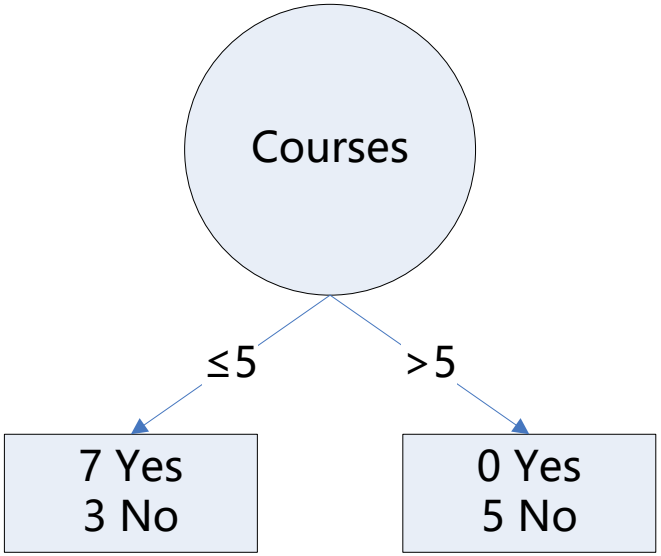


图2.3 Courses作为根节点的局部决策树

完整决策树

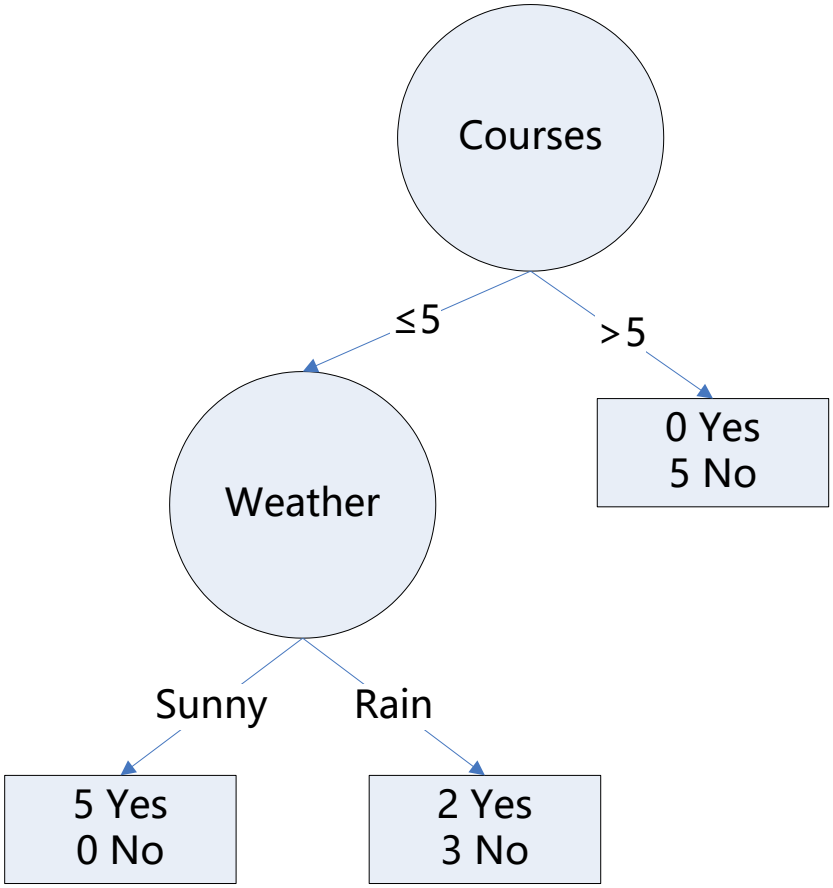


图2.4 *Courses*作为根节点的完整决策树

贝叶斯分类

泰州学院-计算机科学与技术学院

先验概率，后验概率

贝叶斯定理

贝叶斯解释生活案例

朴素贝叶斯分类模型

条件独立



贝叶斯概述

背景

贝叶斯分类基于**贝叶斯定理**，由18世纪概率论和决策论的早起研究者Thomas Bayes发明的，故用其名字命名为贝叶斯定理。

分类算法的比较研究发现，一种称为**朴素贝叶斯分类法**的简单贝叶斯分类法可以与**决策树**和**神经网络分类器**相媲美。用于大型数据库，贝叶斯分类法也已表现出高准确率和高速度。

目前研究较多的贝叶斯分类器主要有四种，分别是：Naive Bayes、TAN、BAN和GBN。



Thomas Bayes

Cancer Example

- ω_1: Cancer; ω_2: Normal
- $P(\omega_1)=0.008$; $P(\omega_2)=0.992$
- Lab Test Outcomes: + vs. –
- $P(+|\omega_1)=0.98$; $P(-|\omega_1)=0.02$
- $P(+|\omega_2)=0.03$; $P(-|\omega_2)=0.97$
- Now someone has a positive test result…
- Is he/she doomed?





So we take this problem to learn bayes' theorem



贝叶斯概述-引言

- **如何判定一个人是好人还是坏人?**

好人
- 总做一些好事?
- 助人为乐……

坏人
- 总做一些坏事?
- 犯罪……

人的主观认识



贝叶斯概述-引言

- 当你无法准确的知悉一个事物的本质时，你可以依靠与事物特定本质相关的事件出现的次数来判断其本质属性的概率。
  - 如果你看到一个人总是做一些好事，那这个人就越可能是一个好人。
- 数学语言表达就是：支持某项事件的属性发生得越多，则该事件成立的可能性就愈大
  - 贝叶斯法则



先验概率和后验概率

先验概率（Prior Probability）是指根据以往经验和分析得到的概率，它往往作为"由因求果"问题中的"**因**"出现的概率。

后验概率（Posterior Probability）是指在得到“结果”的信息后重新修正**因**的概率，是“执**果**寻因”的过程 。

先验概率和后验概率的区别：

事件未发生，求该事件发生的可能性的大小，是**先验概率**。

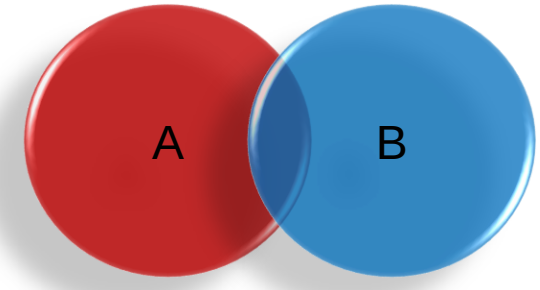
事件已经发生，求该事件发生的原因是由某个因素引起的可能性的大小，是**后验概率**。



贝叶斯定理

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A \cap B) = P(A|B)P(B) = P(B|A)P(A)$$



如果 A 发生，B 发生的概率

A 发生的先验概率

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

由 B 得到 A 的后验概率

B 发生的先验概率



Shooting Example

- **Probability of kill**
  - **P(A): 0.6**
  - **P(B): 0.5**
- **The target is killed with:**
  - **One shoot from A**
  - **One shoot from B**



- **What is the probability that it is shot down by A?**
  - **C: The target is killed.**

$$P(A \mid C) = \frac{P(C \mid A)P(A)}{P(C)} = \frac{1 \times 0.6}{0.6 \times 0.5 + 0.4 \times 0.5 + 0.6 \times 0.5} = \frac{3}{4}$$



Headache & Flu Example

- H = "Having a headache"
- F = "Coming down with flu"
- $P(H) = 1/10$
- $P(F) = 1/40$
- $P(H|F) = 1/2$



- What does this mean?
- One day you wake up with a headache …
- Since 50% flu cases are associated with headaches …
- I must have a 50-50 chance of coming down with flu!

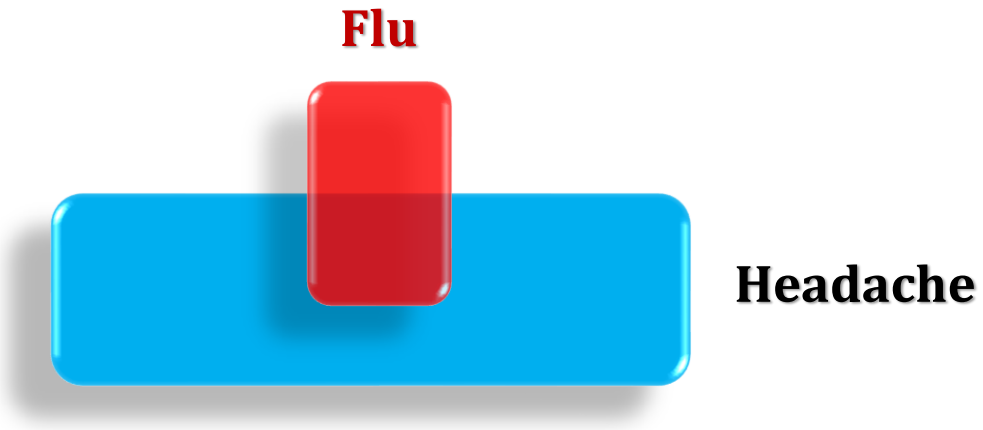




Headache & Flu Example

The truth is …

$$P(F \mid H) = \frac{P(H \mid F)P(F)}{P(H)} = \frac{1/2 \times 1/40}{1/10} = \frac{1}{8}$$





Cancer Example

- ω_1: Cancer; ω_2: Normal
- $P(\omega_1)=0.008$; $P(\omega_2)=0.992$
- Lab Test Outcomes: + vs. –
- $P(+|\omega_1)=0.98$; $P(-|\omega_1)=0.02$
- $P(+|\omega_2)=0.03$; $P(-|\omega_2)=0.97$
- Now someone has a positive test result…
- Is he/she doomed?







Cancer Example

$$P(\omega_1 \mid +) \propto P(+ \mid \omega_1) P(\omega_1) = 0.98 \times 0.008 = 0.0078$$

$$P(\omega_2 \mid +) \propto P(+ \mid \omega_2) P(\omega_2) = 0.03 \times 0.992 = 0.0298$$

$$P(\omega_1 \mid +) < P(\omega_2 \mid +)$$

ω_1: Cancer

ω_2: Normal

$$P(\omega_1 \mid +) = \frac{0.0078}{0.0078 + 0.0298} = 0.21 >> P(\omega_1)$$





贝叶斯分类原理

贝叶斯分类器的分类原理：

通过某对象的先验概率，利用贝叶斯公式计算出其后验概率，即该对象属于某一类的概率，选择具有最大后验概率的类作为该对象所属的类。即，贝叶斯分类器是最小错误率意义上的优化。

根据贝叶斯定理：

$$P(\omega|a_i) = \frac{P(a_i|\omega)P(\omega)}{P(a_i)}$$

由于$P(a_i)$对于所有类为常数，所以只需要$P(a_i|\omega)P(\omega)$最大即可



朴素贝叶斯分类器（Naïve Bayes Classifier）

$$\omega_{MAP} = \arg\max_{\omega_i \in \omega} P(\omega_i \mid a_1, a_2, ..., a_n)$$

$$\omega_{MAP} = \arg\max_{\omega_i \in \omega} \frac{P(a_1, a_2, ..., a_n \mid \omega_i) P(\omega_i)}{P(a_1, a_2, ..., a_n)}$$

$$\omega_{MAP} = \arg\max_{\omega_i \in \omega} P(a_1, a_2, ..., a_n \mid \omega_i) P(\omega_i)$$

联合概率密度函数

Conditionally Independent
条件独立

$$\omega_{MAP} = \arg\max_{\omega_i \in \omega} P(\omega_i) \prod_j P(a_j \mid \omega_i)$$

概率边缘密度函数

MAP: Maximum A Posterior（最大的一个后验概率）



朴素贝叶斯模型（Naïve Bayesian Model）

- **朴素贝叶斯：基于贝叶斯定理与特征条件独立假设的分类方法**
- **朴素贝叶斯模型：统计学分类器（与一般分类器不同）**
  即，选择后验概率最大的类作为所属类

朴素贝叶斯分类器基于一个简单的假设：给定目标值时属性之间相互条件独立



独立（Independence）

$$P(A \cap B) = P(A)P(B|A) \quad + \quad P(B|A) = P(B)$$

$$\Downarrow$$

$$P(A \cap B) = P(A)P(B)$$

Conditionally Independent
条件独立

$$P(X,Y \mid Z) = P(X \mid Z)P(Y \mid Z) \iff P(X \mid Z,Y) = P(X \mid Z)$$

$$P(X|Y,Z) = \frac{P(X|Y,Z)P(Y|Z)}{P(Y|Z)} = \frac{P(X|Y,Z)\frac{P(Y,Z)}{P(Z)}}{P(Y|Z)} = \frac{\frac{P(X,Y,Z)}{P(Z)}}{P(Y|Z)} = \frac{P(X,Y|Z)}{P(Y|Z)} = P(X|Z)$$

$$P(A \cap B) = P(A,B) = P(B)P(A|B) \Leftarrow \text{条件概率公式}$$

条件独立（Conditional Independence）



$$P(Cancer|Male) = 65/100,000$$

$$P(Cancer|Female) = 48/100,000$$



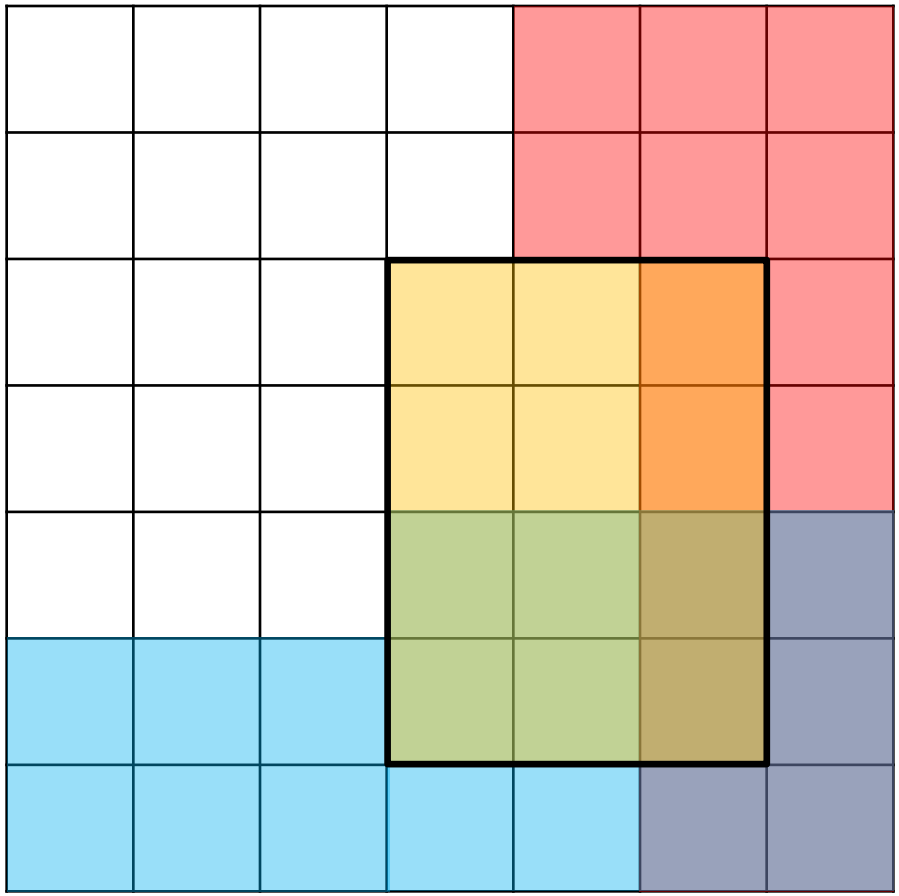
- 这两个事件：男性/女性和癌症独立吗?
- 假设吸烟是导致癌症的唯一因素

Conditionally Independent

条件独立

$$P(Cancer|Male, Smoking) = P(Cancer|Smoking)$$

条件独立（Conditionally Independence）



$$P(R \cap B) = 6/49$$

$$P(R) = 16/49$$

$$P(B) = 18/49$$

$$P(R \cap B) \neq P(R)P(B)$$

Not Independent

$$P(R \cap B|Y) = 1/6$$

$$P(R|Y) = 1/3$$

$$P(B|Y) = 1/2$$

$$P(R \cap B|Y) = P(R|Y)P(B|Y)$$

Conditionally Independent



Tennis Example

Day	Outlook	Temperature	Humidity	Wind	Play Tennis
Day1	Sunny	Hot	High	Weak	*No*
Day2	Sunny	Hot	High	Strong	*No*
Day3	Overcast	Hot	High	Weak	Yes
Day4	Rain	Mild	High	Weak	Yes
Day5	Rain	Cool	Normal	Weak	Yes
Day6	Rain	Cool	Normal	Strong	*No*
Day7	Overcast	Cool	Normal	Strong	Yes
Day8	Sunny	Mild	High	Weak	*No*
Day9	Sunny	Cool	Normal	Weak	Yes
Day10	Rain	Mild	Normal	Weak	Yes
Day11	Sunny	Mild	Normal	Strong	Yes
Day12	Overcast	Mild	High	Strong	Yes
Day13	Overcast	Hot	Normal	Weak	Yes
Day14	Rain	Mild	High	Strong	*No*

Given :

$< \text{Outlook} = \textit{sunny}, \text{Temperature} = \textit{cool}, \text{Humidity} = \textit{high}, \text{Wind} = \textit{strong} >$

Predict :

$\textit{PlayTennis}\,(\textit{yes or no})$



Tennis Example

Given :

$< \text{Outlook} = sunny, \text{Temperature} = cool, \text{Humidity} = high, \text{Wind} = strong >$

Predict :

$PlayTennis\,(yes\ or\ no)$

Bayes Solution:

$P(PlayTennis = yes) = 9/14$

$P(PlayTennis = no) = 5/14$

$P(Wind = strong \mid PlayTennis = yes) = 3/9$

$P(Wind = strong \mid PlayTennis = no) = 3/5$

...

$P(yes)P(sunny \mid yes)P(cool \mid yes)P(high \mid yes)P(strong \mid yes) = 0.0053$

$P(no)P(sunny \mid no)P(cool \mid no)P(high \mid no)P(strong \mid no) = 0.0206$

The conclusion is not to play tennis with probability : $\dfrac{0.0206}{0.0206 + 0.0053} = 0.795$



Estimating $\mathbf{P(\alpha_j|\omega_i)}$

α_1	α_2	α_3	ω
	+		ω_1
			ω_2
	-		ω_1
	+		ω_1
			ω_2

$$P(\omega_1)=3/5; \qquad P(\omega_2)=2/5$$

$$P(a_2='+'|\omega_1)=2/3$$

$$P(a_2='-'|\omega_1)=1/3$$

Laplace Smoothing
拉普拉斯平滑

$$P(a_{jk}\mid\omega_i)=\frac{|a_j=a_{jk}\wedge\omega=\omega_i|+1}{|\omega=\omega_i|+|a_j|}$$

属性取值的个数

How about continuous variables?



Independent ≠ Uncorrelated

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} = \frac{E\big((X-\mu_X)(Y-\mu_Y)\big)}{\sigma_X \sigma_Y}$$

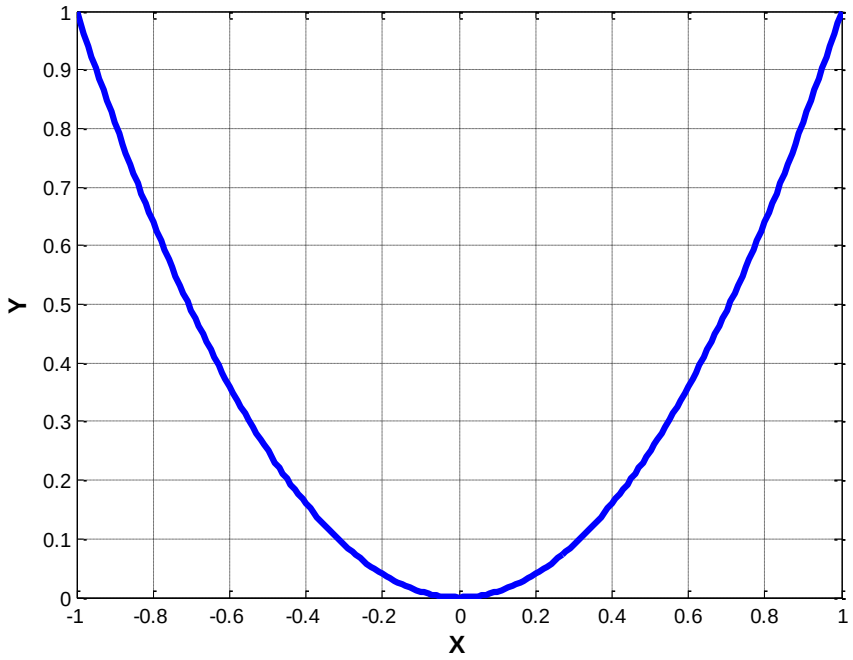
$$X \in [-1,\ 1]$$

$$Y = X^2$$

Cov (X,Y)=0 ➔ X and Y are uncorrelated.

However, Y is completely determined by X.

X	Y
1	1
0.5	0.25
0.2	0.04
0	0
-0.2	0.04
-0.5	0.25
-1	1

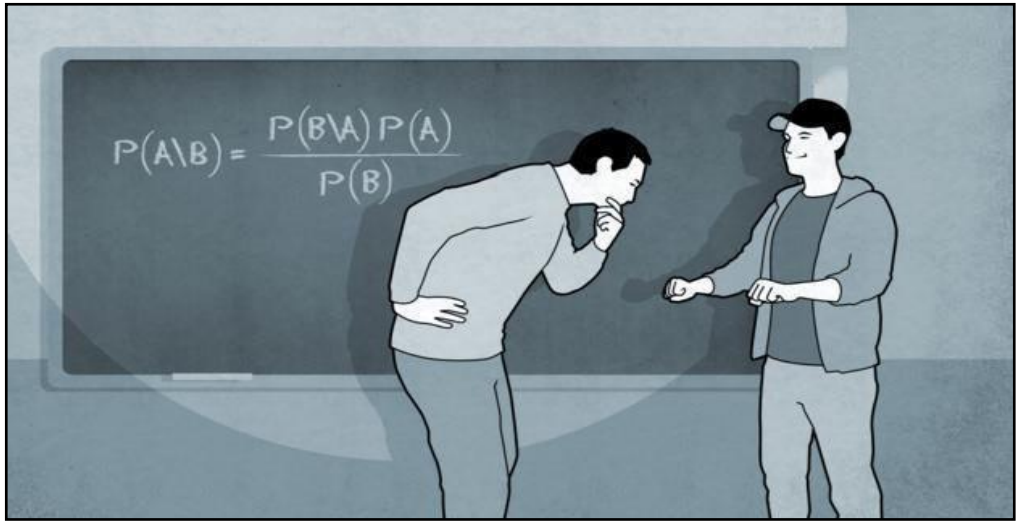




贝叶斯理论总结

贝叶斯定理（Bayes' theorem）是概率论中的一个结果，它联随机变量的条件概率以及边缘概率分布有关。在有些关于概率的解说中，贝叶斯定理能够告知我们如何利用新证据修改已有的看法。

通常，事件A在事件B（发生）的条件下的概率，与事件B在事件A的条件下的概率是不一样的；然而，这两者是有确定的关系，贝叶斯定理就是这种关系的陈述。





贝叶斯分析（Bayesian Analysis）

- 一种参数估计方法。
- 将关于未知参数的先验信息与样本信息相结合，根据贝叶斯公式，得出后验信息，然后根据后验信息去推断未知参数。
- 在决策支持、风险评估、模式识别等方面都得到了很广泛的应用，被用来建立分类模型，就是著名的贝叶斯分类器（式7.13）
- **贝叶斯分类器（Bayes Classifier）**
  - 一种简单、功能强大的有指导分类技术。
  - 假定所有输入属性的重要性相等，且彼此是独立的。

$$P(A|B)=\frac{P(B|A)P(A)}{P(B)}$$

(式7.13)

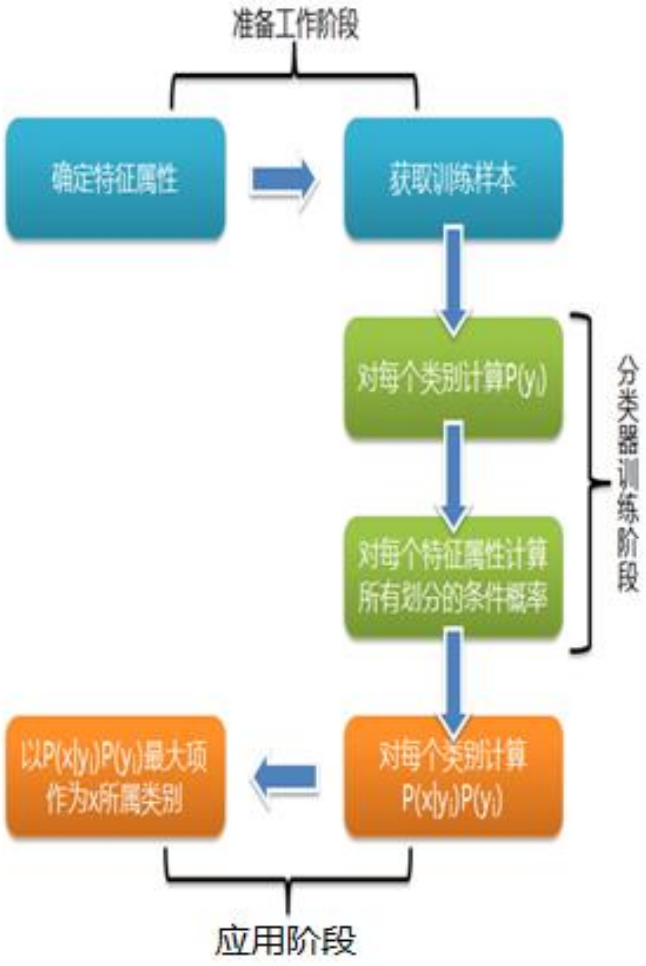


贝叶斯分析

$$P(A|B)=\frac{P(B|A)P(A)}{P(B)}$$

- **其中：**
  - ***A*** **为要检验的假设，*B* 为与假设相关的数据样本。**
- **从分类的角度考察——**
  - **假设 *A* 就是因变量，代表着预测类；**
  - **数据样本 *B* 是输入实例属性值的集合；**
  - ***P*（*B*|*A*）是给定输入实例属性值 *B* 时，假设 *A* 为真的条件概率；**
  - **P（*A*）为先验概率（*Priori Probability*），表示在任何输入属性值*B*出现之前假设的概率。**
  - **条件概率和先验概率可以通过训练数据计算出来。**

贝叶斯分类的流程



准备工作阶段：为贝叶斯分类做准备，根据具体情况确定特征属性，对每个特征属性进行划分，由人工对一部分待分类项进行分类，形成训练样本集合。输入是所有待分类数据，输出是特征属性和训练样本。分类器的质量很大程度由特征属性、特征属性划分及训练样本质量决定。

分类器训练阶段：生成分类器，计算每个类别在训练样本中的出现频率及每个特征属性划分对每个类别的条件概率估计，并将结果记录。通过特征属性和训练样本，生成分类器。

应用阶段：使用分类器对待分类项进行分类，输入是待分类项，输出是分类项与类别的映射关系。



朴素贝叶斯模型应用（Naïve Bayesian Model）

- 朴素贝叶斯模型（Naive Bayesian Model，NBM）一般用于**文本挖掘**。

原因：文本挖掘符合贝叶斯概率原理，因为我们把一个词组看作一个单独的模式，例如英文文本处理一些长度不等的单词，也都作为单独独立的模式进行处理，这是自然语言与其他分类识别问题的不同点。
实际计算先验概率时候，因为这些模式都是作为概率被程序计算，而不是自然语言被人来理解，所以结果是一样的。



本讲作业

1. 数据分类的定义。
2. 信息熵的定义和公式并描述公式。
3. 简述 ID3算法和 C4.5算法的基本思想。并阐述 ID3算法的优缺点。
4. C4.5算法基于 ID3算法做了哪些改进？
5. 解释贝叶斯定理。
6. 阐述朴素贝叶斯分类的优缺点。朴素贝叶斯一般分为哪几个阶段？贝叶斯分析三要素是哪些并解释其三要素？
7. 简述什么是“条件独立”？

本次作业请于*10月25日*上课前提交