填空

分类

1.分类是一种有监督学习。

2.分类过程:获取数据、预处理、分类器设计、分类决策。

3.决策树－采用自顶向下的递归方式产生一个类似于流程图的树结构。

4.决策树归纳的基本算法是贪心算法。

5.决策树的构造可分为:特征选择、决策树的生成，决策树的剪枝。

6.信息熵－信息变化的评论信息量。在信息论中，信息熵就是信息的不确定程度的量度。　单位：比特

7.朴素贝叶斯模型一般用于文本挖掘，文本挖掘跟文本检索不一样。

8.贝叶斯分类流程:准备工作阶段、分类器训练阶段、应用阶段。

9.分类算法的评价标准：accuracy(正确率)、error rate(错误率)、sensitive(灵敏度)、specificity(特效度)、precision(精度)、recall(召回率)[和灵敏度一样]。

10.常见的分类方法：决策树分类、基于规则分类、最邻近分类 KNN、朴素贝叶斯分类、人工神经网络 ANN、支持向量机 SVM。

11.基于规则的分类器（分类方法之一）的两条规则：

互斥规则：规则集中不存在两条规则被同一条记录触发。简单说就是保证同一条记录不会同时属于两个类别。

穷举规则：对于属性值的任一组合，R 中都存在一条规则加以覆盖。即每一条记录都保证能以其中一种规则加以分类。

聚类

1.聚类是一种无监督学习。

2.常用来度量数据对象间相似性的统计量有距离函数和相似系数。

3.在聚类分析中，样本之间的相似性通常采用样本之间的距离来表示。

4. 分类与聚类的最大区别在于，分类数据中的一部分的类别是已知的，而聚类数据的类别未知。

5.聚类是将物理或抽象对象的集合分成相似的对象类或簇的过程，同一个簇内的数据对象之间具有较高的相似性，不同簇内的数据对象之间相差则较大。

6. 基于划分方法的聚类分析方法（划分构建数据集的 K 个划分，每个划分表示一个簇。单级聚类）：K 均值、K 中心点、CLARANS。（只能发现球形或圆形的簇。）

基于密度的聚类分析方法（基于邻近区域的密度）：DBSCAN。（可以发现任意形状的簇）

层次方法（多级聚类，将数据集分解为多级进行聚类，可用树形图表示）：DIANA,AGNES。

7.K-mean 算法对噪声和离群点数据敏感。决策树算法对于噪声的干扰不敏感。

8.簇内的相似性越大，簇间差别就越大，聚类就越好。

9. 在基本 K 均值算法里，当邻近度函数采用曼哈顿距离的时候，合适的质心是簇中各点的中位数。

关联规则

1.频繁项集的支持度必须大于支持度阈值。

2.关联规则：一、找出所有的频繁项集（关键）。二、使用频繁项集产生关联规则。（可能填空）

3.Apriori 算法：频繁项集的子集必须频繁，非频繁项集的超集一定是非频繁的。（可能填空）

4.Apriori 算法核心：找出所有频繁项集。

5.一个强规则并不代表它有意义。

6.子序列：对于序列 t 和序列 s，如果 t 中每个有序元素都是 s 中的一个有序元素的子集，那么 t 是 s 的子序列。

7. 支持度：衡量在数据集中规则出现的频率。

置信度：衡量规则的强度。

8. 关联规则挖掘问题可以划分成两个子问题：发现频繁项目集和生成关联规则。（可能填空）

绪论

1.产生“数据丰富而信息贫乏”现象。（可能填空）

2.数据、信息和知识都是广义数据表现的不同形式。（可能填空）

3.一个数据挖掘是一个迭代的过程。

4.机器学习是人工智能的核心，是使计算机具有智能的根本途径，其应用遍及人工智能的各个领域，它主要使用归纳、综合而不是演绎。

5. 数据挖掘，是从大量的、有噪声的、不完全的、模糊和随机的数据中，提取出隐含在其中的、人们事先不知道的、具有潜在利用价值的

信息和知识的过程。

6.孤立点：指不符合数据的一般模型的数据。在挖掘正常类知识时，通常总是把它们作为噪声来处理。

7.大数据的特征（4V）：Volume 数据量大、Variety 类型多样、Value 价值大、Velocity 高速。（可能填空）

8.KDD：数据挖掘与知识发现。

9. 数据挖掘从本质上说是一种新的商业信息处理技术。（可能填空）

10. KDD 在人工智能界更流行，而 Data Mining 在数据库界使用更多。KDD 比数据挖掘出现的更早。（可能填空）

11. 有两个基本的方法来挖掘类知识：分类、聚类。（可能填空）

数据

1. 属性类型：标称型、二元或多元型、序数型、区间标度型、比率标度型、离散型和连续型。
2. 数据集类型：记录数据、基于图形或者网络的数据、有序数据。
3. 噪声数据: 数据中存在着错误或异常(偏离期望值)的数据，这些数据对数据的分析造成了干扰。
4. 如何处理噪声数据:回归和聚类,结合计算机和人工检查。
5. 数据预处理的主要任务:数据清理(处理缺失值、平滑噪声数据、识别分析孤立点或删除离群点，并解决不一致问题)。数据集成（核心任务：将互相关联的分布式异构数据源集成到一起，使用户能够以透明的方式访问这些数据源）。数据约简（降维、数据压缩、特征选择、特征提取）。数据转换（规范化）和数据离散化（正

常化、标准化、离散化操作、生成概念层次结构-聚集）

6. 通过相关性分析和协方差分析可以检测到冗余的属性。
7. 等频、等宽离散化是无监督离散化方法。
8. 对特征进行一定的加工：降维包括特征选择（互信息、MRMR、TF-IDF），特征提取（PCA,LDA）。
9. 特征选择：从原始特征中挑出一些最具代表性、分类性能好的特征以达到降低特征空间维数的方法。

   特征提取：是通过映射的方法，将高维的特征向量变换为低维特征变量。
10. 特征选择后的特征是原特征的一个子集。特征提取后的新特征是原来特征的一个映射。
11. 特征选择的方法：过滤法（方差选择、相关系数、卡方检验，互信息、relief 法）、包裹法（递归特征消除、特征干扰）、嵌入法。

    特征提取的方法：灰度特征提取、纹理特征提取、形状特征提取。
12. 降维技术：小波变换、主成分分析、监督和非线性技术（特征选择、特征提取。）
13. 将数据映射到一个新的空间：傅里叶变换、小波变换。
14. 主成分分析（PCA）：是一种统计方法。通过正交变换将一组可能存在相关性的变量转换为一组线性不相关的变量，转换后的这组变量叫主成分。
15. 线性判别分析（LDA）：尽可能保留类的区分信息的同时进行降维操作。将样本投影到一条直线上。

16.噪声数据：数据中存在着错误或异常(偏离期望值)的数据，这些数据对数据的分析造成了干扰。

17.数据清洗是指去除或修补源数据中的不完整、不一致、含噪音的数据。（可能填空）

简答

1、分类的评价准则

分类模型总体判断的准确性：

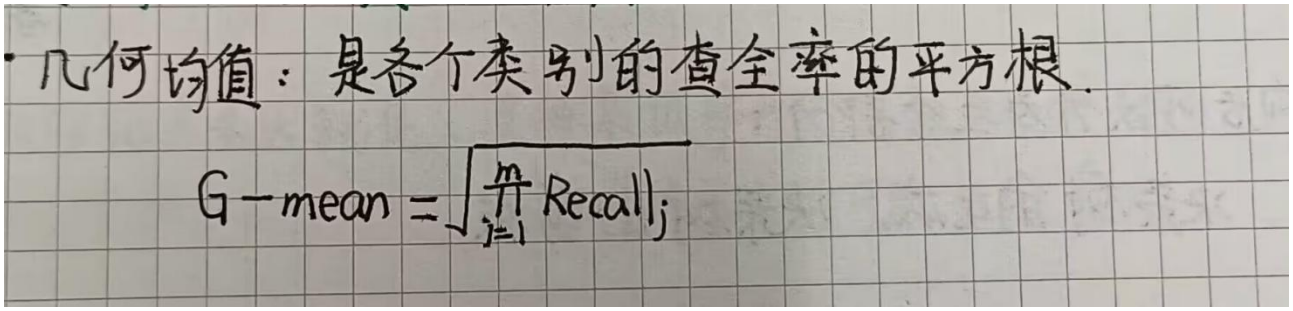
Accuaracy=(TP+TN)/TP+TN+FP+FN

查全率：表示在本类样本中被正确分类的样本所占比

Sensitivity=Recall=TP/(TP+FN)[正确分类为正类在真实为正类的占比]

查准率：表示被分类为该类的样本中，真正属于该类的所占的比例

Precision=TP/(TP+FP) Negative Prediction=TN/(TN+FN)



2、关联规则步骤：找出所有频繁项集；使用频繁项集产生关联规则

3、Apriori 算法的关键思想：频繁项集的子集必须频繁；任何不频繁的超集都不能频繁

Apriori 算法的核心：生成所有频繁项集

4、Apriori 算法的缺点：多次扫描数据库，需要很大的 IO 负载；可能产生庞大的候选集

5、数据挖掘的过程：业务理解->数据理解->数据准备->数据建模->模型评估->部署阶段

6、数据预处理的主要任务：数据清理、数据集成、数据规范化、数据约简、数据离散化

共同点：1. 均可以对数据进行降维；

2. 都属于特征提取；

3. 在降维时均使用了矩阵特征分解的思想；

4. 都假设数据符合高斯分布。

异同点：PCA 基于统计学，LDA 基于机器学习。

PCA 不考虑数据的类别信息（无监督降维分析），LDA 考虑数据的类别信息（有监督降维分析）。

PCA 选择数据最大方差的方向，LDA 选择分类性能最好的投影方向。

7、ID3 的优缺点：

优点：ID3 算法建树过程简单易懂。

缺点：ID3 算法存在多值偏向问题、属性间的关联性不强、对噪声数据很敏感、结果会随着训练集规模的不同而不同。

8、C4.5 算法基于 ID3 算法改进的部分

改进 1：用信息增益率代替信息增益来选择属性

改进 2：能够完成对连续值属性的离散化处理

改进 3：能处理属性值缺失的情况

改进 4：在决策树构造完成之后进行剪枝

9、聚类分析对算法的基本要求

可伸缩性

处理不同类型属性的能力

发现任意形状聚类的能力

减小对先验知识和用户自定义参数的依赖性

处理噪声或离群点数据的能力

对数据输入顺序不敏感

具有处理高维度数据的能力

可解释性和实用性

10、K-means 算法的优缺点

优点：可扩展性较好，简单，适用于规则的不相交簇

算法收敛速度较快

算法复杂度为 O(nkt)

缺点：簇数目 k 需要事先给定，但非常难以选定；

初始聚类中心的选择对聚类结果有较大的影响（会出现局部最优）；

不适合于发现非球状簇；

对噪声和离群点数据敏感。

10、分类和聚类的相同点和不同点

相同点：聚类可看作一种特殊的分类，它用由数据导出的类（簇）标号创建对象的标记。

不同点：分类是有监督学习，称为监督分类。聚类是无监督学习，称聚类分析为非监督分类。分类依赖于已知类别的数据对象，类是预先定义的，类别数已知。聚类要划分的类、类别个数都是未知的。

11、数据挖掘、分类、聚类、关联规则、频繁项集定义

数据挖掘：是从大量的、有噪声的、不完全的、模糊和随机的数据中，提取出隐含在其中的、人们事先不知道的、具有潜在利用价值的信息和知识的过程。

分类：分类是指把数据样本映射到一个事先定义的类中的学习过程。

聚类：聚类是将物理或抽象对象的集合分成相似的对象类或簇的过程。

关联规则：事务数据中支持度大于最小支持度阈值且置信度大于最小置信度阈值的所有规则。

频繁项集：事务数据中支持度大于最小支持度阈值的所有项集。

计算题

1、二值离散型属性的相似性计算方法

已知条件如下两个样本 P=[1 0 0 0 0 0 0 0 0 0]

Q=[0 0 0 0 0 0 1 0 0 1]

a=0 (P=1,Q=1)

b=1 (P=1,Q=0)

C=2 (P=0,Q=1)

D=7 (P=0,Q=0)

解：SMC=(b+c)/(a+b+c+d)=0.3

JC=(b+c)/(a+b+c)=1

简答

1.分类和聚类的相同点和不同点：

相同点：聚类可看作一种特殊的分类，它用由数据导出的类（簇）标号创建对象的标记。

不同点：

分类是有监督学习，称为监督分类。

聚类是无监督学习，称聚类分析为非监督分类。

分类依赖于已知类别的数据对象，类是预先定义的，类别数已知。

聚类要划分的类、类别个数都是未知的。

2.Apriori 算法的不足之处：

多次扫描事务数据库，需要很大的 I/O 负载

可能产生庞大的候选集

3.Apriori 算法的核心和思想：

核心：生成所有的频繁项集。

思想：1.频繁项集的子集必须频繁

2.任何不频繁项集的超集都不能频繁

4.根据分类方法聚类可为哪两个类型，分别举出算法事例

基于划分：K-means，K-medoids，CLARANS

基于层次：自顶而下法，自底向上法

5.如果样本的属性都是对称的二值离散型属性,则样本间的距离可用简单匹配系数(Simple Matching Coefficients, SMC)计算：

SMC = (b + c) / (a + b + c + d)

其中：对称的二值离散型属性是指属性取值为 1 或者 0 同等重要。

6.如果样本的属性都是不对称的二值离散型属性， 则样本间的距离可用 Jaccard 系数计算(Jaccard Coefficients, JC)：

JC = (b + c) / (a + b + c)

其中：不对称的二值离散型属性是指属性取值为 1 或者 0 不是同等重要。

大题

1.

TID	项集
1	A,C,D
2	B,E,A
3	A,D,F
4	B,E,F
5	C,F,D
6	A,D,B,E
7	B,E,D
8	C,D
9	A,D,B,E
10	C,F

设最小支持度为 3，根据 Apriori 算法计算右边购物蓝中 C3 和 L3 的数量分别是多少（ ）

A. 2,4　　B. 3,1　　C. 3,2　　D. 4,2

2.

序号	帅气	性格	身高	上进心	嫁与不嫁
1	帅	不好	矮	不上进	不嫁
2	不帅	好	矮	上进	不嫁
3	帅	好	矮	上进	嫁
4	不帅	好	高	上进	嫁
5	帅	不好	矮	上进	不嫁
6	不帅	不好	矮	不上进	不嫁
7	帅	好	高	不上进	嫁
8	不帅	好	高	上进	嫁
9	帅	好	高	上进	嫁
10	不帅	不好	高	上进	嫁
11	帅	好	矮	不上进	不嫁
12	帅	好	矮	不上进	不嫁

分别用决策树算法 C4.5 和朴素贝叶斯算法

求解 Instance13（帅，不好，高，上进）样本的类别属性

决策树 C4.5

信息熵：-6/12（嫁）*$\log_2$6/12-6/12（不嫁）*$\log_2$6/12=1

条件熵：（帅，不好，高，上进）

=7/12(帅)[-4/7*$\log_2$4/7-3/7*$\log_2$3/7]
+5/12(不帅)[-2/5*$\log_2$2/5-3/5*$\log_2$3/5]
=0.29
1-0.29=0.71

=4/12(不好)[-3/4*$\log_2$3/4-1/4*$\log_2$1/4]
+8/12(好)[-3/8*$\log_2$3/8-5/8*$\log_2$5/8]
=0.27
1-0.27=0.73

=5/12(高)[-1*$\log_2$1]
+7/12(矮)[-6/7*$\log_2$6/7-1/7*$\log_2$1/7]
=0.1
1-0.1=0.9

=7/12(上进)[-2/7*$\log_2$2/7-5/7*$\log_2$5/7]
+5/12(不上进）[-4/5*$\log_2$4/5-1/5*$\log_2$1/5]
=0.24
1-0.24=0.76

朴素贝叶斯：

P(嫁|帅，不好，高，上进)
=P(帅，不好，高，上进|嫁)*P(嫁)/P(帅，不好，高，上进)
P(不嫁|帅，不好，高，上进)
=P(帅，不好，高，上进|不嫁)*P(不嫁)/P(帅，不好，高，上进)
所以比较：（其余相等）
P(帅，不好，高，上进|嫁)
=P(帅|嫁)*P(不好|嫁)*P(高|嫁)*P(上进|嫁)
P(帅，不好，高，上进|不嫁)
=P(帅|不嫁)*P(不好|不嫁)*P(高|不嫁)*P(上进|不嫁)

序号	帅气	性格	身高	上进心	嫁与不嫁
3	帅	好	矮	上进	嫁
4	不帅	好	高	上进	嫁
7	帅	好	高	不上进	嫁
8	不帅	好	高	上进	嫁
9	帅	好	高	上进	嫁
10	不帅	不好	高	上进	嫁

P(帅|嫁)*P(不好|嫁)*P(高|嫁)*P(上进|嫁)

=1/2*1/6*5/6*5/6

=25/432

序号	帅气	性格	身高	上进心	嫁与不嫁
1	帅	不好	矮	不上进	不嫁
2	不帅	好	矮	上进	不嫁
5	帅	不好	矮	上进	不嫁
6	不帅	不好	矮	不上进	不嫁
11	帅	好	矮	不上进	不嫁
12	帅	好	矮	不上进	不嫁

P(帅|不嫁)*P(不好|不嫁)*P(高|不嫁)*P(上进|不嫁)

=2/3*1/2*0*1/3

=0

选择

1.(D)的目的缩小数据的取值范围，使其更适合于数据挖掘算法的需要，并且能够得到和原始数据相同的分析结果。

A.数据清洗　　B.数据集成

C.数据变换　　D.数据归约

2. 某超市研究销售纪录数据后发现，买 C 的人很大概率也会购买 D，这种属于数据挖掘的哪类问题？(A)

A. 关联规则发现　　B. 聚类

C. 分类　　D. 自然语言处理

3. 以下两种描述分别对应哪两种对分类算法的评价标准？ (A)

(a)警察抓小偷，描述警察抓的人中有多少个是小偷的标准。

(b)描述有多少比例的小偷给警察抓了的标准。

A. Precision,Recall　　B. Recall,Precision

C. Precision,ROC　　D. Recall,ROC

4. 将原始数据进行集成、变换、维度规约、数值规约是在以下哪个步骤的任务？(C)

A. 频繁模式挖掘　　B. 分类和预测　　C. 数据预处理　　D. 数据流挖掘

5. 当不知道数据所带标签时，可以使用哪种技术促使带同类标签的数据与带其他标签的数据相分离？(B)

A. 分类　　B. 聚类　　C. 关联分析　　D. 隐马尔可夫链

6. 建立一个模型，通过这个模型根据已知的变量值来预测其他某个变量值属于数据挖掘的哪一类任务？(C　)

A. 根据内容检索　　B. 建模描述　　C. 预测建模　　D. 寻找模式和规则

7. 下面哪种不属于数据预处理的方法？（　D)

A.变量代换　　B.离散化　　C.聚集　　D.估计遗漏值

8. 假设 12 个销售价格记录组已经排序如下：5, 10, 11, 13, 15, 35, 50, 55, 72, 92, 204, 215 使用如下每种方法将它们划分成四个箱。等频（等深）划分时，15 在第几个箱子内？ (B　)

A.第一个　　B.第二个　　C.第三个　　D.第四个

9. 下面哪个不属于数据的属性类型：（　D)

A.标称　　B.序数　　C.区间　　D.相异

10. 只有非零值才重要的二元属性被称作：(C)

A.计数属性　　B.离散属性　　C.非对称的二元属性　　D.对称属性

11. 以下哪种方法不属于特征选择的标准方法：(D　)

A.嵌入　　B.过滤　　C.包装　　D.抽样

12. 下面不属于创建新属性的相关方法的是：　(B)

A.特征提取　　B.特征修改　　C.映射数据到新的空间　　D.特征构造

13. 下面哪个属于映射数据到新的空间的方法？（　A)

A.傅立叶变换　　B.特征加权　　C.渐进抽样　　D.维归约

14. 假设属性 income 的最大最小值分别是 12000 元和 98000 元。利用最大最小规范化的方法将属性的值映射到 0 至 1 的范围内。对属性 income 的 73600 元将被转化为：(D　)

A.0.821　　B.1.224　　C.1.458　　D.0.716

15. 一所大学内的各年级人数分别为：一年级 200 人，二年级 160 人，三年级 130 人，四年级 110 人。则年级属性的众数是：(A)

A.一年级　　B.二年级　　C.三年级　　D.四年级

16. 下列哪个不是专门用于可视化时间空间数据的技术：　(B　)

A.等高线图　　B.饼图　　C.曲面图　　D.矢量场图

17. 在抽样方法中，当合适的样本容量很难确定时，可以使用的抽样方法是：(B)

A.有放回的简单随机抽样　　B.无放回的简单随机抽样

C.分层抽样　　D 渐进抽样

18. 设 X={1，2，3}是频繁项集，则可由 X 产生(　C)个关联规则。

A.4　　B.5　　C.6　　D.7

19. 考虑下面的频繁 3- 项集的集合：{1,2,3},{1,2,4},{1,2,5},{1,3,4},{1,3,5},{1,4,5},{2,3,4},{2,3,5},{3,4,5}假定数据集中只有 5 个项,采用合并策略,由候选产生过程得到频繁 4-项集不包含（C　）

A.1,2,3,4　　B.1,2,3,5　　C.1,2,4,5　　D.1,3,4,5

20. 下面选项中 t 不是 s 的子序列的是　(　C)

A.s=<{2,4},{3,5,6},{8}> t=<{2},{3,6},{8}>　　B.s=<{2,4},{3,5,6},{8}> t=<{2},{8}>

C.s=<{1,2},{3,4}> t=<{1},{2}>　　D.s=<{2,4},{2,4}> t=<{2},{4}>

21. 在图集合中发现一组公共子结构,这样的任务称为（ B）
A.频繁子集挖掘 B.频繁子图挖掘 C.频繁数据项挖掘 D.频繁模式挖掘
22. 下列度量不具有反演性的是（D ）
A.系数 B.几率 C.Cohen 度量 D.兴趣因子
23. 下列（A)不是将主观信息加入到模式发现任务中的方法。
A.与同一时期其他数据对比 B.可视化
C.基于模板的方法 D.主观兴趣度量
24. 设最小支持度为 3，根据 Apriori 算法计算右边购物蓝中 C3 和 L3 的数量分别是多少（ D ）

TID	项集
1	A,C,D
2	B,E,A
3	A,D,F
4	B,E,F
5	C,F,D
6	A,D,B,E
7	B,E,D
8	C,D
9	A,D,B,E
10	C,F

A.2,4 B.3,1 C.3,2 D.4,2
25. 以下哪些算法是分类算法 （ B ）
A.DBSCAN B.C4.5 C.K-Mean D.EM
26. 以下哪些分类方法可以较好地避免样本的不平衡问题（ A ）
A.KNN B.SVM C.Bayes D.神经网络
27. 决策树中不包含一下哪种结点（C)
A.根结点（root node) B.内部结点（internal node）
C.外部结点（external node） D.叶结点（leaf node）
28. 以下哪项关于决策树的说法是错误的（C)
A. 冗余属性不会对决策树的准确率造成不利的影响 B. 子树可能在决策树中重复多次
C. 决策树算法对于噪声的干扰非常敏感 D. 寻找最佳决策树是 NP 完全问题
29. 以下哪些算法是基于规则的分类器（A)
A. C4.5 B. KNN C. Naive Bayes D. ANN
30. 可用作数据挖掘分析中的关联规则算法有（ C ）。
A. 决策树、对数回归、关联模式 B. K 均值法、SOM 神经网络
C. Apriori 算法、FP-Tree 算法 D. RBF 神经网络、K 均值法、决策树
31. 用于分类与回归应用的主要算法有:（D)
A.Apriori 算法、HotSpot 算法 B.RBF 神经网络、K 均值法、决策树

C.K 均值法、SOM 神经网络　　D.决策树、BP 神经网络、贝叶斯

32. 考虑两队之间的足球比赛：队 0 和队 1。假设 65%的比赛队 0 胜出,剩余的比赛队 1 获胜。队 0 获胜的比赛中只有 30%是在队 1 的主场,而队 1 取胜的比赛中 75%是主场获胜。如果下一场比赛在队 1 的主场进行队 1 获胜的概率为（D　）

A.0.75　　B.0.35　　C.0.4678　　D.0.5738

33. 以下关于人工神经网络（ANN）的描述错误的有（A　）

A.神经网络对训练数据中的噪声非常鲁棒　　B.可以处理冗余特征

C.训练 ANN 是一个很耗时的过程　　D.至少含有一个隐藏层的多层神经网络

判断

1. 分类是预测数据对象的离散类别，预测是用于数据对象的连续取值。（ T ）
2. 时序预测回归预测一样，也是用已知的数据预测未来的值，但这些数据的区别是变量所处时间的不同。（ F ）
3. 数据挖掘的主要任务是从数据中发现潜在的规则，从而能更好的完成描述数据、预测数据等任务。（T　）
4. 对遗漏数据的处理方法主要有：忽略该条记录；手工填补遗漏值；利用默认值填补遗漏值；利用均值填补遗漏值；利用同类别均值填补遗漏值；利用最可能的值填充遗漏值。（ T ）
5. 神经网络对噪音数据具有高承受能力，并能对未经过训练的数据具有分类能力，但其需要很长的训练时间，因而对于有足够长训练时间的应用更合适。（T ）
6. 数据分类由两步过程组成：第一步，建立一个聚类模型，描述指定的数据类集或概念集；第二步，使用模型进行分类。（ F ）
7. 聚类是指将物理或抽象对象的集合分组成为由类似的对象组成的多个类的过程。（T ）
8. 决策树方法通常用于关联规则挖掘。（ F ）
9. 置信度是对关联规则的准确度的衡量。（ F）
9. 数据规范化指将数据按比例缩放(如更换大单位)，使之落入一个特定的区域（如 0-1）以提高数据挖掘效率的方法。规范化的常用方法有：最大-最小规范化、分数规范化、小数定标规范化。（T　）
10. 模型的具体化就是预测公式，公式可以产生与观察值有相似结构的输出，这就是预测值。（ T ）
11. 数据取样时，除了要求抽样时严把质量关外，还要求抽样数据必须在足够范围内有代表性。（ T ）
12. 分类规则的挖掘方法通常有：决策树法、贝叶斯法、人工神经网络法、粗糙集法和遗传算法。（ T ）
13. 大数据的 4V 特点是 Volume、Velocity、Variety、Veracity。（ T）
14. 孤立点在数据挖掘时总是被视为异常、无用数据而丢弃。（ F ）
15. Apriori 算法是一种典型的关联规则挖掘算法。（ T ）
16. 用于分类的离散化方法之间的根本区别在于是否使用类信息。（ T ）
17. 特征提取技术并不依赖于特定的领域。（F　）
18. 文本挖掘又称信息检索，是从大量文本数据中提取以前未知的、有用的、可理解的、可操作的知识的过程。（F ）
19. 定量属性可以是整数值或者是连续值。（T ）
20. 关联规则挖掘过程是发现满足最小支持度的所有项集代表的规则。（ F）

21. 利用先验原理可以帮助减少频繁项集产生时需要探查的候选项个数。（ T ）
22. 先验原理可以表述为：如果一个项集是频繁的，那包含它的所有项集也是频繁的。（F ）
23. 回归分析通常用于挖掘关联规则。（ F ）
24. 具有较高的支持度的项集具有较高的置信度。（ F）
25. 维归约可以去掉不重要的属性，减少数据立方体的维数，从而减少数据挖掘处理
的数据量，提高挖掘效率。（T ）
26. 聚类是这样的过程：它找出描述并区分数据类或概念的模型(或函数)，以便能够
使用模型预测类标记未知的对象类。（ F ）
27. Bayes 法是一种在已知后验概率与类条件概率的情况下的模式分类方法，待分样本
的分类结果取决于各类域中样本的全体。（ F）
28. 在决策树中，随着树中结点数变得太大，即使模型的训练误差还在继续减低，但
是检验误差开始增大，这是出现了模型拟合不足的问题。（F ）
29. 在聚类分析中，簇内相似性越大，簇间差别越大，聚类的效果就越差。（ F ）
30. 聚类分析可以看作是一种非监督的分类。（ T ）
31. K 均值是产生划分聚类基于密度的聚类算法，簇的个数由算法自动地确定。（F ）
32. 如果一个对象不强属于任何簇，那么该对象是基于聚类的离群点。（T ）