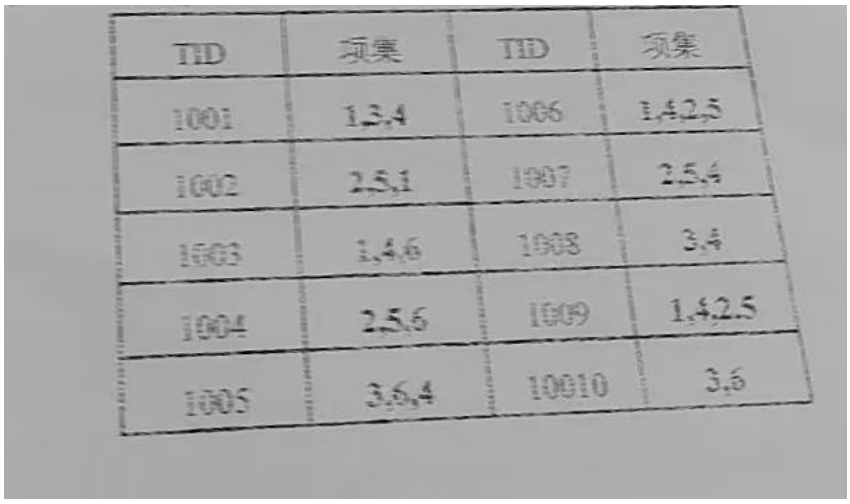
一、选择题

1. 某超市研究销售纪录数据后发现，买 C 的人很大概率也会购买 D，这种属于数据挖掘的哪类问题（ A ）
   A. 关联规则挖掘 B. 分类与回归 C. 聚类分析 D. 时序预测
2. 混淆矩阵中 False Positive（FP）含义是：（ A ）
   A. 被错误的分为正类的样本(FP) B. 被正确地分为正类的样本(TP)
   C. 被错误的分为负类的样本(FN) C. 被正确的分为负类的样本(TN)
3. 假设属性 income 的最大最小值分别是 9800 元和 3000 元。利用最大最小规范化的方法将属性的值映射到 0 至 1 的范围内。对属性 income 的 7360 元将被转化为(C)
   A. 0.688 B. 0.751 C. 0.641 D. 0.719
   (7360-3000)/(9800-3000)=0.641
4. 在 PCA（主成分分析）变换中,应尽量把数据向什么方向投影：（ C ）
   A. 数据集中的方向 B. 数据集散布大的方向
   C. 数据分组特征明显的方向 D. 平行于原始坐标的方向
5. 当两个类的中心重合的时候，LDA（线性判别分析）无法正常工作的原因是：（ C ）
   A. Fisher 准则函数分母为零 B. 类内散布矩阵奇异
   C. Fisher 准则函数分子于零 D. 类间散布矩阵满秩
6. 用于分类与回归应用的主要算法有：（ D ）
   A. Apriari 算法、HotSpot 算法 B. RBF 神经网络、K 均值法、决策树
   C. K 均值法，SOM 神经网络 D. 决策树、BP 神经网络、贝叶斯
7. 若两个事件 A 和 B 条件独立， 那么用数学公式可表示为:（ A ）
   A. P(A,B)=P(A)P(B) B. P(A,B)=P(A|B)P(B)
   C. P(A|B)=P(A) D. P(A|B,C)=P(A,C)
8. 假设某数据案的原始为熵值为 0.7，已知某属性的信息增益为 0.2，那么利用该属性进行划分后数据集的熵值为:（ C ）
   A. 0.9 B. 0.7 C. 0.5 D. 0.2
9. 若 S={a,b,c}是频繁项集，则由项集 S 可以产生(B)个关联规则。
   A. 4 B. 6 C. 7 D. 8
10. 假设 12 个销售价格记录如下：55，50，11，198，15，40，35，9，72，88，227，13；使用等频（等深）将它们递增排序后划分成四个箱，72 在第几个箱子内？（ C ）
    A. 第一个 B. 第二个 C. 第三个 D. 第四个
    9，11，13，15，35，40，50，55，72，88，198，227
    {9，11，13}，{15，35，40}，{50，55，72}，{88，198，227}
11. 在聚类的验证和评价阶段，对于 Silhouette 图表表述正确的是：（ A ）
    A. 可以体现出簇的紧凑性 B. 每个点的取值越接近于 0 越好
    C. 每个样本点的取值范围为[0,1] D. 对于离群点，取值可能超过 1
12. 关于 a 队和 b 队的篮球比赛。若 a 队的胜率为 0.65,b 队的胜率为 0.35。a 队获胜的比赛中只有三成是在 b 队的主场,而 b 队取胜的比赛中 75%是主场获胜。若下一场比赛 b 队主场获胜的概率为（ ）
    A. 0.35 B. 0.75 C. 0.4678 D. 0.5738

13. 设最小支持度为 3，根据 Apriori 算法计算下方购物篮中 C3 和 L3 的数量分别是多少（ ）

A. 4,1　B. 4,2　C. 3,1　D. 3,2



TID	项集	TID	项集
1001	1,3,4	1006	1,4,2,5
1002	2,5,1	1007	2,5,4
1003	1,4,6	1008	3,4
1004	2,5,6	1009	1,4,2,5
1005	3,6,4	10010	3,6

14. 关于分类器的性能曲线的理想状态，对 ROCarea 描述正确的是：（ C ）

A. 对角线(AUC=0.5)　B. 越靠下越好(AUC 趋近于 0)

C. 越靠上越好(AUC 趋近于 1)　D. Random Guess

15. 适合可视化高维数据的方法是：（ C ）

A. 圆饼图　B. 散点图　C. 平行坐标　D. 数据直方图

16. 以下关于决策树算法的说法正确的是：（ D ）

A.　决策树的结构越复杂，分类能力越强

B.　在性能相同的情况下，通常选择能充分利用各种属性的决策树

C.　对于同一个数据集，有且只有一个决策树可以将其完美分开

D.　对于同一个数据集，可以生成多个决策树

17. 一个好的聚类算法应当具备哪些潜质和要求，其中不包括（ D ）

A. 能够处理非球形的数据分布　B. 能够处理噪点和离群点

C. 对样本输入序列不敏感　D. 对用户自定义参数的依赖性

18. 设数据集中只有 5 个项，若频繁 3-项集的集合：{1，2，3}，{1，2，4}，{1，2，5}，{1,3,4},{1,3,5}，{1,4,5},{2,3,4},{2,3,5},{3,4,5}，用 Aprioni 合并策略，最终产生的频繁 4-项集包含（ B ）

A. 1,2,3,4　B. 1,2,4,5　C. 1,3,4,5　D. 2,3,4,5

19. 以下关于 M-P 模型说法正确的是：（ B ）

A. 多层感知机比感知机只多了一个隐含层

B. 感知机只能形成线性判决平面，无法解决异或问题

C. 多层感知机可以有多个隐含层，但是只能有一个输出单元

D. 隐含层神经元的个数应当小于输入层神经元的个数

20. 关于分支定界法不正确的描述是：（ A ）

A. 随机搜索算法　B. 树状搜索算法

C. 依赖属性单调性的假设　D. 能够减少搜索空间

二、填空题

1. 某数据样本属性是职业，其取值为教师、公务员、医生。那么该属性为(标称)型属性。

2. 在人工神经网络领域，神经元是由细胞体、（ 树突 ）、（ 轴突 ）、（ 突触 ）组成。
3. 朴素贝叶斯分类方法是基于（ 类条件独立 ）假设的一种分类模型。
4. 信息熵是描述系统信息量的多少，也是该数据系统不确定性的度量，信息熵的单位是（ 比特 ）。
5. 在处理数据分类前，通常会把原始数据样本分为（ 训练集 ）和（ 检验集 ）两部分。
6. 在决策树算法中，ID3 算法是由（ 信息增益 ）决定选择某个分类属性，而 C4.5 算法是由（ 信息增益比 ）决定选择某个分裂属性的。

三、判断题

1. 聚类是这样的过程：它找出描述并区分数据类或概念的模型(或函数），以便能够使用模型预测类标记未知的对象类。（ × ）
2. 支持度是对关联规则的准确度的衡量。（ × ）
3. 当长度单位米变为厘米后，此长度属性特征的权重会上升。（ × ）
4. 文本挖掘通常称为信息检索，这里的信息检索是指从大量文本数据中提取以前未知的、有用的、可理解的、可操作的新知识的过程。（ × ）
5. 在聚类分析中，簇内相似性越大，簇间差别越大，聚类的效果就越差。（ × ）
6. 离散的标称属性数据间并不存在大小顺序关系，不能直接用距离函数来计算相似度或相异度。（ √ ）
7. 分类是预测数据对象的离散类别，预测是拟合数据对象的连续取值。（ √ ）
8. 关联规则挖掘过程是发现满足最小支持度的所有项集代表的规则。（ × ）
9. 标称类型属性可以通过编码方案转换成二元离散数据类型。（ √ ）
10. K-means 算法是产生划分的聚类算法，簇的个数需事先手动确定。（ √ ）

四、简答题

1. 描述数据挖掘领域的几大问题，并针对每类问题列出一种相应的算法。

(1) 分类问题；决策树算法。
(2) 聚类问题；K 均值算法（K-means）。
(3) 关联规则问题；apriror 算法。
(4) 预测（回归）问题；一元线性回归分析。

2. 画出在分类评价中的混淆矩阵，并分别说明每一项代表什么。

Confusion Matrix				
		Predicted Value		
		Positive	Negative	Total
Actual Value	Positive	True Positive	False Negative	P
	Negative	False Positive	True Negative	N
Total		P'	N'	

TPR=TP/(TP+FN)

TNR=TN/(TN+FP)

Accuracy=(TP+TN)/(P+N)



***TP*: 1(1)** ***FN*: 1(0)**
***FP*: 0(1)** ***TN*: 0(0)**

***TP*: 正确接受** ***FN*: 错误拒绝**
***FP*: 错误接受** ***TN*: 正确拒绝**



3. 简述决策树算法中的 ID3 算法和 C4.5 算法核心思想并说明后者基于前者的改进之处。

ID3 算法核心思想：信息熵
C4.5 算法核心思想：决策树
改进 1：用信息增益率代替信息增益来选择属性
改进 2：能够完成对连续值属性的离散化处理
改进 3：能处理属性值缺失的情况
改进 4：在决策树构造完成之后进行剪枝

4. 简述什么是频繁项集并说明在 Apriori 算法中其具备的性质。

频繁项集：事务数据中支持度大于最小支持度阈值的所有项集。
性质 1：频繁项集的子集必为频繁项集
性质 2：非频繁项集的超集一定是非频繁的

5. 简述主成分分析与线性判别分析的相同点与不同点。

共同点：
1. 均可以对数据进行降维；
2. 都属于特征提取；
3. 在降维时均使用了 矩阵特征分解的思想；
4. 都假设数据符合高斯分布。

不同点：
主成分分析是统计学思想降维分析，线性判别分析是机器学习思想降维分析；
主成分分析不考虑数据的类别信息（无监督降维分析），线性判别分析考虑数据的类别信息（有监督降维分析）；
主成分分析选择数据最大方差的方向，线性判别分析选择分类性能最好的投影方向。

五、应用题

1. 已知如下数据样本，假设每个属性没有先后顺序和权重之分，试完成下列计算。(写出计算步骤，不可以只写结果)

样本序号	学历	年龄段	收入标准
1	硕士	青年	中
2	学士	青年	低
3	学士	老年	中
4	博士	中年	高

完成： 1.1(本题 4 分)用简单匹配法计算出样本 1 与样本 2 的相似度。

1.2(本题 6 分)用数据属性转换法计算出样本 2 与样本 3 的相似度。

2. 请利用 Apriori 算法求项目集 I={I1, I2, I3, I4, I5}中，根据下列事务表:



TID	项 ID 的列表
T100	I1，I2，I4
T200	I1，I3，I4
T300	I2，I4，I5
T400	I1，I4，I5
T500	I1，I3，I5
T600	I2，I3，I4
T700	I1，I4，I5
T800	I1，I2，I4，I5
T900	I1，I2，I3

完成：2.1(本题 4 分）假定最小支持度设定为 3，请找出了所有的频繁项集；
2.2（本题 4 分）假定最小置信度设定为 80%，请求出最大项集的关联规则并算出置信度；
2.3（本题 2 分）总结出此算法不足之处。

多次扫描事务数据库，需要很大的 I/O 负载

可能产生庞大的候选集