# 第 6 讲　聚 类

聚类的定义

聚类算法分类

聚类的典型应用

相似性度量

聚类的评价和验证

*k-means*算法，*k-medoids*算法，连续引导算法

分类和聚类区别



# 聚类（Clustering）

- 我们身边有聚类现象吗?
- 无处不在的聚类









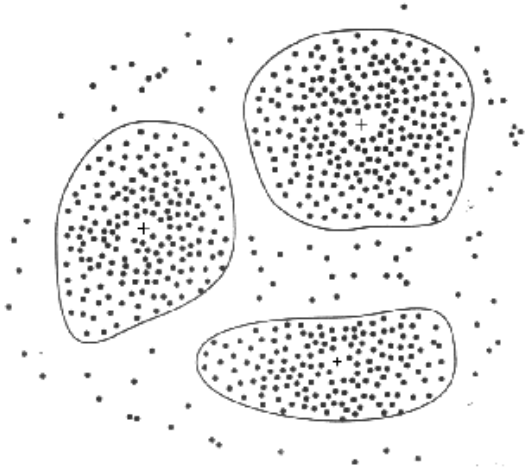
# 聚类

- 什么是聚类?
  - **聚类**（Clustering）是将物理或抽象对象的集合分成相似的对象类或**簇**（Cluster）的过程，同一个簇内的数据对象之间具有**较高的相似性**，不同簇内的数据对象之间**相差则较大**，聚类是一种**无监督分类法：**没有预先指定的类别，数据集中的数据没有预定义的类别标号（无训练集和训练的过程）
- 相关概念
  - **簇：**是数据对象集合，同一个簇中的对象之间具有很高的相似度，而不同簇中的对象高度相异
  - **相异度：**根据描述对象的属性值评估，常使用距离度量



# 聚类概述

- 聚类的**实质**
  - 根据样本（变量）间的亲疏关系将样本（变量）分为类，相近的归为一类，差别较大的归为另一类。所获得的分类应有一定的意义。
- 聚类分析的**关键**
  - 亲疏关系的判别：**相似性与距离**（不相似性）
  - 簇数的确定：**聚多少类合适**
- 聚类分析的**基本要求**：
  - **高的簇内相似性**
  - **低的簇间相似性**





# 聚类分析的类型

- 根据分类的对象：
  - **Q型**聚类（样品聚类*Clustering for individuals*）–**纵向**
  - **R型**聚类（指标聚类*Clustering for variables*）–**横向**
- 根据分类的方法：
  - **基于层次：**系统聚类(*Hierarchical clustering*)
  - **划分法：**快速聚类(*K-means clustering*)
  - **基于密度法：***DBSCAN*算法
  - **基于网格的聚类方法**



# 基于划分的聚类分析方法

- **划分方法（*Partitioning Methods*）**
  - 定义：给定n个对象或数据元组的数据库 ***D***，划分方法构建数据的 ***k*** 个划分（$k \le n$），每个划分表示一簇
  - 方法：给定要构建的划分数目 ***k***，划分方法创建一个初始划分；然后采用迭代重定位技术，尝试通过对象在组建移动来改进划分
  - 由于划分法基于与原型的距离进行分组，因此一般只能发现圆形或球形的簇。
- **比较常用的算法**
  - ***k-means***：***k*-均值聚类算法**，其中每个簇都用该簇中对象的均值来表示 **<入选数据挖掘十大算法>**
  - ***k-medoids***：***k*-中心点聚类算法**，其中每个簇用接近簇中心的一个对象来表示
  - ***CLARANS***：**大型数据库中的划分聚类算法**

***Reference***

**J. MacQueen (1967): "Some Methods for Classification and Analysis of Multivariate Observations", *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol.1, pp. 281-297.**

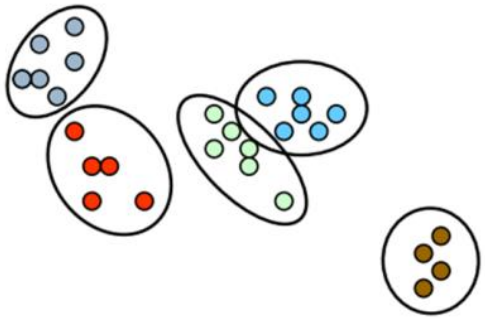


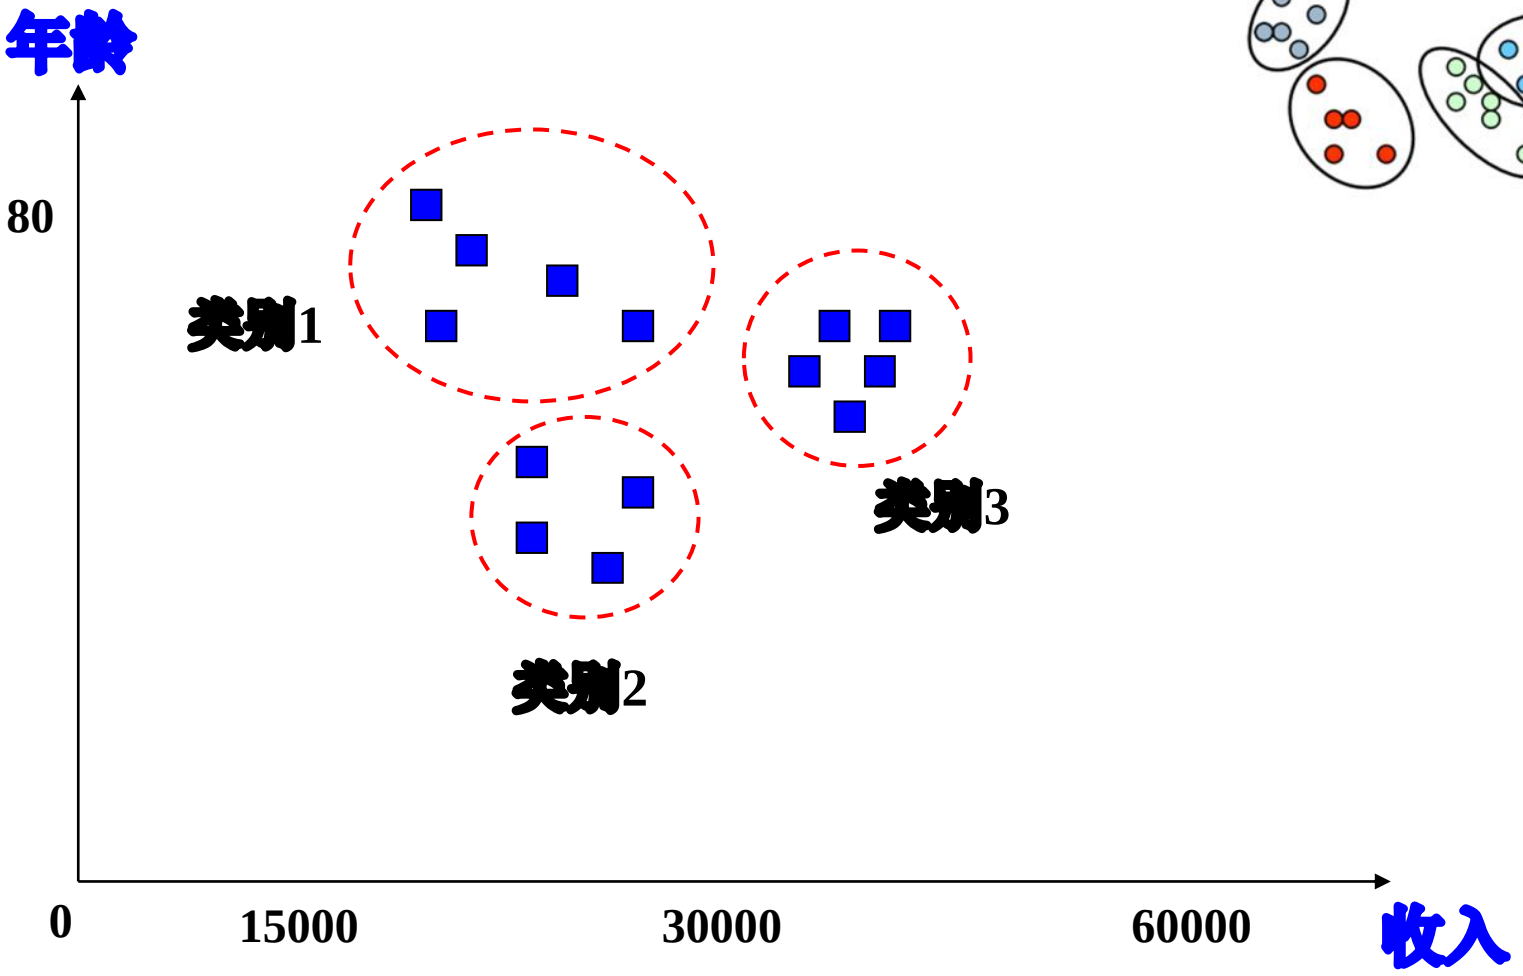
# 基于层次的聚类分析方法

– **层次法**（Hierarchical Methods）：对给定的数据集进行层次分解，形成一个树形的聚类结果。

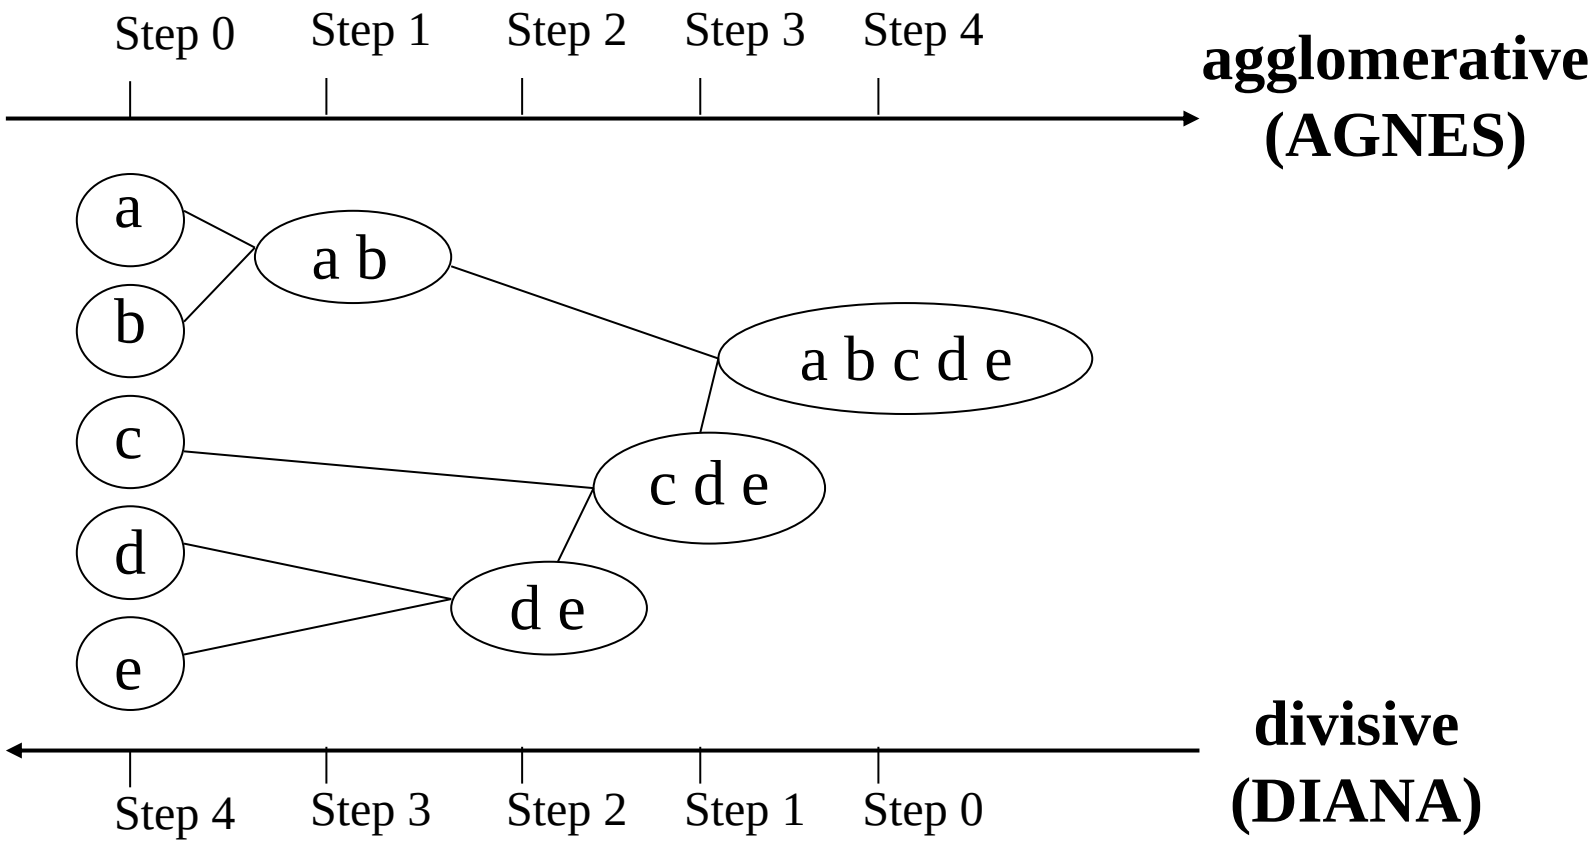
- 属于这样的聚类方法有：自顶向下法、自底向上法。

# 聚类分析方法-划分法示例





# 聚类分析方法-层次法示例





# 聚类问题的数学描述

- **给定数据集合*V*，根据数据对象间的相似程度将数据集合分成组，并满足：**

$$\{C_j \mid j = 1, 2, ..., k\}$$

$$C_i \subseteq V$$

$$C_i \cap C_j = \varnothing$$

$$\bigcup_{i=1}^{k} C_i = V$$

**则该过程称为聚类。*Ci*称为簇。**



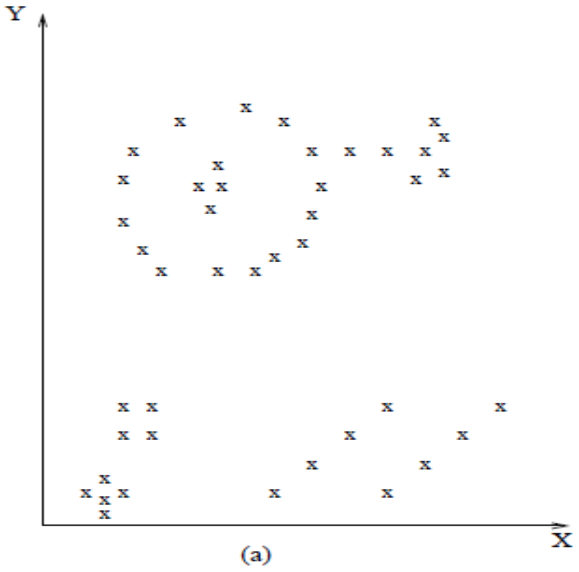
# 聚类分析用途

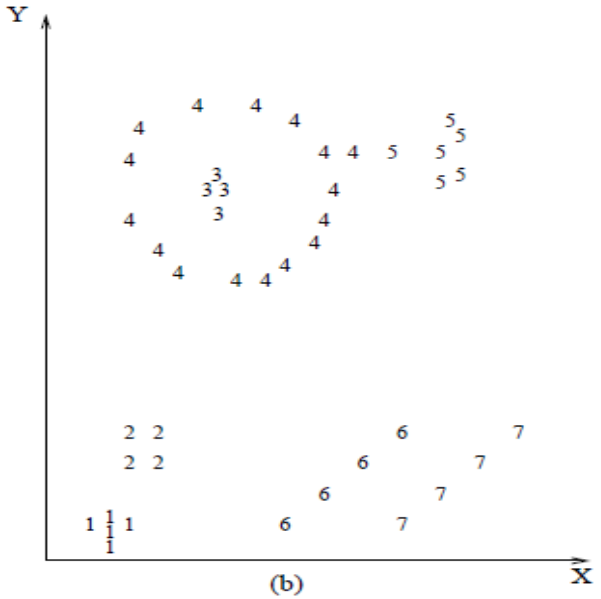
- **聚类分析在数据挖掘中的作用：**
  - **作为一个独立的工具来获得数据集中数据的分布情况：**
    - 首先，对数据集执行聚类，获得所有簇；
    - 然后，根据每个簇中样本的数目获得数据集中每类数据的大体分布情况。
  - **作为其他数据挖掘算法的预处理步骤：**
    - 首先，对数据进行聚类——**粗分类**；
    - 然后，分别对每个簇进行特征提取和**细分类**，可以有效提高分类精度。



# 聚类表现

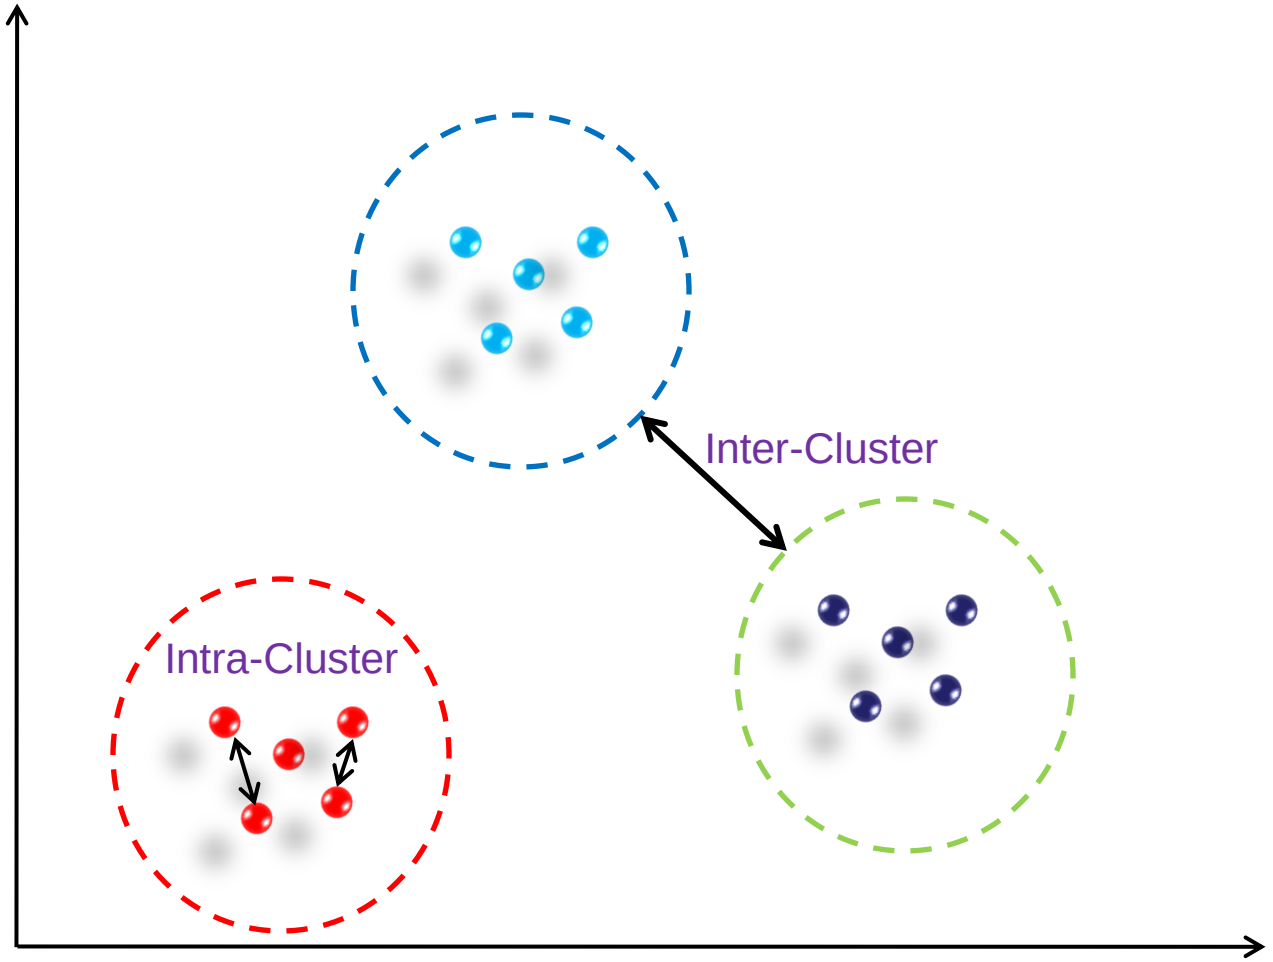
- 发现一组对象
  - 相似的对象在同一个组中
  - 对象们不同于其它组的对象
- 无监督学习
  - 无标签（No labels）
  - 数据驱动（Data driven）



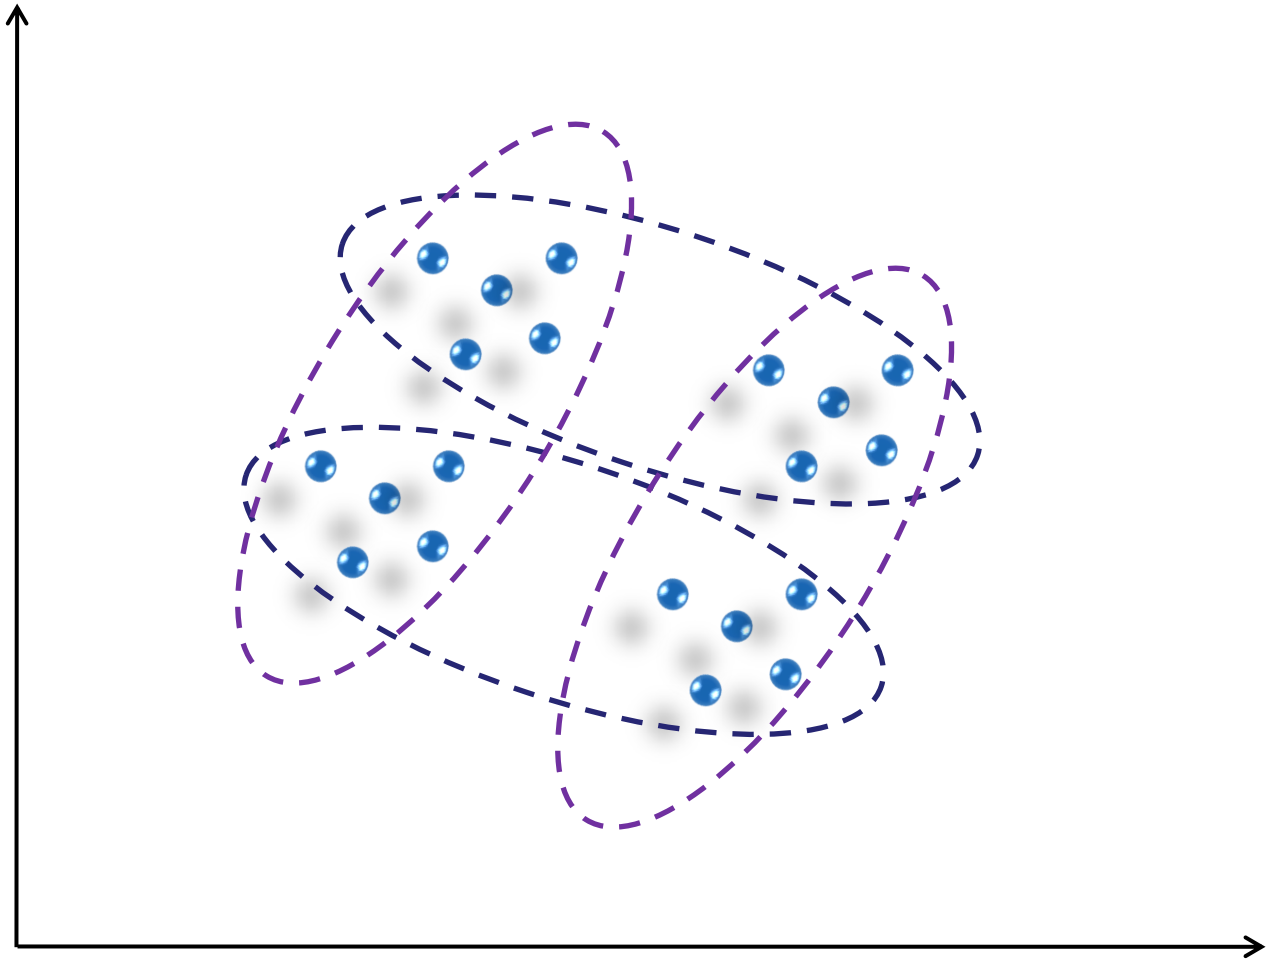


# 聚类现象



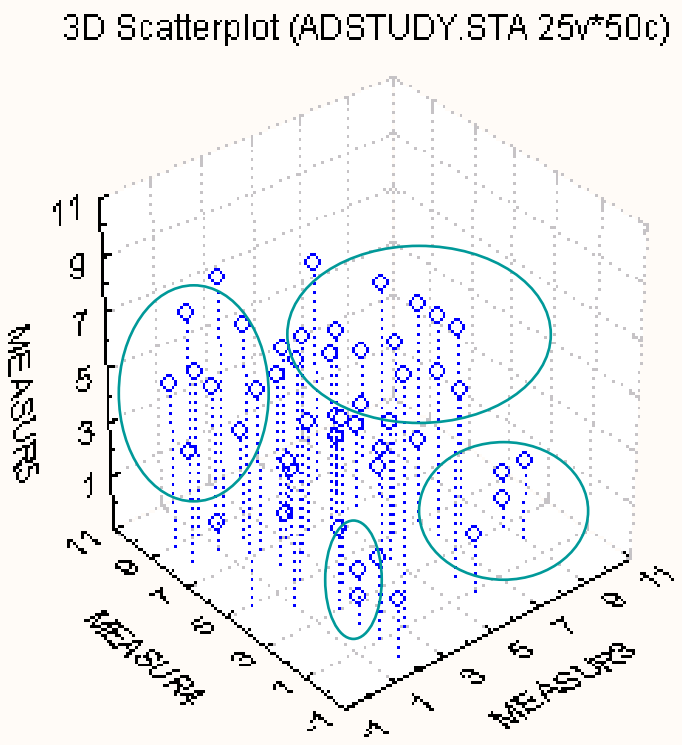


# 聚类现象



# 聚类现象（3D）

| 編號 | 性別 | 年齡 | 婚姻 | 家庭人數 |
|---|---|---|---|---|
| A0001 | Male | 45 | 未婚 | 1 |
| A0002 | Male | 52 | 已婚 | 7 |
| A0003 | Female | 38 | 已婚 | 5 |
| A0004 | Male | 25 | 已婚 | 5 |
| A0005 | Female | 48 | 已婚 | 4 |
| A0006 | Male | 32 | 未婚 | 3 |
| A0007 | Female | 65 | 已婚 | 4 |
| A0008 | Male | 33 | 已婚 | 3 |
| A0009 | Male | 45 | 已婚 | 4 |
| A0010 | Female | 52 | 未婚 | 1 |
| A0011 | Male | 38 | 未婚 | 1 |
| … | … | … | … | … |
| Z0099 | Male | 22 | 未婚 | 4 |





# 聚类典型应用

## 聚类典型应用

**市场营销：**聚类分析技术可把顾客消费数据划分成不同分组，帮助企业市场分析人员从顾客消费数据库中区分出不同的消费群体来，并且概括出每一类消费群体的消费模式，从而进一步开展市场营销活动。

**搜索引擎：**通过聚类对搜索结果划分成若干不同的簇，每个簇对应具有某些共同特征的Web页面文档，可实现对搜索结果分类。

**生物学：**生物实验室容易获得数以万计的基因组信息，通过使用聚类分析技术对基因组信息分组，可对具有类似功能的基因进行分类，帮助科研人员进一步研究这些基因组之间的关系。



# 聚类典型应用

## 聚类典型应用

**保险：**保险公司拥有大量客户理赔记录数据，通过对这些数据进行聚类分析，对客户分类，发现不同险种如车险、人寿保险等对应的具有较高索赔概率的潜在群体，为进一步展开保险业务决策提供支持。

**租房信息：**成千上万的房主在租房网站上发布数以万计算的房源信息，网站系统通过采用聚类分析，自动将房源信息根据区域、房型、租金、出租方式、设施等进行分类，以便租客选择自己所需的房源信息。

**医学：**一种疾病或健康状况通常有多种变种，聚类分析可以用来发现这些子类别。



# 聚类典型应用

## 聚类典型应用

**汇总：**将算法用于仅包含簇原型的数据集，而不是整个数据集。依赖分析类型、原型个数和原型代表数据的精度，汇总结果可以与使用所有数据得到的结果相媲美。

**压缩：**簇原型可以用于数据压缩。例如，创建一个包含所有簇原型的表，即每个原型赋予一个整数值，作为它在表中的位置。每个对象用与它所在的簇相关联的原型的索引表示。

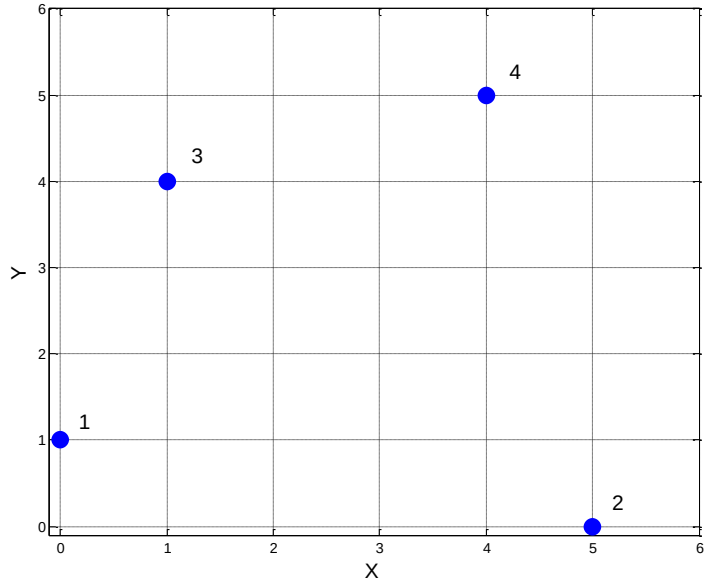


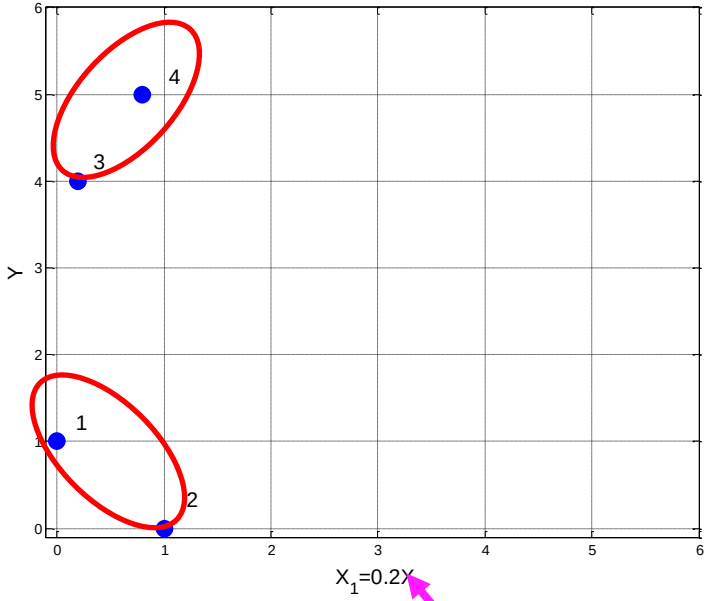
# 聚类算法要求

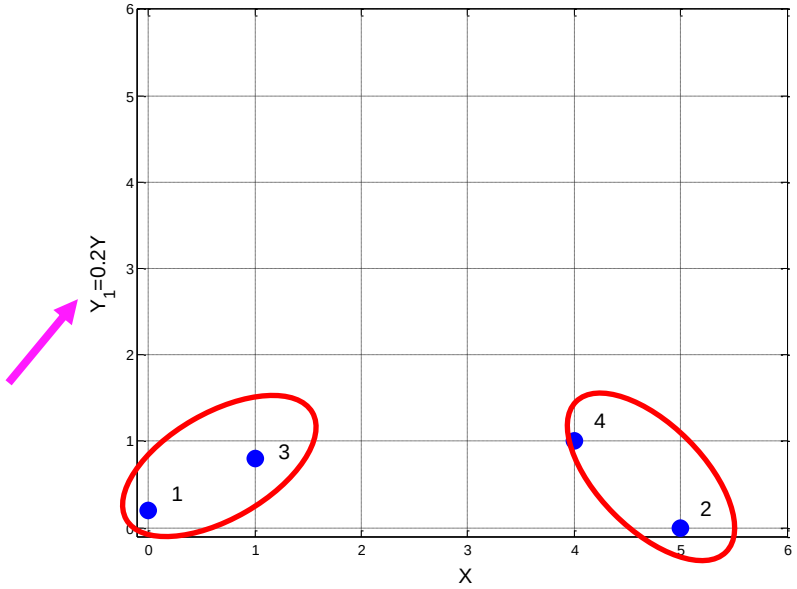
- **数据挖掘技术对聚类分析的要求：**
  - 可伸缩性
  - 处理不同类型属性的能力
  - 发现任意形状聚类的能力
  - 减小对先验知识和用户自定义参数的依赖性
  - 处理噪声或离群点数据的能力
  - 对数据输入顺序不敏感
  - 具有处理高维度数据的能力
  - 可解释性和实用性



# 实际问题（Practical Considerations）



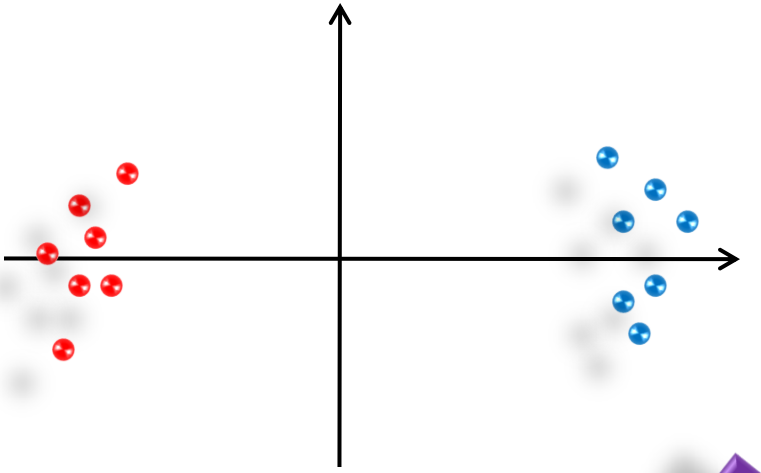



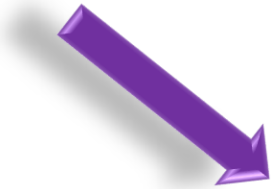



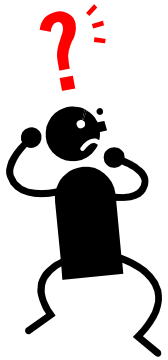

**缩放事件问题**
**(Scaling Matters! )**

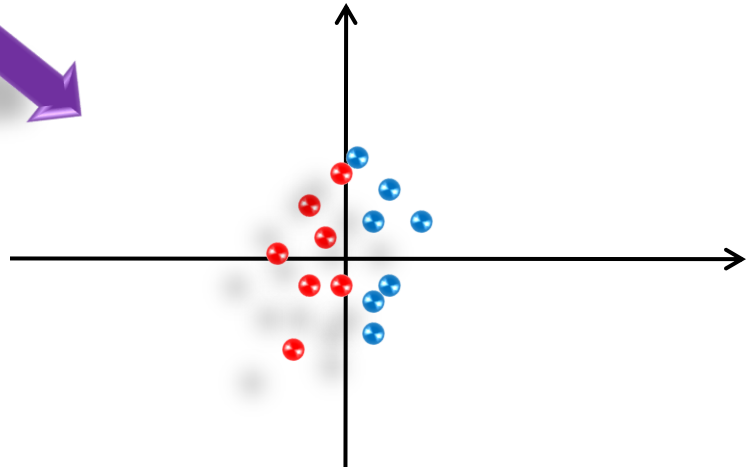


# 标准化问题（Normalization or Not？）











# 相似性度量

相似性用来描述分类对象之间**接近和相似的程度**，是划分法聚类技术的聚类依据--**相似性度量**，需要定义一些统计量作为聚类的数量指标，从而可以定量地进行聚类。

常用来度量数据对象间相似性的统计量有**距离函数**和**相似系数**，它们的定义与数据对象属性的类型有关，不同属性类型有不同的定义方式。

不管距离函数、相似系数，还是别的统计量，均用符号 $d_{ij}$ 表示，都表示数据对象 $i$ 和 $j$ 之间的接近或相似（远离或相异）程度。



# 相似性计算方法

- 在聚类分析中，样本之间的**相似性**通常采用**样本之间的距离**来表示。
  - 两个样本之间的**距离越大**，表示两个样本越**不相似性**，差异性越大；
  - 两个样本之间的**距离越小**，表示两个样本**越相似性**，差异性越小。
  - 特例：当两个样本之间的**距离为零**时，表示两个样本**完全一样**，无差异。



# 相似性计算方法

- 在聚类分析中，样本之间的**相似性**通常采用**样本之间的距离**来表示。
  - **样本之间的距离**是在样本的**描述属性**（特征）上进行计算的。
  - 在不同应用领域，样本的**描述属性**的类型可能不同，因此相似性的计算方法也不尽相同。
    - 连续型属性(如：重量、高度、年龄等)
    - 二值离散型属性(如：性别、考试是否通过等)
    - 多值离散型属性(如：收入分为高、中、低等)
    - 混合类型属性(上述类型的属性至少同时存在两种)



# 连续型属性的相似性计算方法

- 假设两个样本 $X_i$ 和 $X_j$ 分别表示成如下形式：
  - $X_i=(x_{i1}, x_{i2}, \ldots, x_{id})$
  - $X_j=(x_{j1}, x_{j2}, \ldots, x_{jd})$
  - 它们都是 $d$ 维的特征向量，并且每维特征都是一个**连续型数值**。
- 对于连续型属性，样本之间的相似性通常采用如下三种距离公式进行计算。



# 连续型属性的相似性计算方法

数据对象标准化后，或没有被标准化，可基于距离和相似系数统计量计算两个数据对象 *i* 和 *j* 之间的相异度。

**基于距离函数的相异度计算**

- 连续性属性**距离**度量方法有:

**明考斯基距离*(Minkowski distance):***

$$d(i,j)=\sqrt[q]{(|x_{i_1}-x_{j_1}|^q+|x_{i_2}-x_{j_2}|^q+...+|x_{i_p}-x_{j_p}|^q)}$$

其中 $i = (x_{i1}, x_{i2}, \ldots, x_{ip})$ 和 $j = (x_{j1}, x_{j2}, \ldots, x_{jp})$ 是两个$p$维的数据对象, $q$是一个正整数。

当$q = 1$时, $d$ 称为**曼哈顿距离*(Manhattan distance)***

$$d(i,j)=|x_{i_1}-x_{j_1}|+|x_{i_2}-x_{j_2}|+...+|x_{i_p}-x_{j_p}|$$



# 连续型属性的相似性计算方法

- 当 $q=2$ 时, $d$ 就成为**欧几里德距离*(Euclidean distance)*:**

$$d(i,j)=\sqrt{(|x_{i_1}-x_{j_1}|^2+|x_{i_2}-x_{j_2}|^2+...+|x_{i_p}-x_{j_p}|^2)}$$

- ***Euclidean*距离和*Manhattan*距离的性质:**
  - $d(i,j) \geq 0$
  - $d(i,i) = 0$
  - $d(i,j) = d(j,i)$
  - $d(i,j) \leq d(i,k) + d(k,j)$
- 可以根据每个变量的重要性赋予一个权重



# 连续型属性的相似性计算方法

- 欧氏距离（Euclidean distance）

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^{d} (x_{ik} - x_{jk})^2}$$

q=2

- 曼哈顿距离（Manhattan distance）

$$d(x_i, x_j) = \sum_{k=1}^{d} |x_{ik} - x_{jk}|$$

q=1

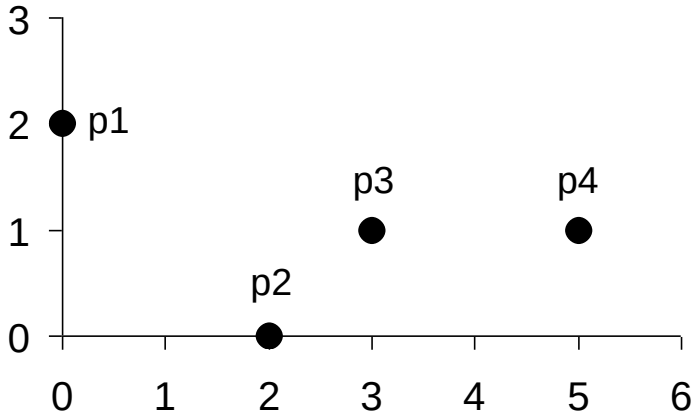
- 明考斯基距离（Minkowski distance）

$$d(x_i, x_j) = (\sum_{k=1}^{d} |x_{ik} - x_{jk}|^q)^{1/q}$$



# 连续型属性的相似性计算方法

- **欧式距离的示例**




| point | x | y |
|---|---|---|
| p1 | 0 | 2 |
| p2 | 2 | 0 |
| p3 | 3 | 1 |
| p4 | 5 | 1 |

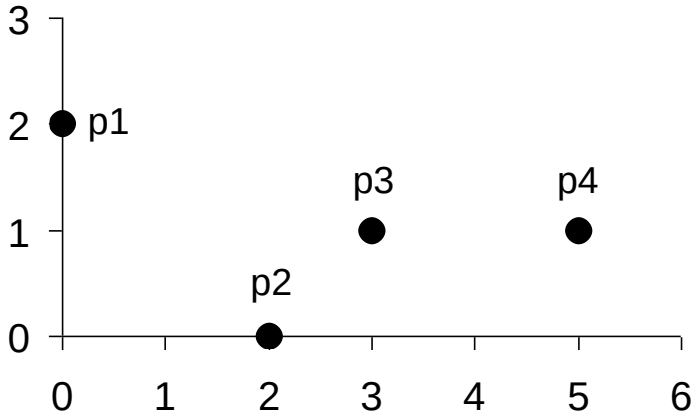
| | p1 | p2 | p3 | p4 |
|---|---|---|---|---|
| p1 | 0 | 2.828 | 3.162 | 5.099 |
| p2 | 2.828 | 0 | 1.414 | 3.162 |
| p3 | 3.162 | 1.414 | 0 | 2 |
| p4 | 5.099 | 3.162 | 2 | 0 |

**Distance Matrix**



# 连续型属性的相似性计算方法

- **曼哈顿距离的示例**




| point | x | y |
|---|---|---|
| **p1** | 0 | 2 |
| **p2** | 2 | 0 |
| **p3** | 3 | 1 |
| **p4** | 5 | 1 |

| | p1 | p2 | p3 | p4 |
|---|---|---|---|---|
| **p1** | 0 | 4 | 4 | 6 |
| **p2** | 4 | 0 | 2 | 4 |
| **p3** | 4 | 2 | 0 | 2 |
| **p4** | 6 | 4 | 2 | 0 |

**Distance Matrix**



# 二值离散型属性的相似性计算方法

- 二值离散型属性只有0和1两个取值。
  - 其中：0表示该属性为空，1表示该属性存在。
  - 例如：描述病人的是否抽烟的属性(*smoker*)，取值为1表示病人抽烟，取值0表示病人不抽烟。
- 假设两个样本 $X_i$ 和 $X_j$ 分别表示成如下形式：
  - $X_i=(x_{i1}, x_{i2}, \ldots, x_{ip})$
  - $X_j=(x_{j1}, x_{j2}, \ldots, x_{jp})$
  - 它们都是 $p$ 维的特征向量，并且每维特征都是一个二值离散型数值。



# 二值离散型属性的相似性计算方法

- **假设二值离散型属性的两个取值具有相同的权重，则可以得到一个两行两列的可能性矩阵。**

| | | $X_j$ 1 | 0 | sum |
|---|---|---|---|---|
| $X_i$ | 1 | $a$ | $b$ | $a+b$ |
| | 0 | $c$ | $d$ | $c+d$ |
| | sum | $a+c$ | $b+d$ | $p$ |

$Xi=$（0 1 0 0 0 1 0）
$Xj=$（0 0 1 1 1 0 0）

**a = the number of attributes where $X_i$ was 1 and $X_j$ was 1;**

**b = the number of attributes where $X_i$ was 1 and $X_j$ was 0;**

**c = the number of attributes where $X_i$ was 0 and $X_j$ was 1;**

**d = the number of attributes where $X_i$ was 0 and $X_j$ was 0.**



# 二值离散型属性的相似性计算方法

- 如果样本的属性都是**对称的**二值离散型属性，则样本间的距离可用**简单匹配系数**(*Simple Matching Coefficients, SMC*)计算：

$$SMC = (b + c) / (a + b + c + d)$$

  - 其中：**对称的**二值离散型属性是指属性取值为1或者0同等重要。
  - **例如：性别就是一个对称的二值离散型属性，即：用1表示男性，用0表示女性；或者用0表示男性，用1表示女性是等价的，属性的两个取值没有主次之分。**



# 二值离散型属性的相似性计算方法

- 如果样本的属性都是**不对称的**二值离散型属性，则样本间的距离可用 ***Jaccard* 系数**计算(*Jaccard Coefficients, JC*)：

$$JC = (b + c) / (a + b + c)$$

  - 其中：**不对称的**二值离散型属性是指属性取值为1或者0不是同等重要。
  - **例如：血液的检查结果是不对称的二值离散型属性，阳性结果的重要程度高于阴性结果，因此通常用1来表示阳性结果，而用0来表示阴性结果。**



# 二值离散型属性的相似性计算方法

- 例：已知两个样本

***p=[1 0 0 0 0 0 0 0 0 0]*** ***q= [0 0 0 0 0 0 1 0 0 1]***

– **a = 0** (the number of attributes where p was 1 and q was 1)

– **b = 1** (the number of attributes where p was 1 and q was 0)

– **c = 2** (the number of attributes where p was 0 and q was 1)

– **d = 7** (the number of attributes where p was 0 and q was 0)



# 二值离散型属性的相似性计算方法

- ***SMC = (b + c) / (a + b + c + d)***

  = (1+2) / (0+1+2+7)

  = 0.3 ⟸ **对称二值离散-简单匹配系数**

- ***JC = (b+c) / (a + b + c)***

  = (1+2) / (0+1+2)

  = 1 ⟸ **非对称二值离散-*Jaccard* 系数**



# 多值离散型属性的相似性计算方法

- 多值离散型属性是指取值个数大于2的离散型属性。
  - **例如：成绩可以分为 优、良、中、差。**
- 假设一个多值离散型属性的取值个数为 $N$，给定数据集 $X=\{x_i \mid i=1,2,\ldots,total\}$
  - 其中：每个样本$x_i$可用一个 $d$ 维特征向量描述，并且每维特征都是一个多值离散型属性
  - 即：$x_i = (x_{i1}, x_{i2}, \ldots, x_{id})$

**每维特征都是一个多值离散型属性。**



# 多值离散型属性的相似性计算方法

- **问题：给定两个样本**

$$x_i = (x_{i1}, x_{i2}, \ldots, x_{id}),\quad x_j = (x_{j1}, x_{j2}, \ldots, x_{jd})$$

**-如何计算它们之间的距离?**

- **方法一：简单匹配方法。**
- **方法二：先将多值离散型属性转换成多个二值离散型属性，然后再使用 *Jaccard系数* 计算样本之间的距离。**



# 多值离散型属性的相似性计算方法

- **问题：给定两个样本**

$$x_i = (x_{i1}, x_{i2}, \ldots, x_{id}),\quad x_j = (x_{j1}, x_{j2}, \ldots, x_{jd})$$

**-如何计算它们之间的距离?**

- **方法一：简单匹配方法。**
  - **距离计算公式如下：**

$$d(x_i, x_j) = \frac{d-u}{d}$$

  - **其中：** $d$ **为数据集中的属性个数，** $u$**为样本中** $x_i$**和** $x_j$ **取值相同的属性个数**



# 多值离散型属性的相似性计算方法

- **问题：给定两个样本**

$$x_i = (x_{i1}, x_{i2}, \ldots, x_{id}),\quad x_j = (x_{j1}, x_{j2}, \ldots, x_{jd})$$

**-如何计算它们之间的距离?**

- **方法一：简单匹配方法。**

| 样本序号 | 年龄段 | 学历 | 收入 |
|---|---|---|---|
| $x_1$ | 青年 | 研究生 | 高 |
| $x_2$ | 青年 | 本科 | 低 |
| $x_3$ | 老年 | 本科以下 | 中 |
| $x_4$ | 中年 | 研究生 | 高 |

$$d(x_1, x_2) = (3-1)/3 \approx 0.667$$

$$d(x_1, x_3) = (3-0)/3 = 1$$

$$d(x_1, x_4) = (3-2)/3 \approx 0.333$$



# 多值离散型属性的相似性计算方法

- **问题：给定两个样本**

$$x_i = (x_{i1}, x_{i2}, \ldots, x_{id}),\quad x_j = (x_{j1}, x_{j2}, \ldots, x_{jd})$$

**-如何计算它们之间的距离?**

- **方法二：先将多值离散型属性转换成多个二值离散型属性，然后再使用 *Jaccard系数* 计算样本之间的距离。**
  - **对有 *N* 个取值的多值离散型属性，可依据该属性的*每种取值*分别创建一个新的二值离散型属性，这样可将多值离散型属性转换成多个二值离散型属性。**



# 多值离散型属性的相似性计算方法

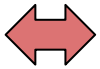
- **问题：给定两个样本**

$$x_i = (x_{i1}, x_{i2}, \ldots, x_{id}),\quad x_j = (x_{j1}, x_{j2}, \ldots, x_{jd})$$

**-如何计算它们之间的距离?**

- **方法二：先将多值离散型属性转换成多个二值离散型属性，然后再使用 *Jaccard系数* 计算样本之间的距离。**

| 样本序号 | 年龄段 | 学历 | 收入 |
|---|---|---|---|
| $x_1$ | 青年 | 研究生 | 高 |
| $x_2$ | 青年 | 本科 | 低 |
| $x_3$ | 老年 | 本科以下 | 中 |
| $x_4$ | 中年 | 研究生 | 高 |



| 样本序号 | 青年 | 中年 | 老年 | 本科以下 | 本科 | 研究生 | 高 | 中 | 低 |
|---|---|---|---|---|---|---|---|---|---|
| $x_1$ | 1 | 0 | 0 | 0 | 0 | 1 | 1 | 0 | 0 |
| $x_2$ | 1 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 1 |
| $x_3$ | 0 | 0 | 1 | 1 | 0 | 0 | 0 | 1 | 0 |
| $x_4$ | 0 | 1 | 0 | 0 | 0 | 1 | 1 | 0 | 0 |



# 多值离散型属性的相似性计算方法

- **练习：计算样本间的相似性（2种方法）**

| 样本序号 | 职业 | 收入 | 学位 |
|---|---|---|---|
| $X_1$ | 公司职员 | 高 | 硕士 |
| $X_2$ | 公务员 | 中 | 学士 |
| $X_3$ | 公司职员 | 低 | 无学位 |
| $X_4$ | 教师 | 高 | 博士 |
| $X_5$ | 教师 | 中 | 学士 |

**计算：**

*X1*和*X3*的相似性度量
*X2*和*X5*的相似性程度

（假设所有属性取值都是标称型的）

**1. 简单匹配法　　2. 属性转换法**



# *k-means* 算法

**Algorithm: *k*-means.** The *k*-means algorithm for partitioning, where each cluster's center is represented by the mean value of the objects in the cluster.

**Input:**

- *k*: the number of clusters,
- *D*: a data set containing *n* objects.

**Output:** A set of *k* clusters.

**Method:**

(1) arbitrarily choose *k* objects from *D* as the initial cluster centers;
(2) **repeat**
(3) (re)assign each object to the cluster to which the object is the most similar, based on the mean value of the objects in the cluster;
(4) update the cluster means, that is, calculate the mean value of the objects for each cluster;
(5) **until** no change;

**Reference**

J. MacQueen (1967): "Some Methods for Classification and Analysis of Multivariate Observations", *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol.1, pp. 281-297.



# k-means算法基本思想

（1）随机选择一个 **k** 值，用以确定簇的总数。

（2）在数据集中任意选择 **k** 个实例，将它们作为初始的簇中心。

（3）计算这 **k** 个簇中心与其他剩余实例的简单欧氏距离（*Euclidean Distance*），用这个距离作为实例之间相似性的度量，将与某个簇相似度高的实例划分到该簇中，成为其成员之一。

（4）使用每个簇中的实例来计算该簇新的簇中心。

（5）如果计算得到新的簇中心等于上次迭代的簇中心，终止算法过程。否则，用新的簇中心作为簇中心并重复步骤（3）~（5）。

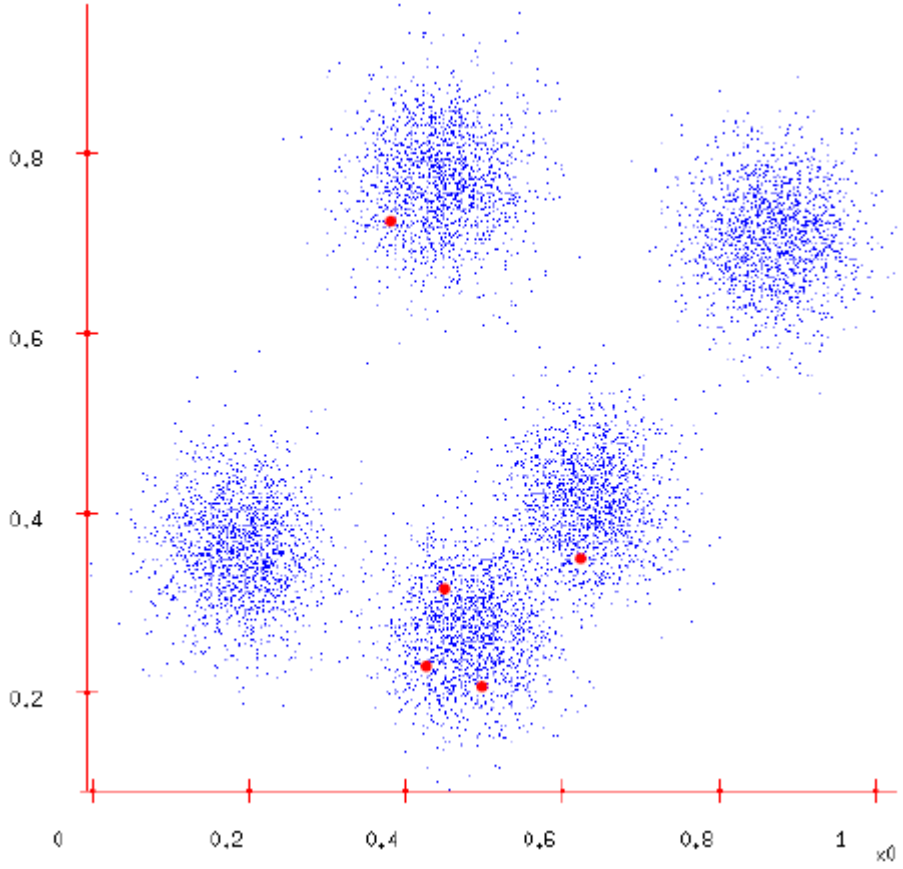
$$Distance(A\text{-}B)=\sqrt{(x_1-x_2)^2+(y_1-y_2)^2}$$

$$d(x_i,x_j)=\sqrt{\sum_{k=1}^{d}(x_{ik}-x_{jk})^2}$$

其中：$A$、$B$ 为两个对象；$x_1$、$y_1$为对象$A$的属性；$x_2$、$y_2$为对象 $B$ 的属性。



# *k-means* 算法

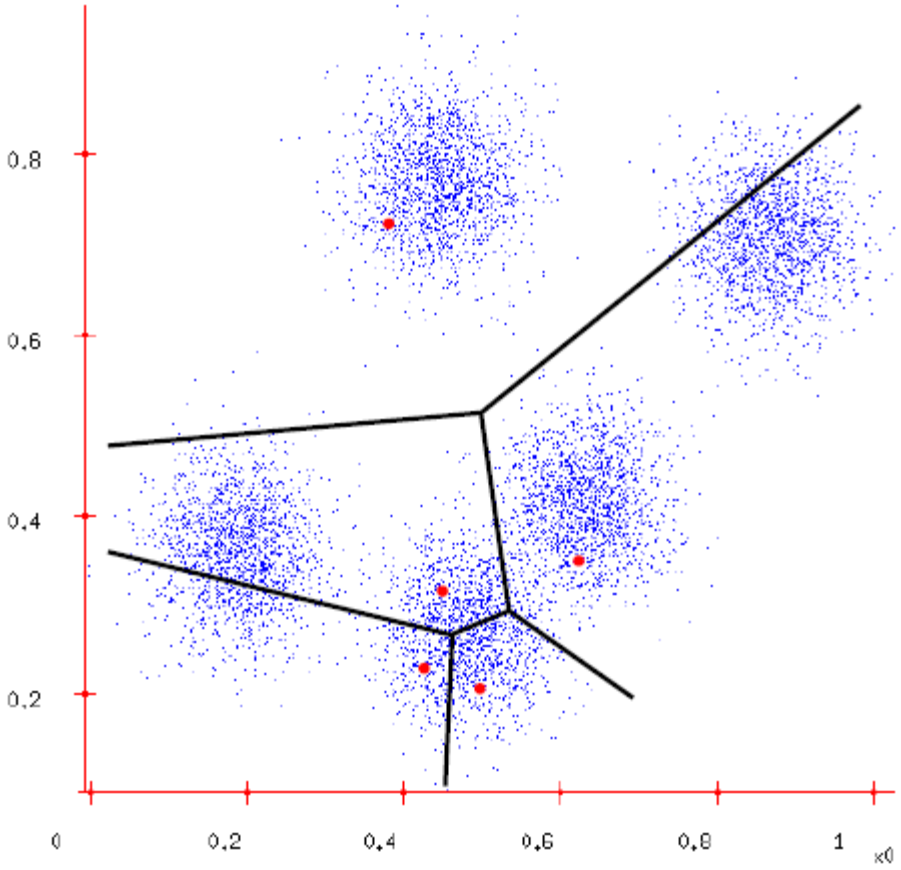



**二维数据：可能用眼睛能看出来簇的个数及样本大概的分布情况；**

**高维数据：根本无法看出样本簇的分布状况**

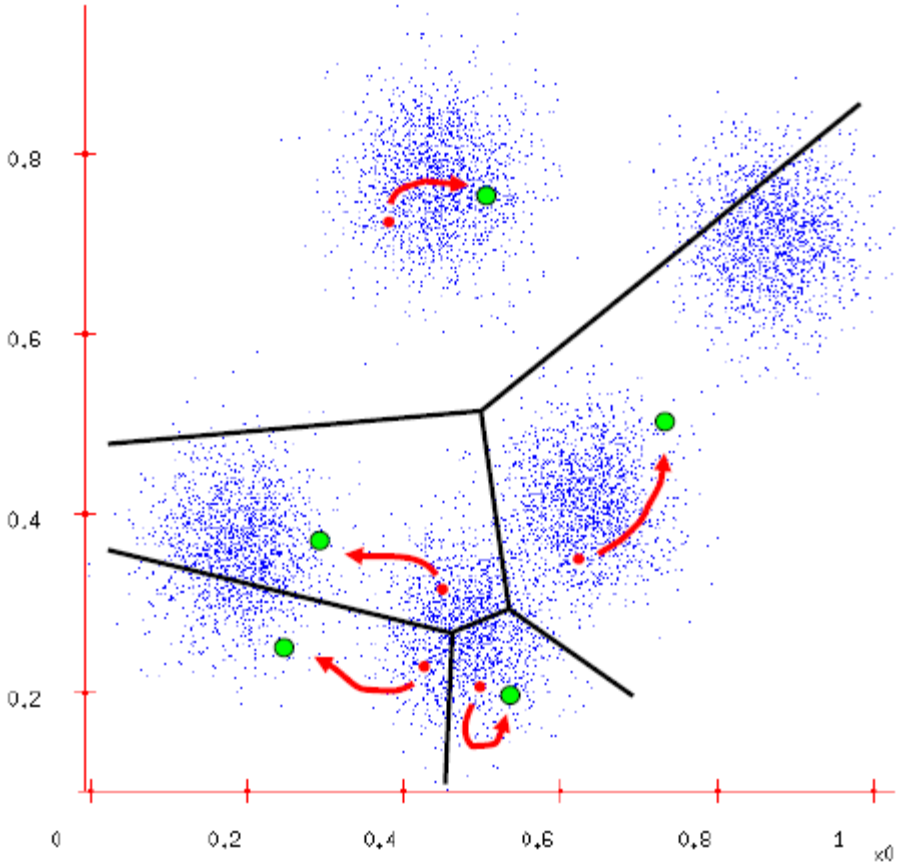


# *k-means* 算法





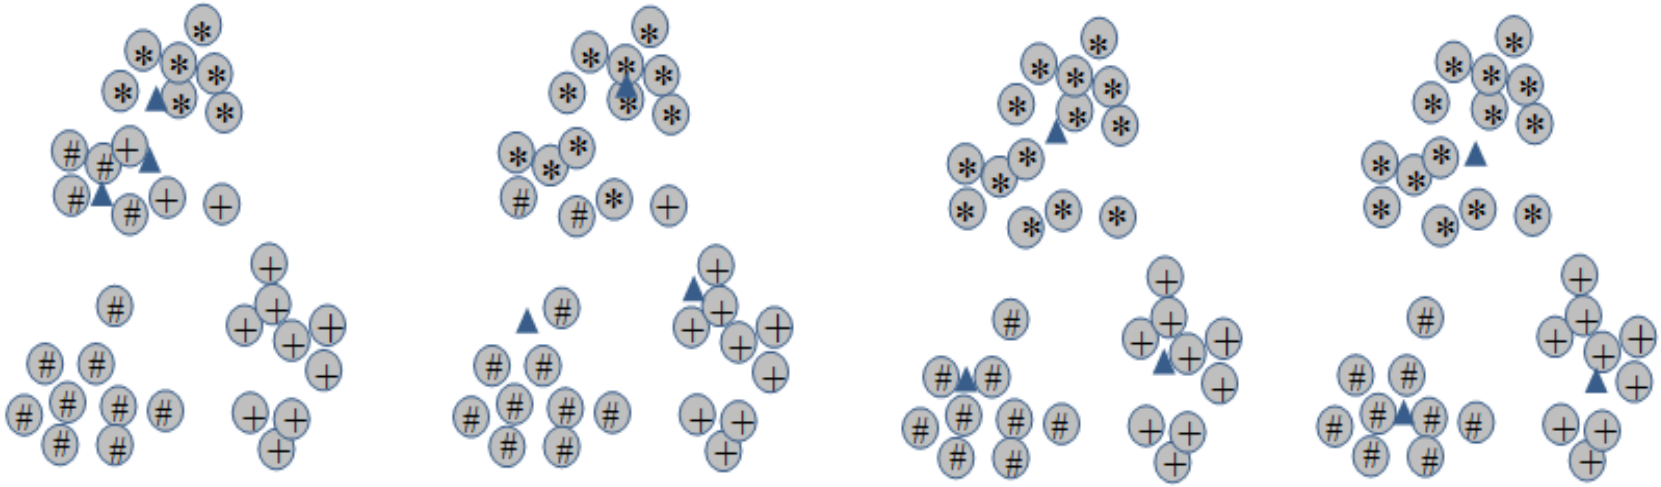
# *k-means* 算法




**算法如此迭代下去，更新簇的中心点。**
**直到本次迭代计算出的所有簇的中心点和上次迭代计算出的所有簇的中心的完全一样时，算法收敛从而终止运算。**

# *k-means* 算法-迭代过程

**K-Means算法聚类迭代过程：**



(a) 第 1 次迭代　(b) 第 2 次迭代　(c) 第 3 次迭代　(d) 第 4 次迭代



# *k-means* 算法评价标准

- *k-means* 算法的评价准则：**误差平方和准则**

$$E = \sum_{i=1}^{k} \sum_{p \in C_i} |p - m_i|^2$$

$k$是簇的个数

$p$是簇$C_i$中的样本

$m_i$是簇$C_i$的均值

**误差平方和达到最优（小）时，可以使各聚类的类内尽可能紧凑，而使各聚类之间尽可能分开。**

**对于同一个数据集，由于*k-means*算法对初始选取的聚类中心敏感，因此可用该准则评价聚类结果的优劣。**

**通常，对于任意一个数据集，*k-means*算法无法达到全局最优，只能达到局部最优。**



# *k-means* 算法评价标准

**假设 *n* 个对象划分为 *k* 个簇** $C_1$，$C_2$，…，$C_k$，

**相应簇中心为** $o_1$，$o_2$，…，$o_k$

**那么相异度总和为：**

$$E = \sum_{j=1}^{k} \sum_{i \in C_j} d_{io_j} \quad \Leftarrow \quad d_{io_j} = |p - m_i|^2$$

***k-means* 聚类问题可看作一个 *E* 值（相异度）优化问题**



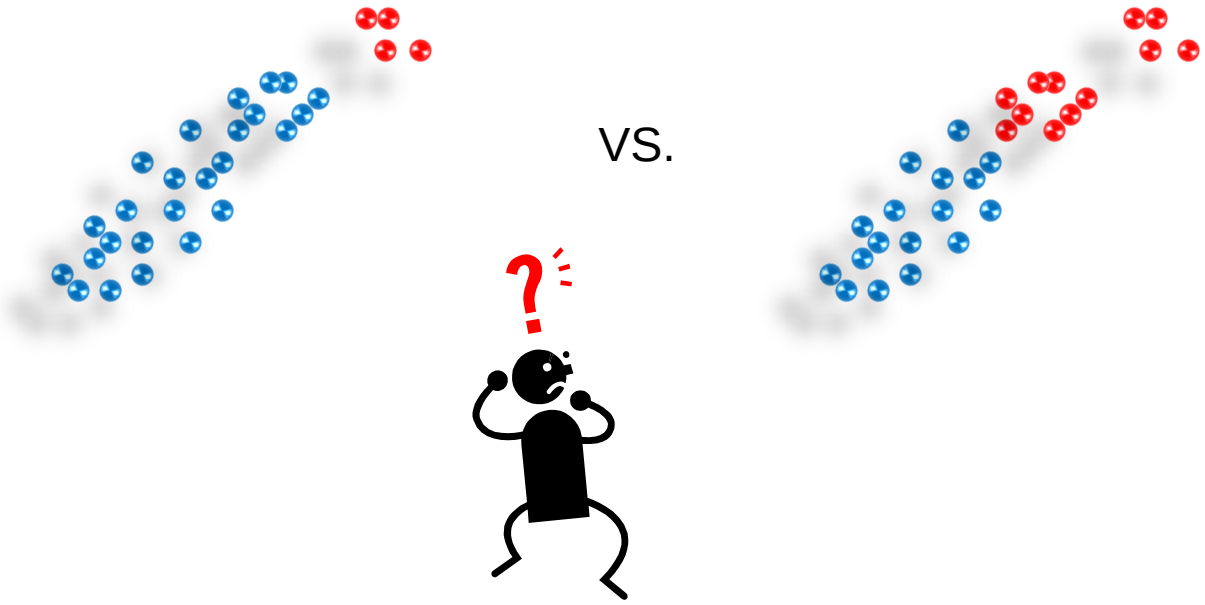
# 聚类评价标准 (Evaluation)

$$J_e = \sum_{i=1}^{k} \sum_{p \in C_i} \|p - m_i\|^2$$

$$m_i = \frac{1}{n_i} \sum_{p \in C_i} C_i$$

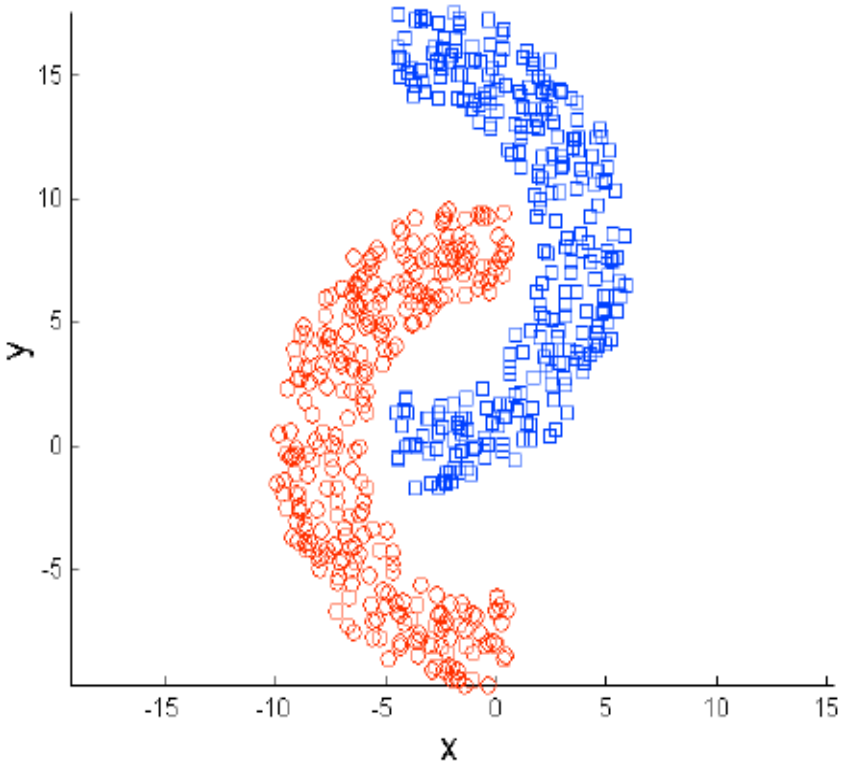
**J 值越小越好**

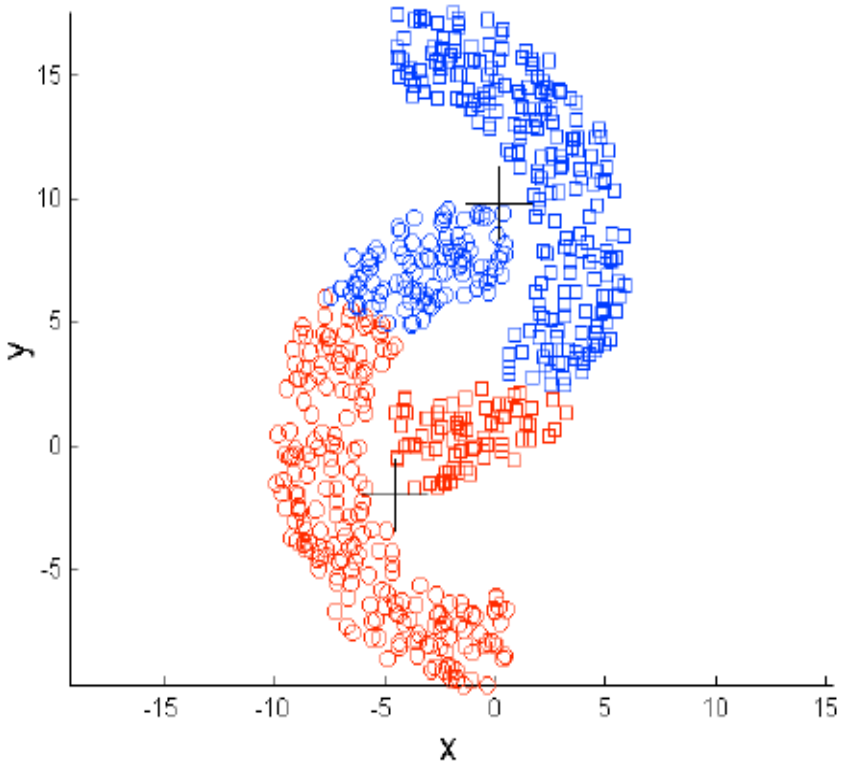
**数据样本的质心（平均中心点）**





# 聚类评价标准 *(Evaluation)*





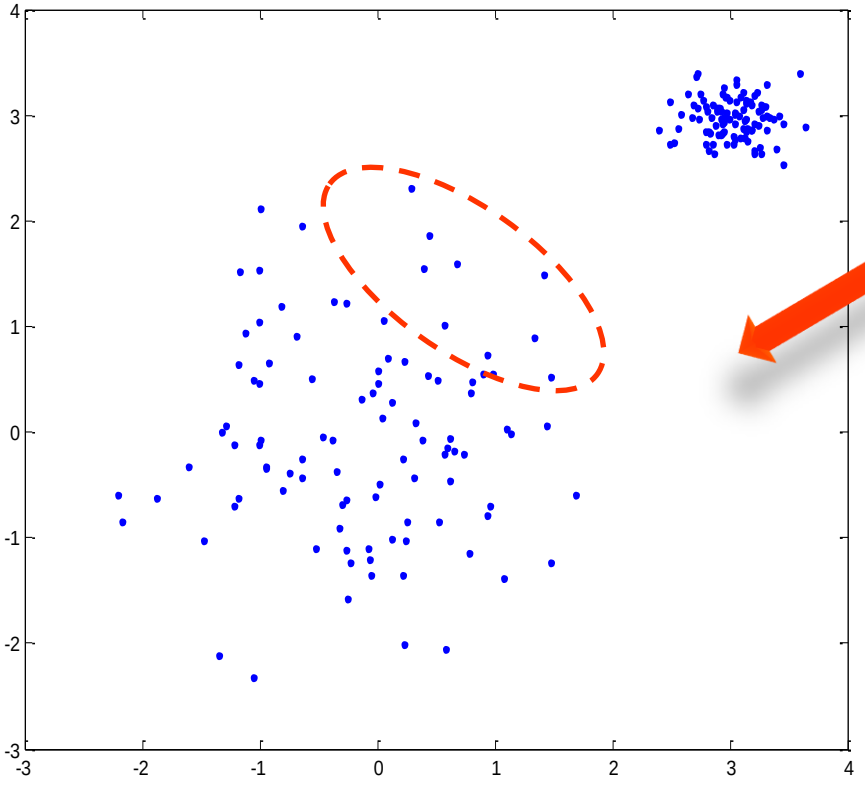
# 聚类的解释和验证-*Silhouette*

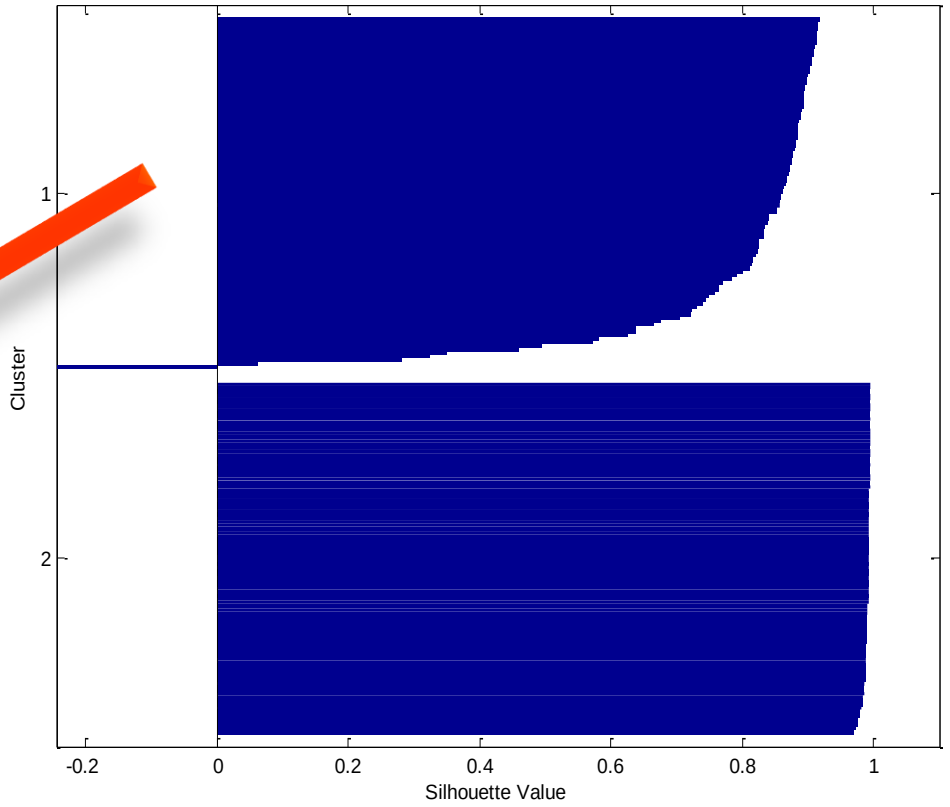
- **数据簇的解释和验证方法**
- **可以用简洁的图形表示，表示每个数据点在其集群中与其他集群相比的情况**
- ***a(i)*：*i* 与 同一簇中 所有其他点的平均不相似度(*Average Dissimilarity*)**
- ***b(i)*：*i* 与 其他簇 的最小的平均不相似度**

$$s(i) = \frac{b(i) - a(i)}{\max\{b(i), a(i)\}}$$



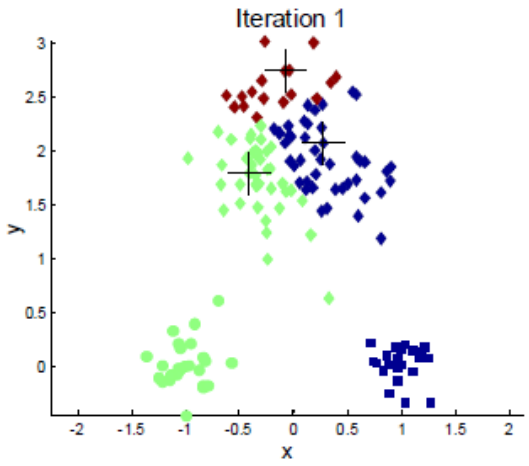
# 聚类的解释和验证

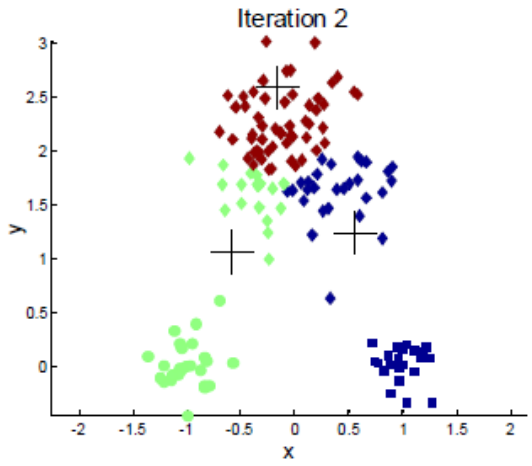

4
3
2
1
0
-1
-2
-3
-3
-2
-1
0
1
2
3
4

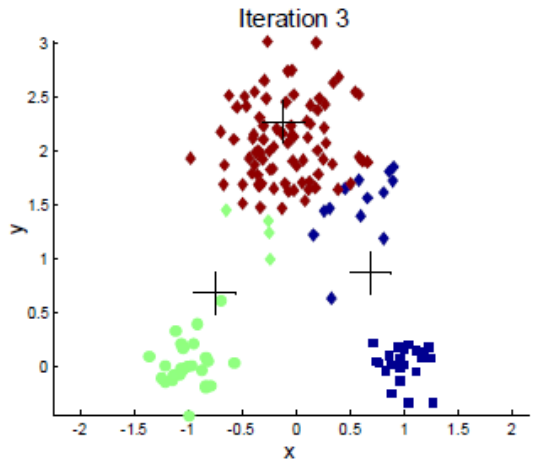

Cluster
1
2
-0.2
0
0.2
0.4
0.6
0.8
1
Silhouette Value

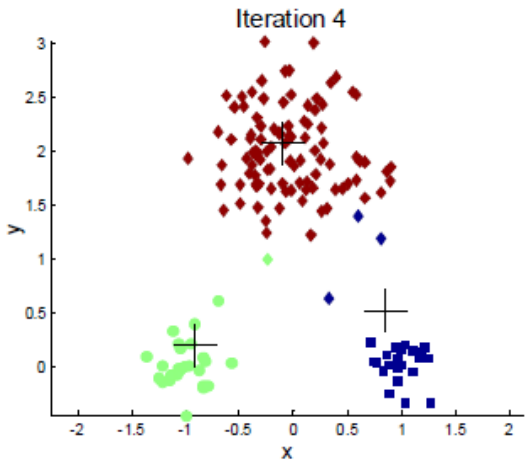


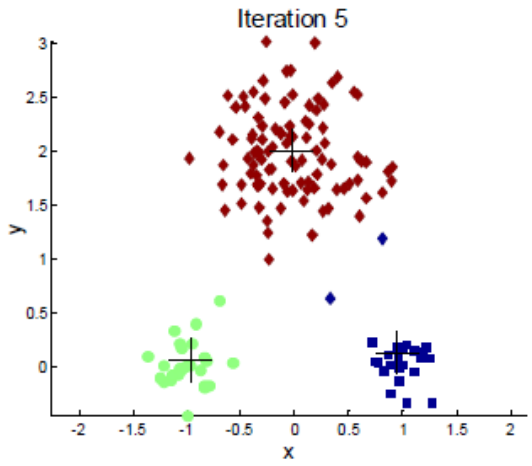
# 初始点的影响

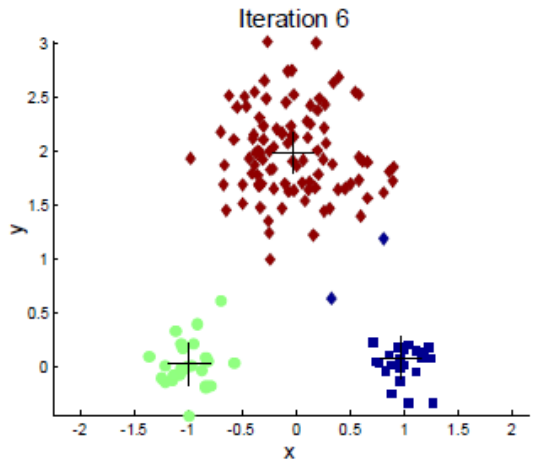

Iteration 1
x
y


Iteration 2
x
y


Iteration 3
x
y

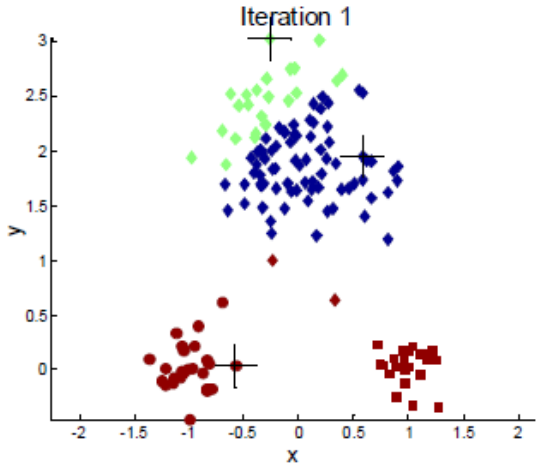

Iteration 4
x
y

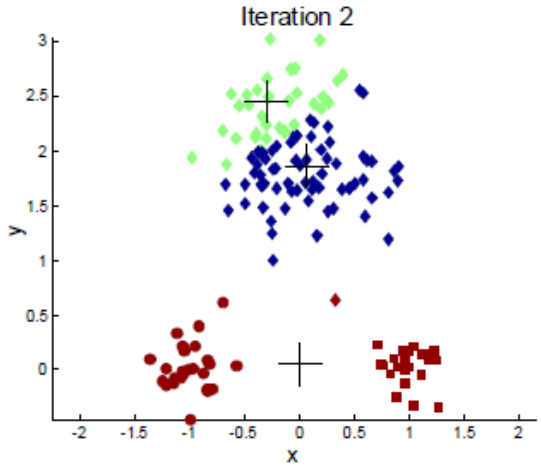

Iteration 5
x
y

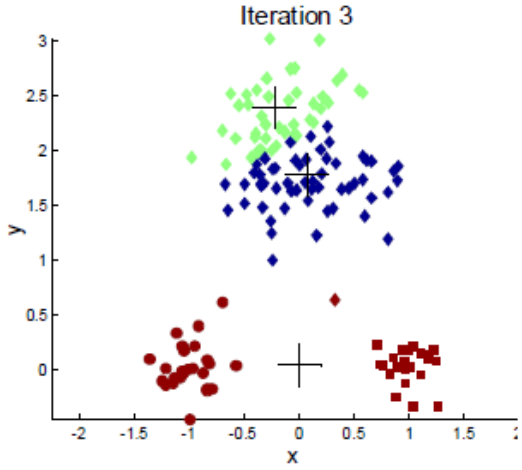

Iteration 6
x
y

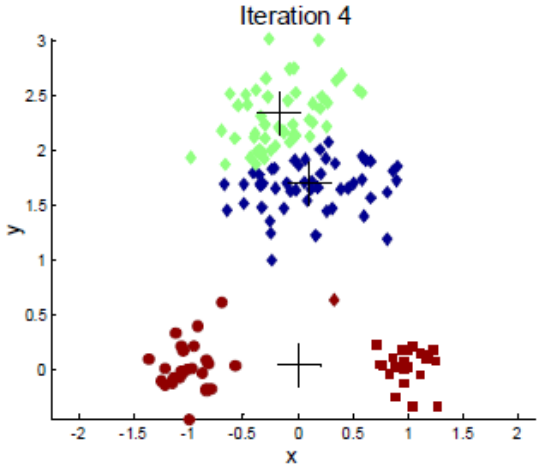


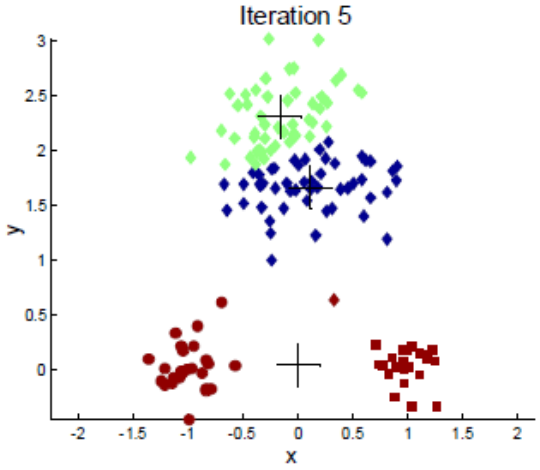
# 初始点的影响


Iteration 1
x
y


Iteration 2
x
y


Iteration 3
x
y


Iteration 4
x
y


Iteration 5
x
y



# *k-means* 算法

- **优点：**
  - 可扩展性较好，简单，适用于规则的不相交簇
  - 算法收敛速度较快
  - 算法复杂度为$O(nkt)$
    - 其中：$n$ 为样本个数，$k$ 是簇的个数，$t$ 是迭代次数
- **缺点：**
  - 簇数目 $k$ 需要事先给定，但非常难以选定；
  - 初始聚类中心的选择对聚类结果有较大的影响（会出现局部最优）；
  - 不适合于发现非球状簇；
  - 对噪声和离群点数据敏感。



# *k-medoids* 算法

***k-means*算法存在两方面不足：**

**（1）仅适用于数据对象平均值有意义的数据集，无法处理名义尺度或序数尺度数据；**

**（2） 每次迭代中，*k-means*算法通过计算簇均值重新指定簇中心，容易受到极大值或孤立点数据影响**

**因此改进办法是不采用簇对象的平均值，取而代之，用每个簇中最靠近中心的对象，即 *medoid*，作为簇中心（原型，代表对象）称这种基于 *medoid* 的聚类算法为*k-medoids***



# *k-medoids* 算法

***k-medoids* 聚类算法的基本思路为：**

**算法首先随机地选择 *k* 个对象，每个对象初始地代表了一个簇的中心。**

**剩下的对象根据与各簇中心的距离，分配到最近的簇中心。被分配到同一个中心的所有数据对象构成一个簇。**

**然后反复地用非中心对象替换中心对象，重新指派非中心对象，改进聚类质量，即降低相异度值，直到簇中心不发生变化。**



# *k-medoids* 算法

- 优点
  - 对属性类型没有局限性
  - 通过簇内主要点的位置来确定选择中心点，对孤立点和噪声数据的敏感性小
- 不足
  - 处理时间要比 *k-mean* 更长
  - 用户事先指定所需聚类簇个数 *k*
  - 发现的聚类与输入数据的顺序无关





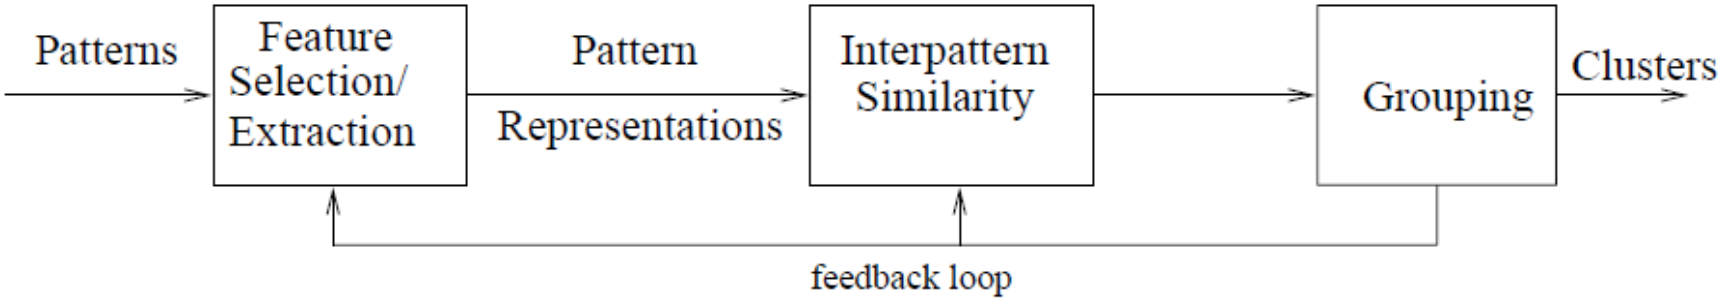
# *Sequential Leader Clustering*（连续引导聚类）

- **一种非常有效的聚类算法**
  - ***No iteration*（无迭代）**
  - ***A single pass of the data*（数据单个传递）**
- **无需事先确定K值**
- **但需要确定簇之间的阈值**
- **对于每一个新的数据点：**
  - **计算新数据点与每个集群中心之间的距离**
  - **如果最小距离小于所选的阈值，则将新数据点分配到相应的集群并重新计算集群中心**
  - **否则，创建一个以新数据点为中心的新集群**
- **聚类结果可能受数据点序列的影响**





# The Big Picture




***Key Point：Similarity***



# 分类与聚类（*Classification and Clustering*）

- 尽管分类是一种识别对象组或类的有效手段，但是它常常需要高昂的代价收集和标记大量训练元组集或模式，以便分类法使用它们对每个组建模型
- 希望：
  - 首先，基于数据的相似性把数据集合划分成组
  - 然后，给这些数量相对较少的组指定标号
- 基于聚类的过程的另一个优点：
  - 可以适应变化，并且能够找出区分不同组的有用特征



# 分类与聚类（*Classification and Clustering*）

**分类：** 依赖于已知类别的数据对象，类是预先定义的，类别数已知。在分类分析中，对于目标数据集中存在哪些类是知道的，要做的就是将每个数据对象分别属于哪一类标记出来。

**聚类：** 可看作一种特殊的分类，它用由数据导出的类（簇）标号创建对象的标记，然而与分类又有很大的不同。

聚类要划分的类、类别个数都是未知的。不知道目标数据集到底有多少类的情况下，将所有数据对象划分成不同的类或者说“聚类”，并且使得在这种分类情况下，以某种度量为标准的相似性，在同一聚类之间最小化，而在不同聚类之间最大化。



# 分类与聚类（*Classification and Clustering*）

**在机器学习领域：**

**分类是有监督学习，称为监督分类**

**聚类是无监督学习，称聚类分析为非监督分类**

**有监督分类需提供若干已标记的模式（预分类过的）开发模型，为一个新遇到的但新的、无标记的模式标记类别号。监督分类依赖于已知类别的训练样本，因此又称分类是通过例子学习的。**

**非监督分类将已给定的若干无标记的模式聚集起来，使之成为有意义的聚类。聚类不依赖预先定义的类和训练样本，因此又称聚类是观察学习的。**

**在数据挖掘中，不附加任何条件使用术语分类时，通常是指监督分类。**



# 作业

1. 聚类的定义。
2. 根据分类方法聚类可分为哪两个类型，分别举出算法事例。
3. 聚类分析对算法的基本要求。
4. 什么是相似性度量?
5. 分别列出连续型、二值离散型、多元离散型属性的相似性计算方法及衡量指标。
6. 写出 *k-means* 算法的基本思想。
7. 列出 *k-means* 算法的优缺点。
8. 总结分类和聚类的相同点和不同点。

**本次作业请于*10/23*日中午放学前提交**