分类模型总体判断的准确率：

$$Accuracy = \frac{TP + TN}{TP+TN+FP+FN}$$

查全率：

$$Sensitivity = Recall = \frac{TP}{TP+FN}$$

查准率：

$$Precision = \frac{TP}{TP+FP} \qquad Negative\ Prediction = \frac{TN}{TN+FN}$$

几何均值：

$$G\text{-}mean = \sqrt{\prod_{j=1}^{m} Recall_j} \qquad Acc^{+} = \frac{TP}{TP+FN} \qquad Acc^{-} = \frac{TN}{TN+FP}$$

决策树

定义：从数据产生决策树的机器学习技术

决策树可建立分类和预测模型.

决策树归纳的基本算法是贪心算法，它以自顶而下递归各个击破的方式构造决策树

在决策树生成过程中，分割方法即属性选择度是关键。

信息熵

信息变化的平均信息量称为"信息熵"

信息熵越大，信息越不容易预测

C4.5 算法

$$GainRatio(A) = \frac{Gain(A)}{SplitsInfo(A)}$$

SplitsInfo(A) 作用是对A属性的增益值的标准化，
目的是消除属性选择上的偏差

$$SplitsInfo(A) = -\sum_{j=1}^{k} \frac{N_A}{N} \log_2 \frac{N_A}{N}$$ (分得越细，熵越大)

贝叶斯分类算法：

$$P(W|a_i) = \frac{P(a_i|W)P(W)}{P(a_i)}$$

关联规则

$X \Rightarrow Y$, $X \subseteq I$ 且 $Y \subseteq I$, $X \cap Y = \emptyset$

支持度：衡量在数据集中规则出现的频率
项目(或项目集)X的支持是该项目(或项目集)发生的事务的比

$$Support(X) = \frac{\#X}{n}$$

置信度：衡量规则的强度

Lift（提升度）：$P(X,Y)/P(X)P(Y)$，Lift=1时表示X和Y独立

$Lift(X\rightarrow Y)=P(Y|X)/P(Y)=Confidence(X\rightarrow Y)/P(Y)$

Leverage（杠杆率）：$P(X,Y)-P(X)P(Y)$，Leverage=0时X和Y独立

Apriori算法

关键思想：频繁项集的子集必须频繁

任何不频繁项集的超集都不能频繁。

聚类分析类型

·根据分类对象：

Q型聚类（样品聚类）—纵向

R型聚类（指标聚类）—横向

·根据分类的方法：

基于层次：系统聚类

划分法：快速聚类

基于密度法：DBSCAN算法

基于网格的聚类方法

k-means 算法的评价准则：误差平方和准则

$$E=\sum_{i=1}^{k}\sum_{p\in C_i}|p-m_i|^2$$ E越小越好

k：簇的个数 p：簇C_i中的样本 m_i：簇C_i的均值

感知机特性：

线性可分性、算法收敛性

XOR：$p\oplus q=\neg(p\wedge q)\wedge(p\vee q)$

反向传播算法（BP算法-隐含层节点）

$$\frac{\partial E_d}{\partial net_j}=\sum_{k\in Downstream(j)}-\delta_k w_{kj} o_j(1-o_j)$$

复习

数据预处理

- 数据类型和变量类型
- 维度和离群点(检测)
- 数据属性类型，属性描述

PCA和LDA是特征提取

LDA是费歇尔准则，是个优化问题

高维可视化方法：玫瑰图、平行坐标图、箱线图.

信息熵是随机变量不确定性的度量.

ABC数据，可能性矩阵，样本差异度