# 第2讲　数 据

数据的定义

数据集类型

数据预处理（任务，方法）

数据类型转换（标准化、离散化）

数据抽样

主成分分析（PCA）、线性判别分析（LDA)

数据可视化

# 2.1 数据的定义

# Where are data from?



















# 什么是数据?

- 数据是用一组刻画对象基本特性（如物体质量或事件发生时间）的属性描述
- 数据的其他名称
  - 记录、点、向量、模式、事件、案例、样本、观测或实体
- 属性（Attribute）是对象的性质或特性，他因对象而异，或随时间而变化

Attributes

Objects

| *Tid* | Refund | Marital Status | Taxable Income | Cheat |
|---|---|---|---|---|
| 1 | Yes | Single | 125K | No |
| 2 | No | Married | 100K | No |
| 3 | No | Single | 70K | No |
| 4 | Yes | Married | 120K | No |
| 5 | No | Divorced | 95K | Yes |
| 6 | No | Married | 60K | No |
| 7 | Yes | Divorced | 220K | No |
| 8 | No | Single | 85K | Yes |
| 9 | No | Married | 75K | No |
| 10 | No | Single | 90K | Yes |

属性如何测量和描述，既取决于事物本身的客观性质，也和所掌握的技术手段相关



# 属性类型

**属性**是一个数据字段，表示数据对象的特征。

- 在文献中，属性、维度（dimension）、特征（feature）、变量（variance）可以互换的使用。
- “维”，一般用在数据仓库中。
- “特征”，一般用在机器学习中。
- “变量”，一般用在统计学中。
- 一个属性的类型由该属性可能具有的值的集合决定，可以是标称的、二元的、序数的、数值的。



# 属性类型

**标称型：**标称属性的值是一些符号或事物的名称。

- 在计算机科学中，这些值也被看做是枚举的（enumeration）。尽管标称属性的值是一些符号或“事物的名称”，但也可以用数表示这些符号或名称，如发色可以用 0 表示黑色，1 表示黄色。因为标称属性的值不具有有意义的序，而且不是定量的。

**二元或多元型：**二元属性是一种标称属性，只有两个状态：0 或 1。如果两种状态对应的是 true 和 false，二元属性又称布尔属性。

- 例如：“性别”的取值“男性”，“女性”。“HIV”有“阴性”和“阳性”等

**序数型：**序数属性是一种属性，其可能的值之间具有有意义的序或秩评定（ranking），但是相继值之间的差是未知的。

- 比如：对一个餐厅评价“优”，“良”，“差”这些值是有意义的先后次序，但是我们不能说“优”比“良”好多少，“良”比“差”好多少，它们之间的差是未知的。
- 序数属性的其他例子包括：教师有助教、讲师、副教授、教授。对于军衔有列兵，下士、中士等等。



# 属性取值

## 属性取值：连续型和离散型

- **连续型**：定量型、量度型变量，是指在一定区间内可以任意取值的变量
  - 文献中，术语“数值属性”和“连续属性”可以互换的使用。实践中，实数值用有限位数数字表示，连续属性一般用浮点变量表示。
- **离散型**：具有有限个或无限个可数个数，可以用或不用整数表示
  - 有限可数：头发的颜色、学生的人数等都有有限个值，因此是离散的。
  - 无限可数：如果一个属性可能的值集合是无限的，但是可以建立一个与自然数一一对应的映射关系，则该属性是无限可数的。比如说customer_ID 就是无限可数的。

**Ps：** 一种特殊类型的离散型变量是周期变量，例如：星期、月和年中的日期



# 属性类型

- 下面使用一个简单的例子来具体说明属性的各种类型

| 学生ID | 姓名 | 性别 | 选修科目 | 成绩 | 评定 |
|---|---|---|---|---|---|
| 20201203 | Tom | 男 | 语文 | 95.0 | 优 |
| 20201204 | Jerry | 女 | 英语 | 80.5 | 良 |
| 20201205 | Kevin | 男 | 语文 | 77.2 | 中 |
| 20201206 | Mary | 女 | 数学 | 85.3 | 良 |
| 20201207 | Jim | 男 | 数学 | 61.2 | 差 |
| 离散属性 | 标称属性 | 二元属性 | 标称属性 | 连续属性 | 序数属性 |

# 2.2 数据集类型



# 数据集类型（三大类）

- **记录数据**
  - 关系记录
  - 数据矩阵：数值矩阵，交叉
  - 文本数据：词矩阵
  - 事务交易数据
- **基于图形或网络的数据**
  - 万维网
  - 社会或信息网络
  - 分子结构
  - 图像和多媒体
- **有序数据**
  - 时间数据：时间序列
  - 基因序列数据
  - 空间数据：地图
  - 顺序数据：交易序列

**数据集：数据的集合**

| | team | coach | play | ball | score | game | win | lost | timeout | season |
|---|---|---|---|---|---|---|---|---|---|---|
| Document 1 | 3 | 0 | 5 | 0 | 2 | 6 | 0 | 2 | 0 | 2 |
| Document 2 | 0 | 7 | 0 | 2 | 1 | 0 | 0 | 3 | 0 | 0 |
| Document 3 | 0 | 1 | 0 | 0 | 1 | 2 | 2 | 0 | 3 | 0 |

| *TID* | *Items* |
|---|---|
| 1 | Bread, Coke, Milk |
| 2 | Beer, Bread |
| 3 | Beer, Coke, Diaper, Milk |
| 4 | Beer, Bread, Diaper, Milk |
| 5 | Coke, Diaper, Milk |



# 数据集的一般特性

- 维度(Dimensionality)
  - **数据集的维度是数据集中的对象具有的属性数目**
  - 维灾难（Curse of Dimensionality）
  - 维归约（Dimensionality Reduction）
- 稀疏性(Sparsity)
  - 如具有非对称特征的数据集，一个对象的大部分属性上的值都为0
  - 只存储和处理非零值
- 分辨率(Resolution)
  - 数据的模式依赖于分辨率——度量尺度(Scale)
    - 在数米的分辨率下，地球表面看上去很不平坦，但在数十公里的分辨率下却相对平坦
    - 小时标度下的气压变化反映风暴或其他天气系统的移动；在月标度下，这些现象就检测不到



# 数据集类型1：记录数据: 数据矩阵

- 数据矩阵:

如果一个数据集中的所有数据对象都**具有相同的数值属性集**，则数据对象可以看做是**多维空间中的点**，其中每个位代表描述对象的一个不同属性

- 这样的数据集可以用一个mxn的矩阵表示

| preg | plas | pres | skin | insu | mass | pedi | age | class |
|---|---|---|---|---|---|---|---|---|
| 6 | 148 | 72 | 35 | 0 | 33.6 | 0.627 | 50 | positive |
| 1 | 85 | 66 | 29 | 0 | 26.6 | 0.351 | 31 | negative |
| 8 | 183 | 64 | 0 | 0 | 23.3 | 0.672 | 32 | positive |



# 数据集类型1：记录数据: 事务数据

- 典型的记录数据：事务数据或购物篮数据

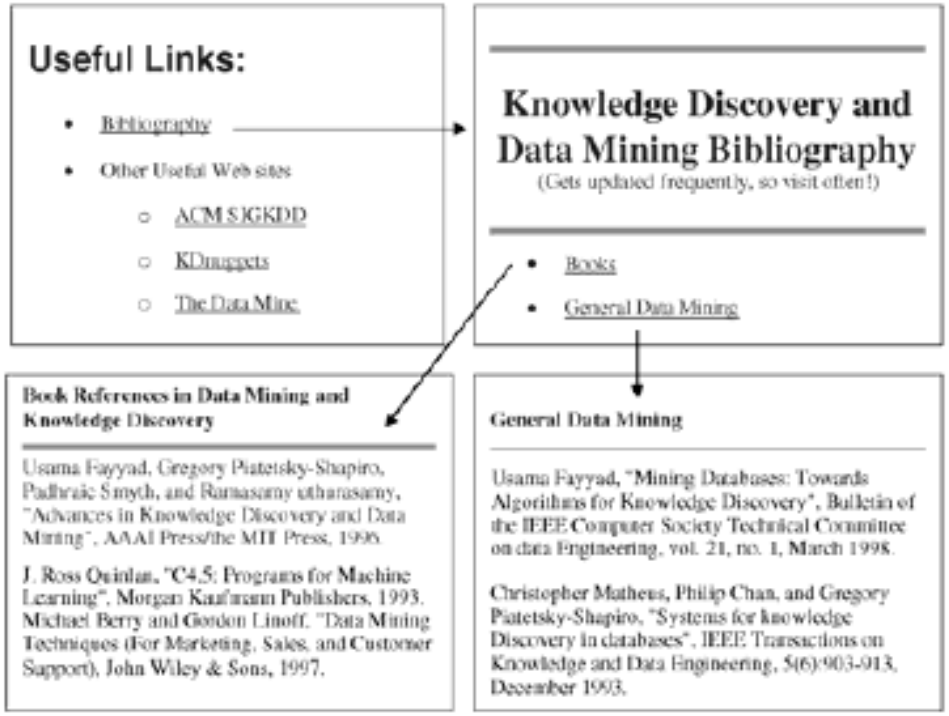
| *Tid* | Refund | Marital Status | Taxable Income | Cheat |
|---|---|---|---|---|
| 1 | Yes | Single | 125K | No |
| 2 | No | Married | 100K | No |
| 3 | No | Single | 70K | No |
| 4 | Yes | Married | 120K | No |
| 5 | No | Divorced | 95K | Yes |
| 6 | No | Married | 60K | No |
| 7 | Yes | Divorced | 220K | No |
| 8 | No | Single | 85K | Yes |
| 9 | No | Married | 75K | No |
| 10 | No | Single | 90K | Yes |

| *TID* | *Items* |
|---|---|
| 1 | Bread, Coke, Milk |
| 2 | Beer, Bread |
| 3 | Beer, Coke, Diaper, Milk |
| 4 | Beer, Bread, Diaper, Milk |
| 5 | Coke, Diaper, Milk |



# 数据集类型2：基于图形的数据1

- 带有对象之间联系的数据
  - Examples: HTML Links

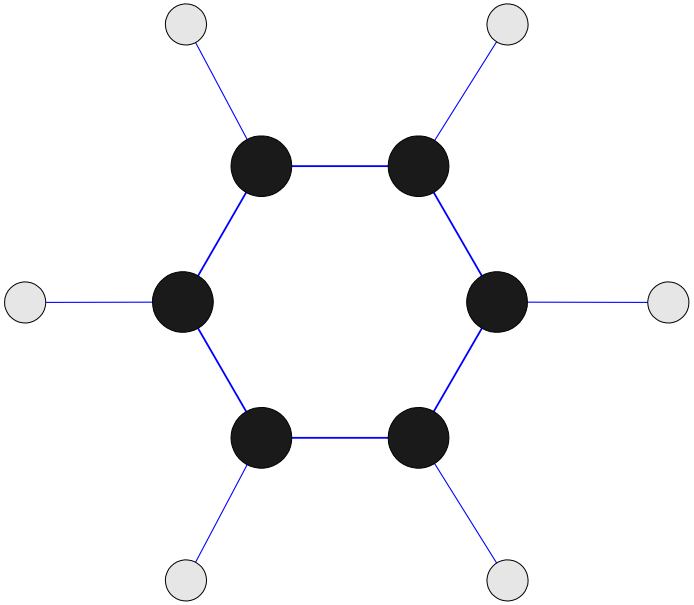



(a) 链接的网页



# 数据集类型2：基于图形的数据2

- 具有图形对象的数据
  - 对象具有结构，即对象**包含具有联系的子对象**
  - 例: 苯分子的球-棍图，包含碳原子（黑色）和氢原子（灰色）





# 数据集类型3：有序数据: 时序数据

- 有序数据有多种，常常涉及时间或空间排序
- 时序数据（Sequential Data）
  - 也称时间数据（Temporal Data）
  - **时间次序重要, 但具体时间不重要**
  - 例：事务序列

| 时间 | 顾客 | 购买的商品 |
|---|---|---|
| t1 | C1 | A, B |
| t2 | C3 | A, C |
| t2 | C1 | C, D |
| t3 | C2 | A, D |
| t4 | C2 | E |
| t5 | C1 | A, E |

| 顾客 | 购买时间与购买商品 |
|---|---|
| C1 | (t1: A,B) (t2:C,D) (t5:A,E) |
| C2 | (t3: A, D) (t4: E) |
| C3 | (t2: A, C) |



# 数据集类型3：有序数据: 序列数据

- 序列数据（Sequence Data）
  - **个体项的序列**
  - 例：基因组序列数据
    - DNA都由4种核苷酸 A, T, G和C构造
    - 没有时间标记，但与时序数据类似
    - 重要的是在**序列中的位置**

```
GGTTCCGCCTTCAGCCCCGCGCC
CGCAGGGCCCGCCCCGCGCCGTC
GAGAAGGGCCCGCCTGGCGGGCG
GGGGGAGGCGGGGCCGCCCGAGC
CCAACCGAGTCCGACCAGGTGCC
CCCTCTGCTCGGCCTAGACCTGA
GCTCATTAGGCGGCAGCGGACAG
GCCAAGTAGAACACGCGAAGCGC
TGGGCTGCCTGCTGCGACCAGGG
```

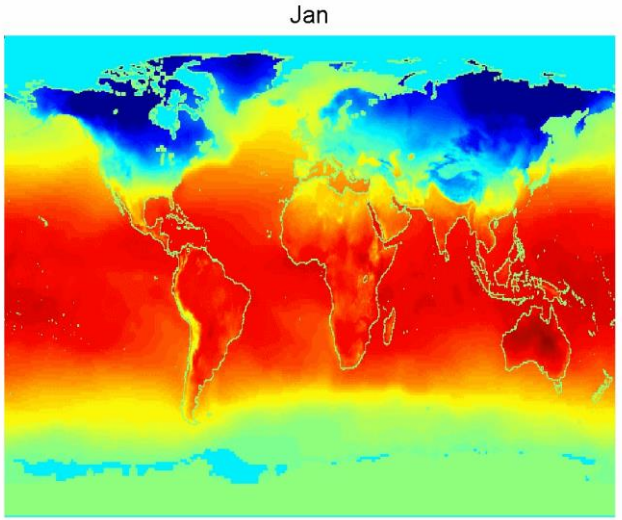
# 数据集类型3：有序数据: 时间序列数据





# 数据集类型3：有序数据:空间数据

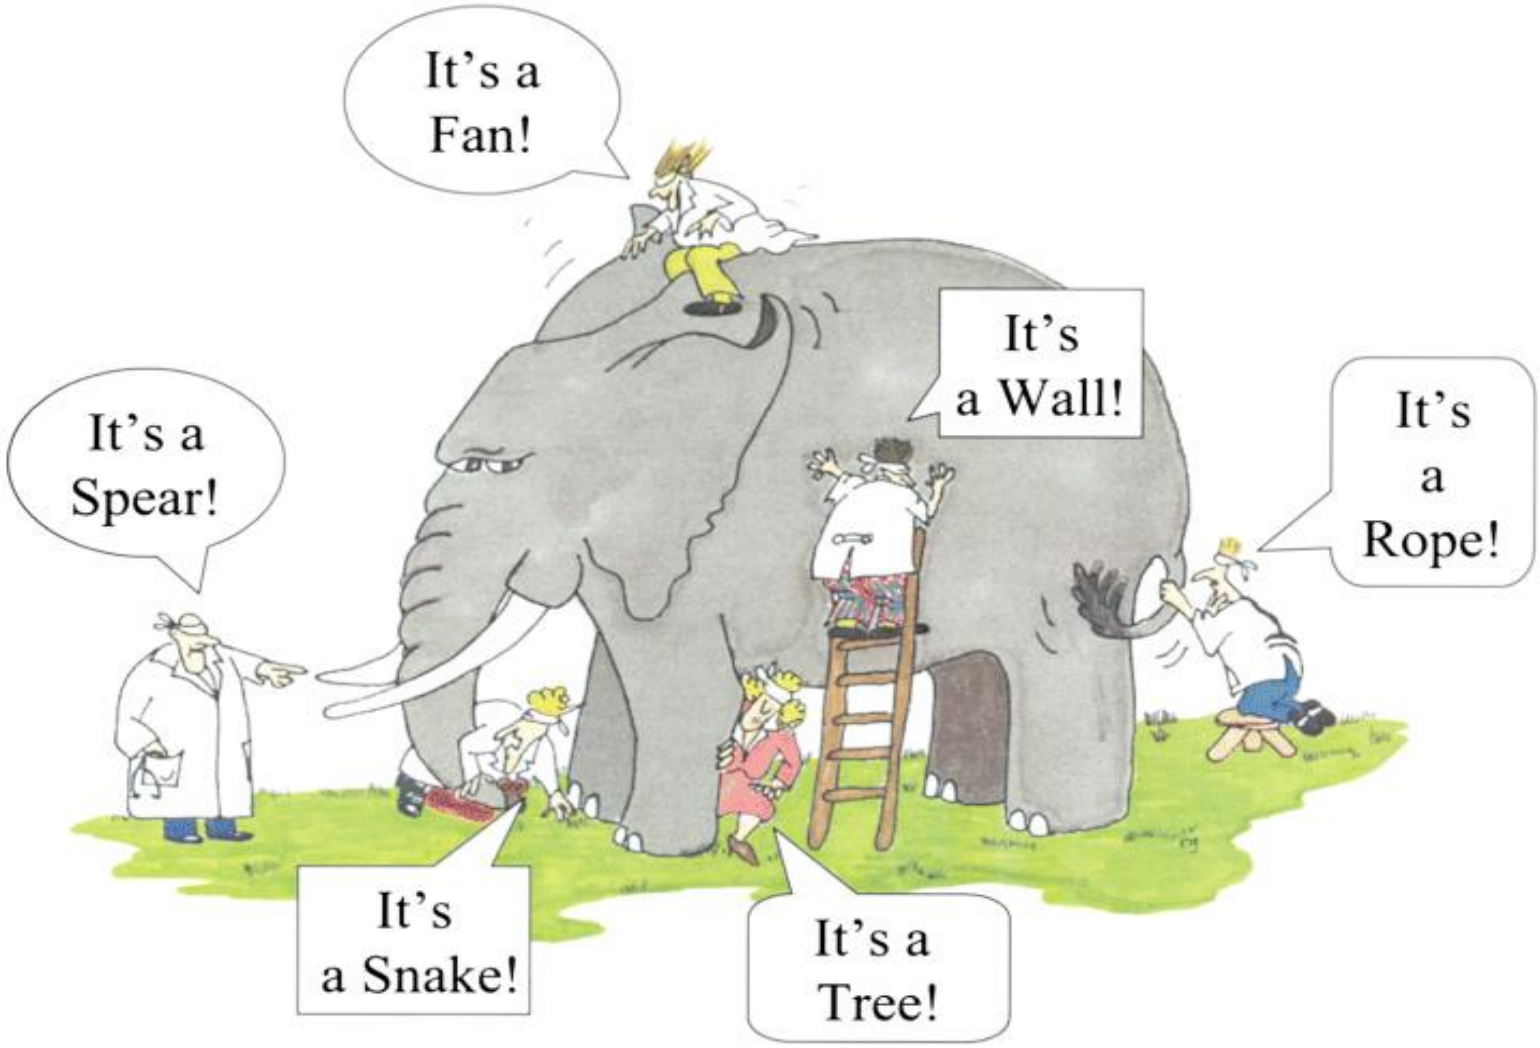
- 空间数据
  - 具有**空间属性**，如位置或区域
  - 例: 不同的地理位置收集的气象数据（降水量、气温、气压）
  - **空间自相关性**（Spatial Autocorrelation）: 物理上靠近的对象趋向于在其他方面也相似
  - 右图每月是空间数据，显示一月份的**时间-空间数据**(Spatial-Temporal Data)



# 2.3 数据的预处理



# 瞎子摸象





# Survivorship Bias 幸存者偏差问题(样本偏差)





# 为什么要数据预处理?

- **Real data are notoriously dirty!**（现实的数据一般都是“脏” 的）
  - The biggest challenge in many data mining projects.
- **Incomplete and Missing data**（不完整和缺失）
  - Occupancy = “ ”
- **Noisy**（噪声）
  - Salary = “-100”
- **Inconsistent**（不一致）
  - Age = “42” vs. Birthday = “01/09/1985”
  - Rate: 1,2,3 vs. A,B,C
- **Redundant**（冗余）
  - Too much data or too many features for analytical analysis
- **Others**（其他）
  - Data types
  - Imbalanced datasets










# 数据预处理

- **典型问题**
  - 属性值缺失
  - 不同的命名方案
  - 不可行的值
  - 不一致的数据
  - 离群值
- **数据质量**
  - 精度（Accuracy）
  - 完整性（Completeness）
  - 一致性（Consistency）
  - 可解释性（Interpretability）
  - 可信性，确实性（Credibility）
  - 时效性（Timeliness）









# 不完整（丢失）数据

- 数据并不总是可用的
  - 例如，许多元组没有属性，如客户收入、销售数据的记录值
- 丢失的数据，可能是由于
  - 设备故障
  - 与其他记录的数据不一致，从而删除
  - 因误会而未读入
  - 在读入的时候，某些数据可能不会被认为是重要的
- 丢失的数据可能需要被推断
  - N/A (Not Applicable)

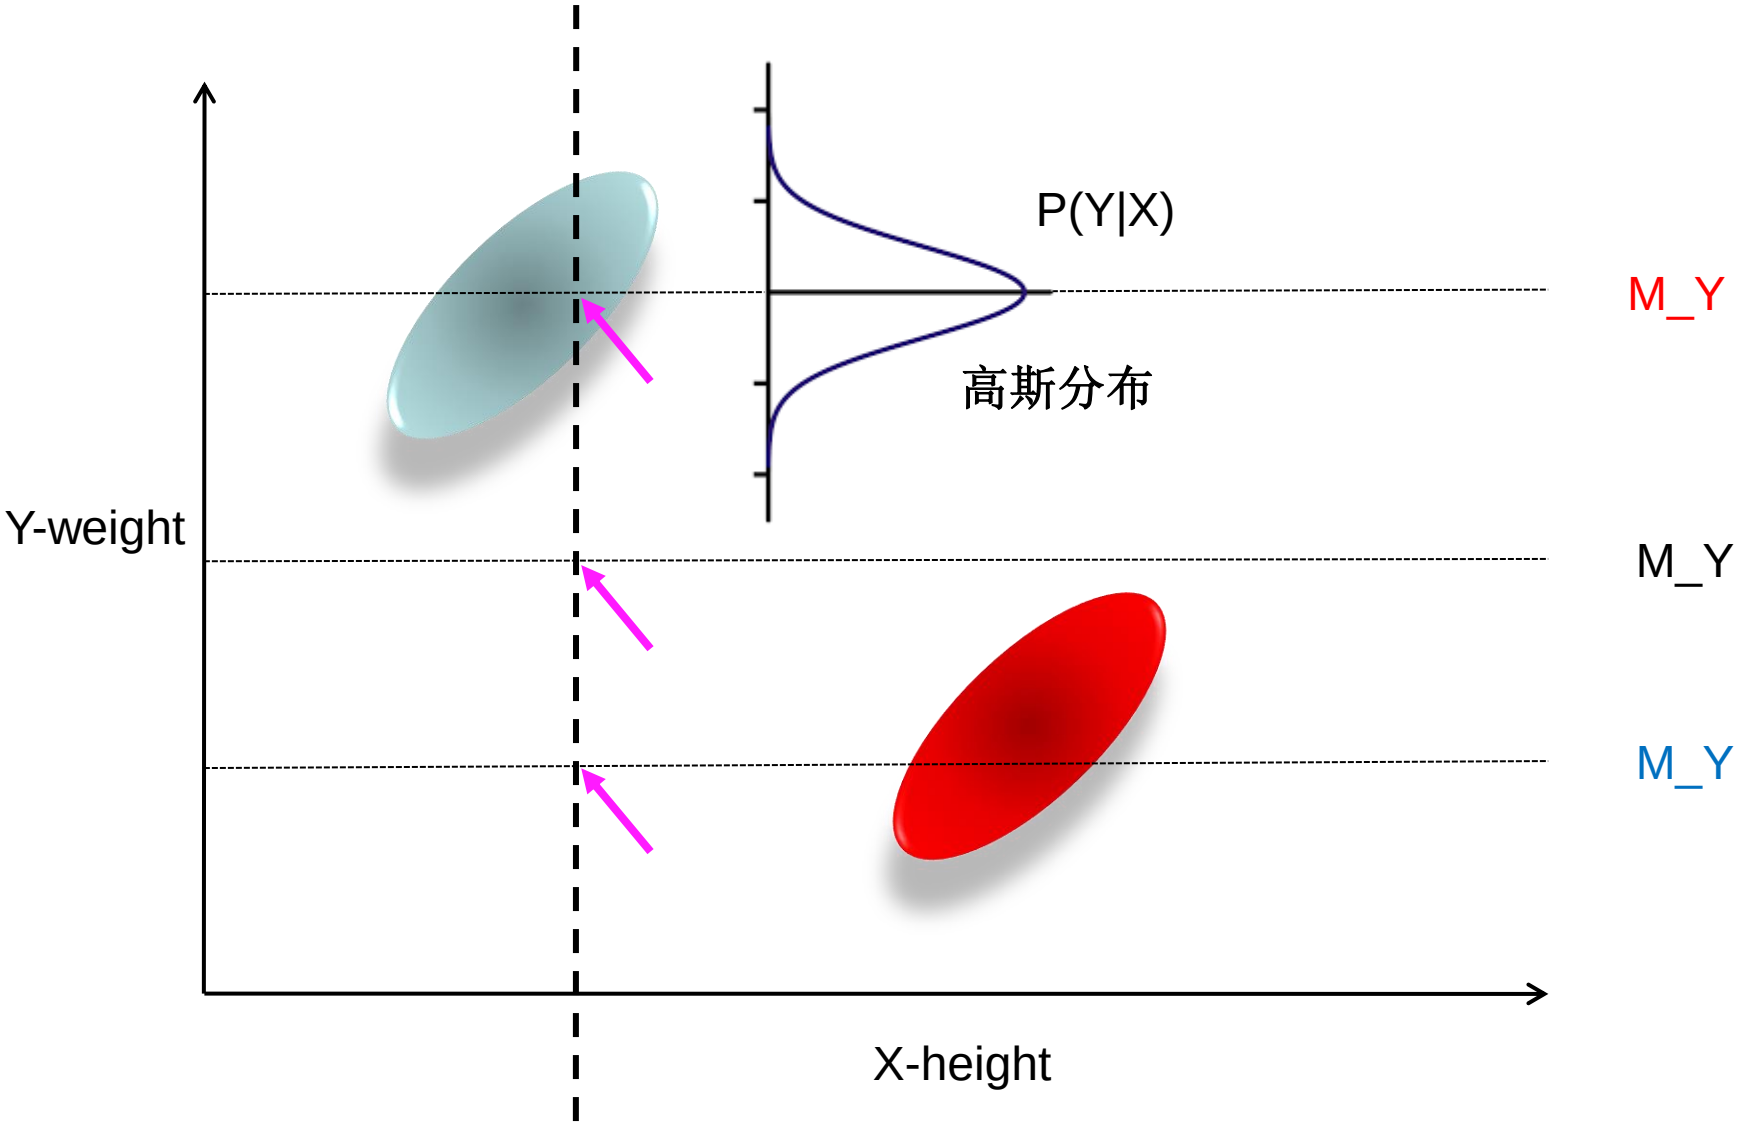




# 如何处理不完整（丢失）数据?

- 忽略元组数据样本：通常是类标签丢失时（分类问题），每个属性的缺失值有很大的差别
- 手动填写遗漏值
- 自动填写
  - 全局常量
  - 属性含义
  - 该属性所有样本属于是否同一类
  - 最有可能的值：基于诸如贝叶斯公式或决策树推理

# 数据缺失问题：





# 噪声数据

- 噪声：数据中存在着**错误**或**异常**(偏离期望值)的数据，这些数据对数据的分析造成了干扰
- 原因
  - 收集工具故障
  - 数据录入问题
  - 数据传输问题
  - 技术限制
  - 命名约定不一致

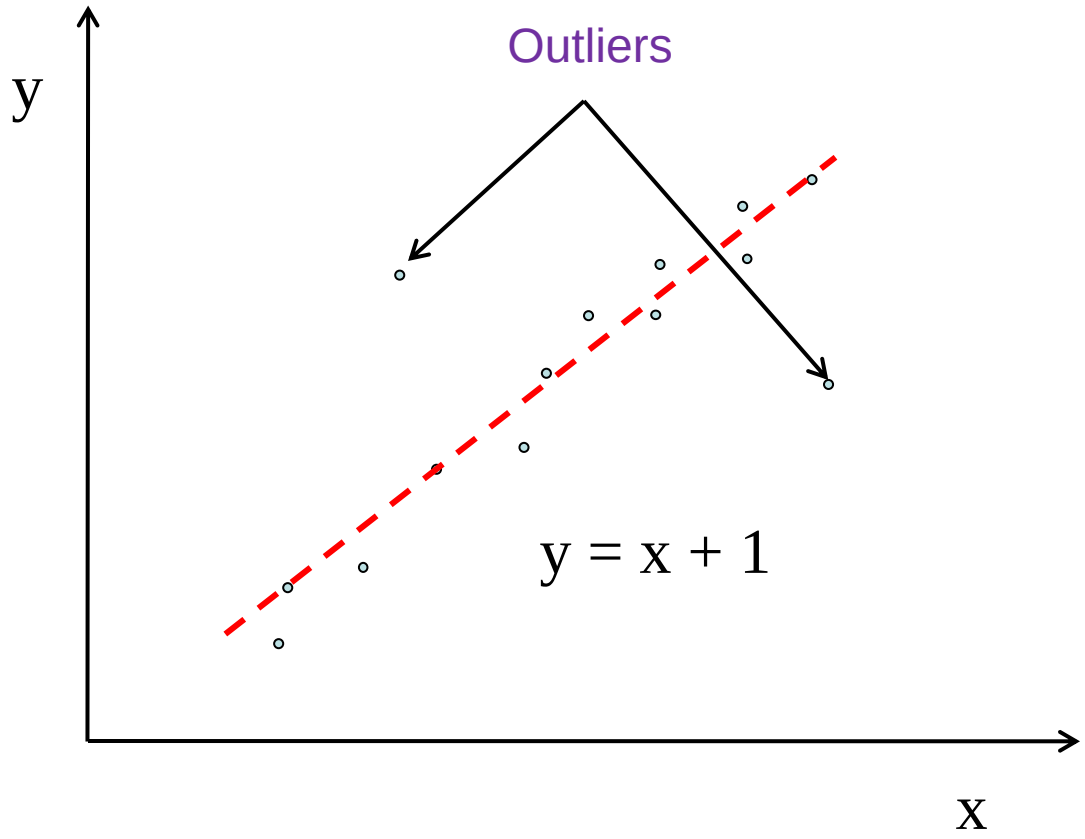


# 如何处理噪声数据（异常值）？

- **回归**
  - 数据拟合能够很清晰地探测到噪声数据，对其进行改正或者删除
- **聚类**
  - 直观地检测和删除异常或离群值
- **结合计算机和人工检查**
  - 检测可疑的数据（如：人工处理可能的异常值）

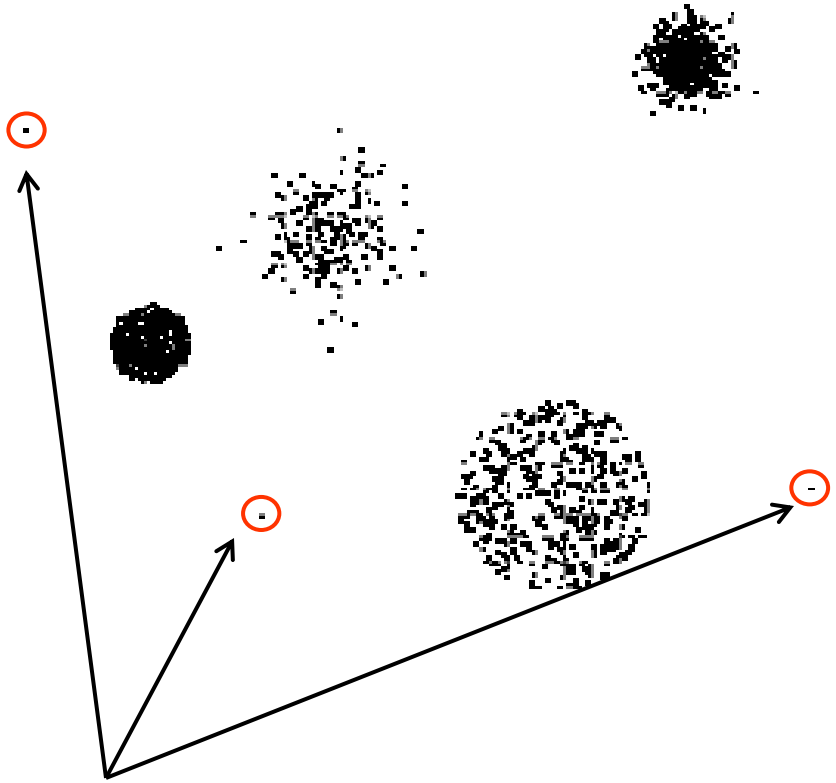


# 离群点（Outliers）





# 离群点（Outliers）



Outliers



# 异常与离群（Anomaly vs. Outlier）





# 异常点（离群点）探测

- 在大型数据集中，通常存在着**不遵循数据模型的普遍行为的样本**，这些样本和其他残余部分数据有很大不同或不一致，叫做**异常点**

- 异常点一般是由测量误差造成的，所以对数据分析的结果可能会产生可变性结果

例如：在检测银行交易中的信用卡欺诈行为时，异常点是可能揭示欺诈行为的典型例子

- 数据异常或离群点简单的探测方法如下：



# 异常值的探测方法

## ◆第一，一维样本异常点的检测方法

- 例如：如果所给的数据集用20个不同的值描述**年龄特征**：

3, 56, 23, 39, 156, 52, 41, 22, 9,28,-32

139, 31, 55, 20, -67, 37, 11, 55, 45, 37

**均值=39.9; 标准差=45.65**

**阈值=均值±2×标准差**

- 那么，所有在**[-54.1, 131.2]**区间以外的数据都是潜在的异常点。根据实际可以把区间缩减到**[0, 131.2]**，由这个标准发现3个异常点：156, 139, -32, -67



# 异常值的探测方法

## 第二，基于距离的异常点检测（**二维以上数据**）

- 例如：数据集为：

$S=\{S_1,S_2,S_3,S_4,S_5,S_6,S_7 \ldots\ldots\} =$

$\{(2,4),(3,2),(1,1),(4,3),(1,6),(5,3),(4,2),$

$(6,6),(3,1),(7,2),(4,4),(5,1),(1,3),(2,2),(5,7)\ldots\ldots\}$

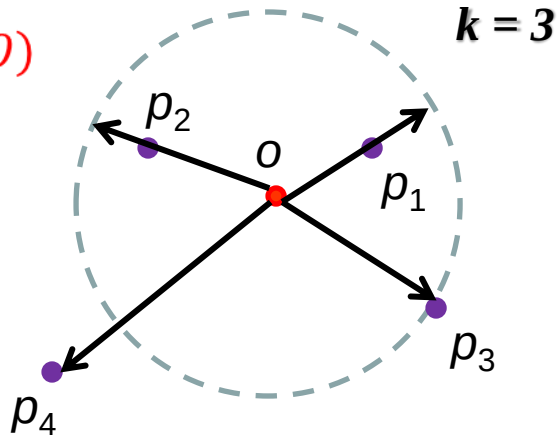
欧氏距离 $d=[(X_1-X_2)^2+(Y_1-Y_2)^2]^{1/2}$

设定：**阈值**距离为：$d=3$



# Local Outlier Factor

$distance_k(O)$



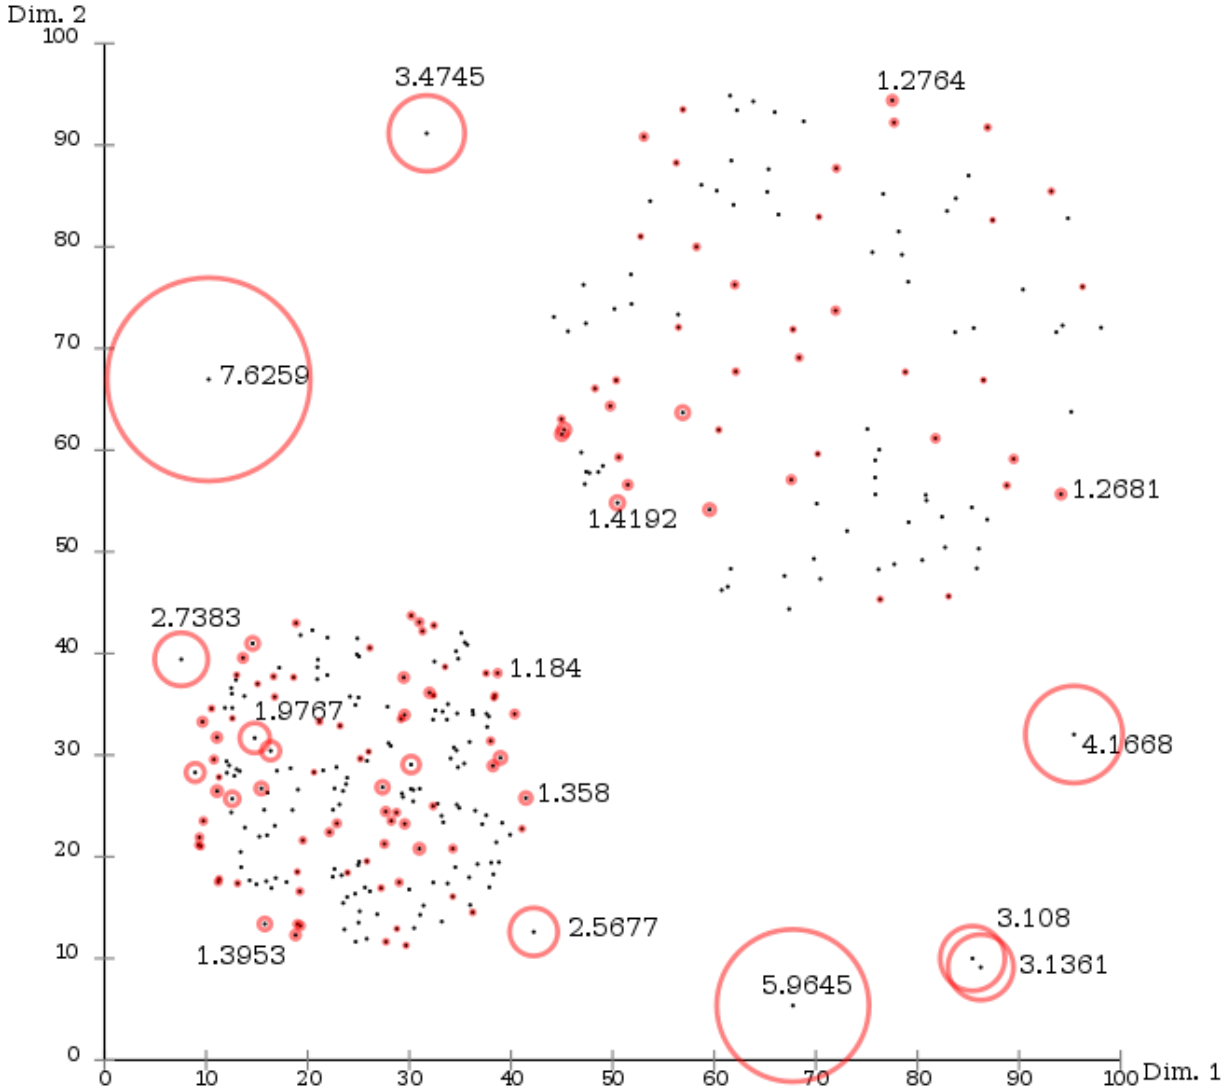

$$distance_k(A,B) = max\{distance_k(B), d(A,B)\}$$

$$lrd(A) = 1/\left(\frac{\sum_{B\in N_k(A)} distance_k(A,B)}{|N_k(A)|}\right)$$

$$LOF_k(A) = \frac{\sum_{B\in N_k(A)} \frac{lrd(B)}{lrd(A)}}{|N_k(A)|} = \frac{\sum_{B\in N_k(A)} lrd(B)}{|N_k(A)|} / lrd(A)$$



# Local Outlier Factor





# 数据预处理主要任务（Data Preprocessing）

- **数据清理（Cleansing）**
  - 处理缺失值
    - 忽略元组：分类时缺少类标签属性时常使用
    - 数据补齐：人工、特殊值、平均值、最可能的值
    - 不处理：鲁棒性（贝叶斯、神经网络）
  - 平滑噪声数据
  - 识别分析孤立点或删除离群点，并解决不一致问题





# 数据预处理主要任务（Data Preprocessing）

- **数据集成（Integration）**
  - 将若干个分散的数据源中的数据，逻辑地或物理地集成到一个统一的数据集合中。这些数据源包括关系数据库、数据仓库和一般文件。
  - 核心任务：将互相关联的分布式异构数据源集成到一起，使用户能够以透明的方式访问这些数据源





# 数据集成中的冗余信息的处理

- 整合多个数据库经常发生数据冗余
  - **目标识别（Object identification）**：相同的属性或对象可能有不同的名字在不同的数据库中
  - **派生数据（Derivable data）**：一个属性可能是“派生”的另一个表中的属性，例如，年收入
- 通过**相关性分析**和**协方差分析**可以检测到冗余的属性
- 仔细集成来自多个数据源，有助于减少/避免冗余和不一致的地方，并提高读取速度和质量



# 属性间相关性分析

- **皮尔森相关系数（Pearson's correlation）**

$$r_{A,B} = \frac{\sum (A-\overline{A})(B-\overline{B})}{(n-1)\sigma_A \sigma_B} = \frac{\sum (AB) - n\overline{A}\,\overline{B}}{(n-1)\sigma_A \sigma_B}$$

其中n是样本的数目，而*A*和*B*是各自属性的具体值， $\sigma_A$和$\sigma_B$是各自的标准偏差

**$r_{A,B}$ = A,B向量协方差/A,B向量标准差**

- 若 $r_{A,B} > 0$, A 和 B 存在**正相关**
- 若 $r_{A,B} = 0$, A 和 B **线性不相关**
- 若 $r_{A,B} < 0$, A 和 B 存在**负相关**

**Ps：**

相关性并不蕴含因果关系，也就是说，如果A和B是相关的，并不意味着A导致B或者B导致A



# 属性间相关性分析

- **卡方检验**
  - 对于标称属性，两个属性A和B之间的相关联系可以通过卡方检验发现， $x^2$ 的值可用下式计算：

$$\chi^2 = \sum \frac{(Observed - Expected)^2}{Expected}$$

| | Play chess | Not play chess | Sum (row) |
|---|---|---|---|
| Like science fiction | 250 (90) | 200 (360) | 450 |
| Not like science fiction | 50 (210) | 1000 (840) | 1050 |
| Sum (col.) | 300 | 1200 | 1500 |

$$\chi^2 = \frac{(250-90)^2}{90} + \frac{(50-210)^2}{210} + \frac{(200-360)^2}{360} + \frac{(1000-840)^2}{840} = 507.93$$



# 数据预处理主要任务（Data Preprocessing）

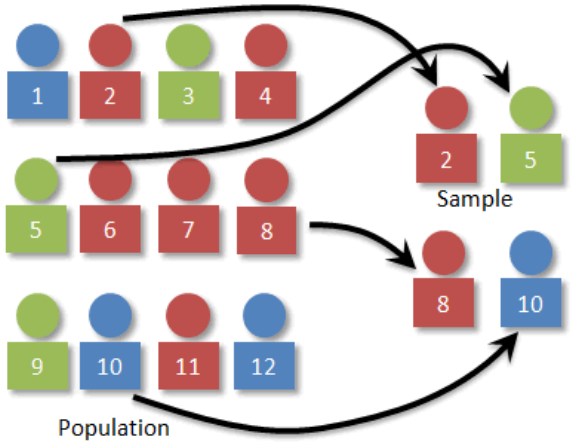
- 数据缩减（Reduction）
  - **在尽可能保持原始数据集完整性的前提下，最大限度地精简数据量。**
  - 降维（维归约）
  - 数据压缩
  - 特征选择（Feature Selection）
  - 特征提取（Feature Extraction）
- 数据转换和数据离散化（Transformation）
  - 正常化操作
  - 标准化操作
  - 离散化操作
  - 生成概念层次结构-聚集



# 2.4 数据类型转换

# 数据类型转换

- 即使拥有一个无错误的数据集
- 仍然需要数据的标准化操作
- 数据类型转换
- 数据标准化、离散化
- 数据采样








# 数据属性的描述与分布

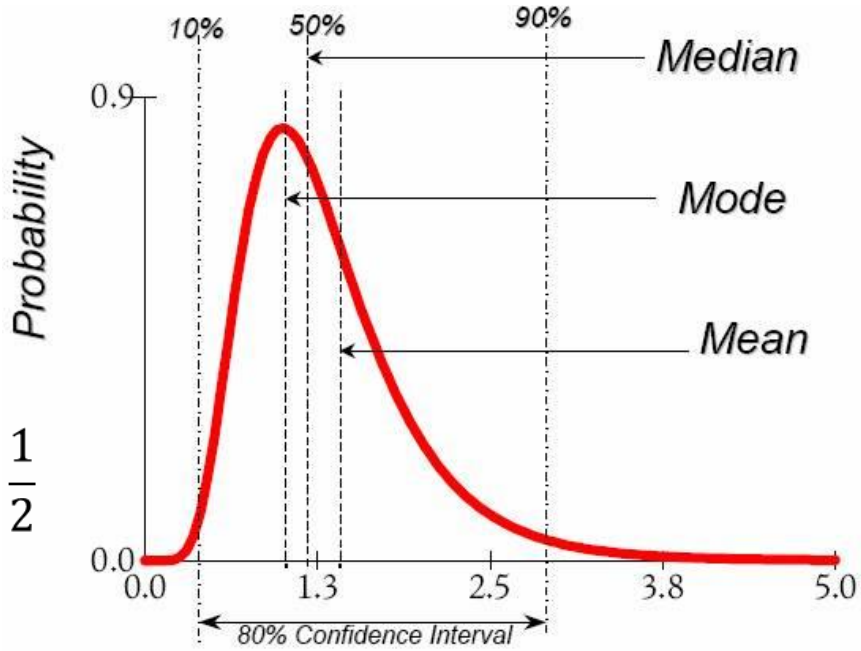
- **均值**
  - 算术平均值

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{1}{n}(x_1 + \cdots + x_n)$$

- **中位数**

$$P(X \le m) = P(X \ge m) = \int_{-\infty}^{m} f(x)dx = \frac{1}{2}$$

- **频率Mode**
  - 列表中最常出现的值
  - 可以与非数值数据一起使用




- **方差**
  - -- 自由度多样性

$$Var(X) = E[(X-\mu)^2] \qquad Var(X) = \int (x-\mu)^2 f(x)dx$$

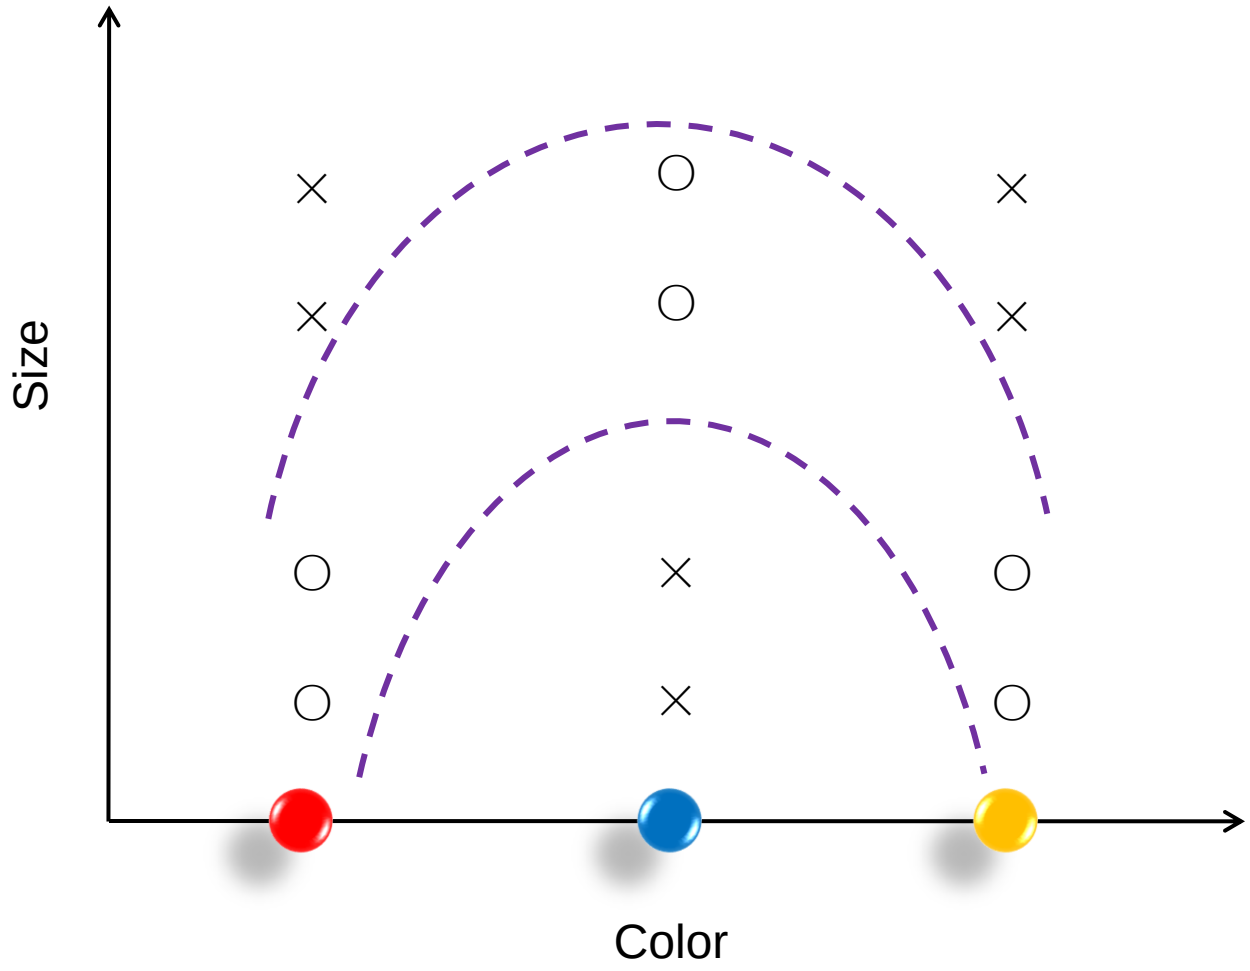


# Attribute Types

- **Continuous**
  - **Real values: Temperature, Height, Weight …**
- **Discrete**
  - **Integer values: Number of people …**
- **Ordinal**
  - **Rankings: {Average, Good, Best}, {Low, Medium, High} …**
- **Nominal**
  - **Symbols: {Teacher, Worker, Salesman}, {Red, Green, Blue} …**
- **String**
  - **Text: “Taizhou University”, “No. 93, Jichuan Road, Hailing …” …**



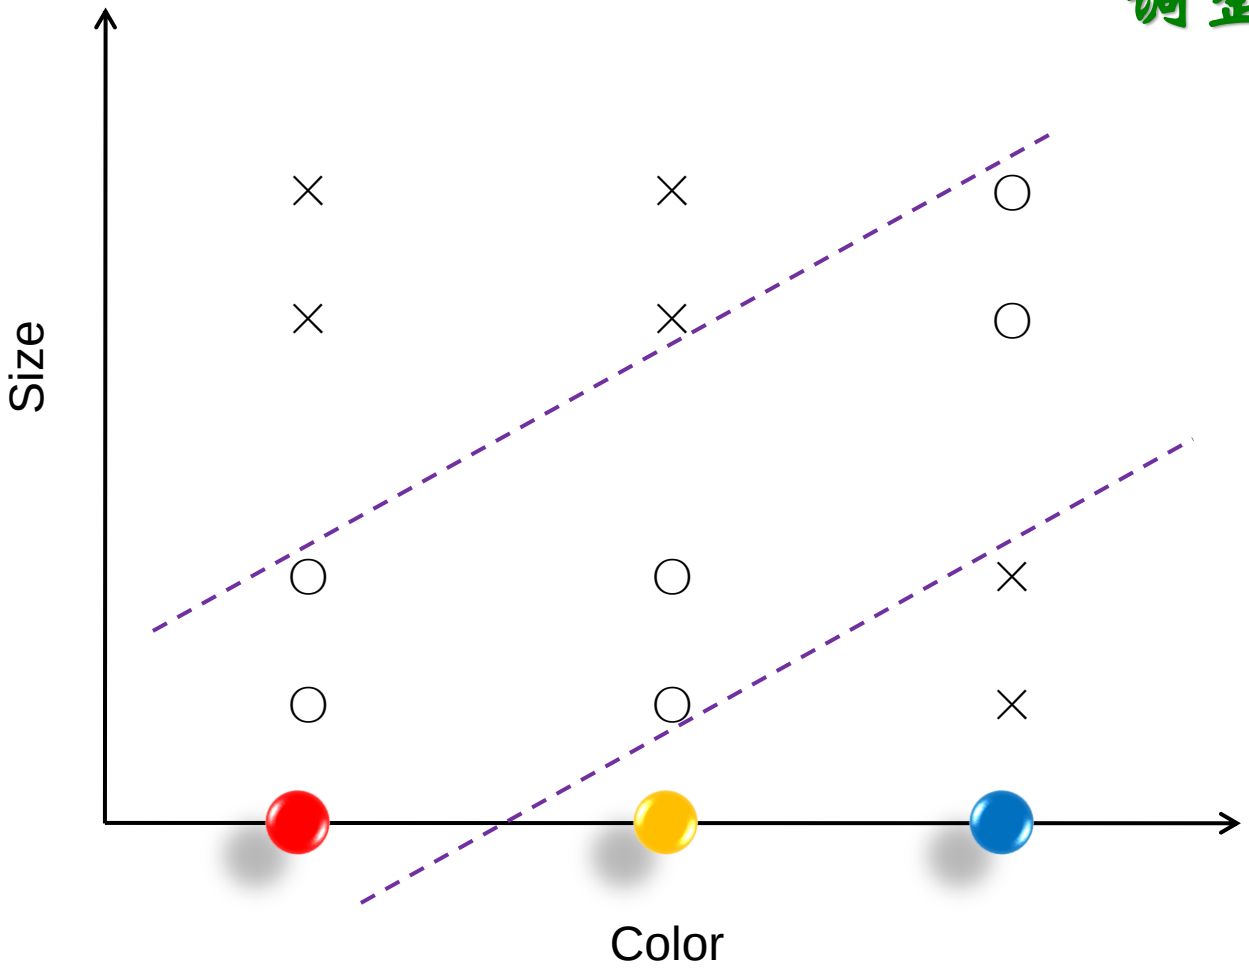
# 类型转换





# 类型转换

调整数据集结构





# 类型转换

R  0 0 0 1

Y  0 0 1 0

调整数据属性编码方式

B  0 1 0 0

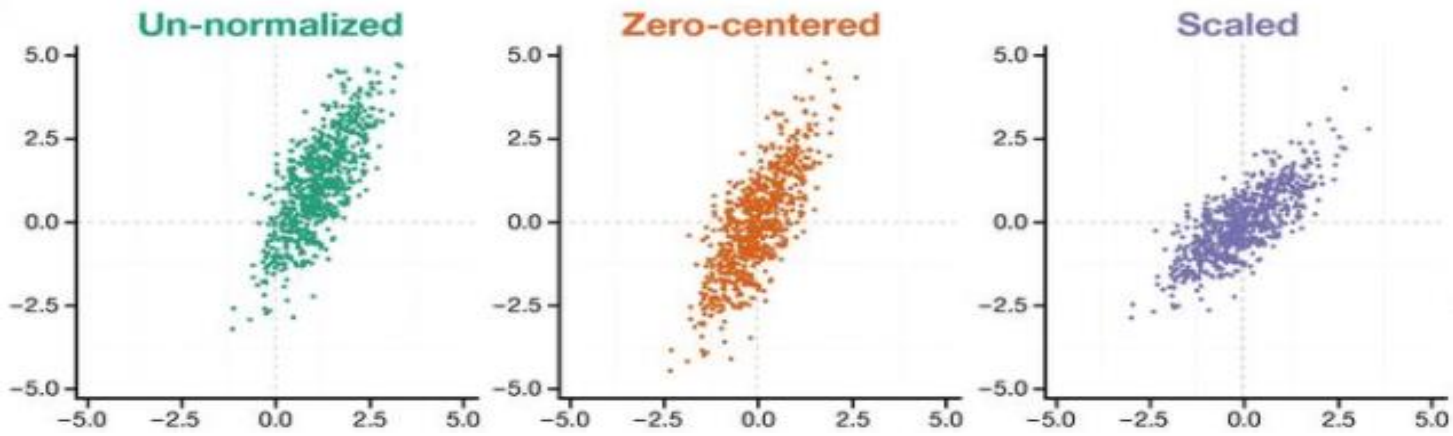
BL  1 0 0 0



# 数据类型转换-数据标准化（规范化）

## 为什么要进行标准化?

* 一些数据挖掘方法，需对数据进行标准化以获得最佳的效果
  * 例如：分类算法-神经网络的算法、最邻近分类算法、聚类的距离度量算法，都需将训练样本属性度量输入值规范化，这样有助于加快学习阶段的速度。
  * 对于基于距离的方法，规范化可以帮助防止具有较大初始值域的属性与具有较小初始值域的属性相比，权重过大。
  * 规范化是指通过将属性数据按比例缩放，使之落入一个小的特定区间，如0.0到1.0，对属性标准化。





# 数据标准化

- 某人的身高是1.7 或170 或 1700 ...
- 极值标准化（数据归一化）：

$$v' = \frac{v - min}{max - min}(new_max - new_min) + new_min$$

  - 让收入范围从 $12,000 到 $98,000 归一化在 [0.0, 1.0]。 那么 $73,600 就可以归一化为：

$$\frac{73{,}600 - 12{,}000}{98{,}000 - 12{,}000}(1.0 - 0) + 0 = 0.716$$

- Z-分数标准化( $\overline{X}$：均值，$S$：标准差):
  (标准差规范化)

$$X_i' = \frac{X_i - \overline{X}}{S}$$

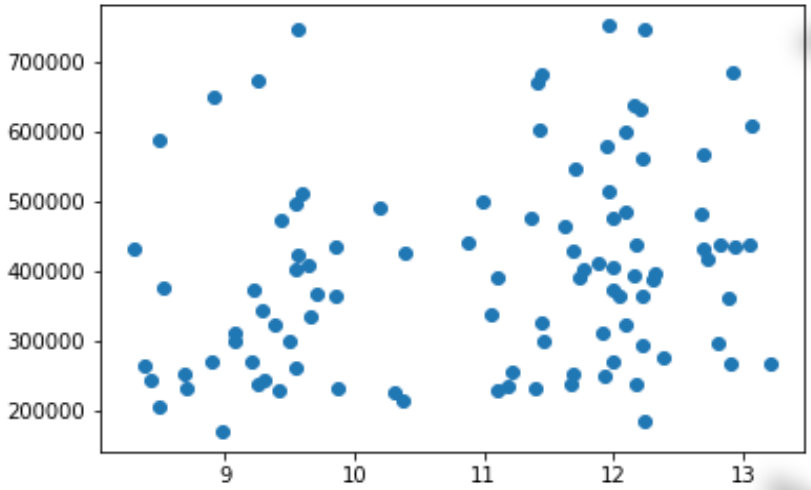
✱ 注意：该方法适用于当属性X的最大和最小值未知，或孤立点左右了最大-最小规范化的情况下。

  - 若 $\overline{X}$ = 54,000，$S$ = 16,000. 则 $\frac{73{,}600 - 54{,}000}{16{,}000} = 1.225$

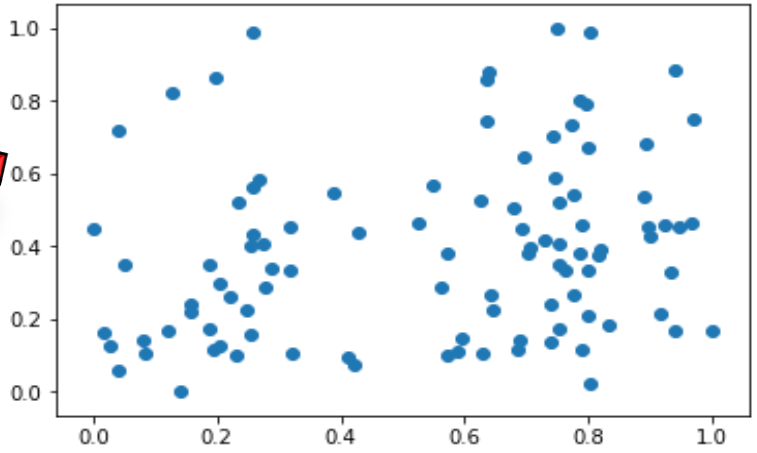


# 数据标准化

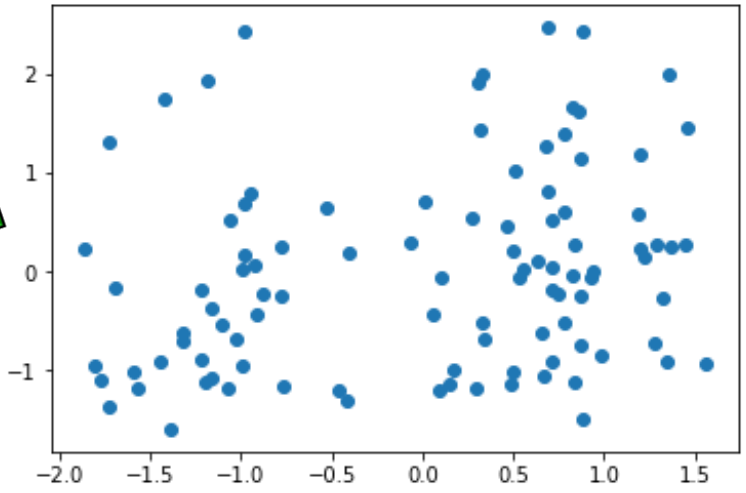
原始数据分布




归一化后




z-分数标准化





# 数据预处理-数据离散化

- **为什么要进行离散化?**

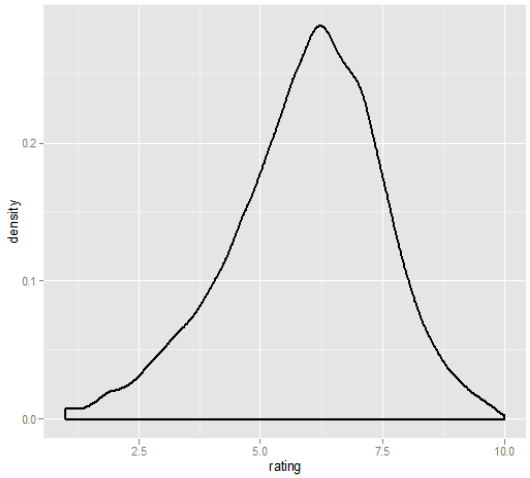
✱在**机器学习**和**数据挖掘**中，已经发展了处理离散型数据的很多算法，如决策树、关联规则及基于粗糙集理论的许多方法，而这些算法对于连续型数据却不适用

✱有些算法即使能处理连续型数据，挖掘和学习也没有处理离散型数据有用和有效。

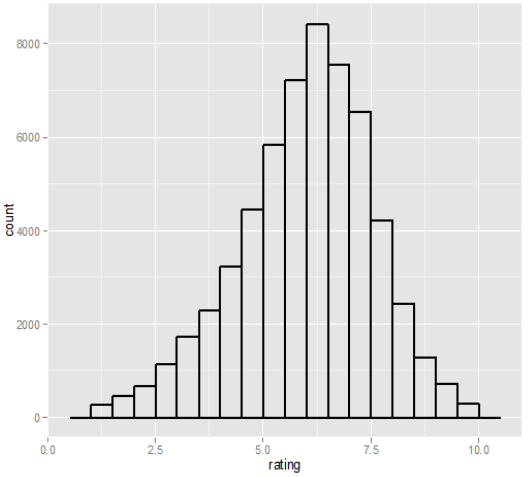


# 数据预处理-数据离散化

- **连续属性的离散化：将数值属性的值域划分为若干子区间，每个区间内所有值映射到一个相同的离散值**
- 离散化方法依据不同的标准主要有以下几种划分：
  - **–有监督和无监督离散化**
  - **–动态和静态离散化**
  - **–全局和局部离散化**
  - **–自顶向下和自底向上离散化、等**







# 有监督和无监督离散化

- **按照离散化过程中是否考虑类别信息，可以将离散化算法分为有监督算法和无监督算法**
- **有监督离散化：**输入样本集中除了待离散化的数值属性外，还有一个或多个离散型的类别属性。这种算法在离散化时，将类别信息作为参考
- **无监督离散化：**在离散化过程中不考虑类别信息的方法，其输入样本集中仅含有待离散化的属性
  - 早期的**等宽**、**等频**的离散化方法是无监督方法的典型代表。
  - 无监督的方法的缺陷在于它对分布不均匀的数据不适用，对异常点比较敏感。



# 有监督和无监督离散化

- **等频等宽的离散化：**

将排好序的数据从最小值到最大值均匀划分成 **n** 等份，每份的间距是相等的。

假设 **A** 和 **B** 分别是**属性值的最小值和最大值**，那么划分间距为 $w = (B - A) / n$

**缺点：** 对异常点比较敏感，倾向于不均匀地把实例分布到各个箱中。

**等宽离散化**

将数据总记录数均匀分为 **n** 等份，每份包含的数据个数相同。

假设 **n=10**，那么每一份中将包含大约10%的**数据对象**。

**缺点：** 可能将**不相同类标号的相同属性值的实例**划分到不同的箱中以满足箱中数据固定个数的条件。

**等频离散化**

# 2.5 数据采样



# 数据采样

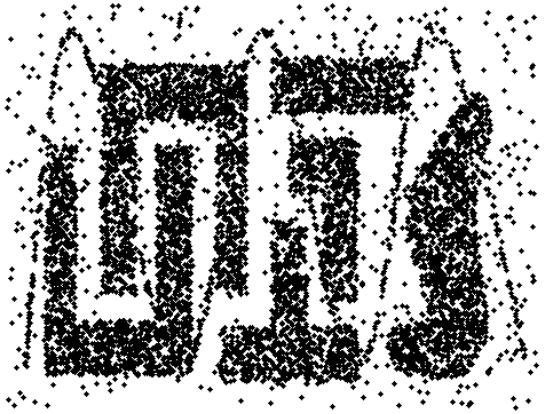
- **数据采样：获得一个小样本代表整个数据样本，它是一种选择数据对象子集进行分析的常用方法**
- 统计学采样vs数据挖掘采样
  - 统计学采样的原因是因为得到感兴趣的整个数据集的代价太高
  - 数据挖掘使用采样是因为处理所有数据的代价太高
- 有效采样主要原则：
  - 简单随机采样
  - 选择有代表性的数据子集
  - 保留原数据集的性质
  - 开发的自适应采样方法，例如分层采样
- 注：采样不得减少数据库

**另一好处：**
**对原始数据集调整数据类的比例**

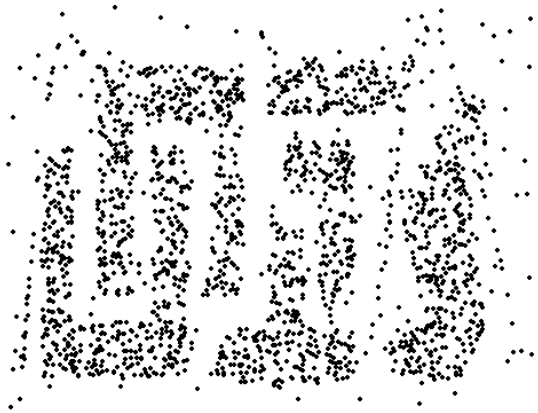


# 样本大小: 例子

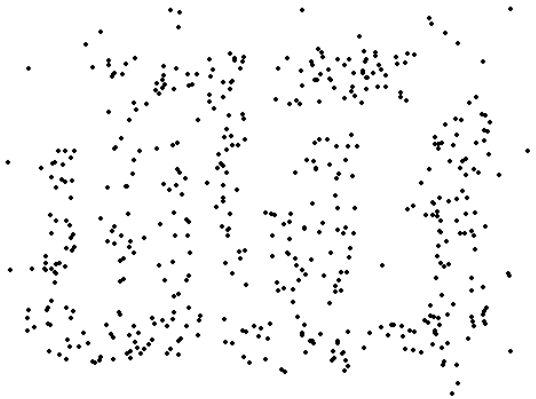
- 从8000个点分别抽2000和500个点
  - 2000个点的样本保留了数据集的大部分结构
  - 500个点的样本丢失了许多结构



**8000 points**



**2000 Points**



**500 Points**

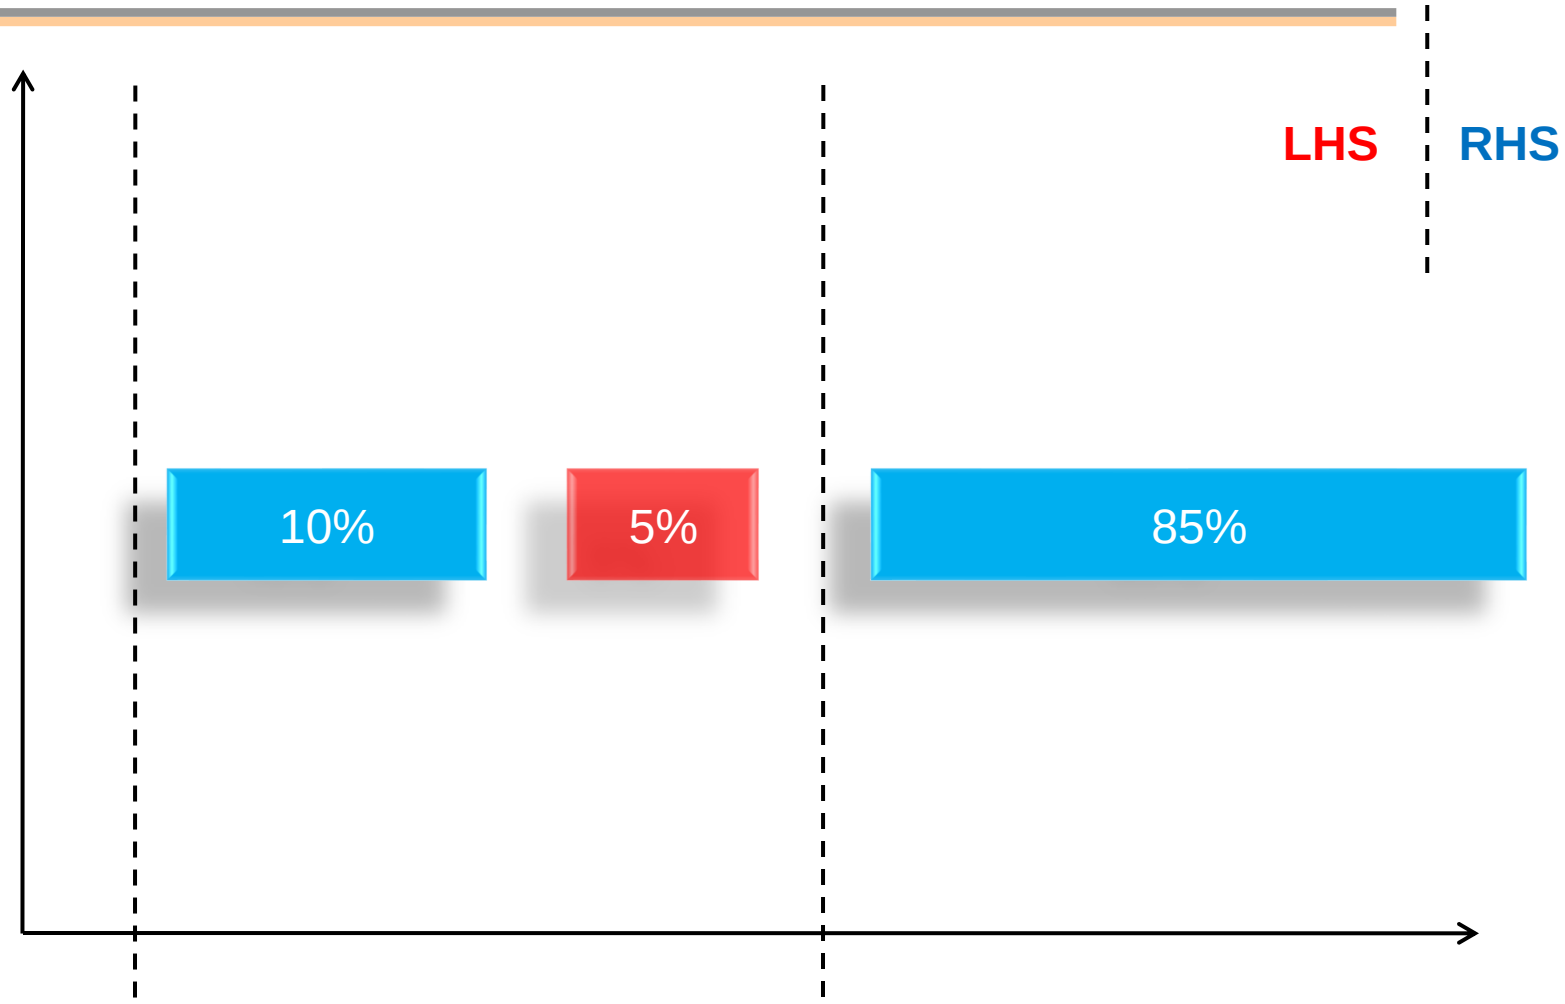


# 采样类型

- 简单随机采样
  - 相等的概率选择
- 不放回采样
  - 一旦对象被选中，则将其删除
- 更换采样
  - 选择对象不会被删除
- 分层采样
  - 对每个分区进行数据集的分区采样（也就是说，大约相同比例的数据进行抽取样本）
  - 用于偏斜数据



# 不平衡数据





# 不平衡数据

►► 对于一些**不平衡数据集**我们不能单纯的从分类算法的分类准确度来衡量分类器的好与坏，必须采用更科学的准确度度量，如：

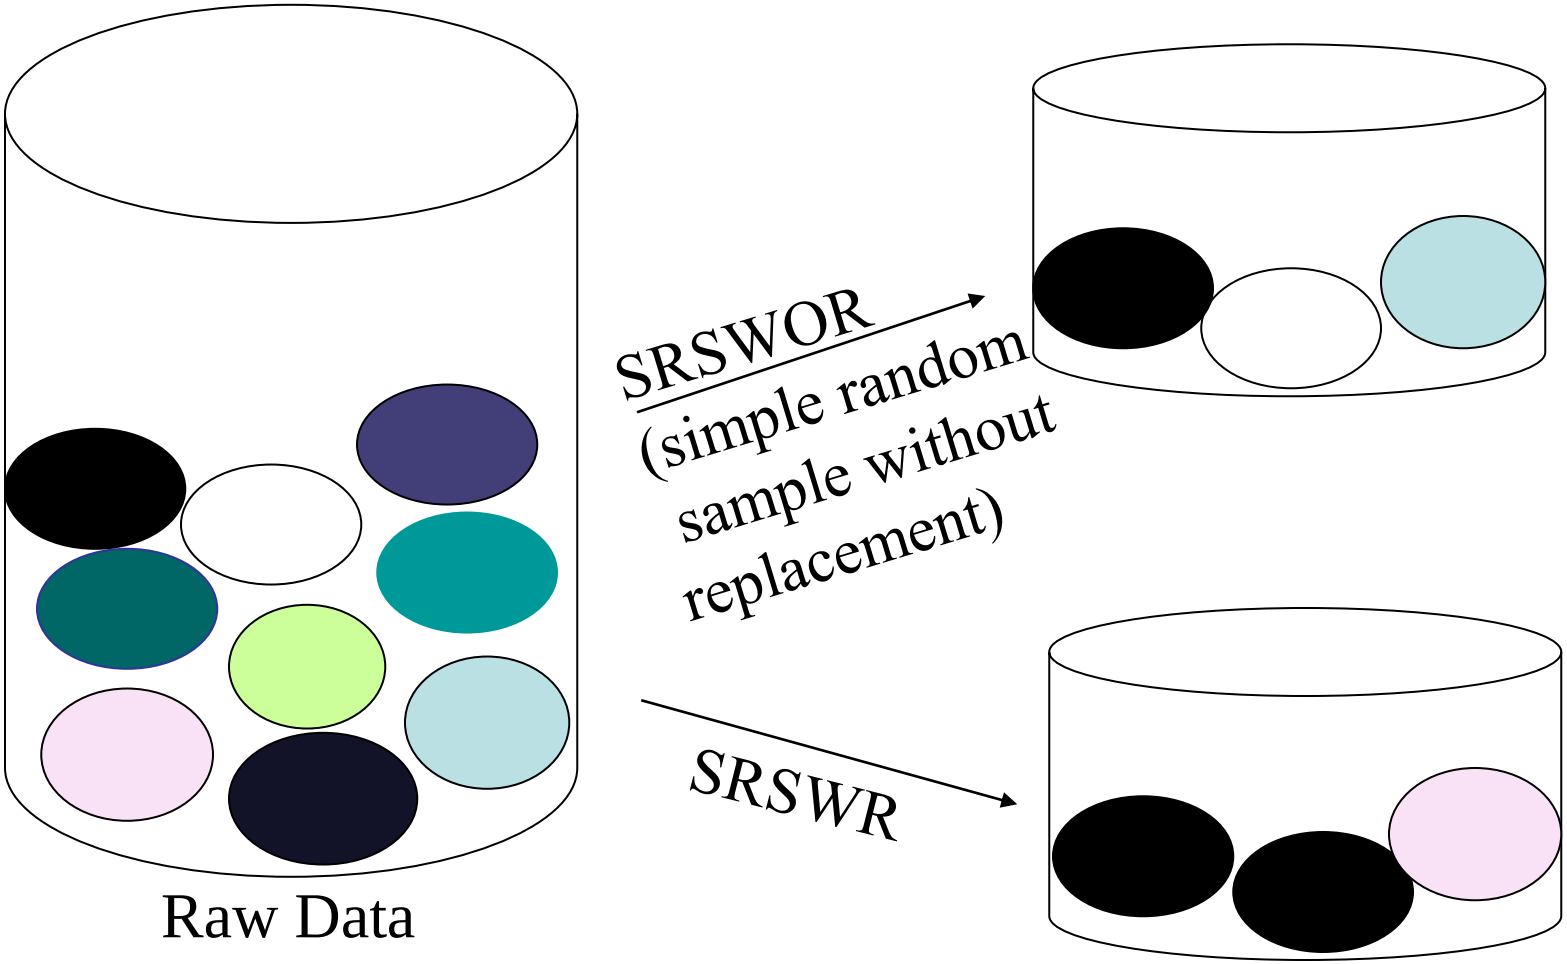
$$G-mean=(Acc^{+}\times Acc^{-})^{1/2}$$

几何均值

$$where\ \ Acc^{+}=\frac{TP}{TP+FN};\quad Acc^{-}=\frac{TN}{TN+FP}$$



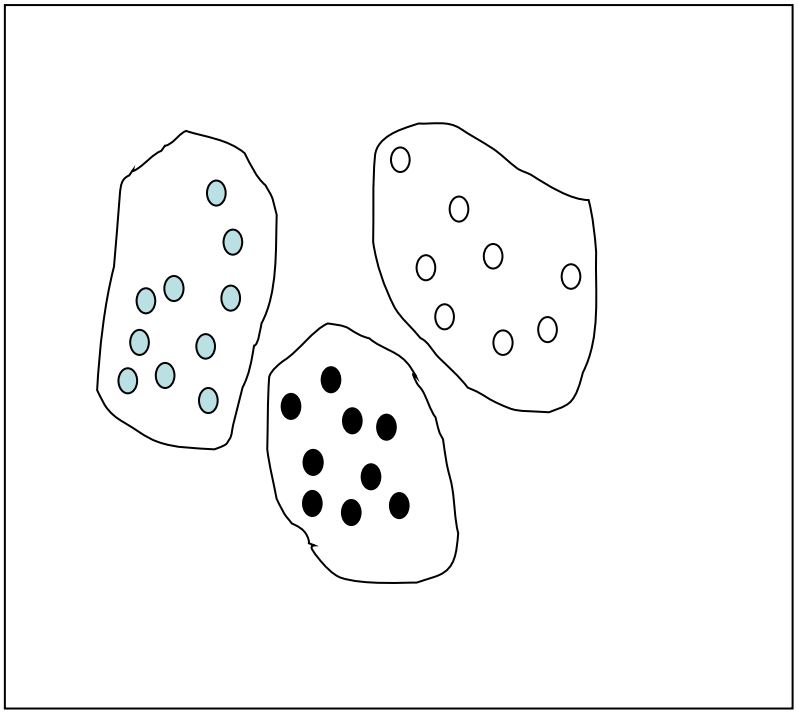
# 取样：用或不用更换


SRSWOR
(simple random sample without replacement)
SRSWR
Raw Data

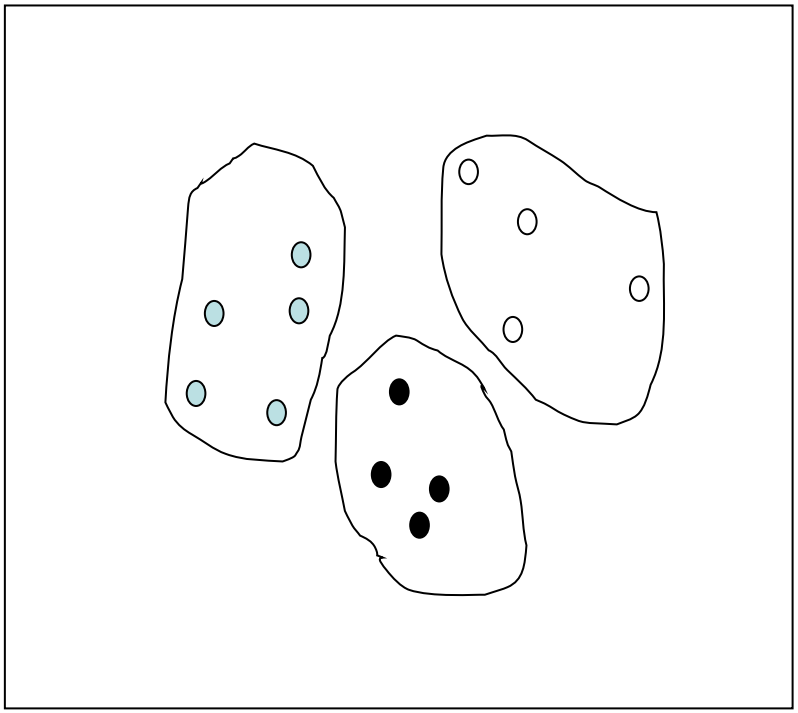


# 采样：群集或分层抽样

Raw Data

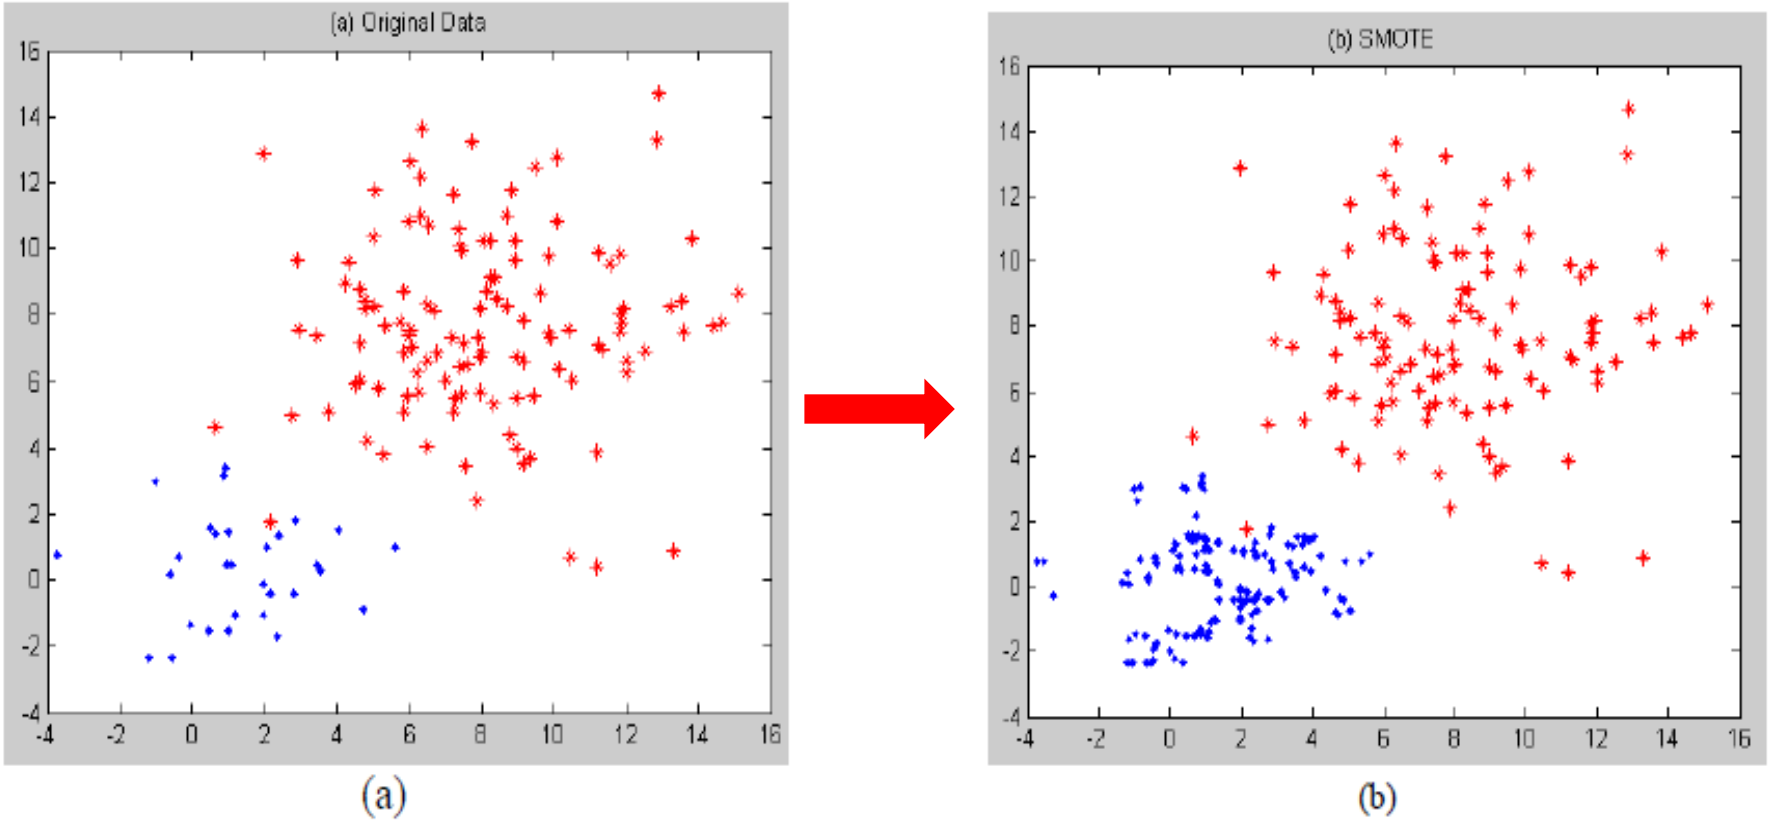


Cluster/Stratified Sample





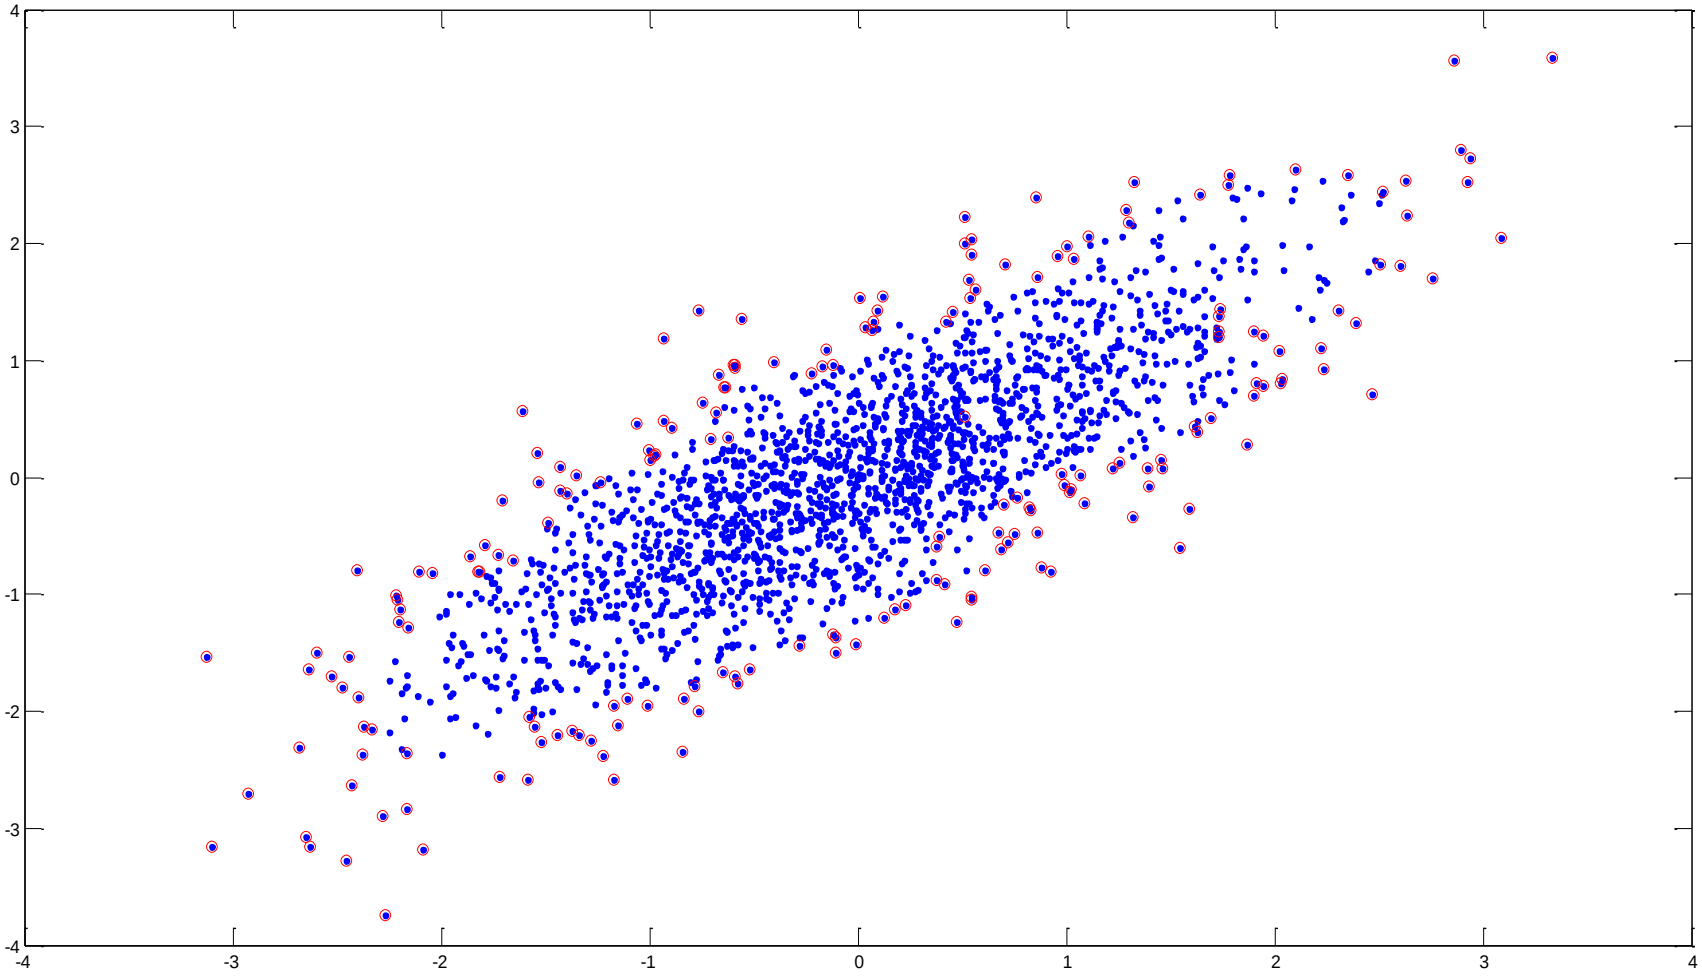
# 过采样




SMOTE



# 边缘采样

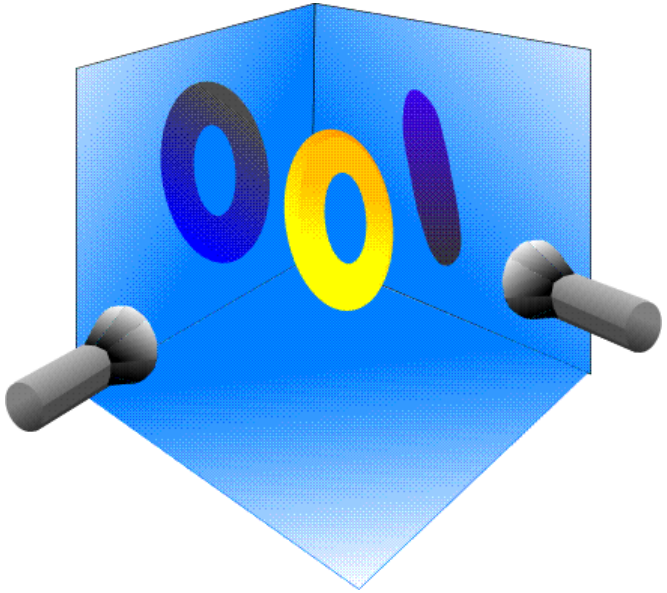


# 特征提取与主成分分析









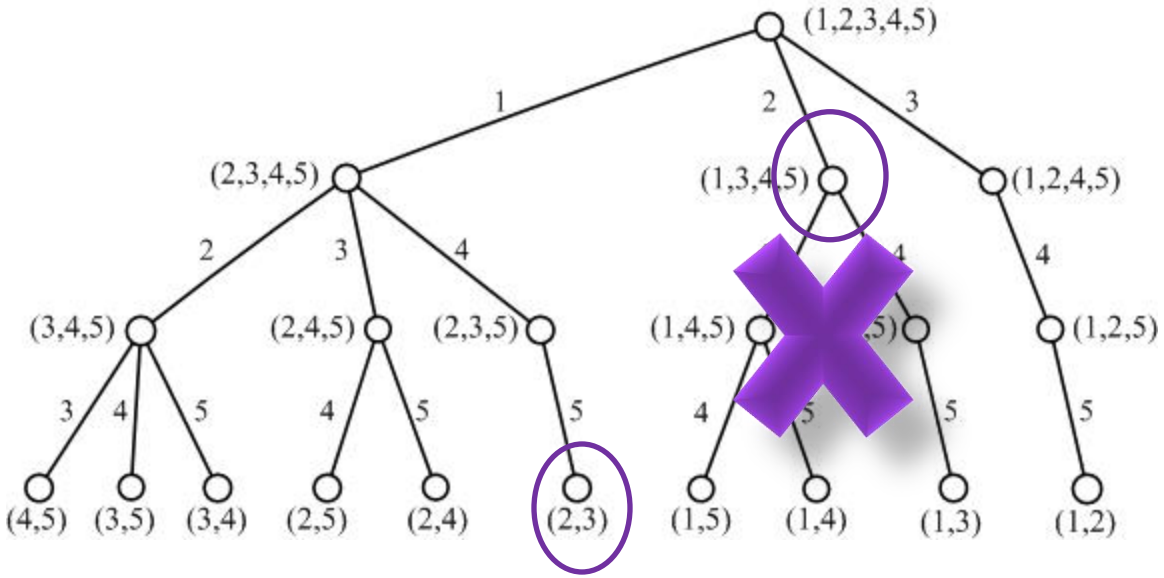


# 搜索特征子集（特征选择）

- **完整**
  - **所有可能性的组合：**

$$C_{10}^{3}=\frac{10!}{(10-3)!3!}=120 \qquad C_{20}^{5}=\frac{20!}{(20-5)!5!}=15504$$

- **分支定界：**




$$S_1 \supset S_2 \supset S_3 \quad \Rightarrow \quad J(S_1) > J(S_2) > J(S_3)$$



# Feature Subset Search

- **Top K Individual Features**

$$J(X_k) = \{J(x_1), \cdots, J(x_k)\},\ J(x_1) > J(x_2) > \ldots > J(x_k)$$

- **Sequential Forward Selection**

$$J(X_k + x_1) > J(X_k + x_2) > \cdots > J(X_k + x_{D-k}),\ x_i \notin X_k$$

- **Sequential Backward Selection**

$$J(X_k - x_1) > J(X_k - x_2) > \cdots > J(X_k - x_k),\ x_i \in X_k$$

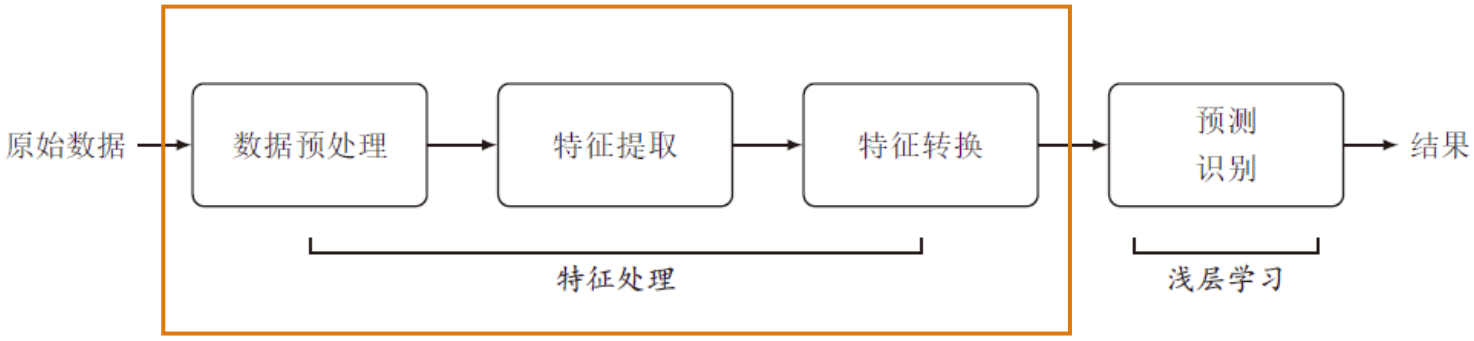
- **Optimization Algorithms**
  - **Simulated Annealing**
  - **Tabu Search**
  - **Genetic Algorithms**
  - **…**





# 特征工程问题

- 在实际应用中，特征往往比分类器更重要
  - 预处理：经过数据的预处理，如去除噪声等。比如在文本分类中，去除停用词等。
  - 特征提取：从原始数据中提取一些有效的特征。比如在图像分类中，提取边缘、尺度不变特征变换特征等。或对特征进行一定的加工，比如降维和升维。降维包括
    - 特征提取（Feature Extraction）： PCA、LDA
    - 特征选择（Feature Selection）：互信息、MRMR、TF-IDF(词频逆向文件频率算法)





# Features or attributes

## Feature Selection and Feature Extraction：

Dimensionality reduction is wide spread preprocessing in high dimensional data analysis, visualization and modeling. One of the simplest ways to reduce dimensionality is by Feature Selection; one selects only those input dimensions that contain the relevant information for solving the particular problem.

**特征选择（Feature Selection）**: Choosing a subset of all the features.

特征选择后的特征是原来特征的一个子集。

Feature Extraction is a more general method in which one tries to develop a transformation of the input space onto the lowdimensional subspace that preserves most of the relevant information.

**特征提取（Feature Extraction）**: Creating a subset of new features by combinations of the existing features.

特征抽取后的新特征是原来特征的一个映射。



# 维归约

- **数据集包含大量特征**
  - 例：文档数据集，数以万计的词对应数以万计的属性
- **维灾难(Curse of Dimensionality)**
  - 随着数据维度的增加，许多数据分析变得非常困难。特殊地，随着维度增加，数据在它所占据的空间中越来越稀疏
    - 对于分类，这可能意味没有足够的数据对象来创建模型
    - 对于聚类，点之间的密度和距离的定义（对聚类是至关重要的）变得不太有意义
  - 结果: 对于高维数据, 许多分类和聚类算法（以及其他数据分析算法）都有麻烦——分类准确率降低，聚类质量下降



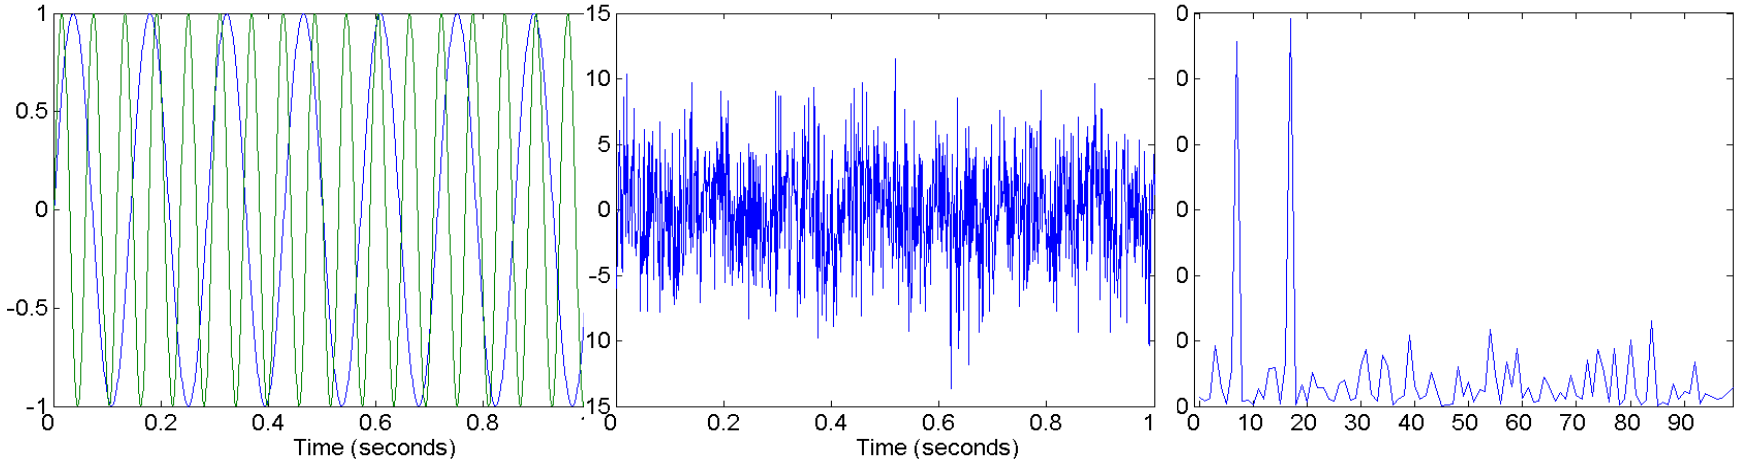
# 降维

- **降维作用**
  - 避免维数灾难
  - 帮助消除无关紧要的属性，并降低噪音
  - 减少数据挖掘所需的时间和空间
  - 更容易的可视化
- **降维技术**
  - 小波变换
  - 主成分分析
  - 监督和非线性技术（例如：特征选择，**PCA**，**LDA**）



# 将数据映射到一个新的空间

- **傅里叶变换(Fourier transform)**
- **小波变换(Wavelet transform)**
- 例: 傅里叶变换
  - 左: 两个sin波;
  - 中: 两个sin波之和+噪声; 检测不到模式
  - 右: 傅里叶变换到频谱; 两个尖峰对应于两个无噪声的时间序列




**Two Sine Waves**

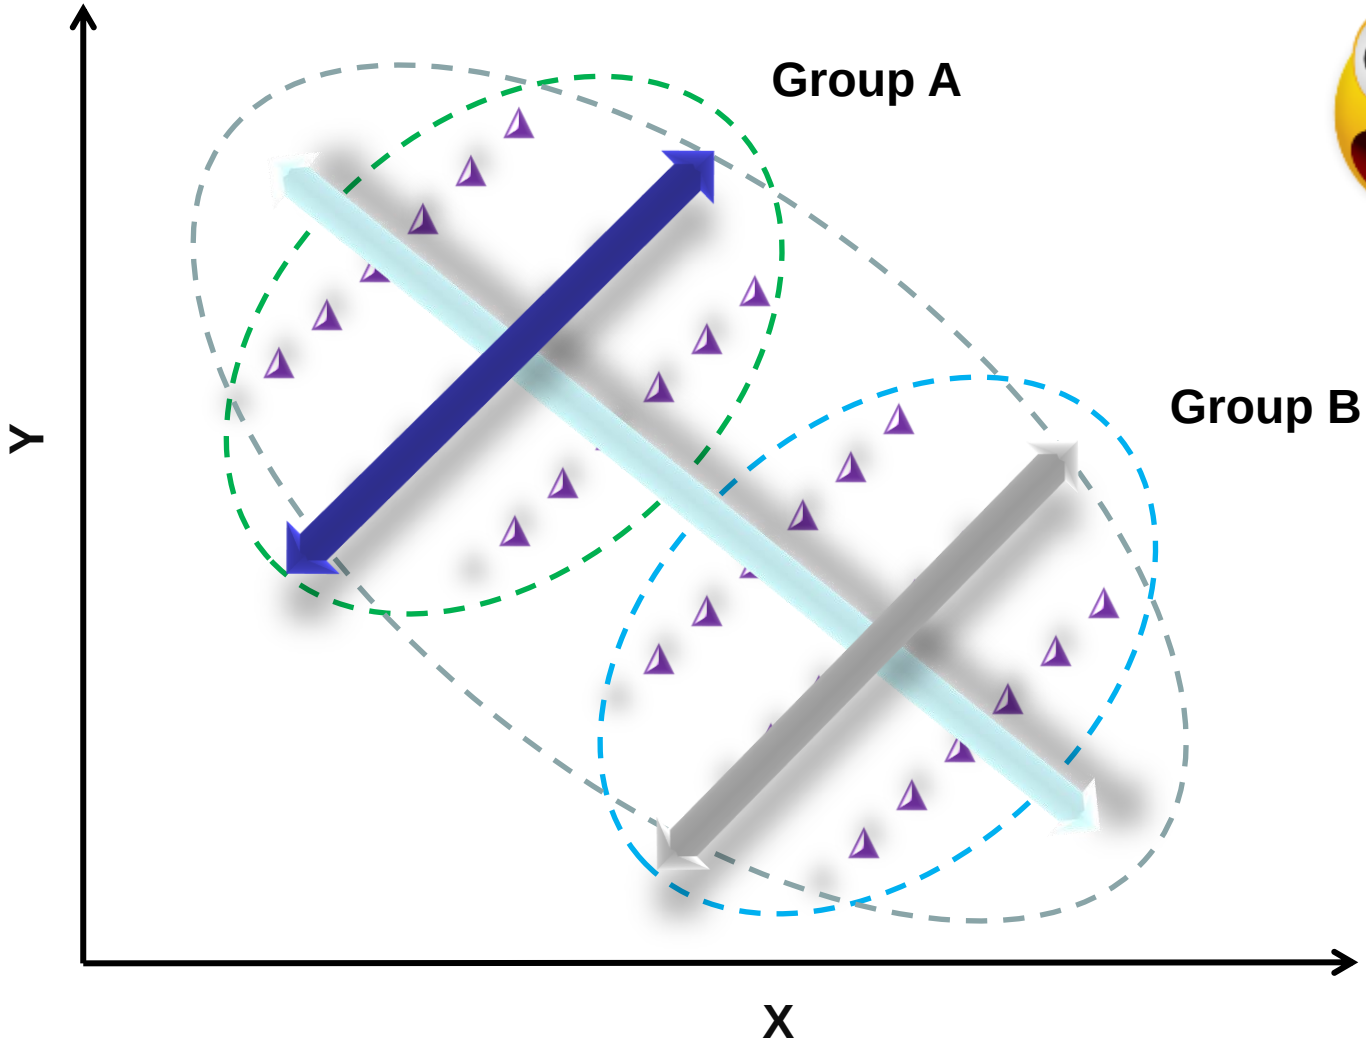
**Two Sine Waves + Noise**

**Frequency**



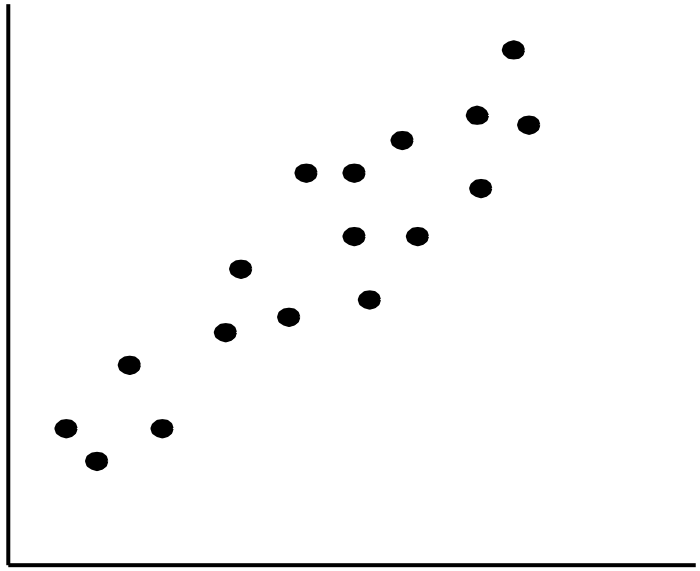
# Grouping

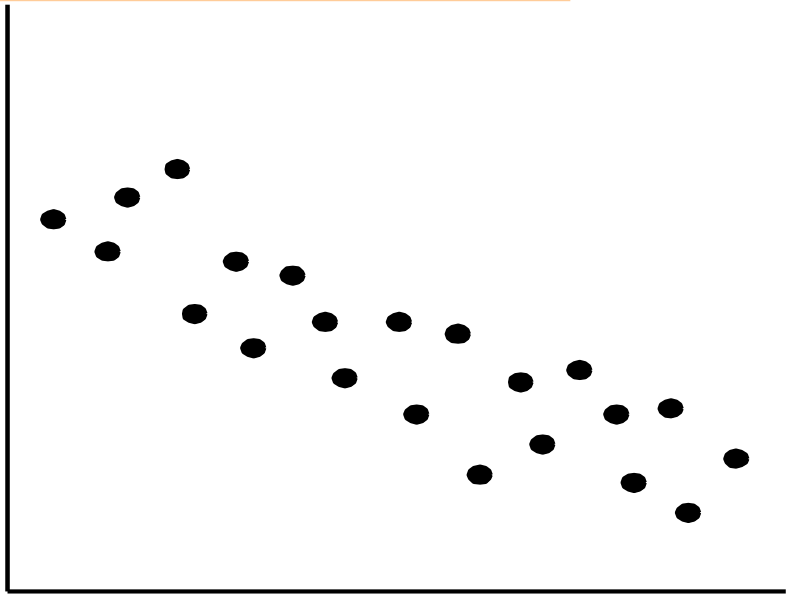


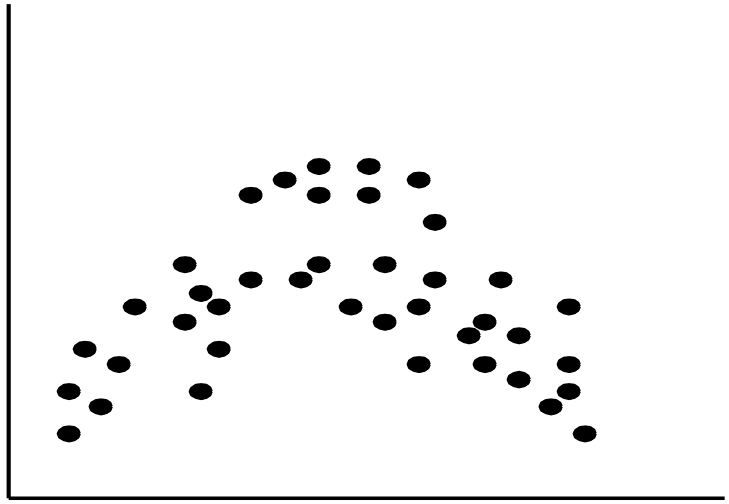




# 正面和负面的相关数据



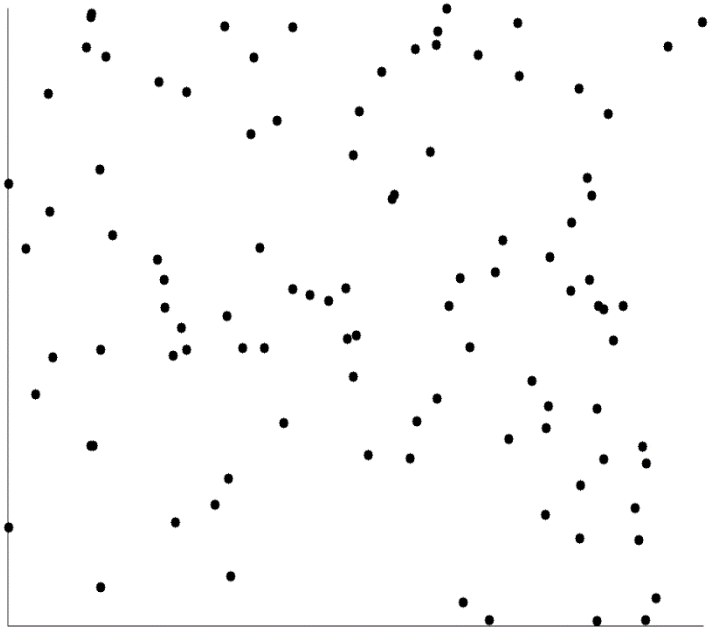


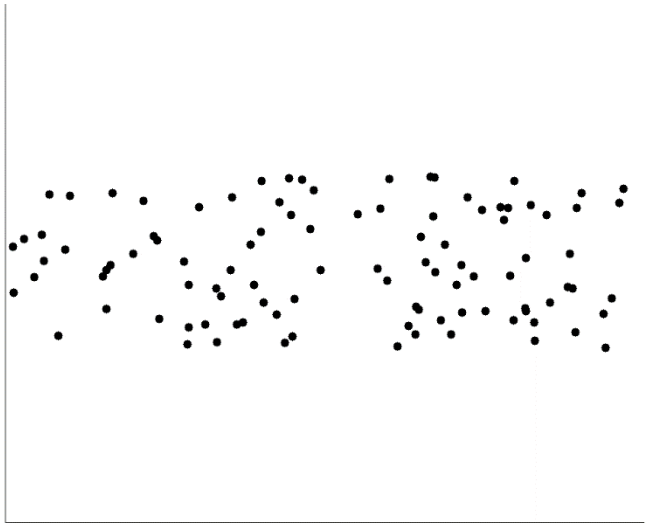


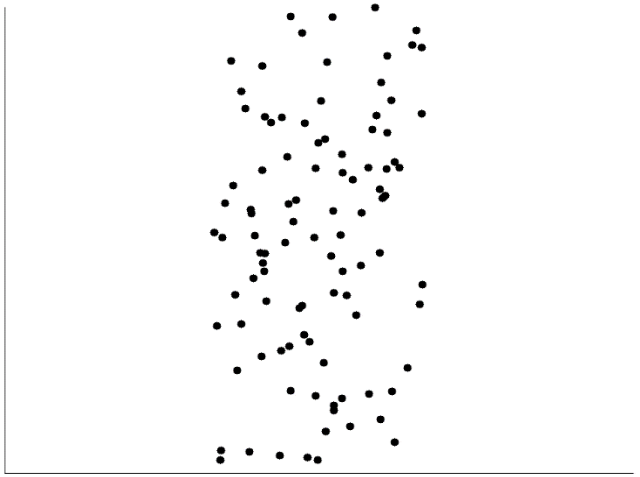
- 左半片段是正相关的
- 右半边是负相关



# 不相关的数据









# 相关性分析

- **皮尔森相关系数（Pearson's correlation）**

$$r_{A,B} = \frac{\sum (A-\overline{A})(B-\overline{B})}{(n-1)\sigma_A \sigma_B} = \frac{\sum (AB) - n\overline{A}\,\overline{B}}{(n-1)\sigma_A \sigma_B}$$

其中n是元组的数目，而*A*和*B*是各自属性的具体值， $\sigma_A$和$\sigma_B$是各自的标准偏差

- 若 $r_{A,B} > 0$, A 和 B 存在**正相关**
- 若 $r_{A,B} = 0$, A 和 B **线性不相关**
- 若 $r_{A,B} < 0$, A 和 B 存在**负相关**

$r_{A,B}$ = A,B向量协方差/A,B向量标准差

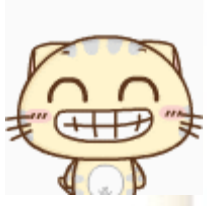


# 这是真的吗？

格力：市场起步阶段，竞争不激烈。经营格力品牌的商家，单店交易额随着商家数量的不断增长而增长，r 值呈现正相关关系，说明该品牌在天猫市场竞争中处于起步阶段，尚未白热化。




图 1-5　格力品牌商家单店支付宝金额和商家数量的关系





# 时间去哪儿了？

九阳：很饱和，竞争惨烈。经营九阳品牌的商家，单店交易额随着商家数量的不断增长而下降，r 值呈现负相关关系，说明该品牌在天猫市场中已

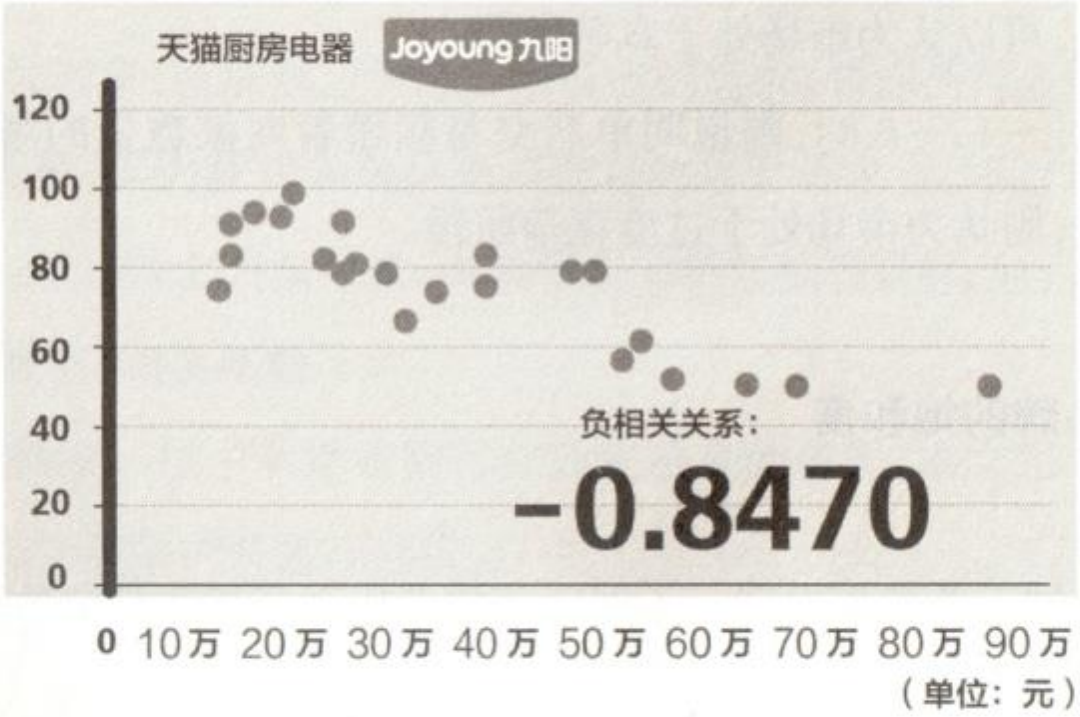
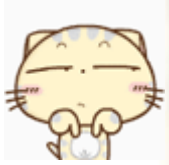


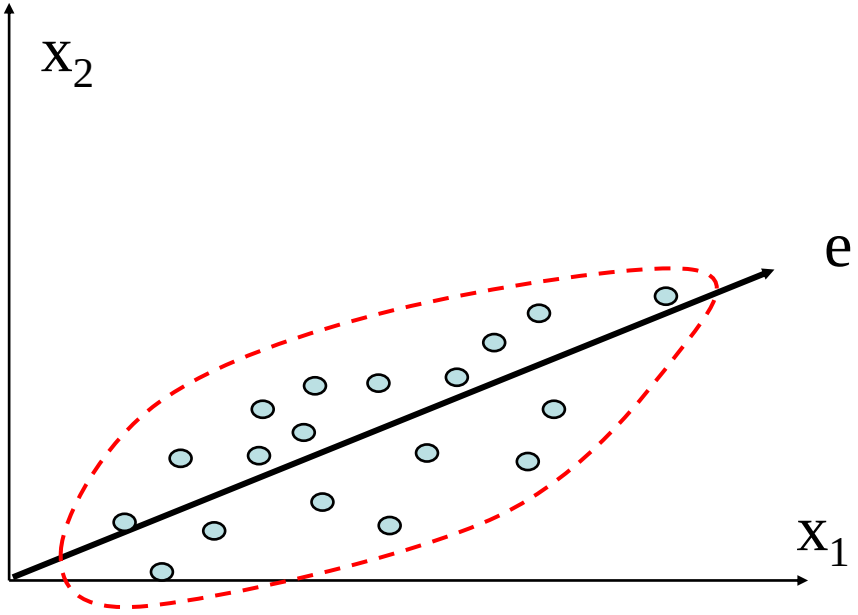

图 1-6　九阳品牌商家单店支付宝金额和商家数量的关系





# 主成分分析（PCA）

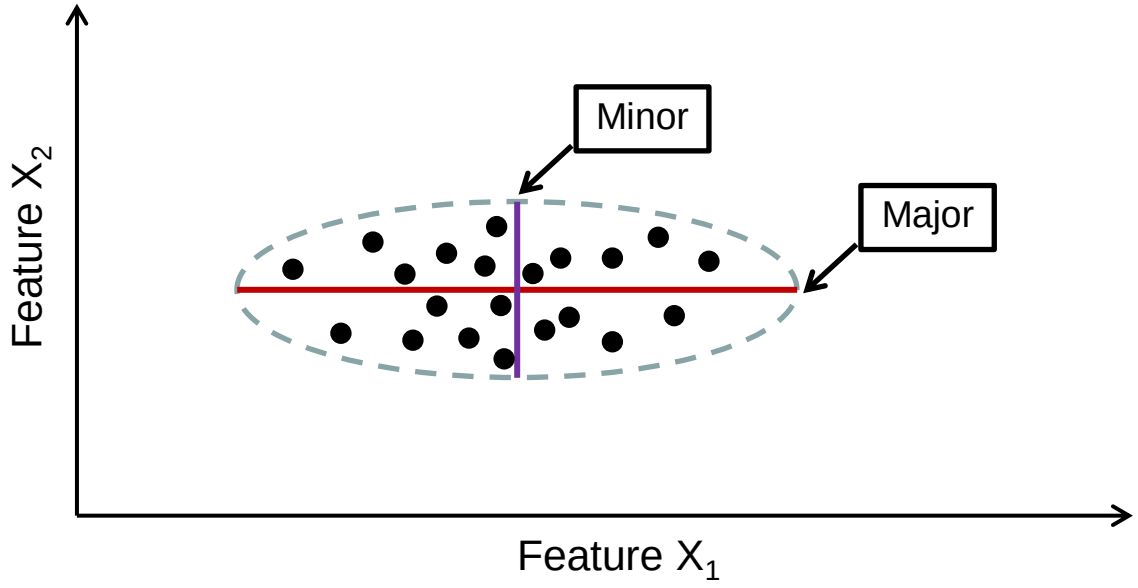
- **定义：**主成分分析（Principal Component Analysis，PCA），是一种统计方法。通过正交变换将一组可能存在相关性的变量转换为一组线性不相关的变量，转换后的这组变量叫**主成分**
- **思想：**将原始数据投影到一个更小的空间，通过投影来捕获数据最大的特征信息，从而维数降低
- **操作：**发现协方差矩阵的特征向量，用这些特征向量定义新的空间
- **针对：**数据相关性分析





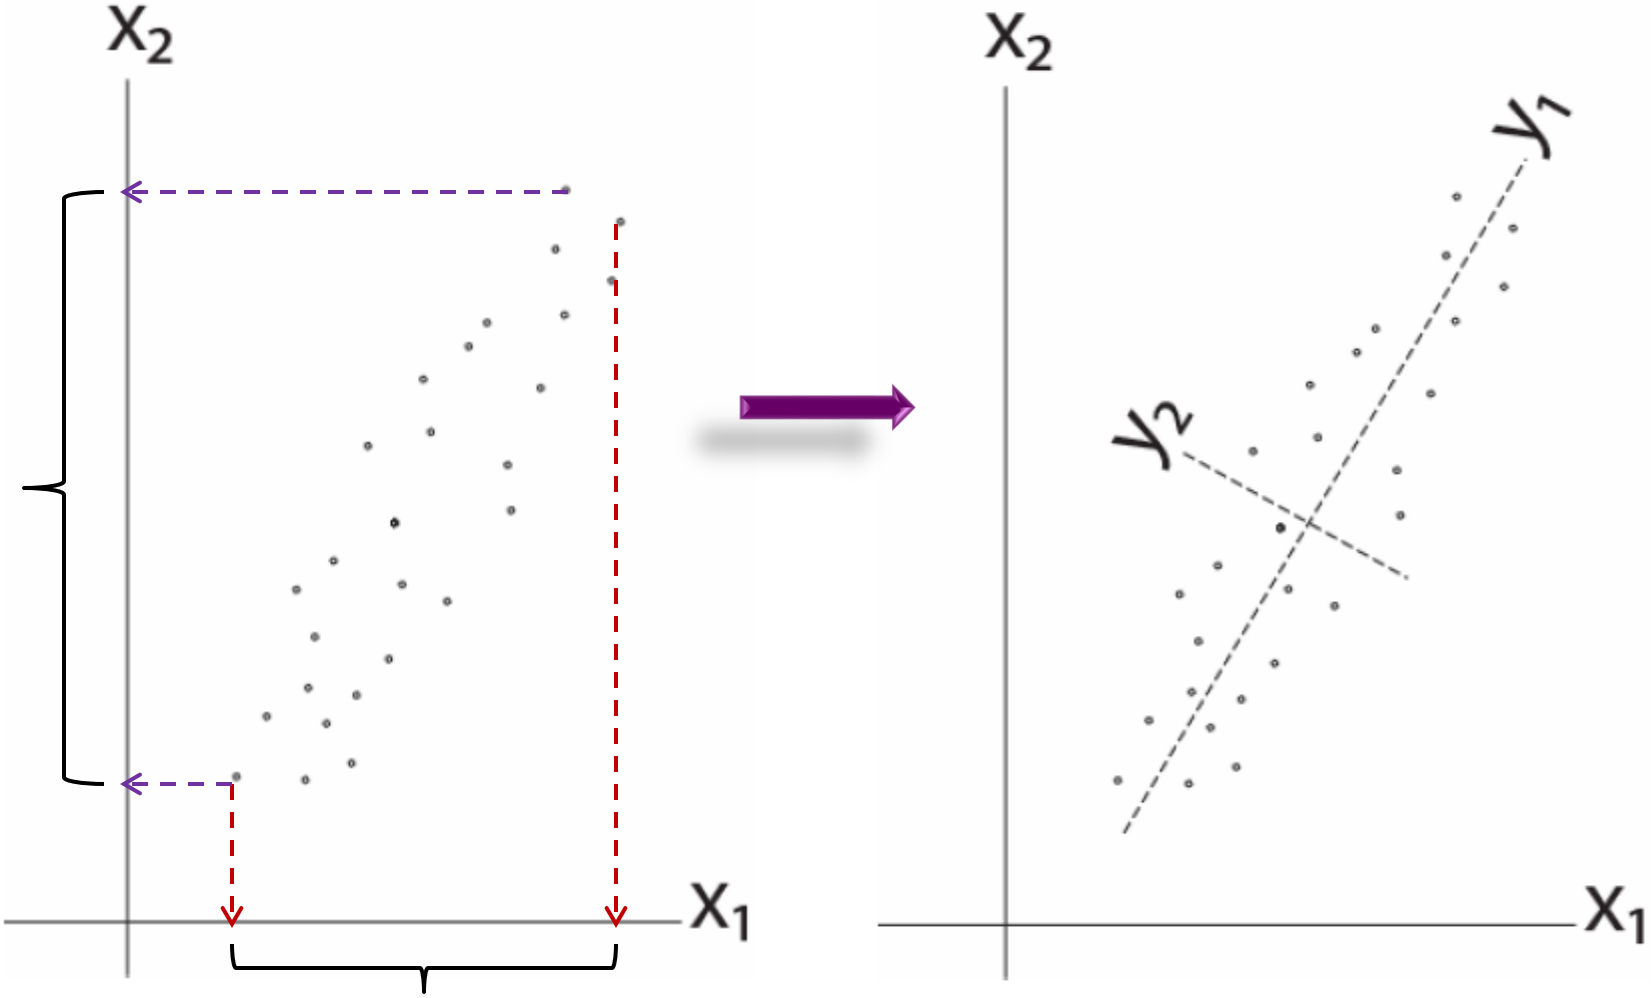
# 二维例子

- **Data: Gaussian Distribution**
- **Variance: Information**
- **Ellipse: Major Axis vs. Minor Axis**
- **Select the attribute corresponding to the Major Axis.**

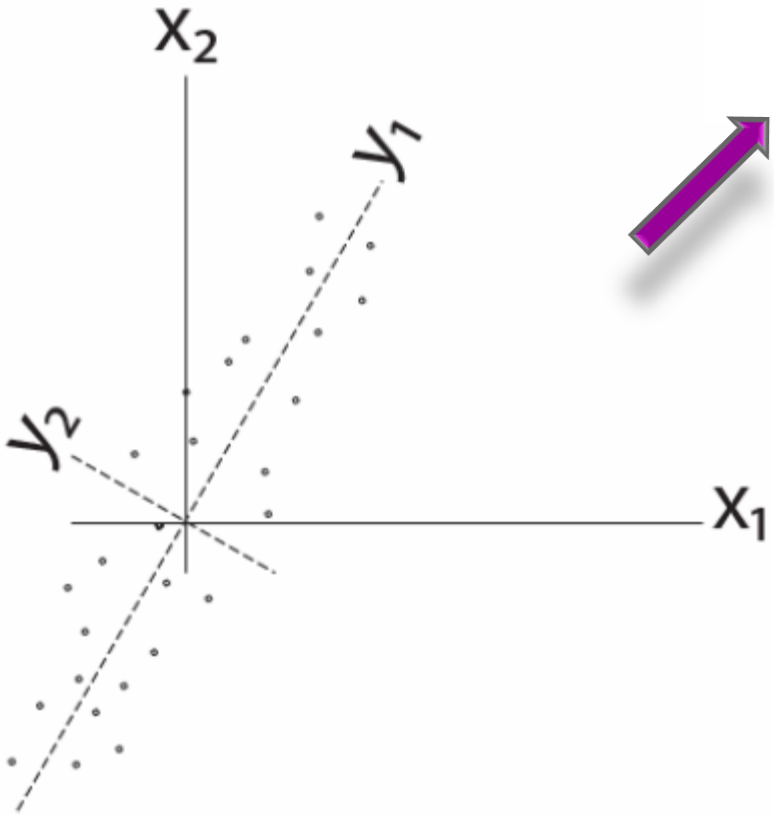


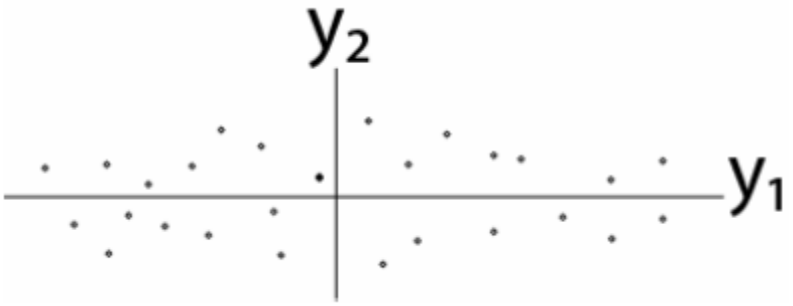


# 二维例子



# 二维例子




$$S(X)=\frac{1}{n-1}XX^T$$

**Remove correlation**
**（去除线性相关）**

$$S(Y)=\frac{1}{n-1}YY^T$$



# 数学转换

**目的：S(Y)具有非零的对角阵，所有非对角元素都为零**

$$Y = PX$$

旋转矩阵

$$S(Y) = \frac{1}{n-1} YY^T$$

希望此为对角阵

$$YY^T = (PX)(PX)^T = PXX^TP^T.$$

$$XX^T = QDQ^T$$

Eigen decomposition
（矩阵特征值分解）

$$(n-1)S(Y) = PXX^TP^T = PQDQ^TP^T = (PQ)D(PQ)^T$$

令 PQ = i（单位阵），则 P 和 Q 为互逆矩阵

特征值分解：Q为正交阵（转置和逆矩阵相同）

$$P = Q^T$$



# A Different View

$$J(e) = \sum_{i=1}^{n} \left\| x_k{}' - x_k \right\|^2$$

$$= \sum_{i=1}^{n} \| \alpha_k e - x_k \|^2$$

$$= \sum_{i=1}^{n} \alpha_k{}^2 \|e\|^2 - 2\sum_{i=1}^{n} \alpha_k e^t x_k + \sum_{i=1}^{n} \|x_k\|^2$$

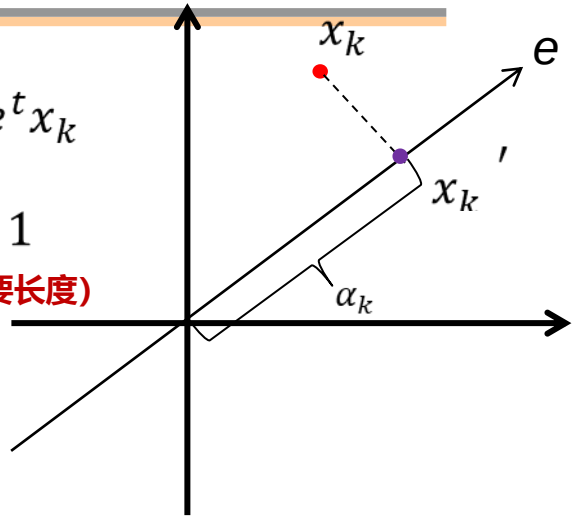
$$= -\sum_{i=1}^{n} \alpha_k{}^2 + \sum_{i=1}^{n} \|x_k\|^2$$

$$= -\sum_{i=1}^{n} e^t x_k x_k{}^t e + \sum_{i=1}^{n} \|x_k\|^2$$

$$\alpha_k = e^t x_k$$

$$\|e\| = 1$$

(只要方向不要长度)




$$\max_e e^t S e \quad s.t. \ \|e\|=1$$

$$S = \sum_{i=1}^{n} x_k x_k{}^t$$



# A Different View

**关系：散布矩阵 = 协方差矩阵×（*n-1*）**

对于二维随机变量（X,Y）之间的相互关系的数字特征，我们用协方差来描述，记为 **Cov(X,Y)：**

$$Cov(X,Y)=\frac{1}{n-1}\sum_{i=1}^{n}(X-\overline{X})(Y-\overline{Y})$$

那么二维随机变量(X,Y)的**协方差矩阵，为**：

$$C_{2*2}=\begin{bmatrix}c_{11} & c_{12}\\ c_{21} & c_{22}\end{bmatrix}=\begin{bmatrix}Cov(X,X) & Cov(X,Y)\\ Cov(Y,X) & Cov(Y,Y)\end{bmatrix}$$

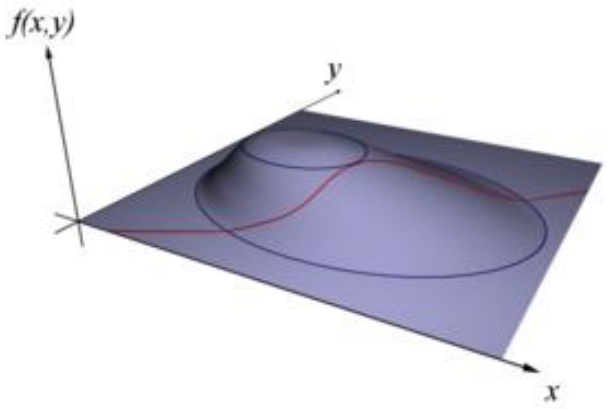
对于三维随机变量$X=(X_1, X_2, \ldots, X_n)$的协方差矩阵可表示为：

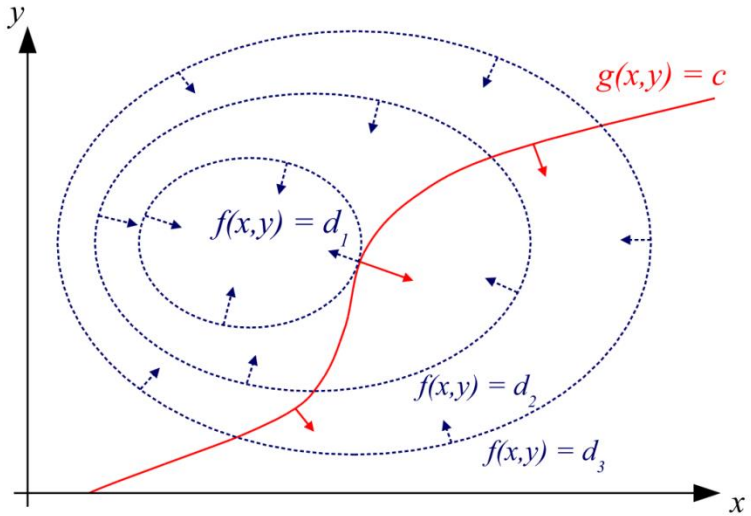
$$C_{3*3}=\begin{bmatrix}c_{11} & c_{12} & c_{13}\\ c_{21} & c_{22} & c_{23}\\ c_{31} & c_{32} & c_{33}\end{bmatrix}=\begin{bmatrix}Cov(X,X) & Cov(X,Y) & Cov(X,Z)\\ Cov(Y,X) & Cov(Y,Y) & Cov(Y,Z)\\ Cov(Z,X) & Cov(Z,Y) & Cov(Z,Z)\end{bmatrix}$$

**协方差**：描述任意两维数据之间的关系，计算的是不同维度之间的协方差，并不是不同样本之间的。

**协方差矩阵**：对称矩阵，半正定矩阵，主对角线是各个维度上的方差。

# 拉格朗日乘数定理




$$\max_{x,y} f(x,y) = 3xy \quad s.t.\ 2x + y = 8$$

$$F(x,y,\lambda) = 3xy - \lambda(2x + y - 8)$$

$$F_x = 3y - 2\lambda$$
$$F_y = 3x - \lambda$$
$$F_\lambda = -(2x + y - 8)$$

$$\lambda = 6$$

$$x = \frac{\lambda}{3} = 2$$

$$y = \frac{2}{3}\lambda = 4$$

$$f(2,4) = 3 \cdot 2 \cdot 4 = 24$$



# More Math ...

$$u = e^t Se - \lambda\left(e^t e - 1\right)$$

$$\frac{\partial u}{\partial e} = 2Se - 2\lambda e$$

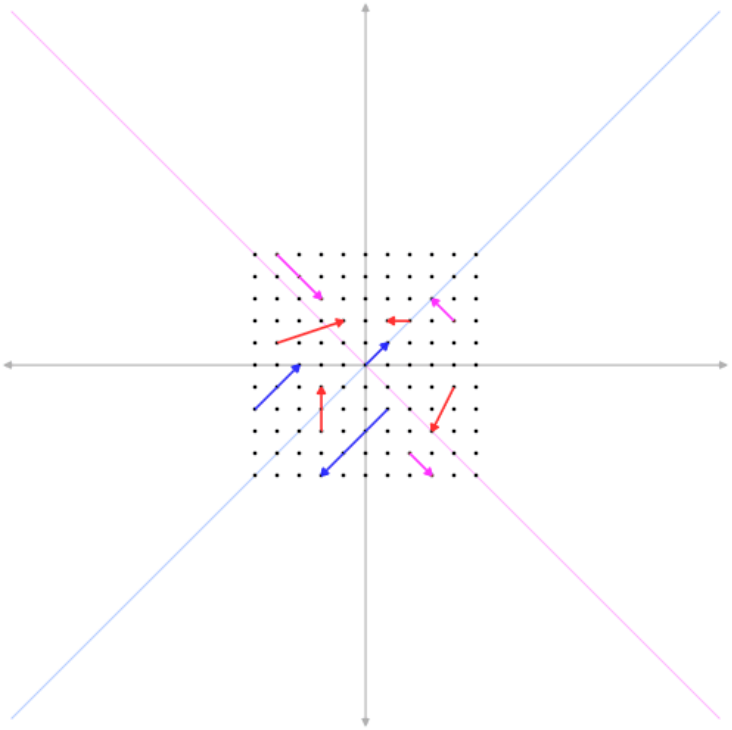
$$Se = \lambda e$$

对称阵

Eigenvector（特征向量）

Eigenvalue（特征值）

$$e^t Se = \lambda e^t e = \lambda$$



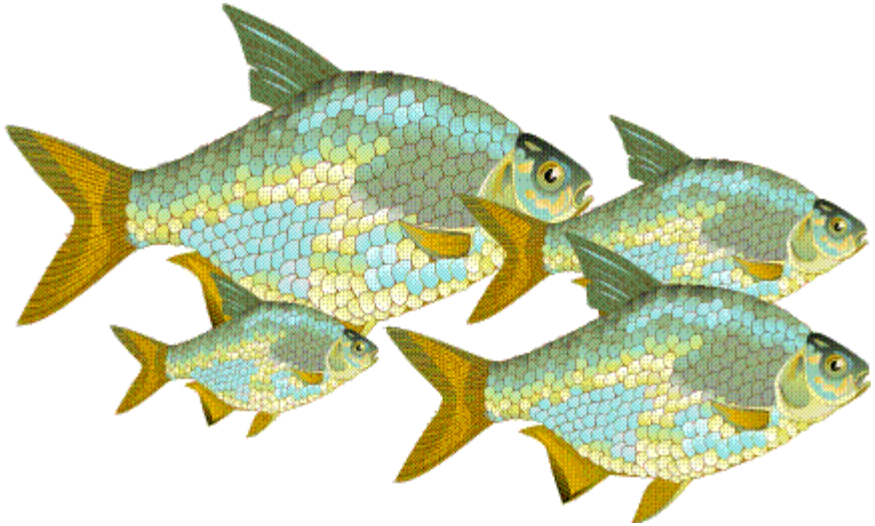
**PCA：将原始数据投影到特征值最大的S特征向量上（可以最大或最大+第二大）**

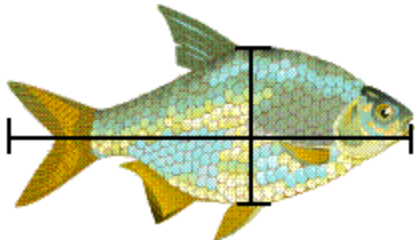
$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

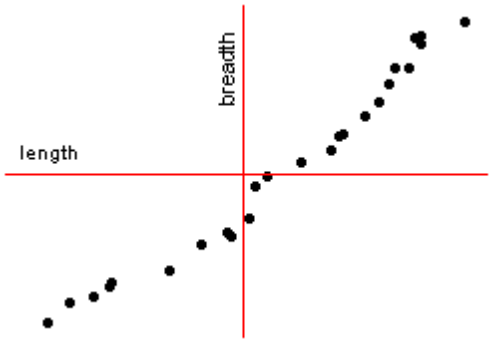
$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

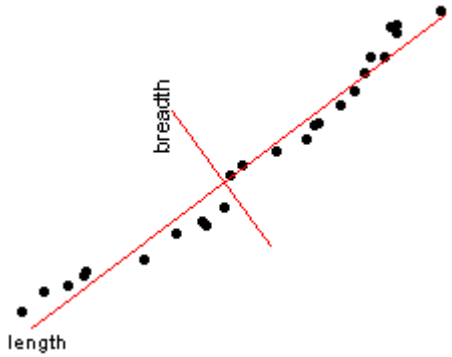


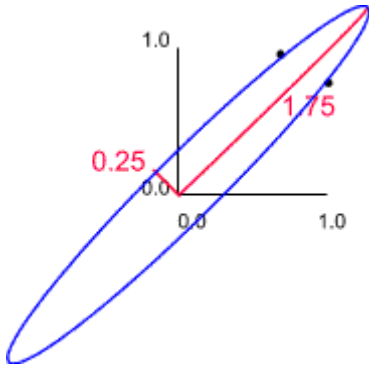
# Fish









# 主成分分析（总结）

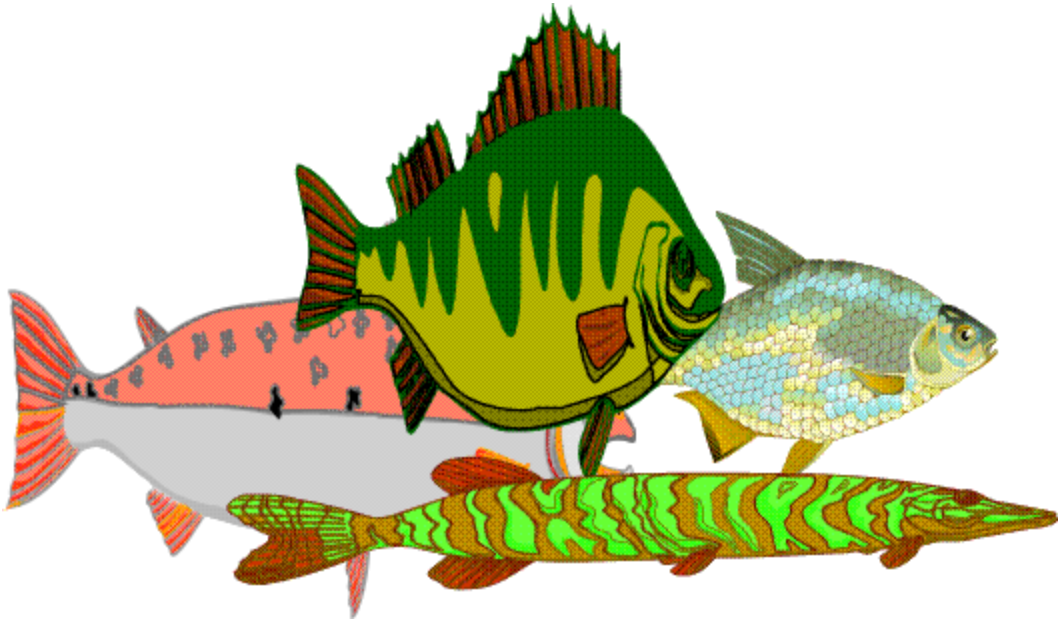
**主成分分析（PCA）：利用降维的思想，将多个变量转化为少数几个综合变量（即主成分），其中每个主成分都是原始变量的线性组合，各主成分之间互不相关，从而这些主成分能够最大程度反映原始变量的特征信息，且所含的信息互不重叠。**

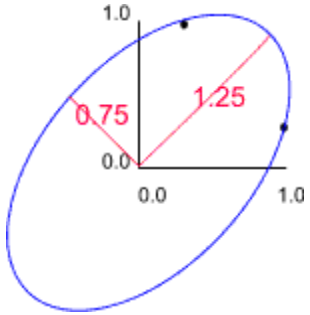
**在代数上表现为将原随机向量的协方差阵变换成对角形阵；**

**在几何上表现为将原坐标系变换成新的正交坐标系，使之指向样本点散布最开的p 个正交方向，然后对多维变量系统进行降维处理，使之能以一个较高的精度转换成低维变量系统，再通过构造适当的价值函数，进一步把低维系统转化成一维系统。**



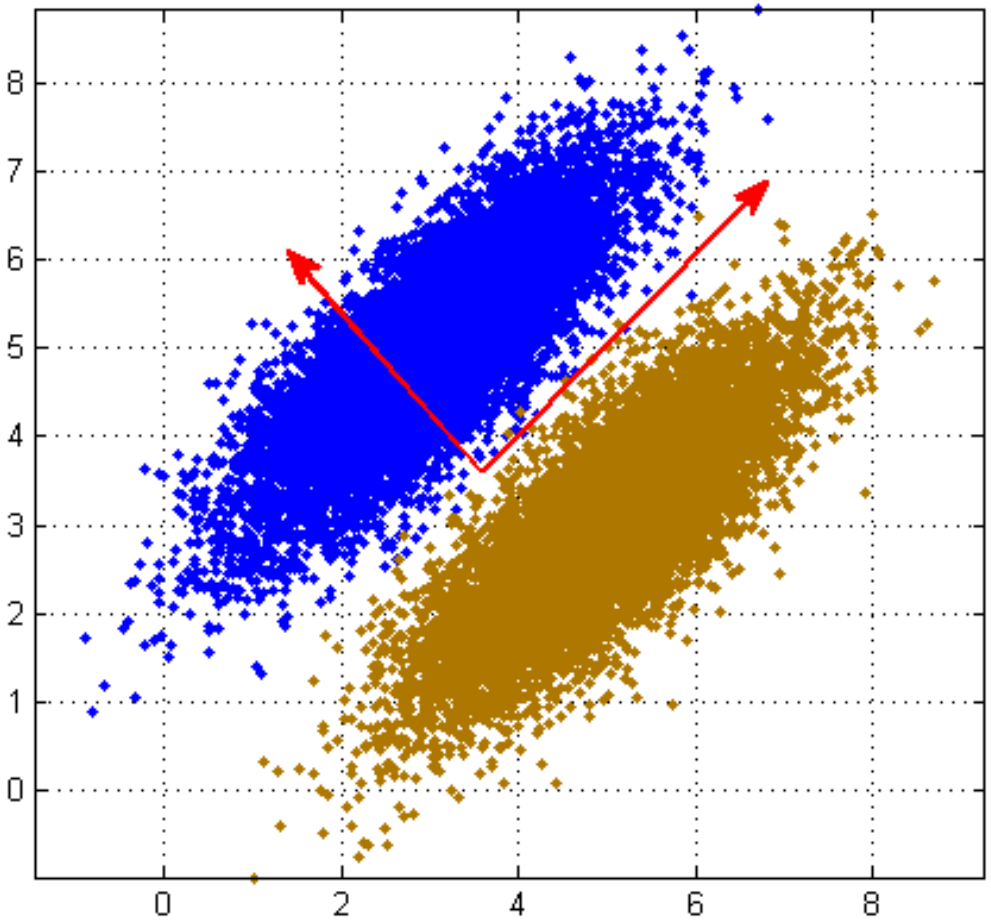
# Fish







# 主成分分析存在的问题




Now, let's consider class information ...

**PCA：无监督的数据分析，不考虑数据的标签（类别的信息）**



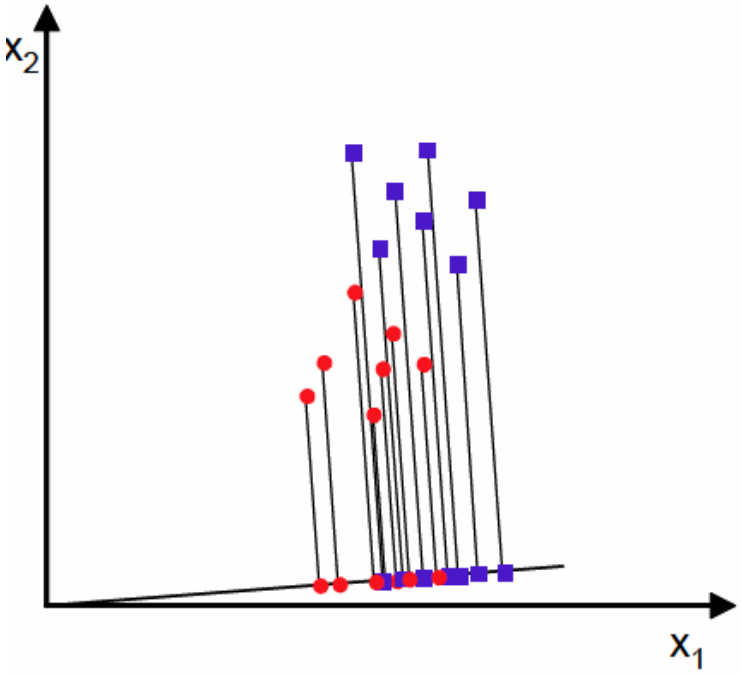
# 线性判别分析-LDA（Linear Discriminant Analysis）

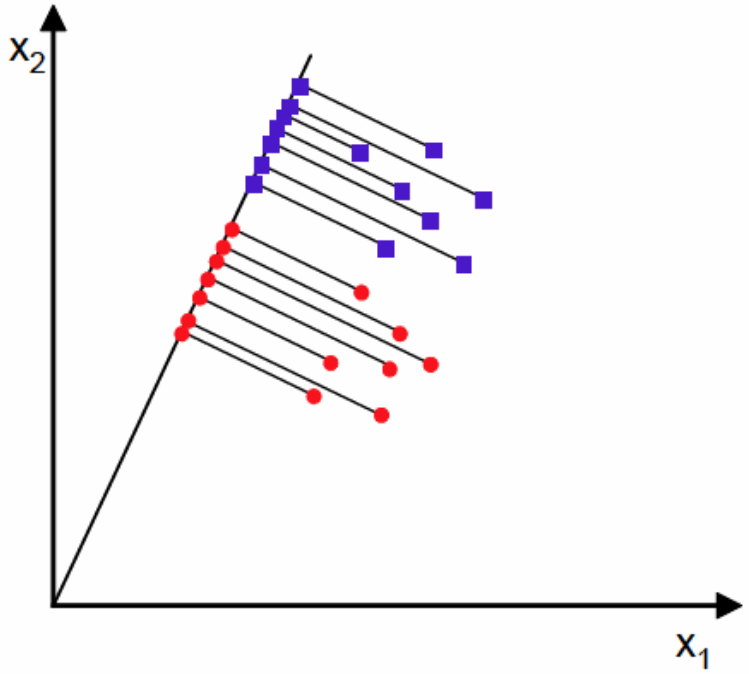
- **提出：1936年，费希尔（Fisher）应用相当广泛。**
- **线性判别分析：**是对费希尔的线性鉴别方法的归纳，试图找到两类物体或事件的特征的一个线性组合，以能够特征化或区分它们。所得的组合可用来作为一个线性分类器，或者为后续的分类做降维处理。
- 目的：尽可能**保留类的区分信息**的同时进行降维操作
- 基本思想：将样本投影到一条直线上



# 线性判别分析-LDA（Linear Discriminant Analysis）

- 给定一组d-D向量，$x_1$，$x_2$，…,$x_n$；$N_1$属于$\omega_1$，$N_2$属于$\omega_2$。在所有可能的投影直线 $y=w^Tx$ 中，找出能最大限度地实现**可分离性**的直线



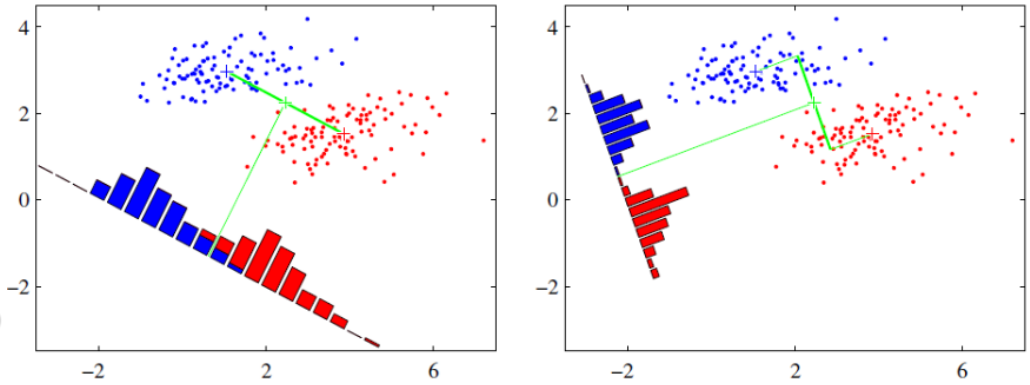


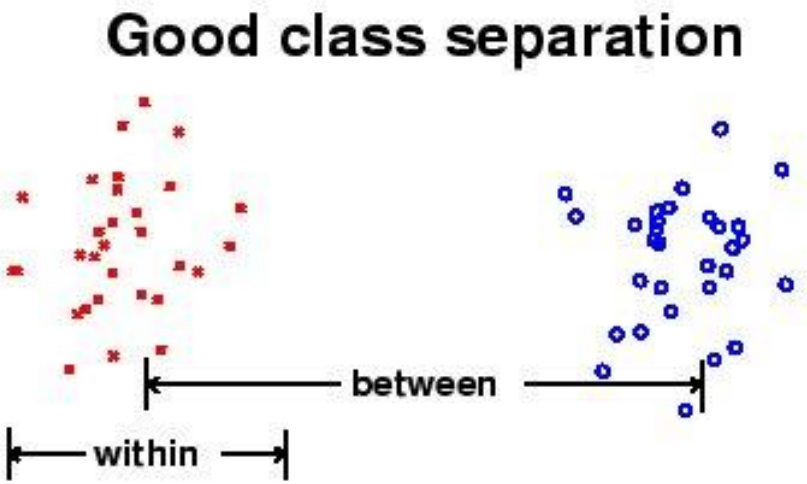
# 线性判别分析LDA

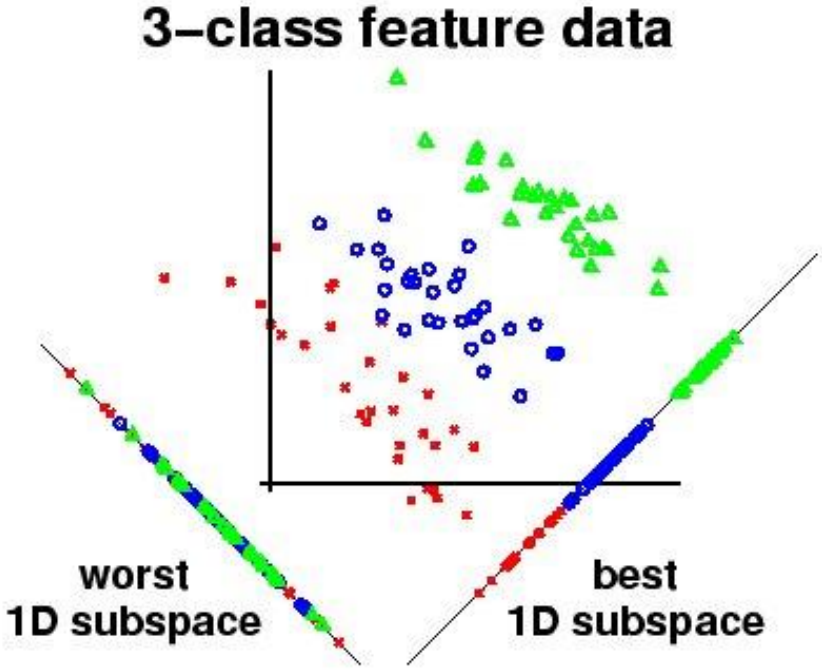
**什么叫做可分离?**

**什么叫做分得开?**

**如何来定义这两个概念?**

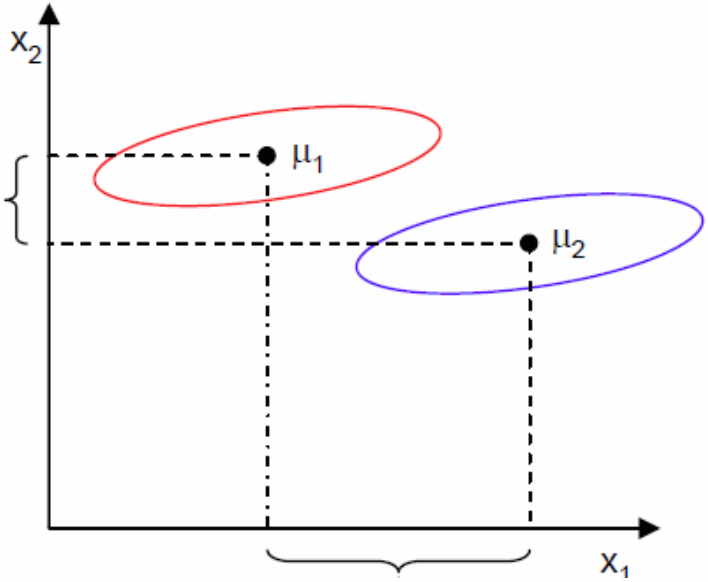


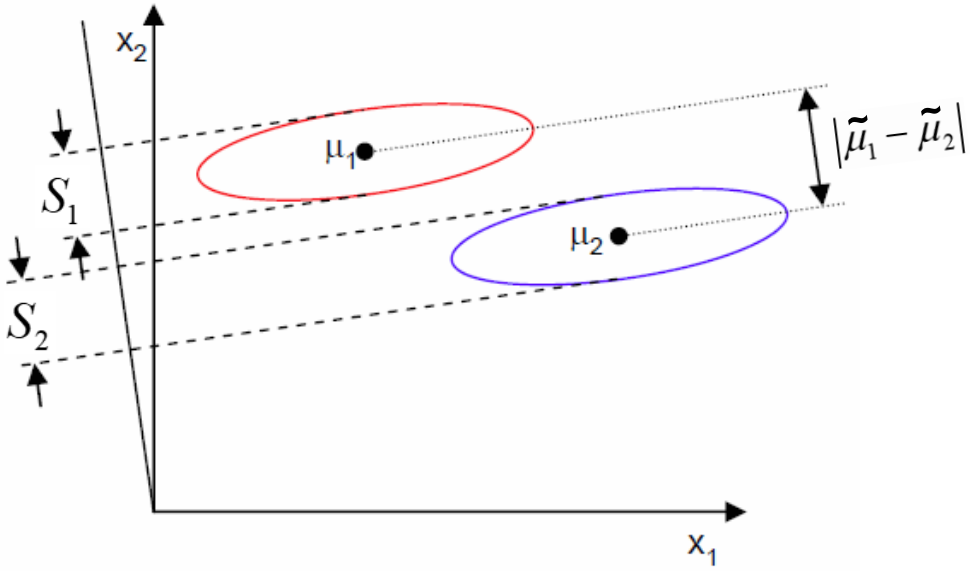





# 费希尔准则（Fisher Criterion）




$$J = \frac{\left|\tilde{\mu}_1 - \tilde{\mu}_2\right|^2}{S_1^2 + S_2^2}$$

⬅ **最大化类之间的距离**

⬅ **最小化每个类中散点的距离**

**注意：所有参数都是指的是投影过后的参数**



# 数学推导 …

$$\mu_i = \frac{1}{N_i}\sum_{x\in\omega_i} x \quad \text{and} \quad \tilde{\mu}_i = \frac{1}{N_i}\sum_{y\in\omega_i} y = \frac{1}{N_i}\sum_{x\in\omega_i} w^T x = w^T\mu_i$$

between-class scatter

$$(\tilde{\mu}_1 - \tilde{\mu}_2)^2 = (w^T\mu_1 - w^T\mu_2)^2 = w^T\underbrace{(\mu_1-\mu_2)(\mu_1-\mu_2)^T}_{S_B}w = w^T S_B w$$

$$S_i = \sum_{x\in\omega_i}(x-\mu_i)(x-\mu_i)^T$$

$$S_1 + S_2 = S_W$$

within-class scatter

$$J(w) = \frac{|\tilde{\mu}_1 - \tilde{\mu}_2|^2}{\tilde{s}_1^2 + \tilde{s}_2^2} \Rightarrow J(w) = \frac{w^T S_B w}{w^T S_W w}$$

$$\tilde{s}_i^2 = \sum_{y\in\omega_i}(y-\tilde{\mu}_i)^2 = \sum_{x\in\omega_i}(w^T x - w^T\mu_i)^2 = \sum_{x\in\omega_i} w^T(x-\mu_i)(x-\mu_i)^T w = w^T S_i w$$

$$\tilde{s}_1^2 + \tilde{s}_2^2 = w^T S_W w$$



# 数学推导...

$$J(w)=\frac{w^T S_B w}{w^T S_W w}$$

Generalized Rayleigh Quotient
（广义瑞利商）

$$\frac{d}{dw}[J(w)]=\frac{d}{dw}\left[\frac{w^T S_B w}{w^T S_W w}\right]=0 \Rightarrow$$

$$\Rightarrow [w^T S_W w]\frac{d[w^T S_B w]}{dw}-[w^T S_B w]\frac{d[w^T S_W w]}{dw}=0 \Rightarrow$$

$$\Rightarrow [w^T S_W w]2S_B w-[w^T S_B w]2S_W w=0$$

除以 ⇨

$$\frac{[w^T S_W w]}{[w^T S_W w]}S_B w-\frac{[w^T S_B w]}{[w^T S_W w]}S_W w=0 \Rightarrow$$

$$\Rightarrow S_B w-JS_W w=0 \Rightarrow$$

$$\Rightarrow S_W^{-1}S_B w-Jw=0$$

$$S_W^{-1}S_B w=Jw$$

特征向量问题



# More Math...

$$S_W^{-1} S_B w = Jw$$ ← 特征向量优化问题

$$S_B w = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w = (\mu_1 - \mu_2)R$$

$$R = (\mu_1 - \mu_2)^T w$$ ← 标量

$$Jw = S_w^{-1}(S_B w) = S_w^{-1}(\mu_1 - \mu_2)R$$

$$w = \frac{R}{J} S_w^{-1}(\mu_1 - \mu_2)$$




$$w^* = \underset{w}{\operatorname{argmax}} \left\{ \frac{w^T S_B w}{w^T S_W w} \right\} = S_W^{-1}(\mu_1 - \mu_2)$$

**注意：** 目前为止此LDA只代表二分类的降维优化方法，
二分类以上问题需要对算法进行调整



# 主成分分析与线性判别分析

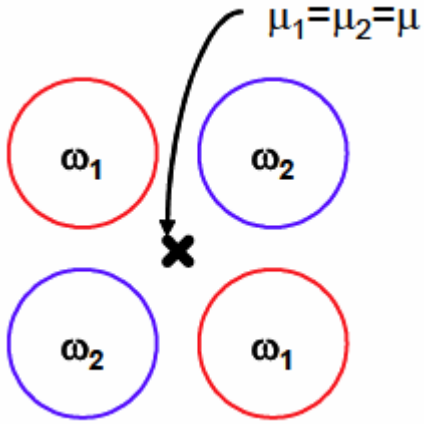
**共同点：**

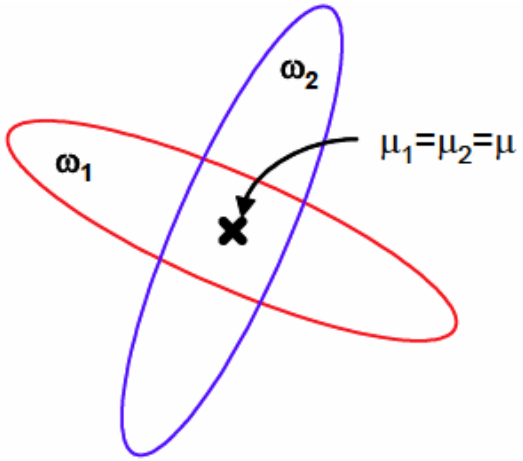
1. 均可以对数据进行**降维**；
2. 都属于**特征提取**；
3. 在降维时均使用了**矩阵特征分解**的思想；
4. 都假设数据符合**高斯分布**。

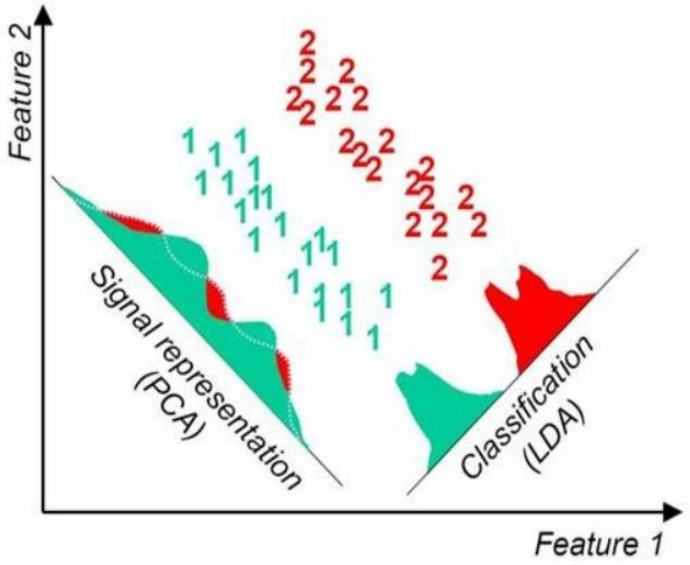
| 主成分分析（PCA） | 线性判别分析（LDA） |
| --- | --- |
| 统计学 | 机器学习 |
| 思想降维分析 | 思想降维分析 |
| 不考虑数据的类别信息（无监督降维分析） | 考虑数据的类别信息（有监督降维分析） |
| 选择数据最大方差的方向 | 选择分类性能最好的投影方向 |

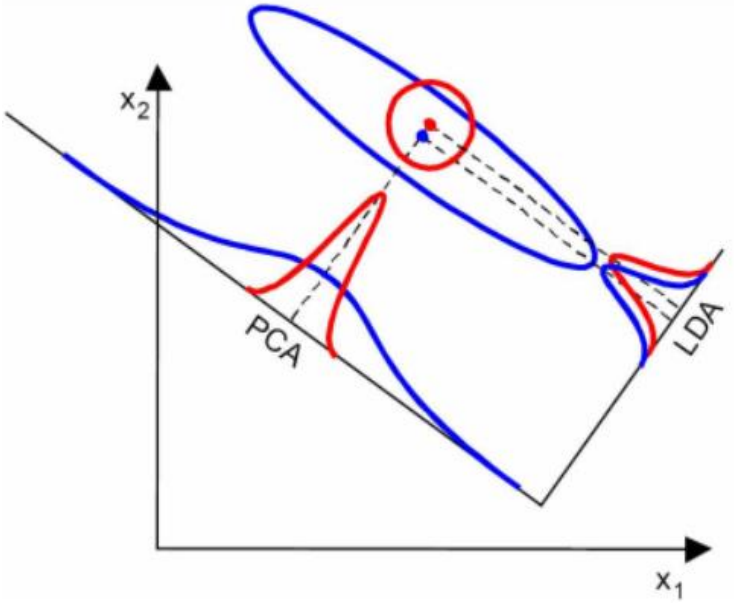


# PCA Vs. LDA


$\mu_1=\mu_2=\mu$
$\omega_1$
$\omega_2$
$\omega_2$
$\omega_1$


$\omega_2$
$\mu_1=\mu_2=\mu$
$\omega_1$


Feature 2
Signal representation (PCA)
Classification (LDA)
Feature 1


$x_2$
PCA
LDA
$x_1$



# 2.7 数据可视化

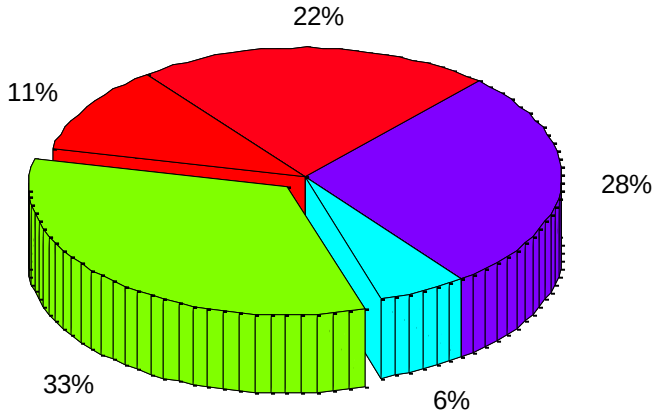


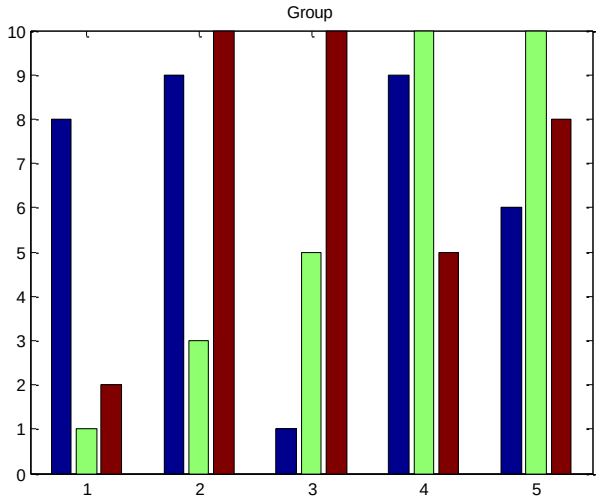
# 数据可视化

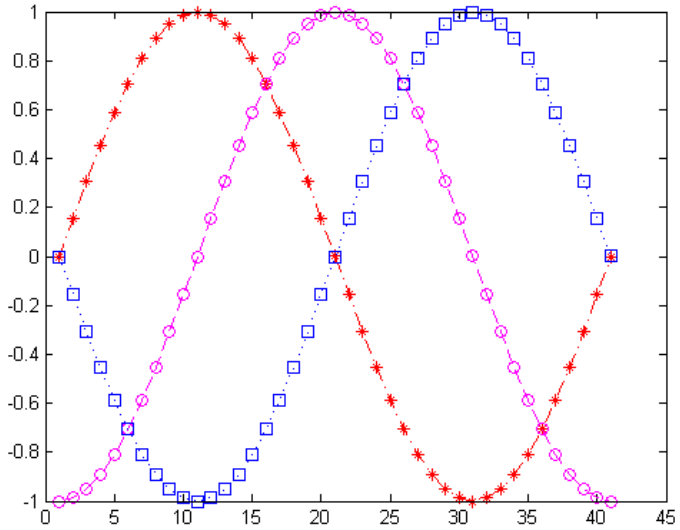
- 为什么数据可视化?
  - 将图元数据映射到信息空间
  - 提供大型数据集的定性浏览
  - 搜索数据之间的关系如模式，趋势，结构，规则，
  - 帮助进一步定量分析， 通过合适的参数找到有趣的地区
  - 提供可视化的陈述
- 典型的可视化方法:
  - 几何技术
  - 基于图标的技术
  - 分层技术

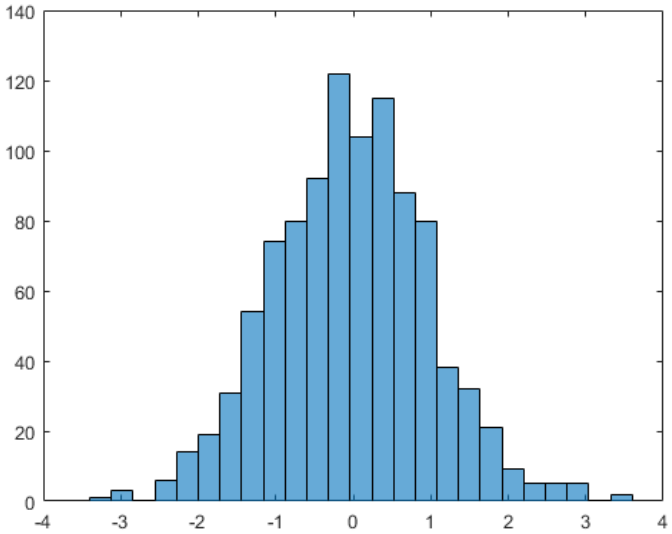


# 数据可视化 (1D)


22%
11%
28%
33%
6%

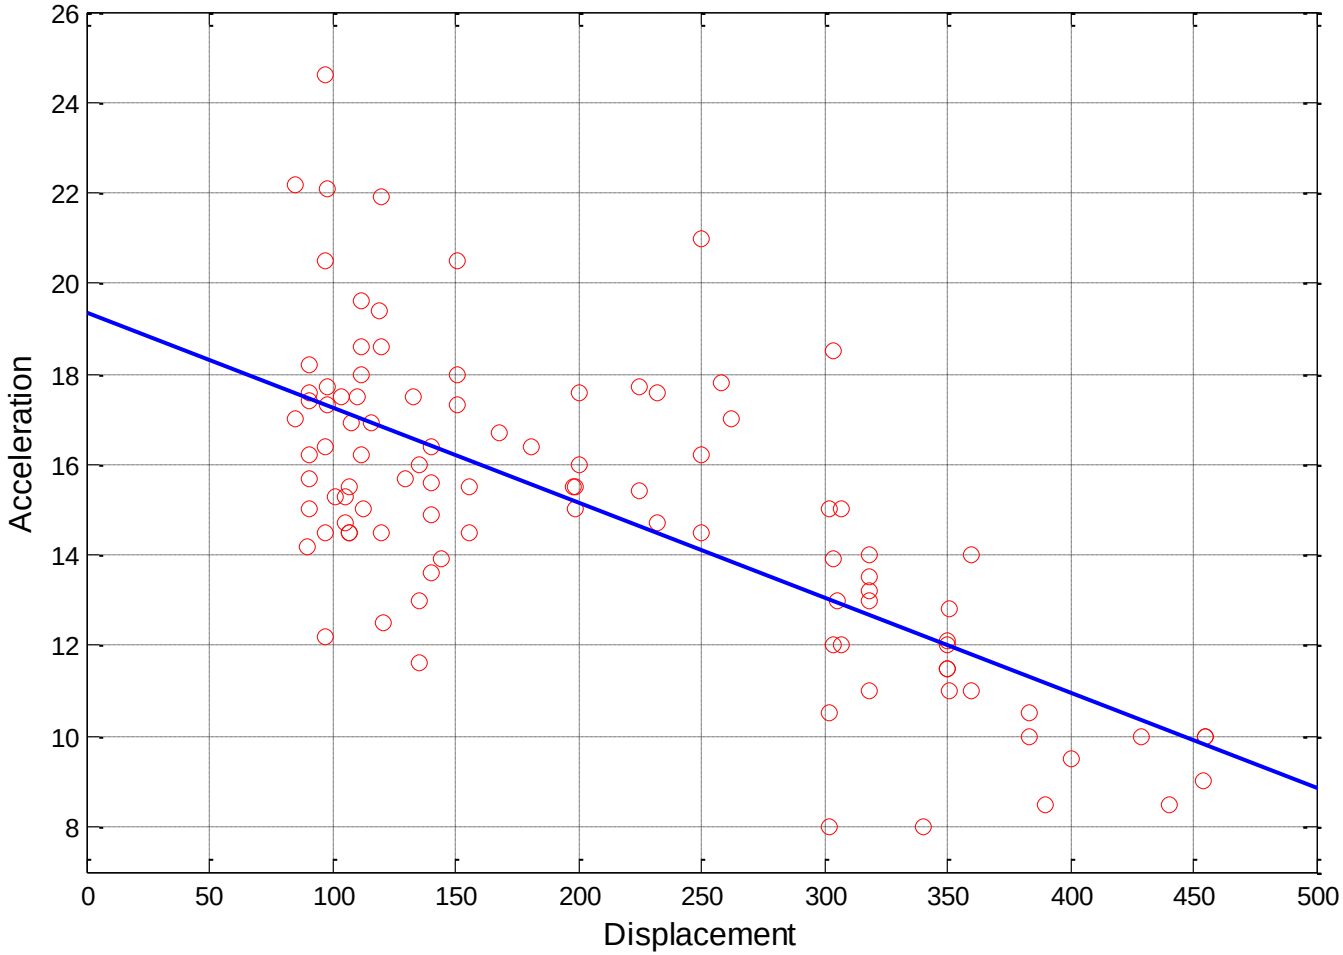

Group
10
9
8
7
6
5
4
3
2
1
0
1
2
3
4
5


1
0.8
0.6
0.4
0.2
0
-0.2
-0.4
-0.6
-0.8
-1
0
5
10
15
20
25
30
35
40
45


140
120
100
80
60
40
20
0
-4
-3
-2
-1
0
1
2
3
4

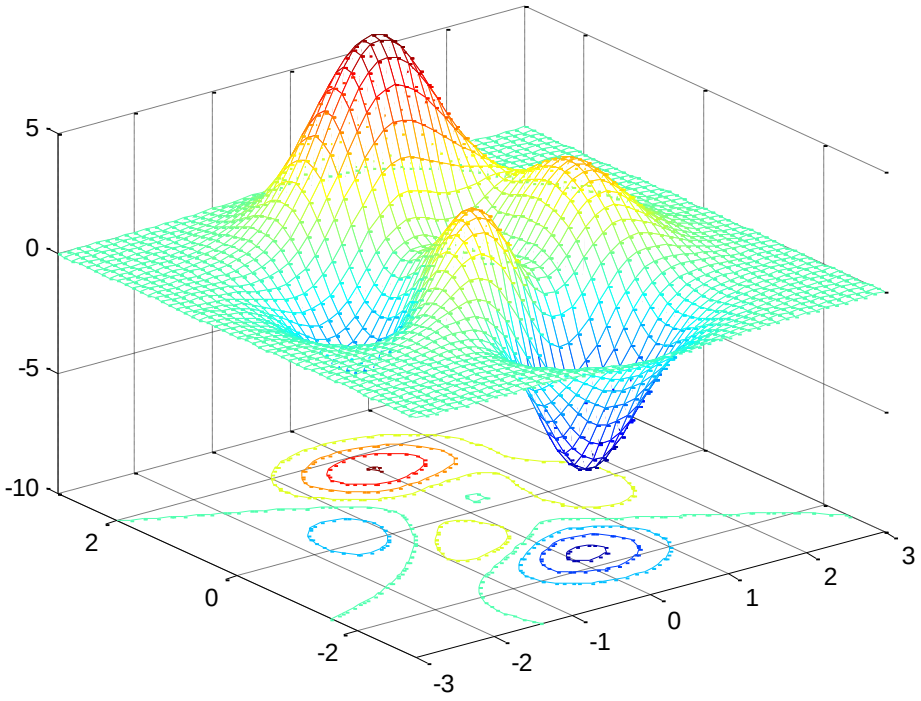


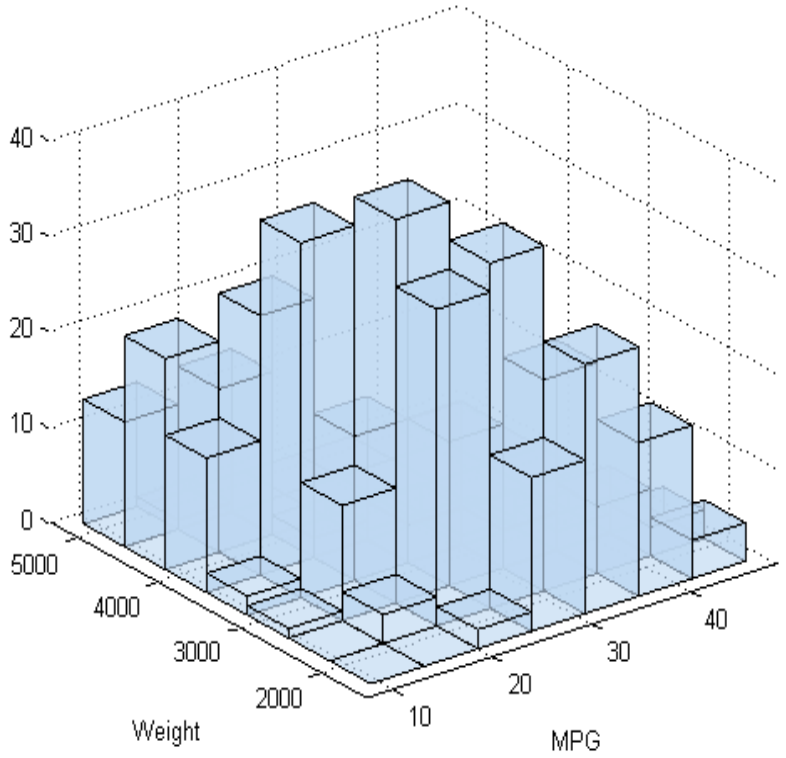
# 数据可视化(2D)


Acceleration
Displacement
26
24
22
20
18
16
14
12
10
8
0
50
100
150
200
250
300
350
400
450
500

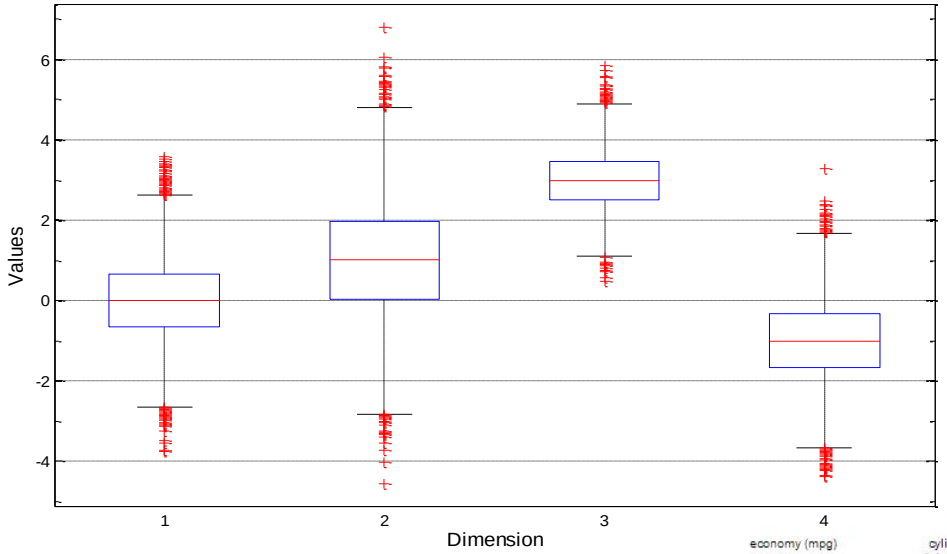


# 数据可视化(3D)


5
0
-5
-10
2
0
-2
-3
-2
-1
0
1
2
3

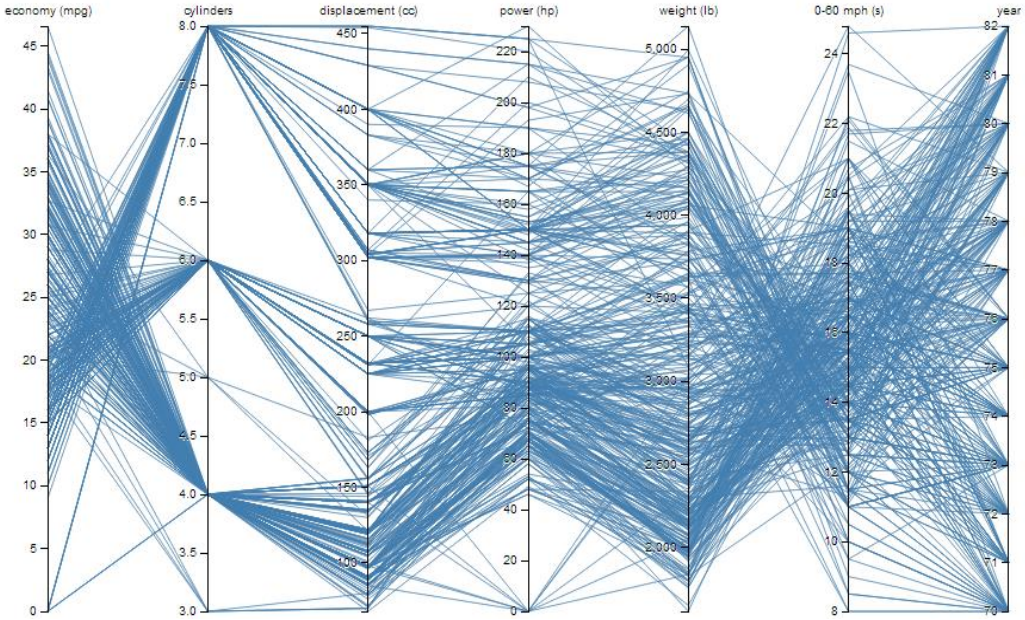

40
30
20
10
0
5000
4000
3000
2000
Weight
10
20
30
40
MPG

# 数据可视化(High Dimensional)




**箱线图**

**维度（属性）平行坐标**





# 本讲作业

1. 数据和数据集的定义。
2. 简述数据预处理的主要任务。
3. 简述属性相关性简分析的两种方法和公式。
4. 说明数据规范化的方法和公式。
5. 简述特征选择和特征提取的区别？
6. 简述PCA和LDA的共同点和异同点。
7. 简述高维数据可视化的方法。

**本次作业请于*10月12日*上课前提交**