1/33

答题卡

1. (单选题) 考虑两队之间的足球比赛:队 0 和队 1。假设 65%的比赛队 0 胜出,剩余的比赛队 1 获胜。队 0 获胜的比赛中只有 30%是在队 1 的主场,而队 1 取胜的比赛中 75%是主场获胜。如果下一场比赛在队 1 的主场进行队 1 获胜的概率为( )

(1.5)

A. 0.75

B. 0.5738

C. 0.35

D. 0.4678

$$\frac{0.35\times0.75}{0.65\times0.3+0.35\times0.75}$$

我的答案：

B

2/33

答题卡

2. (单选题) 为了克服神经网络学习空间中存在的局部最优点应当:( )

(1.5)

A. 增加隐含层神经元个数

B. 尝试从不同的初始点开始训练

C. 采用较小的学习率

D. 将权重初始化为接近于 0 的值

我的答案：

B

3/33

答题卡

3. (单选题) 设 X={I1, I2, I3}是频繁项集,则可由 X 产生( )个关联规则。

(1.5)

A. 8

B. 4

C. 7

D. 6

我的答案：

D

4/33

答题卡

4. (单选题) 若某数据集的属性 consumption 的上下限分别是 9800 元和 3000 元。用数据标准化(归一化)方法将该属性映射到[0,1]区间。那么属性 consumption 的取值为 7360 元将被转化为:( )

(1.5)
A. 0.716
B. 0.641
C. 0.751
D. 0.688
我的答案：
B

5/33

答题卡
5. (单选题) 可用作数据挖掘分析中的关联规则算法有( )。
(1.5)
A. 决策树、对数回归、关联模式
B. RBF 神经网络、K 均值法、决策树
C. K 均值法、SOM 神经网络
D. Apriori 算法、FP-Tree 算法
我的答案：
D

6/33

答题卡
6. (单选题) 假设 12 个销售价格记录如下:55, 50, 11, 215, 15, 40, 35, 5, 72, 92, 204, 13;使用等频(等深)将它们递增排序后划分成四个箱,50 在第几个
箱子内?( )
(1.5)
A. 第三个
B. 第二个
C. 第四个
D. 第一个
我的答案：
A

7/33

答题卡
7. (单选题) 决策树中不包含一下哪种结点 ( )
(1.5)
A. 根结点(root node)
B. 外部结点(external node)
C. 内部结点(internal node)
D. 叶结点(leaf node)
我的答案：

B

8/33

答题卡
8. (单选题) 适合可视化高维数据的方法是:( )
(1.5)
A. 散点图
B. 数据直方图
C. 圆饼图
D. 平行坐标
我的答案：
D

9/33

答题卡
9. (单选题) 考虑下面的频繁 3-项集的集合:{1,2,3},{1,2,4},{1,2,5},{1,3,4},{1,3,5},
{1,4,5},{2,3,4},{2,3,5},{3,4,5},假定数据集中只有 5 个项,用 Apriori 合并策略,由候选产生过程得到频繁 4-项集不包含( )
(1.5)
A. 1,3,4,5
B. 1,2,4,5
C. 1,2,3,5
D. 1,2,3,4
我的答案：
B

10/33

答题卡
10. (单选题) 在 PCA(主成分分析)变换中,应尽量把数据向什么方向投影:( )
(1.5)
A. 数据集散布大的方向
B. 数据分组特征明显的方向
C. 数据集中的方向
D. 平行于原始坐标的方向
我的答案：
A

11/33

答题卡

11. (单选题) 对于事件 A 和事件 B,若 A 和 B 条件独立指的是:( )
(1.5)
A. P(A|B)=P(A)
B. P(A,
C. P(A|B, C)=P(A|C)
D. =P(A)P(B)
B、 P(A, B)=P(A|B)P(B)
我的答案：
C

12/33



13/33

答题卡
13. (单选题) 混淆矩阵中 False Negative(FN)的含义是:( )
(1.5)
A. 被错误地分为正类的样本
B. 被正确地分为正类的样本
C. 被错误地分为负类的样本
D. 被正确的分为负类的样本



我的答案：

A C

14/33

答题卡

14. (单选题) 将原始数据进行集成、变换、维度规约、数值规约是在以下哪个步骤的任务?( )

(1.5)

A. 分类和预测

B. 频繁模式挖掘

C. 数据预处理

D. 数据流挖掘

我的答案：

C

15/33

答题卡

15. (单选题) 在聚类的验证和评价时,对于 Silhouette 图表述正确的是:( )

(1.5)

A. 每个点的取值越接近于 0 越好

B. 每个点的取值范围为[0,1]

C. 对于离群点,取值可能超过 1

D. 可以体现出簇的紧凑性

我的答案：

D

16/33

答题卡

16. (单选题) 某超市研究销售纪录数据后发现,买啤酒的人很大概率也会购买尿布,这种属于数据挖掘的哪类问题?( )

(1.5)

A. 分类

B. 自然语言处理

C. 关联规则发现

D. 聚类

我的答案：

C

17/33

答题卡

17. (单选题) 以下关于决策树分类算法的说法正确的是:( )

(1.5)

A. 在性能相同的情况下,通常选择能充分利用各种属性的决策树

B. 对于某一个数据集,只有一个决策树可以将其完美分开

C. 决策树越复杂,分类能力越强

D. 对于某一个数据集,可以生成多个决策树

我的答案：

D

18/33

答题卡

18. (单选题) 假设某数据集的原始熵值为 0.8, 已知某属性的信息增益为 0.1,那么利用该属性进行划分后数据集的熵值为:( )

(1.5)

A. 0.7

B. 0.9

C. 0.2

D. 0.5

我的答案：

D

19/33

答题卡

19. (单选题) 以下哪些分类方法可以较好地避免样本的不平衡问题( )

(1.5)

A. 神经网络

B. SVM

C. KNN

D. Bayes

我的答案：

C

20/33

答题卡

20. (单选题) 以下哪种方法不属于特征选择的标准方法:( )

(1.5)
A. 包装
B. 抽样
C. 过滤
D. 嵌入
我的答案：
B

21/33

答题卡
21. (判断题) 当长度单位厘米变为米后,此长度属性特征的权重会下降。(2.0)
A. 对
B. 错
我的答案：
对

22/33

答题卡
22. (判断题) 具有较高的支持度的项集具有较高的置信度。(2.0)
A. 对
B. 错
我的答案：
错

23/33

答题卡
23. (判断题) 在聚类分析中,簇内相似性越大,簇间差别越大,聚类的效果就越差。(2.0)
A. 对
B. 错
我的答案：
错

24/33

答题卡
24. (判断题) 聚类分析可以看作是一种非监督的分类。(2.0)

A. 对
B. 错
我的答案：
对

25/33

答题卡
25. (判断题) 如果不对属性值进行标准化处理,那么在使用欧氏距离计算相似度时,将会受到属性值大的属性影响。(2.0)
A. 对
B. 错
我的答案：
错

26/33

答题卡
26. (判断题) 置信度是对关联规则的准确度的衡量。(2.0)
A. 对
B. 错
我的答案：
对

27/33

答题卡
27. (判断题) 决策树方法通常用于关联规则挖掘。(2.0)
A. 对
B. 错
我的答案：
错

28/33

答题卡
28. (判断题) 神经网络对噪音数据具有高承受能力,并能对未经过训练的数据具有分类能力,但其需要很长的训练时间,因而对于有足够长训练时间的应用更合适。(2.0)
A. 对
B. 错
我的答案：
对

29/33

答题卡

29. (判断题) 文本挖掘又称信息检索,是从大量文本数据中提取以前未知的、有用的、可理解的、可操作的知识的过程。

(2.0)

A. 对

B. 错

我的答案：

错

30/33

答题卡

30. (判断题) 分类是对数据对象的离散类别的拟合,预测和回归则是用于数据对象的连续取值的拟合。(2.0)

A. 对

B. 错

我的答案：

对

31

31. (填空题)

1. 某数据样本属性是学位，其取值为学士、硕士、博士、无学位。那么该属性为_____类型属性。
2. 在人工神经网络领域，神经元是由 _____、_____、_____和突触组成。
3. 朴素贝叶斯分类是基于 _____ 假设的一种分类模型方法。
4. 信息熵是描述系统信息量的多少，也是该数据系统 _____ 性的度量。
5. 在数据分类中，应该把数据样本分为 _____ 和 _____ 两部分。
6. 在 ID3 算法中，是由 _____ 决定分裂属性，而在 C4.5 算法中则是由____决定分裂属性的。

我的答案：

(1) 1.序数型2.细胞体，树突，轴突3.特征条件独立4.不确定性5.分类和聚类6.信息增益，信息增益率

4. 事务数据中支持度大于最小支持度阈值的所有项集.

① 频繁项集的子集一定是频繁项集;

② 非频繁项集的超集一定是非频繁的。

5. ID3：信息熵　　@用信息增益率代替信息增益来选择属性；
C4.5：决策树　　@对连续值属性进行离散化处理；
①能够处理属性值缺失情况；
④构造决策树完成后可以进行剪枝。

32

下午2:49 12月21日 周四 ···　　66

考试详情

32/33

答题卡

32. (简答题)

1.(本题 6 分）简述 PCA 和 LDA 的相同点与不同点。

2.(本题 6 分）简述数据挖掘领域处理的几大问题，并对每个问题至少列出一种相应的算法。

3.(本题 6 分）简单画出分类中的混淆矩阵，并分别说明每一项代表什么。

4.(本题 6 分）简述频繁项集概念并说明在 Apriori 算法中其具备的性质。

5.(本题 6 分）简述 ID3 算法和 C4.5 算法核心思想并说明改进之处。

1. 同：@都可对数据进行降维；
②都属于特征提取；
③在对数据进行降维时都使用矩阵特征分解思想；
④都假设符合高斯分布。
异：@ PCA是统计学思想降维分析，
LDA是机器学习思想降维分析；
@ PCA是无监督降维分析，
LDA是监督降维分析；
③ PCA选择数据最大方差方向；
LDA选择分类性能最好的投影方向

2. 分类：决策树算法
聚类：K-means算法
关联规则问题：Apriori
回归问题：一元线性回归分析

3.

		Predicted Value	
		True	False
Actual Value	True	TP	FN
	False	FP	TN

TP：正确接受
FP：错误接受
FN：错误拒绝
TN：正确拒绝