1. (　)的目的缩小数据的取值范围，使其更适合于数据挖掘算法的需要，并且能够得到和原始数据相同的分析结果。

A. 数据清洗　　B. 数据集成

C. 数据变换　　D. 数据归约

2. 某超市研究销售纪录数据后发现，买C的人很大概率也会购买D，这种属于数据挖掘的哪类问题？(　)

A. 关联规则发现　　B. 聚类

C. 分类　　D. 自然语言处理

3. 以下两种描述分别对应哪两种对分类算法的评价标准？(　)

(a)警察抓小偷，描述警察抓的人中有多少个是小偷的标准。

(b)描述有多少比例的小偷给警察抓了的标准。

A. Precision, Recall　　B. Recall, Precision

C. Precision, ROC　　D. Recall, ROC

4. 将原始数据进行集成、变换、维度规约、数值规约是在以下哪个步骤的任务？(　)

A. 频繁模式挖掘　　B. 分类和预测　　C. 数据预处理　　D. 数据流挖掘

5. 当不知道数据所带标签时，可以使用哪种技术促使带同类标签的数据与带其他标签的数据相分离？(　)

A. 分类　　B. 聚类　　C. 关联分析　　D. 隐马尔可夫链

6. 建立一个模型，通过这个模型根据已知的变量值来预测其他某个变量值属于数据挖掘的哪一类任

A. 根据内容检索　　B. 建模描述　　C. 预测建模　　D. 寻找模式和规则

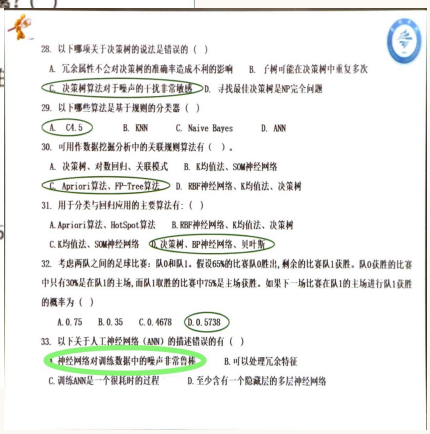
7. 下面哪种不属于数据预处理的方法？(　)

A. 变量代换　　B. 离散化　　C. 聚集　　D. 填补遗漏值

8. 假设12个销售价格记录组已经排序如下：5, 10, 11, 13, 15, 35, 50, 55, 72, 92, 204, 215

它们划分成四个箱。等频(等深)划分时，15在第几个箱子内？(　)

A. 第一个　　B. 第二个　　C. 第三个　　D. 第四个



28. 以下哪项关于决策树的说法是错误的(　)

A. 冗余属性不会对决策树的准确率造成不利的影响　　B. 子树可能在决策树中重复多次

C. 决策树算法对于噪声的干扰非常敏感　　D. 寻找最佳决策树是NP完全问题

29. 以下哪些算法是基于规则的分类器(　)

A. C4.5　　B. KNN　　C. Naive Bayes　　D. ANN

30. 可用作数据挖掘分析中的关联规则算法有(　)。

A. 决策树、对数回归、关联模式　　B. K均值法、SOM神经网络

C. Apriori算法、FP-Tree算法　　D. RBF神经网络、K均值法、决策树

31. 用于分类与回归应用的主要算法有：(　)

A. Apriori算法、HotSpot算法　　B. RBF神经网络、K均值法、决策树

C. K均值法、SOM神经网络　　D. 决策树、BP神经网络、贝叶斯

32. 考虑两队之间的足球比赛：队0和队1。假设65%的比赛队0胜出，剩余的比赛队1获胜。队0获胜的比赛中只有30%是在队1的主场，而队1取胜的比赛中75%是主场获胜。如果下一场比赛在队1的主场进行队1获胜的概率为(　)

A. 0.75　　B. 0.35　　C. 0.4678　　D. 0.5738

33. 以下关于人工神经网络(ANN)的描述错误的有(　)

A. 神经网络对训练数据中的噪声非常鲁棒　　B. 可以处理冗余特征

C. 训练ANN是一个很耗时的过程　　D. 至少含有一个隐藏层的多层神经网络

9. 下面哪个不属于数据的属性类型：(　)

A. 标称　　B. 序数　　C. 区间　　D. 相异

10. 只有非零值才重要的二元属性被称作：(　)

A. 计数属性　　B. 离散属性　　C. 非对称的二元属性　　D. 对称属性

11. 以下哪种方法不属于特征选择的标准方法：(　)

A. 嵌入　　B. 过滤　　C. 包装　　D. 抽样

12. 下面不属于创建新属性的相关方法的是：(　)

A. 特征提取　　B. 特征修改　　C. 映射数据到新的空间　　D. 特征构造

13. 下面哪个属于映射数据到新的空间的方法？(　)

A. 傅立叶变换　　B. 特征加权　　C. 渐进抽样　　D. 维归约

14. 假设属性income的最大最小值分别是12000元和98000元。利用最大最小规范化的方法将属性的值映射到0至1的范围内。对属性income的73600元将被转化为：(　)

A. 0.821　　B. 1.224　　C. 1.458　　D. 0.716

15. 一所大学内的各年级人数分别为：一年级200人，二年级160人，三年级130人，四年级110人。则年级属性的众数是：(　)

A. 一年级　　B. 二年级　　C. 三年级　　D. 四年级

16. 下列哪个不是专门用于可视化时间空间数据的技术：(　)

A. 等高线图　　B. 饼图　　C. 曲面图　　D. 矢量场图

17. 在抽样方法中，当合适的样本容量很难确定时，可以使用的抽样方法是：(　)

A. 有放回的简单随机抽样　　B. 无放回的简单随机抽样

C. 分层抽样　　D 渐进抽样

18. 设X={1, 2, 3}是频繁项集，则可由X产生(　)个关联规则。

A. 4　　B. 5　　C. 6　　D. 7

19. 考虑下面的频繁3-项集的集合：{1,2,3}, {1,2,4}, {1,2,5}, {1,3,4}, {1,3,5}, {1,4,5}, {2,3,4}, {2,3,5}, {3,4,5}假定数据集中只有5个项,采用合并策略,由候选产生过程得到频繁4-项集不包含（ ）

A. 1,2,3,4　　B. 1,2,3,5　　C. 1,2,4,5　　D. 1,3,4,5

20. 下面选项中t不是s的子序列的是 （ ）

A. s=<{2,4}, {3,5,6}, {8}> t=<{2}, {3,6}, {8}>　　B. s=<{2,4}, {3,5,6}, {8}> t=<{2}, {8}>

C. s=<{1,2}, {3,4}> t=<{1}, {2}>　　D. s=<{2,4}, {2,4}> t=<{2}, {4}>

21. 在图集合中发现一组公共子结构,这样的任务称为（ ）

A. 频繁子集挖掘　　B. 频繁子图挖掘　　C. 频繁数据项挖掘　　D. 频繁模式挖掘

22. 下列度量不具有反演性的是（ ）

A. 系数　　B. 几率　　C. Cohen度量　　D. 兴趣因子

23. 下列（ ）不是将主观信息加入到模式发现任务中的方法。

A. 与同一时期其他数据对比　　B. 可视化

C. 基于模板的方法　　D. 主观兴趣度量

24. 设最小支持度为3，根据Apriori算法计算右边购物蓝中 C3和 L3的数量分别是多少（ ）

A. 2,4　　B. 3,1　　C. 3,2　　D. 4,2

25. 以下哪些算法是分类算法 （ ）

A. DBSCAN　　B. C4.5　　C. K-Mean　　D. EM

26. 以下哪些分类方法可以较好地避免样本的不平衡问题（ ）

A. KNN　　B. SVM　　C. Bayes　　D. 神经网络

27. 决策树中不包含一下哪种结点（ ）

A. 根结点（root node）　　B. 内部结点（internal node）

C. 外部结点（external node）　　D. 叶结点（leaf node）

TID	项集
1	A,C,D
2	B,E,A
3	A,D,F
4	B,E,F
5	C,F,D
6	A,D,B,E
7	B,E,D
8	C,D
9	A,D,B,E
10	C,F

28. 以下哪项关于决策树的说法是错误的（ ）

A. 冗余属性不会对决策树的准确率造成不利的影响　　B. 子树可能在决策树中重复多次

C. 决策树算法对于噪声的干扰非常敏感　　D. 寻找最佳决策树是NP完全问题

29. 以下哪些算法是基于规则的分类器（ ）

A. C4.5　　B. KNN　　C. Naive Bayes　　D. ANN

30. 可用作数据挖掘分析中的关联规则算法有（ ）。

A. 决策树、对数回归、关联模式　　B. K均值法、SOM神经网络

C. Apriori算法、FP-Tree算法　　D. RBF神经网络、K均值法、决策树

31. 用于分类与回归应用的主要算法有:（ ）

A. Apriori算法、HotSpot算法　　B. RBF神经网络、K均值法、决策树

C. K均值法、SOM神经网络　　D. 决策树、BP神经网络、贝叶斯

32. 考虑两队之间的足球比赛：队0和队1。假设65%的比赛队0胜出,剩余的比赛队1获胜。队0获胜的比赛中只有30%是在队1的主场,而队1取胜的比赛中75%是主场获胜。如果下一场比赛在队1的主场进行队1获胜的概率为（ ）

A. 0.75　　B. 0.35　　C. 0.4678　　D. 0.5738

33. 以下关于人工神经网络（ANN）的描述错误的有（ ）

A. 神经网络对训练数据中的噪声非常鲁棒　　B. 可以处理冗余特征

C. 训练ANN是一个很耗时的过程　　D. 至少含有一个隐藏层的多层神经网络

1. 分类是预测数据对象的离散类别，预测是用于数据对象的连续取值。(√)
2. 时序预测回归预测一样，也是用已知的数据预测未来的值，但这些数据的区别是变量所处时间的不同。(X)
3. 数据挖掘的主要任务是从数据中发现潜在的规则，从而能更好的完成描述数据、预测数据等任务。(√)
4. 对遗漏数据的处理方法主要有：忽略该条记录；手工填补遗漏值；利用默认值填补遗漏值；利用均值填补遗漏值；利用同类别均值填补遗漏值；利用最可能的值填充遗漏值。(√)
5. 神经网络对噪音数据具有高承受能力，并能对未经过训练的数据具有分类能力，但其需要很长的训练时间，因而对于有足够长训练时间的应用更合适。(√)
6. 数据分类由两步过程组成：第一步，建立一个聚类模型，描述指定的数据类集或概念集；第二步，使用模型进行分类。(X)
7. 聚类是指将物理或抽象对象的集合分组成为由类似的对象组成的多个类的过程。(√)
8. 决策树方法通常用于关联规则挖掘。(X)
9. 置信度是对关联规则的准确度的衡量。(X)

9. 数据规范化指将数据按比例缩放(如更换大单位)，使之落入一个特定的区域（如0-1）以提高数据挖掘效率的方法。规范化的常用方法有：最大-最小规范化、分数规范化、小数定标规范化。(√)
10. 模型的具体化就是预测公式，公式可以产生与观察值有相似结构的输出，这就是预测值。(√)
11. 数据取样时，除了要求抽样时严把质量关外，还要求抽样数据必须在足够范围内有代表性。(√)
12. 分类规则的挖掘方法通常有：决策树法、贝叶斯法、人工神经网络法、粗糙集法和遗传算法。(√)
13. 大数据的4V特点是Volume、Velocity、Variety、Veracity。(√)
14. 孤立点在数据挖掘时总是被视为异常、无用数据而丢弃。(X)
15. Apriori算法是一种典型的关联规则挖掘算法。(√)
16. 用于分类的离散化方法之间的根本区别在于是否使用类信息。(√)
17. 特征提取技术并不依赖于特定的领域。(X)
18. 文本挖掘又称信息检索，是从大量文本数据中提取以前未知的、有用的、可理解的、可操作的知识的过程。(X)
19. 定量属性可以是整数值或者是连续值。(√)

20. 关联规则挖掘过程是发现满足最小支持度的所有项集代表的规则。(X)
21. 利用先验原理可以帮助减少频繁项集产生时需要探查的候选项个数。(√)
22. 先验原理可以表述为：如果一个项集是频繁的，那包含它的所有项集也是频繁的。(X)
23. 回归分析通常用于挖掘关联规则。(X)
24. 具有较高的支持度的项集具有较高的置信度。(X)
25. 维归约可以去掉不重要的属性，减少数据立方体的维数，从而减少数据挖掘处理的数据量，提高挖掘效率。(√)
26. 聚类是这样的过程：它找出描述并区分数据类或概念的模型(或函数)，以便能够使用模型预测类标记未知的对象类。(X)
27. Bayes法是一种在已知后验概率与类条件概率的情况下的模式分类方法，待分样本的分类结果取决于各类域中样本的全体。(X)
28. 在决策树中，随着树中结点数变得太大，即使模型的训练误差还在继续减低，但是检验误差开始增大，这是出现了模型拟合不足的问题。(X)
29. 在聚类分析中，簇内相似性越大，簇间差别越大，聚类的效果就越差。(X)
30. 聚类分析可以看作是一种非监督的分类。(√)
31. K均值是产生划分聚类基于密度的聚类算法，簇的个数由算法自动地确定。(X)
32. 如果一个对象不强属于任何簇，那么该对象是基于聚类的离群点。(√)

1. 数据挖掘的几大问题，算法举例。
2. 计算数据对象 X = (3,5,2,7) 和 Y = (6,8,2,3) 之间的欧式距离和曼哈顿距离。
3. 请解释什么是数据归一化，并列举至少两种常见的归一化方法。
4. 考虑下面的频繁3-项集：{1,2,3}, {1,2,4}, {1,2,5}, {1,3,4}, {1,3,5}, {2,3,4}, {2,3,5}, {3,4,5}
   假定数据集中只有5项。列出Apriori算法的C4和L4。
5. 描述ROC曲线以及AUC（Area Under the Curve）的意义，并说明它们如何帮助评估分类器性能。
6. 如果你有一组非线性可分的数据点，你会用什么方法对其进行有效分类？举例说明。
7. 请比较监督学习与无监督学习的区别，并举例说明每种学习方式的一个应用场景。
8. 给定一组事务如下：
   - T1: {牛奶, 面包, 黄油}
   - T2: {面包, 黄油, 茶}
   - T3: {牛奶, 面包, 茶}
   - T4: {黄油, 茶, 糖}
   - T5: {牛奶, 面包, 黄油, 茶}

   使用Apriori算法找出支持度大于等于60%的所有频繁项集。
9. 请描述朴素贝叶斯分类器的工作原理，并说明它为什么被称为“朴素”。
10. 请描述信息增益和信息增益率的区别以应用场景。
11. 请描述神经网络的基本结构，并解释反向传播算法是如何优化权重的。

已知数据集如下：

序号	帅气	性格	身高	上进心	嫁与不嫁
1	帅	不好	矮	不上进	不嫁
2	不帅	好	矮	上进	不嫁
3	帅	好	矮	上进	嫁
4	不帅	好	高	上进	嫁
5	帅	不好	矮	上进	不嫁
6	不帅	不好	矮	不上进	不嫁
7	帅	好	高	不上进	嫁
8	不帅	好	高	上进	嫁
9	帅	好	高	上进	嫁
10	不帅	不好	高	上进	嫁
11	帅	好	矮	不上进	不嫁
12	帅	好	矮	不上进	不嫁

分别用决策树算法C4.5和朴素贝叶斯算法

求解 *Instance13*（帅，不好，高，上进）样本的类别属性

1. 数据类型和变量类型

数据类型：编程语言中对数据的分类，用于确定数据的特征和操作方式。

变量类型：由变量所存储的数据类型决定。

2. 维度和离群点

维度：数据集中对象具有的属性数目。

离群点：

- 在大型数据集中，通常存在着**不遵循数据模型的普遍行为的样本**，这些样本和其他残余部分数据有很大不同或不一致，叫做**异常点**

异常值的探测方法

◆第一，一维样本异常点的检测方法

- 例如：如果所给的数据集用20个不同的值描述**年龄特征**：

3, 56, 23, 39, 156, 52, 41, 22, 9,28,-32
139, 31, 55, 20, -67, 37, 11, 55, 45, 37

均值=39.9; 标准差=45.65

阈值=均值±2×标准差

- 那么，所有在**[-54.1, 131.2]**区间以外的数据都是潜在的异常点。根据实际可以把区间缩减到**[0, 131.2]**，由这个标准发现3个异常点：156, 139, -32, -67

异常值的探测方法

第二，基于距离的异常点检测（**二维以上数据**）

- 例如：数据集为：

$S=\{S_1,S_2,S_3,S_4,S_5,S_6,S_7 \ldots\ldots\} =$
$\{(2,4),(3,2),(1,1),(4,3),(1,6),(5,3),(4,2),(6,6),(3,1),(7,2),(4,4),(5,1),(1,3),(2,2),(5,7)\ldots\ldots\}$

欧氏距离 $d=[(X_1-X_2)^2+(Y_1-Y_2)^2]^{1/2}$

设定：**阈值**距离为：**d=3**

3. 数据属性类型，属性描述

属性是一个数据字段，表示数据对象的特征。

属性类型

标称型：标称属性的值是一些符号或事物的名称。

- 在计算机科学中，这些值也被看做是枚举的（enumeration）。尽管标称属性的值是一些符号或“事物的名称”，但也可以用数表示这些符号或名称，如发色可以用 0 表示黑色，1 表示黄色。因为标称属性的值不具有有意义的序，而且不是定量的。

二元或多元型：二元属性是一种标称属性，只有两个状态：0 或 1。如果两种状态对应的是 true 和 false，二元属性又称布尔属性。

- 例如：“性别”的取值“男性”，“女性”。“HIV”有“阴性”和“阳性”等

序数型：序数属性是一种属性，其可能的值之间具有有意义的序或秩评定（ranking），但是相继值之间的差是未知的。

- 比如：对一个餐厅评价“优”，“良”，“差”这些值是有意义的先后次序，但是我们不能说“优”比“良”好多少，“良”比“差”好多少，它们之间的差是未知的。
- 序数属性的其他例子包括：教师有助教、讲师、副教授、教授。对于军衔有列兵，下士、中士等等。

属性取值

属性取值：连续型和离散型

- **连续型：**定量型、量度型变量，是指在一定区间内可以任意取值的变量
  - 文献中，术语“数值属性”和“连续属性”可以互换的使用。实践中，实数值用有限位数数字表示，连续属性一般用浮点变量表示。
- **离散型：**具有有限个或无限个可数个数，可以用或不用整数表示
  - 有限可数：头发的颜色、学生的人数等都有有限个值，因此是离散的。
  - 无限可数：如果一个属性可能的值集合是无限的，但是可以建立一个与自然数一一对应的映射关系，则该属性是无限可数的。比如说customer_ID 就是无限可数的。

Ps：一种特殊类型的离散型变量是周期变量，例如：星期、月和年中的日期

属性类型

- 下面使用一个简单的例子来具体说明属性的各种类型

学生ID	姓名	性别	选修科目	成绩	评定
20201203	Tom	男	语文	95.0	优
20201204	Jerry	女	英语	80.5	良
20201205	Kevin	男	语文	77.2	中
20201206	Mary	女	数学	85.3	良
20201207	Jim	男	数学	61.2	差
离散属性	标称属性	二元属性	标称属性	连续属性	序数属性

练习：计算样本间的相似性（2种方法）

样本序号	职业	收入	学位
x_1	公司职员	高	硕士
x_2	公务员	中	学士
x_3	公司职员	低	无学位
x_4	教师	高	博士
x_5	教师	中	学士

计算：

X1和X3的相似性度量
X2和X5的相似性程度 （假设所有属性取值都是标称型的）

1. 已知如下数据样本，假设每个属性没有先后顺序和权重之分，试完成下列计算。(写出计算步骤，不可以只写结果)

样本序号	学历	年龄段	收入标准
1	硕士	青年	中
2	学士	青年	低
3	学士	老年	中
4	博士	中年	高

完成: 1.1(本题 4 分)用简单匹配法计算出样本 1 与样本 2 的相似度。
1.2(本题 6 分)用数据属性转换法计算出样本 2 与样本 3 的相似度。

1.1 样本1、2只有学历学士一样

相似度 $= \frac{3-1}{6} = \frac{2}{3}$

1.2

	学士	硕士	博士	青	中	老	低	中	高
x_2	1	0	0	1	0	0	0	0	1
x_3	1	0	0	0	0	1	0	1	0

相似度 $= \frac{4}{9}$ $\frac{4}{5}$